

Estadística Descriptiva Multivariada

Métodos multivariados aplicados (Aprendizaje no supervisado)

Contexto de la estadística descriptiva multivariada,
contenido del curso y criterios de calificación

Jimmy A Corzo S^{1 2}

¹Profesor Titular
Departamento de Estadística

²Facultad de ciencias
Universidad Nacional de Colombia

February 24, 2026

Panorama


La Estadística Descriptiva Multivariada (EDM) en el contexto moderno del aprendizaje estadístico no supervisado

Aprendizaje Estadístico Supervisado: el problema

Objetivo. Predecir una variable respuesta Y a partir de predictores $X_1, \dots, X_p$ mediante un modelo

$$Y = f(X_1, \dots, X_p).$$


Evaluación. La calidad del modelo se mide con un *criterio externo de error* que compara predicciones $\hat{y}_i$ con observaciones reales y_i .



¿Por qué se llama “supervisado”?

Idea clave. Al observar Y , el aprendizaje se puede *supervisar*:


- **Entrenamiento:** ajustar f usando una parte de los datos.
- **Prueba/validación:** evaluar en datos independientes comparando $\hat{y}_i$ vs. y_i con una medida de error.



Métodos típicos en la categoría supervisada

Pertenecen a esta categoría métodos como:

- **Regresión:** regresión lineal; regresión polinómica; regresión regularizada (ridge/lasso).
- **Clasificación:** regresión logística; árboles; k-NN; SVM; redes neuronales.
- **Modelos extendidos:** modelos lineales generalizados (GLM) y aditivos generalizados (GAM).




Familias de métodos



Contraste: Aprendizaje Supervisado vs No Supervisado

Idea central. En el **Aprendizaje Estadístico No Supervisado** solo se observan variables explicativas $X_1, \dots, X_p$; no existe una variable respuesta Y que permita supervisar el aprendizaje ni evaluar el ajuste mediante un criterio externo de error.


- No hay una respuesta observable que se desee predecir.
- El problema no se formula en términos de predicción supervisada.
- La evaluación del resultado es interna al método y de carácter exploratorio.



Objeto e interés del Análisis No Supervisado

En ausencia de una variable respuesta, el **análisis no supervisado** se orienta a la **exploración de la estructura interna de los datos**.


- Identificar asociaciones entre variables.
- Detectar similitudes o agrupamientos entre individuos.
- Descubrir patrones o estructuras latentes.
- Construir representaciones gráficas informativas.
- Reducir la dimensionalidad del problema.



Métodos en Aprendizaje No Supervisado

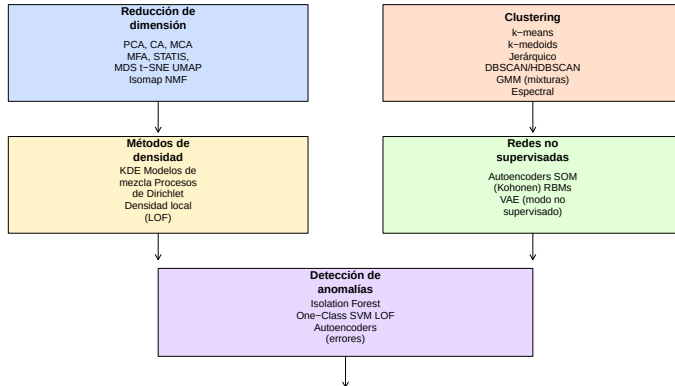
Como parte del **Aprendizaje Estadístico No Supervisado** se incluyen, entre otros, los siguientes métodos:

- **Reducción de dimensión:** Análisis de Componentes Principales (ACP).
- **Asociación en tablas categóricas:** Análisis de Correspondencias (AC) y Análisis de Correspondencias Múltiples (ACM).
- **Estructura de similitud:** métodos de agrupamiento (*clustering*).



Mapa conceptual de métodos de aprendizaje no supervisado

Mapa conceptual de métodos de aprendizaje NO supervisado



Métodos de reducción de las dimensiones

- **PCA (Principal Components Analysis).** Metodo lineal para variables numericas que busca direcciones de maxima varianza. **Basado directamente en la SVD** de la matriz centrada.
- **CA (Correspondence Analysis).** Método de análisis de dos variables cualitativas en tablas de contingencia basada en perfiles centrados y ponderados. **Utiliza una SVD ponderada** para obtener coordenadas principales.
- **MCA (Multiple Correspondence Analysis).** Extension del CA a multiples variables cualitativas mediante la matriz indicatoria o de Burt (tabla de tablas de contingencia). **Fundamentado en una SVD en el espacio chi-cuadrado.**

Métodos de reducción de las dimensiones

- **MFA (Multiple Factor Analysis).** Metodo para analizar múltiples tablas en el cual unas tablas pueden ser de variables cuantitativas o numéricas y otras pueden ser de variables cualitativas que normaliza cada bloque y luego aplica **una SVD global** para extraer factores comunes.
- **STATIS (incluye DiSTATIS).** Metodo para tablas estructuradas en tres vias; construye una compromise matrix y aplica **SVD o descomposicion espectral** para obtener configuraciones y compromisos.
- **MDS clasico (Classical Multidimensional Scaling o CMDS).** Recupera coordenadas en un espacio euclidiano mediante la **descomposicion espectral de la matriz de distancias doblemente centrada**, algebraicamente equivalente a una SVD.

Metodos no lineales o no basados en SVD

- **t-SNE (t-distributed Stochastic Neighbor Embedding).** Metodo no lineal que minimiza la divergencia de Kullback–Leibler entre distribuciones de vecinos. **No utiliza SVD** salvo como opcion para inicializacion.
- **UMAP (Uniform Manifold Approximation and Projection).** Metodo de aprendizaje de variedades basado en grafos fuzzy y optimizacion de atraccion-repulsion. **No utiliza SVD** excepto cuando se inicializa con PCA.
- **Isomap.** Metodo de aprendizaje de manifolds basado en distancias geodesicas. Realiza MDS al final, pero **no es un metodo basado en SVD**, aunque emplea descomposicion espectral en la etapa final.
- **NMF (Nonnegative Matrix Factorization).** Factorizacion iterativa de matrices no negativas mediante algoritmos multiplicativos o ALS. **No utiliza SVD**, aunque puede inicializarse con ella.

Métodos de agrupamiento (Clustering)

- **K-means.** Algoritmo particional que asigna cada observacion al centroide mas cercano, minimizando la suma de distancias cuadraticas dentro de cada grupo. Requiere fijar el numero de clusters y es sensible a valores atipicos.
- **K-medoids (PAM).** Variante robusta de k-means que utiliza medoids (observaciones reales) en lugar de centroides, adecuada para diferentes metricas de distancia y menos sensible a valores atipicos.
- **Clustering jerarquico (aglomerativo o divisivo).** Construye un dendrograma que agrupa observaciones de manera secuencial. No requiere especificar el numero de clusters a priori y permite distintos criterios de enlace (single, complete, average, Ward).

Métodos de agrupamiento (Clustering)

- **DBSCAN.** Metodo basado en densidad que identifica regiones densas separadas por zonas de baja densidad. Detecta ruido y produce clusters de formas arbitrarias sin necesidad de fijar el numero de grupos.
- **HDBSCAN.** Extension jerarquica de DBSCAN que permite densidades variables. Produce clusters mas estables y una mejor deteccion de ruido en datos con heterogeneidad de densidad.
- **GMM (Gaussian Mixture Models).** Modelo probabilistico que representa los datos como una mezcla de distribuciones normales. Ofrece pertenencias suaves (probabilidades) mediante el algoritmo EM y permite clusters elipticos.
- **Clustering espectral.** Metodo que utiliza los autovectores del Laplaciano de un grafo de similitudes para representar los datos en un espacio reducido, donde luego se aplica un algoritmo particional como k-means. Permite detectar clusters no lineales.

- **PCA (Principal Components Analysis).**
- **CA (Correspondence Analysis).**
- **MCA (Multiple Correspondence Analysis).**
- **K-means.**
- **Clustering jerarquico (aglomerativo o divisivo).**

Elementos de álgebra lineal requeridos en análisis multivariado

- **Espacios vectoriales:** vectores, subespacios, bases y dimensión.
- **Producto interno:** norma, ángulos y ortogonalidad.
- **Proyección ortogonal** y mínimos cuadrados.
- **Matrices:** operaciones matriciales, rango, traza e inversa (cuando existe).
- **Matrices simétricas** y definidas positivas.
- **Valores y vectores propios.**
- **Teorema de la descomposición espectral (TDE).**
- **Teorema de la descomposición en valores singulares (TDVS).**

Conjuntos de datos utilizados en los ejemplos y ejercicios

- **ciudades** Tabla de datos de 22 ciudades colombianas con 6 variables referentes a la educación y número de habitantes.
- **etiq_ciudades**
- **ciudadesC** Tabla de datos de 22 ciudades colombianas con 84 variables clasificadas en grupos que abarcan temas como Recursos Humanos, Ciencia y Tecnología, Infraestructura, Finanzas públicas entre otros.
- **Etiquetas ciudades** Contiene las etiquetas del archivo ciudadesC
- **ARWU_100_top** Tabla de datos de puntajes y posiciones de las 100 mejores universidades del mundo según el ranking Academic Rank of World Universities (ARWU)
- **arwu**
- **r14_Sci_Qs_Webometrics** Tabla de datos de puntajes y posiciones de 149 universidades latinoamericanas según

Panorama del análisis multivariado

Tipos de variables para visualización de datos

En visualización y análisis no supervisado, las variables se clasifican según el **tipo de información que contienen**:

- Esta clasificación determina:
 - los métodos gráficos apropiados,
 - las métricas de similitud o distancia,
 - y las técnicas multivariadas aplicables.
- Distinguimos principalmente entre:
 - **variables cualitativas o categóricas,**
 - **variables cuantitativas o numéricas.**

Variables cualitativas

- Describen **cualidades, categorías o clases** de los objetos.
- No admiten operaciones aritméticas directas.
- Se distinguen dos tipos principales:
 - **Nominales:**
 - funcionan como códigos sin orden implícito,
 - ejemplos: ciudades, países, identificadores.
 - **Categóricas (u ordinales):**
 - representan categorías con **orden o jerarquía**,
 - ejemplos: niveles educativos, estratos socioeconómicos, posiciones en rankings universitarios.
- Sus valores se denominan **modalidades u opciones de respuesta**.

Variables cuantitativas

- Se expresan en una **escala numérica** y admiten comparaciones métricas.
- Permiten definir distancias y aplicar operaciones aritméticas.
- Se dividen en:
 - **Continuas:**
 - toman valores en un intervalo continuo,
 - interpretación directa,
 - ejemplos: altura, edad, ingresos, longitud.
 - **Discretas:**
 - toman valores enteros,
 - ejemplos: número de habitantes, conteos de eventos,
 - promedios pueden producir valores no directamente interpretables (p. ej., 4.6 aviones por minuto).

Tipos de variables y métodos multivariados

- La elección del método de análisis multivariado depende directamente del **tipo de variables** disponibles.
- En análisis no supervisado, los métodos más utilizados son:

Correspondencia entre variables y métodos



- **PCA (Análisis de Componentes Principales)** Variables **cuantitativas** (continuas o discretas tratadas como numéricas).
- **MCA (Análisis de Correspondencias Múltiples)** Variables **cualitativas** (nominales u ordinales codificadas en modalidades).
- **MFA (Análisis Factorial Múltiple)** Conjuntos de variables **mixtas** o **estructuradas en grupos** (cuantitativas y/o cualitativas).

El tipo de variable determina la geometría del espacio y la métrica

Motivación: ¿por qué componentes principales?

- Los **gráficos de dispersión** permiten explorar relaciones entre pares de variables cuantitativas e identificar patrones, tendencias y valores atípicos.
- Mediante colores, tamaños o etiquetas es posible incorporar información adicional, pero la representación sigue estando **limitada a dos dimensiones**.
- Cuando el número de variables es grande, los planos definidos por variables originales **no capturan adecuadamente** la estructura global de los datos.
- Las **componentes principales** definen nuevos ejes, como combinaciones lineales de las variables originales, que **maximizan la variabilidad**.
- Los planos generados por las primeras componentes proporcionan **representaciones más informativas y sintéticas** de los datos.

Motivación: variables originales vs plano PCA



Ejemplo

- Los **rankings universitarios** son clasificaciones basadas en criterios definidos por las entidades que los elaboran.
- Dichos criterios responden a un **modelo implícito de universidad de élite**, que puede variar entre rankings.
- Por esta razón, los resultados y ponderaciones **difieren significativamente** de un ranking a otro.
- Entre los criterios más frecuentes se encuentran:
 - producción e impacto de publicaciones científicas,
 - calidad e impacto de las revistas,
 - actividades de investigación e innovación,
 - proporción de docentes con doctorado,
 - reputación académica y entre empleadores,
 - presencia e internacionalización,
 - premios de docentes y egresados.

Ejemplo

- Desde el punto de vista estadístico, los rankings universitarios se construyen a partir de **múltiples indicadores** asociados a diferentes criterios.
- Los indicadores suelen ser **normalizados o estandarizados** para hacerlos comparables.
- Luego se calcula un **puntaje total** mediante una **suma ponderada** (combinación lineal ponderada) de los indicadores; los pesos reflejan el **modelo implícito de universidad** del ranking.
- Con el puntaje total se obtiene un **ordenamiento**: puesto 1 al mayor puntaje, puesto 2 al siguiente, etc.
- El resultado es un **orden relativo**; las diferencias numéricas entre puntajes no necesariamente tienen interpretación como “distancias”.

Ejemplo

- Uno de los rankings más reconocidos y selectivos es el **Academic Ranking of World Universities (ARWU)**.
- Su metodología se basa en indicadores asociados principalmente al desempeño académico y de investigación, entre ellos:
 - **Premios Nobel y Medallas Fields** de egresados (Alumni) y docentes (Staff),
 - **investigadores altamente citados** (Highly Cited Researchers),
 - **publicaciones en Nature y Science**,
 - **artículos indexados** en índices bibliométricos (p. ej., SCIE/SSCI),
 - **desempeño per cápita** del personal académico (PCP).
- En este ejemplo se consideran las universidades ubicadas en los **100 primeros puestos** del ARWU (año 2013) y se analizan sus posiciones **mundial** y, por derivación, sus posiciones **nacional** y **regional**.
- Para más detalles metodológicos, ver ?.

Ejemplo


Distribución por país en el Top 100 (ARWU 2013)

US	UK	GE	JP	CA	AS	FR	SE	SW	DE	NL	BE	FI	IR	NW	RU
54	11	5	5	4	3	3	3	3	2	2	1	1	1	1	1


En la Tabla ?? se muestra la distribución del número de universidades por país entre las **100 primeras** del ARWU 2013. Se observa una alta concentración en pocos países: **Estados Unidos (US)** aporta **54** universidades, seguido por el **Reino Unido (UK)** con **11**. En un segundo nivel aparecen **Alemania (GE)** y **Japón (JP)** con **5** universidades cada uno.

Table: 20 mejores universidades del mundo según el ARWU 2013

Institution	Region	Country	Regional.Rank	World.Rank	National.Rank
Harvard University	Americas	US	1	1	1
University of California, Berkeley	Americas	US	2	2	2
Stanford University	Americas	US	3	3	3
Massachusetts Institute of Technology (MIT)	Americas	US	4	4	4
University of Cambridge	Europe	UK	1	5	1
California Institute of Technology	Americas	US	5	6	5
Princeton University	Americas	US	6	7	6
Columbia University	Americas	US	7	8	7
University of Chicago	Americas	US	8	9	8
University of Oxford	Europe	UK	2	10	2
Yale University	Americas	US	9	11	9
Cornell University	Americas	US	10	12	10
University of California, Los Angeles	Americas	US	11	13	11
University of California, San Diego	Americas	US	12	14	12
University of Pennsylvania	Americas	US	13	15	13
University of Washington	Americas	US	14	16	14
University of Wisconsin - Madison	Americas	US	15	17	15
The Johns Hopkins University	Americas	US	16	18	16
University of California, San Francisco	Americas	US	16	18	17
The University of Tokyo	Asia/Pacific	JP	1	20	1



(a) Posición regional vs. posición mundial de las primeras 100 universidades según el ranking ARWU, etiquetadas por su país de origen.



(b) Posición regional vs. posición mundial de las primeras 100 universidades según el ranking ARWU, sobre las dos primeras componentes principales.

Figure: Comparación de la visualización de los datos originales con su proyección sobre las dos primeras componentes principales

Ejemplo

Scimago

Sobre inconsistencias en algunos rankings universitarios

*Scimago es un ranking orientado a la evaluación de la **actividad investigativa** de universidades e instituciones de investigación. Su metodología incluye nueve indicadores de investigación, entre los que se encuentran medidas de impacto, productividad, colaboración internacional, publicaciones de alta calidad, liderazgo científico, excelencia y talento científico, además de tres indicadores de innovación y tres de factor social. Por su enfoque, este ranking privilegia el desempeño científico medido a partir de la producción y el impacto de la investigación. Para más detalles, véase ?.*

Ejemplo

Webranking

Sobre inconsistencias en algunos rankings universitarios

*El Webranking es un ranking de **presencia en la web** que evalúa la visibilidad institucional de las universidades a partir de indicadores como el número de enlaces entrantes al dominio institucional, el número de páginas web y la cantidad de archivos publicados en formatos *pdf, doc, xls*, entre otros, alojados en los dominios universitarios. Adicionalmente, incorpora un indicador de excelencia tomado del ranking Scimago. Este enfoque prioriza la visibilidad digital y la difusión de contenidos académicos en la web. Para más detalles, véase ?.*

Ejemplo

QS

Sobre inconsistencias en algunos rankings universitarios

*El ranking QS combina indicadores de **reputación** y desempeño académico. Incluye dos indicadores de reputación —uno medido entre pares académicos y otro entre empleadores— obtenidos mediante encuestas, así como la razón estudiantes/profesor, el número de profesores con doctorado, el número de citas por artículo, el promedio de artículos por docente y un indicador de impacto web tomado del Webranking. Los indicadores de reputación tienen una ponderación del **25%** cada uno, mientras que los restantes indicadores tienen una ponderación del **10%** cada uno. Por esta razón, este ranking se considera principalmente un ranking de **reputación universitaria**. Para detalles metodológicos (2014), véase ?.*

Rankings universidades latinoamericanas

Ejemplo

Table: Primeras 20 universidades según el ranking Qs

	UniPais	Pais	SC.Lac.Ranking	QS.Ranking	WEB.Ranking.LA
10	POTFIC CATOLICA DE - CHL	CHL	13	1	24
1	DE SAO PAULO (USP) - BRA	BRA	1	2	1
3	Es DE CAMPIS (UNICAMP) - BRA	BRA	4	3	8
5	DO RD Janeiro FED - BRA	BRA	5	4	5
21	LOS ANDES - COL	COL	47	5	38
9	U de - CHL	CHL	10	6	6
61	TECNOLOGICO DE MONTERREY (ITESM) - MEX	MEX	56	7	28
2	NAL AUTONO DE (UM) - MEX	MEX	2	8	2
6	EEs PAULISTA JULIO MESQU - BRA	BRA	3	9	11
7	Fe DO RG D SUL - BRA	BRA	6	10	3
8	Fe MG - BRA	BRA	8	10	9
20	CONCEPCION - CHL	CHL	28	12	32
37	POTFIC CATOLICA DO R de Janeiro -PUC - BRA	BRA	40	13	30
26	NAL DE - COL	COL	18	14	10
11	Fe DE SAO PAULO (UNIFESP) - BRA	BRA	9	15	54
42	SANTIAGO DE (USACH) - CHL	CHL	60	16	34
15	DE BRASILIA - BRA	BRA	19	17	13
16	Fe DE SAO CARLOS - BRA	BRA	21	18	43
4	BUENOS AIRES - ARG	ARG	7	19	7
116	AUSTRAL - ARG	ARG	250	20	262

Rankings universidades latinoamericanas

Ejemplo




Figure: Comparación entre rankings (Scimago, QS y WEB). Entre más lejos de la diagonal mas diferentes son los rankings correspondientes

Rankings universidades latinoamericanas

Ejemplo




Figure: Los dos vectores que representan los ranking SC.Lac.Ranking y WEB.Ranking.LA reflejan su grado de asociación visualizado en la gráfica 2 b). El vector QS.Ranking muestra el grado de independencia de éste con los otros dos rankings, ya identificada en los gráficos 2 a) y 2 c).

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo

La Encuesta Mundial de Valores

*La **Encuesta Mundial de Valores** (World Values Survey) es un estudio internacional comparativo que se realiza periódicamente desde 1981. Su objetivo es medir **valores, creencias y actitudes** de la población sobre múltiples temas sociales y culturales, mediante cuestionarios aplicados en diversos países.*

Entre los temas que indaga se encuentran, por ejemplo, la democracia, la confianza en instituciones, la tolerancia hacia minorías, el papel de la religión en la sociedad, la globalización, el medio ambiente y la diversidad, entre otros ??.

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo

La Encuesta Mundial de Valores

*Una de las muchas preguntas de esta encuesta indaga por la **confianza en la justicia** en un conjunto de países, entre los cuales se encuentran algunos países latinoamericanos. La pregunta es la siguiente:*

*¿Cree usted que la justicia en este país se aplica
de manera justa para todos,
independientemente de su origen social o económico?*

Muchísimo

Mucho

No mucho

Nada

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo

Table: Confianza en la justicia en países seleccionados

	<i>muchis.</i>	<i>mucho</i>	<i>no_mucho</i>	<i>nada</i>	<i>Total_F</i>
<i>Brasil</i>	208	678	404	408	1698
<i>Mexico</i>	105	280	552	778	1715
<i>Colombia</i>	96	105	885	434	1520
<i>Ecuador</i>	90	394	460	237	1181
<i>Chile</i>	43	258	443	235	979
<i>Peru</i>	25	110	389	861	1385
<i>Argentina</i>	17	176	427	365	985
<i>Total_C</i>	584	2001	3560	3318	

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo

Table: Perfiles por países para los grados de confianza en la justicia ordenados por la opción muchísimo

	<i>muchis.</i>	<i>mucho</i>	<i>no_mucho</i>	<i>nada</i>	<i>Suma</i>
<i>Brasil</i>	0.122	0.399	0.238	0.240	1
<i>Ecuador</i>	0.076	0.334	0.390	0.201	1
<i>Colombia</i>	0.063	0.069	0.582	0.286	1
<i>Mexico</i>	0.061	0.163	0.322	0.454	1
<i>Chile</i>	0.044	0.264	0.453	0.240	1
<i>Peru</i>	0.018	0.079	0.281	0.622	1
<i>Argentina</i>	0.017	0.179	0.434	0.371	1

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo




Figure: EMV

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo

Table: Perfiles por modalidades de confianza en la justicia respecto a los países encuestados, ordenados por la opción muchísimo

	<i>muchis.</i>	<i>mucho</i>	<i>no_mucho</i>	<i>nada</i>
<i>Brasil</i>	0.356	0.339	0.113	0.123
<i>Mexico</i>	0.180	0.140	0.155	0.234
<i>Colombia</i>	0.164	0.052	0.249	0.131
<i>Ecuador</i>	0.154	0.197	0.129	0.071
<i>Chile</i>	0.074	0.129	0.124	0.071
<i>Peru</i>	0.043	0.055	0.109	0.259
<i>Argentina</i>	0.029	0.088	0.120	0.110
<i>Suma</i>	1.000	1.000	1.000	1.000

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo




Figure: Comparación de países por proporción de respuestas a la percepción de la justicia

Correspondencias simples y análisis de tablas de contingencia (EMV)

Ejemplo




Figure: Plano de correspondencias simples que muestra tendencias de los países en cuanto a percepciones sobre confianza en la justicia

Correspondencias múltiples: Tablas de tablas de contingencia (ECC)

Ejemplo

Encuesta de Cultura Ciudadana

*La **Encuesta de Cultura Ciudadana (ECC)** fue realizada por la Corporación Visionarios en varias ciudades latinoamericanas con cierta periodicidad. Constituye un instrumento de observación y análisis de distintos aspectos relacionados con la cultura ciudadana y el comportamiento social.*

Correspondencias múltiples: Tablas de tablas de contingencia (ECC)

Ejemplo

Encuesta de Cultura Ciudadana

La encuesta incluye, por ejemplo, preguntas sobre

- *los sentimientos de los encuestados frente a palabras como normas o reglas (Ley, Moral y Cultura),*
- *la facilidad con que pueden actuar conforme a la ley,*
- *las capacidades para celebrar y cumplir acuerdos y las reacciones ante su incumplimiento,*
- *pluralismo (aceptación de las diferencias e inclusión),*
- *seguridad,*
- *confianza interpersonal,*
- *confianza en instituciones,*
- *victimización, entre otros aspectos.*


Correspondencias múltiples: Tablas de tablas de contingencia (ECC)

Ejemplo


20. Dígame si en su opinión se justifica o no desobedecer la ley:

	Sí	No		Sí	No
a. Cuando es la única manera de alcanzar sus objetivos	1	2	g. Cuando es bastante seguro que uno no será castigado	1	2
b. Cuando es la única manera de ayudarle a la familia	1	2	h. Cuando alguien lo ha hecho y le ha ido bien	1	2
c. Cuando es la única manera de luchar públicamente contra una ley o un régimen injusto	1	2	i. Cuando es lo acostumbrado	1	2
d. Cuando es muy provechoso económicamente	1	2	j. Para pagar un favor	1	2
e. Cuando la creencia religiosa lo permite	1	2	k. Para defender propiedades o bienes	1	2
f. Cuando se hace para responder a una ofensa al honor	1	2			

Ejemplo



Ejemplo



Ejemplo




Figure: Las líneas punteadas representan las formas sinuosas que

Métodos de agrupamiento (Clustering) Sistema universitario estatal (SUE)

Ejemplo

*El **Sistema Universitario Estatal** (SUE) es una red de universidades públicas colombianas, orientada hacia la colaboración académica, la investigación y la gestión conjunta de recursos entre estas ellas. Datos de éstas universidades se recolectan en una tabla que contiene 32 indicadores de educación superior para 32 universidades estatales entre 2003 y 2012.*

Métodos de agrupamiento (Clustering) Sistema universitario estatal (SUE)

Ejemplo

Para este ejemplo se utilizan seis indicadores:

- *Docentes de tiempo completo o equivalente (DCTC2012),*
- *gastos en personal administrativo (GPA2012),*
- *matrícula de pregrado (MPRE2012),*
- *matrícula de posgrado (MPOS2012),*
- *graduados de pregrado (GrPre2012),*
- *graduados de posgrado (GrPos2012).*

En la Tabla 6 se presentan los valores de estos indicadores para las 32 universidades públicas.

Métodos de agrupamiento (Clustering) Sistema universitario estatal (SUE)


Ejemplo

Table: Indicadores del SUE para 32 universidades públicas en el año 2012


	DCTC2012	GPA2012	MPRE2012	MPOS2012	GrPre2012	GrPos2012
NACIONAL	2161	347233353	42120	9299	4903	3181
PEDAGOGICA	440	7986738	9321	1614	1186	362
UPTC	828	20641880	24644	2360	3190	1225
CAUCA	550	28539431	12859	700	1372	303
TEC DE PEREIRA	442	15343348	15423	1319	1532	299
CALDAS	418	12877924	12261	971	1953	266
CORDOBA	336	17354987	12081	377	809	0
SURCOLOMBIANA	284	10982676	9867	435	1113	265
AMAZONIA	198	6113236	6851	332	724	177
MILITAR	375	10673047	12850	2678	978	1218
TEC DEL CHOCO	240	21314583	10668	43	1536	49
LLANOS	201	13159385	5218	267	653	136
POPU DEL CESAR	184	5206608	13127	0	1653	159
MAY DE CNAMARCA	203	7597155	5028	235	870	237
PACIFICO	65	3613371	2115	0	128	0
ANTIOQUIA	1848	71634254	36788	2760	3437	815
ATLANTICO	371	11693780	19907	255	1559	151
VALLE	385	61169888	36845	3888	3888	3888

DCTC (1/2)


DCTC2012 vs GPA2012




DCTC2012 vs MPRE2012



DCTC2012 vs MPOS2012




DCTC2012 vs GrPre2012




DCTC2012 vs GrPos2012

GPA2012 vs MPRE2012



GPA2012 vs MPOS2012


GPA2012 vs GrPre2012




GPA2012 vs GrPos2012

Indicadores (10–12)


MPRE2012 vs MPOS2012



MPRE2012 vs GrPre2012




MPOS2012 vs GrPre2012



MPOS2012 vs GrPos2012

GrPre2012 vs GrPos2012



Ejemplo




Figure: Agrupamiento de universidades del SUE en cuatro grupos

Ejemplo




Figure: Agrupamiento de universidades del SUE en tres grupos

Datos atípicos en una variable: Rango intercuartílico (IQR)

Definición (medida de dispersión). El **rango intercuartílico** es una medida robusta de dispersión definida por:

$$IQR = Q_{0.75} - Q_{0.25}.$$

Construcción del rango para detectar atípicos. A partir del IQR se define el intervalo:

$$(Q_{0.25} - 1.5 IQR, Q_{0.75} + 1.5 IQR),$$

y una observación se considera **atípica** si cae por fuera de este rango.

Datos atípicos en una variable: Rango intercuartílico (IQR)

Motivación (referencia normal). Esta regla es coherente con la idea de concentración de probabilidad en la distribución normal $N(\mu, \sigma^2)$: aproximadamente

el 68% de las obs. se encuentran en el intervalo $\mu \pm \sigma$,

el 95% en el intervalo $\mu \pm 2\sigma$

el 99% en el intervalo $\mu \pm 3\sigma$.

Indicadores de educación y número de habitantes ciudades colombianas

Ejemplo

El archivo ciudades contiene datos del número de habitantes y cuatro indicadores de educación en 22 ciudades colombianas. Tabla 7.

Indicadores de educación y número de habitantes ciudades colombianas

Ejemplo

Table: Indicadores de educación y número de habitantes para 22 ciudades colombianas

CIUDADES	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	284120	0.09	1.09	0.27	22.4
Barranquilla	1163007	0.09	1.08	0.31	22.5
Bogota	7050228	0.10	1.00	0.54	22.6
Bucaramanga	520080	0.08	1.19	0.33	22.2
Cali	2169801	0.08	1.02	0.22	22.0
Cartagena	912674	0.12	1.21	0.15	24.4
Cucuta	600049	0.11	1.15	0.22	22.4
Ibague	509796	0.11	0.98	0.18	23.4
Manizales	383483	0.08	1.14	0.23	22.2
Medellin	2264776	0.13	1.22	0.30	26.3
Monteria	390996	0.16	1.11	0.15	26.1
Neiva	322098	0.11	1.10	0.18	23.3
Pasto	394074	0.11	1.05	0.13	21.8
Pereira	448971	0.10	1.12	0.28	22.6
Popayan	261694	0.09	1.14	0.16	21.5
Riohacha	184847	0.27	1.00	0.15	26.1
San Andres	66675	0.08	0.80	0.11	20.4

Ciudades atípicas

Ejemplo

Table: Ciudades atípicas por cada variable

Ciudad	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	284120	0.088	1.095	0.266	22.4
Barranquilla	*	0.0922	1.083	0.306	22.5
Bogota	*	0.0973	0.999	*	22.6
Bucaramanga	520080	0.076	1.192	0.326	22.2
Cali	*	0.0831	1.019	0.223	22.0
Cartagena	912674	0.1213	1.207	0.147	24.4
Cucuta	600049	0.1133	1.147	0.217	22.4
Ibague	509796	0.1073	0.983	0.181	23.4
Manizales	383483	0.0769	1.143	0.23	22.2
Medellin	*	0.1256	1.219	0.3	26.3
Monteria	390996	0.1587	1.109	0.151	26.1
Neiva	322098	0.1131	1.1	0.179	23.3
Pasto	394074	0.1115	1.052	0.128	21.8
Pereira	448971	0.1007	1.124	0.283	22.6
Popayan	261694	0.0915	1.135	0.163	21.5
Riohacha	184847	*	1	0.152	26.1
San Andres	66675	0.0772	*	0.107	20.4
Santa Marta	428374	0.1244	1.005	0.116	22.9
Sincelejo	245180	0.1612	1.228	0.107	24.9
Tunja	161209	0.1023	1.036	0.245	22.1
Mallat...	676976	0.1507	1.017	0.117	21.5

Ciudades atípicas por número de habitantes

Ejemplo





Figure: Número de habitantes por ciudades

Datos atípicos en dos variables - Distancia de Mahalanobis


Ejemplo

Problema




Ejemplo

Problema



Ejemplo

Otro problema



Distancia de Mahalanobis en dos variables

Es una medida de la distancia entre observaciones multivariadas con la propiedad de que incluye tanto las distancias euclidianas entre las variables, como el grado de correlación entre ellas.

Distancia de Mahalanobis entre observaciones de dos variables

Asumiendo que hay n observaciones para dos variables X_1 y X_2 :

$$\begin{bmatrix} x_{11} & x_{12} \\ \vdots & \vdots \\ x_{i1} & x_{i2} \\ \vdots & \vdots \\ x_{i'1} & x_{i'2} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{bmatrix}$$

$$d_M^2(i, i') = \frac{1}{(1 - r_{12}^2)} \left[\frac{(x_{i1} - x_{i'1})^2}{s_1^2} + \frac{(x_{i2} - x_{i'2})^2}{s_2^2} - 2r_{12} \frac{(x_{i1} - x_{i'1})(x_{i2} - x_{i'2})}{s_1 s_2} \right] \quad (1)$$

$\frac{(x_{i1} - x_{i'1})^2}{s_1^2}$ y $\frac{(x_{i2} - x_{i'2})^2}{s_2^2}$ son las distancias euclidianas estandarizadas entre los dos puntos y r_{12} es el coeficiente de correlación entre X_1 y X_2 .

Interpretación de la distancia de Mahalanobis en dos variables

- **Cuando** $r_{12} \rightarrow 0$: las variables son aproximadamente incorrelacionadas y la distancia de Mahalanobis se reduce esencialmente a una suma de distancias euclidianas estandarizadas.
- **Cuando** $r_{12} \rightarrow 1$: las variables están fuertemente correlacionadas de forma positiva; las diferencias en la dirección común de variación aportan poco a la distancia, mientras que las desviaciones ortogonales se amplifican.
- **Cuando** $r_{12} \rightarrow -1$: existe una correlación negativa fuerte; las diferencias opuestas entre X_1 y X_2 se penalizan menos, y las discrepancias fuera de esa relación lineal incrementan la distancia.

Distancia de Mahalanobis y estimación de la varianza

- **Distancia a la media multivariada**

La distancia de Mahalanobis de la observación i al centro de los datos se obtiene reemplazando $x_{i'}$ por la media

$$\bar{\mathbf{x}} = (\bar{x}_1, \bar{x}_2),$$

lo que permite cuantificar la separación de cada individuo respecto a la estructura global de las variables.

- **Estimación de las varianzas**

Para cada variable se utiliza usualmente el estimador insesgado

$$s_j^2 = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2, \quad j = 1, 2.$$

En contextos poblacionales o para tamaños muestrales grandes puede emplearse el denominador n , ya que la diferencia entre n y $n-1$ resulta despreciable.

Caso particular: dos observaciones y dos variables

- **Matriz de datos reducida**

Cuando solo se dispone de dos observaciones, la matriz de datos es

$$\begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix}.$$

- **Varianzas como sumas de cuadrados**

Dado que $n = 2$, las varianzas se reducen a

$$s_j^2 = \sum_{i=1}^2 (x_{ij} - \bar{x}_j)^2, \quad j = 1, 2.$$

- **Interpretación**

Este caso es fundamentalmente ilustrativo y tiene escaso interés práctico, debido a la inestabilidad inherente a trabajar con un número extremadamente pequeño de observaciones.

Ejemplo

Ejemplo

Ejemplo

Ejemplo

FIN DEL CAPÍTULO

Ejemplo