

Medidas descriptivas multivariadas

Transcripción de las univariadas

Jimmy A Corzo S^{1 2}

¹Profesor Titular
Departamento de Estadística

²Facultad de ciencias
Universidad Nacional de colombia

Métodos multivariados aplicados LyX cap 3

- 1 Observaciones multivariadas
- 2 Datos
- 3 Vector de medias o centroide, matriz de covarianzas y matriz de correlación
- 4 combinaciones lineales
- 5 Componentes principales: una combinación lineal específica
- 6 Datos atípicos en una variable
- 7 Distancias entre observaciones multivariadas

Observaciones multivariadas

Para la construcción de los análogos multivariados de las medidas descriptivas univariadas primero se requiere definir las observaciones multivariadas.

En el contexto multivariado en lugar de una se observan p variables $X_1, \dots, X_p$ simultáneamente sobre mismo un objeto i (que puede ser una ciudad, una universidad, una planta, una persona), y por tanto una observación para el objeto i es un vector de p componentes

$$x_i = (x_{i1}, \dots, x_{ij}, \dots, x_{ip})',$$

donde x_{ij} es la observación de la variable j sobre el objeto i .

Tabla de datos

Para n objetos las observaciones se arreglan en una tabla de datos como la siguiente:

Objeto	Variables			
	X_1	$\cdots X_j$	$\cdots$	X_p
1	x_{11}	$\cdots x_{1j}$	$\cdots$	x_{1p}
$\vdots$	$\vdots$	$\cdots \vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\cdots x_{ij}$	$\cdots$	$\vdots$
$\vdots$	$\vdots$	$\cdots \vdots$	$\vdots$	$\vdots$
n	x_{n1}	$\cdots x_{nj}$	$\cdots$	x_{np}

Media, Varianza, Covarianza y Coeficiente de correlación:

$$\bar{x}_j = med(X_j) = \frac{1}{n} \sum_{i=1}^n x_{ij} \quad \text{media de la variable } X_j$$

$$s_j^2 = var(X_j) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \quad \text{varianza de la variable } X_j$$

$$s_{jk} = cov(X_j, X_k) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k), \quad s_{jj} = s_j^2$$

$$r_{jk} = corr(X_j, X_k) = \frac{s_{jk}}{s_j s_k}, \quad s_j = \sqrt{s_j^2} \quad (1)$$

Nótese que para el cálculo de la varianza se utilizó como denominador n debido a que en datos multivariados se considera suficientemente grande como para que s^2 siga siendo un estimador insesgado de la varianza poblacional¹.

¹En R se utiliza $n - 1$ y por tanto para los cálculos debe hacerse la modificación en la salida del comando `var()`.

Media, Varianza, Covarianza y Coeficiente de correlación:

Nótese que para el cálculo de la varianza y la covarianza se utilizó como denominador n debido a que en datos multivariados se considera suficientemente grande como para que s^2 siga siendo un estimador insesgado de la varianza poblacional.

Los comandos `var()` y `cov()` de *R* utilizan $n - 1$ y por tanto para los cálculos debe hacerse la modificación correspondiente.

Tabla de datos

tabla para referirse a los datos con nombres en las filas y columnas
matriz cuando se van a utilizar las propiedades algebraicas de la tabla

$$X = \{x_{ij}\} = \begin{bmatrix} x_{11} & \cdots x_{1j} & \cdots & x_{1p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{i1} & \cdots x_{ij} & \cdots & x_{ip} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & \cdots x_{nJ} & \cdots & x_{np} \end{bmatrix}$$

Columna de la tabla de datos

En esta matriz la columna j , o el punto variable j , representa las observaciones de la variable X_j sobre los n objetos y se denota como un vector columna:

$$X_{.j} = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix}, j = 1, \dots, p$$

Fila de la tabla de datos

Análogamente, la fila i , o el punto objeto i , representa las observaciones de las p variables sobre el objeto i que se denota como un vector columna;

$$x_{i.} = (x_{i1}, \dots, x_{ip})' = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix}, i = 1, \dots, n.$$

Ejemplo Ciudades Colombianas

Table: Tabla de datos multivariados de ciudades colombianas

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	284120	0.09	1.09	0.27	22.4
Barranquilla	1163007	0.09	1.08	0.31	22.5
Bogota	7050228	0.10	1.00	0.54	22.6
Bucaramanga	520080	0.08	1.19	0.33	22.2
Cali	2169801	0.08	1.02	0.22	22.0
Cartagena	912674	0.12	1.21	0.15	24.4
Cucuta	600049	0.11	1.15	0.22	22.4
Ibague	509796	0.11	0.98	0.18	23.4
Manizales	383483	0.08	1.14	0.23	22.2
Medellin	2264776	0.13	1.22	0.30	26.3
Monteria	390996	0.16	1.11	0.15	26.1
Neiva	322098	0.11	1.10	0.18	23.3
Pasto	394074	0.11	1.05	0.13	21.8
Pereira	448971	0.10	1.12	0.28	22.6
Popayan	261694	0.09	1.14	0.16	21.5
Riohacha	184847	0.27	1.00	0.15	26.1
San Andres	66675	0.08	0.80	0.11	20.4
Santa Marta	428374	0.12	1.00	0.12	22.9
Sinceleio	245180	0.16	1.23	0.11	24.9

Fila de la tabla de datos

La fila 5 de la Tabla 1 es la observación de las cinco variables para la ciudad de Cali (objeto 5):

$$x_5 = (2169801, 0.08, 1.02, 0.22, 22)' = \begin{bmatrix} 2168901 \\ 0.08 \\ 1.02 \\ 0.22 \\ 22 \end{bmatrix}$$

Columna de la tabla de datos

la variable X_4 Cobertura en educación superior es la columna

$$X_4 = \begin{bmatrix} 0.27 \\ 0.31 \\ \vdots \\ 0.15 \\ 0.17 \end{bmatrix}$$

Vector de medias o centroide

$$med(X) = \bar{x} = \frac{1}{n} \mathbf{1}_n' X = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}, \quad \text{donde} \quad \mathbf{1}_n = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1_n \end{bmatrix} \quad (2)$$

Ejemplo vector de medias

El vector de medias de las variables de la tabla de ciudades expresado como un vector es: $\bar{x}' = (888021.77, 0.12, 1.09, 0.21, 23.27)'$, el cual, en formato de tabla se muestra en la tabla2 :

Table: Vector de medias para variables de educación de la tabla de ciudades

	Media
Num.Hab	888021.77
Analfabetismo	0.12
Cobertura.pria.y.secdaria	1.09
Cobertura.ed.sup	0.21
Rel.al.prof	23.27

Matriz de datos centrados

$$\tilde{X} = X - \mathbf{1}_n \bar{x}' = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \cdots & x_{1p} - \bar{x}_p \\ x_{21} - \bar{x}_1 & x_{22} - \bar{x}_2 & \cdots & x_{2p} - \bar{x}_p \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} - \bar{x}_1 & x_{n2} - \bar{x}_2 & \cdots & x_{np} - \bar{x}_p \end{bmatrix}, \{\tilde{x}_{ij}\} = \{x_{ij} - \bar{x}_j\} \quad (3)$$

Observe que

$$med(\tilde{X}) = \frac{1}{n} \tilde{X}' \mathbf{1}_n = \left(\frac{1}{n} X' \mathbf{1}_n - \frac{1}{n} \bar{x}' \mathbf{1}_n' \mathbf{1}_n \right) = 0 \quad (4)$$

Matriz de datos centrados

Se puede comprobar fácilmente que todas las variables tienen media cero.

Table: Matriz de datos centrados

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	-603901.77	-0.028	0.009	0.053	-0.873
Barranquilla	274985.23	-0.024	-0.003	0.093	-0.773
Bogota	6162206.23	-0.019	-0.087	0.325	-0.673
Bucaramanga	-367941.77	-0.040	0.106	0.113	-1.073
Cali	1281779.23	-0.033	-0.067	0.010	-1.273
Cartagena	24652.23	0.005	0.121	-0.066	1.127
Cucuta	-287972.77	-0.003	0.061	0.004	-0.873
Ibague	-378225.77	-0.009	-0.103	-0.032	0.127
Manizales	-504538.77	-0.039	0.057	0.017	-1.073
Medellin	1376754.23	0.010	0.133	0.087	3.027
Monteria	-497025.77	0.043	0.023	-0.062	2.827
Neiva	-565923.77	-0.003	0.014	-0.034	0.027
Pasto	-493947.77	-0.005	-0.034	-0.085	-1.473

Matriz de covarianzas

$$S = \frac{1}{n} \tilde{X}' \tilde{X} = \begin{bmatrix} s_1^2 & s_{12} & \cdots & s_{1p} \\ s_{21} & s_2^2 & \cdots & s_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_p^2 \end{bmatrix}, \quad s_j^2 = s_{jj}$$

Nótese que comunmente se utiliza el estimador insesgado para la varianza $s_j = \frac{1}{(n-1)} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2, j = 1, \dots, p$.

Sin embargo, cuando se trata de datos poblacionales como es el caso de los datos de las ciudades colombianas, o cuando n es suficientemente grande, se puede utilizar como denominador n debido a que por ejemplo para $n > 100$, la diferencia entre dividir por n y por $n - 1$ resulta despreciable.

Matriz de datos centrados estandarizados

La matriz de datos centrados estandarizados se obtiene al estandarizar la matriz de datos centrados $\tilde{X}$:

$$\tilde{Y} = \tilde{X}D^{-1/2}, \quad D = \text{diag}\{s_j^2\}, \quad D^{-1/2} = \text{diag}\left\{\frac{1}{s_j}\right\}. \quad (5)$$

Explícitamente,

$$\tilde{Y} = \begin{bmatrix} \frac{x_{11} - \bar{x}_1}{s_1} & \frac{x_{12} - \bar{x}_2}{s_2} & \dots & \frac{x_{1p} - \bar{x}_p}{s_p} \\ \frac{x_{21} - \bar{x}_1}{s_1} & \frac{x_{22} - \bar{x}_2}{s_2} & \dots & \frac{x_{2p} - \bar{x}_p}{s_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{x_{n1} - \bar{x}_1}{s_1} & \frac{x_{n2} - \bar{x}_2}{s_2} & \dots & \frac{x_{np} - \bar{x}_p}{s_p} \end{bmatrix}$$

Utilizando (3) se obtiene que el vector de medias de $\tilde{Y}$ es nulo:

$$\text{med}(\tilde{Y}) = \tilde{Y}'\mathbf{1}_n = D^{-1/2}\tilde{X}'\mathbf{1}_n = D^{-1/2} \cdot 0 = 0$$

Matriz de correlación

Es una matriz simétrica que contiene unos en la diagonal que son las correlaciones de las variables consigo mismas y por fuera de la diagonal las correlaciones r_{ij} entre pares de variables. Se define por

$$R = D^{-1/2}SD^{-1/2} \quad (6)$$

y también se obtiene a partir de la matriz de datos centrados estandarizados así:

$$R = \frac{1}{n} \tilde{Y}'\tilde{Y} = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix}, \quad r_{ij} = \frac{s_{ij}}{s_i s_j} \quad (7)$$

Nótese que la matriz de covarianzas de $\tilde{Y}$ es también R puesto que

$$S_{\tilde{Y}} = \frac{1}{n} \tilde{Y}' \tilde{Y} = \frac{1}{n} D^{-1/2} \tilde{X}' \tilde{X} D^{-1/2} = D^{-1/2} S D^{-1/2} = R \quad (8)$$

Matriz de datos centrados, estandarizados y normados

A partir de la matriz de datos centrados estandarizados $\tilde{Y}$ se define la **matriz de datos centrados, estandarizados y normados**

$$Y = \frac{1}{\sqrt{n}} \tilde{Y} = \frac{1}{\sqrt{n}} \tilde{X} D^{-1/2}. \quad (9)$$

Esta matriz también está centrada puesto que

$$\text{med}(Y) = \frac{1}{\sqrt{n}} \text{med}(\tilde{Y}) = 0.$$

Además, al estar autoponderada por $\frac{1}{\sqrt{n}}$, el producto de la matriz consigo misma produce su matriz de covarianzas, que coincide con la matriz de correlaciones:

$$S_Y = Y'Y = \frac{1}{n} \tilde{Y}' \tilde{Y} = R. \quad (10)$$

Varianza total

La **varianza total** es un indicador de la variabilidad global de una matriz de datos. Se define como la suma de las varianzas de las variables:

$$V_T = \sum_{j=1}^p s_j^2 \quad (11)$$

donde s_j^2 es la varianza de la variable X_j .

En particular, para las matrices de datos centrados y estandarizados se tiene

$$S_{\tilde{Y}} = S_Y = R$$

donde R es la matriz de correlaciones.

Como la diagonal de R está compuesta por unos, se obtiene

$$V_T(\tilde{Y}) = V_T(Y) = \text{tr}(R) = p. \quad (12)$$

Ejemplo

Matriz de covarianzas entre las variables del archivo de ciudades.

Table: Matriz de covarianzas de las variables del archivo de ciudades

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Num.Hab	2.228013e+12	-9797.725	-13331.063	116811.812	-34962.921
Analfabetismo	-9.797725e+03	0.002	0.000	-0.001	0.050
Cobertura.pria.y.secdaria	-1.333106e+04	0.000	0.010	0.001	0.070
Cobertura.ed.sup	1.168118e+05	-0.001	0.001	0.010	-0.025
Rel.al.prof	-3.496292e+04	0.050	0.070	-0.025	2.721

Ejemplo

Matriz correlación entre las variables de la tabla de ciudades.

Table: Matriz de correlación de las variables del archivo de ciudades

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Num.Hab	1.00	-0.15	-0.09	0.79	-0.01
Analfabetismo	-0.15	1.00	-0.01	-0.34	0.71
Cobertura.pria.y.secdaria	-0.09	-0.01	1.00	0.09	0.42
Cobertura.ed.sup	0.79	-0.34	0.09	1.00	-0.15
Rel.al.prof	-0.01	0.71	0.42	-0.15	1.00

Combinaciones lineales

Una combinación lineal es una suma ponderada de los valores de una variable observada en varios objetos, como lo es la media por ser la suma de los valores de la variable ponderados por $1/n$, o como la varianza que es la suma de los desvíos de los valores de la variable respecto a la media $(x_i - \bar{x})^2$ ponderados por $1/n$.

Combinaciones lineales

También es combinación lineal la una suma ponderada de los valores de varias variables observadas en un mismo objeto. Por ejemplo:

Los rankings de universidades

El índice de pobreza multidimensional es una combinación lineal de indicadores de vivienda, servicios básicos, estándar de vida, educación y empleo, y protección social;

El índice de desarrollo humano que podera indicadores de dimensiones como la esperanza de vida, educación y riqueza.

La mayoría de los índices o indicadores utilizados en economía y finanzas para describir y comparar cantidades de diferente naturaleza.

Combinaciones lineales

Las combinaciones lineales son útiles en muchos contextos estadísticos y especialmente en el caso de datos multivariados, donde por ejemplo, **las componentes principales son combinaciones lineales de los valores de las variables cuyas ponderaciones se construyen para que contengan la mayor cantidad posible de la varianza de las variables.**

Combinación lineal de los valores de una variable observada en n objetos

Sea X_j la j -ésima columna de la matriz de datos. Se define la combinación de los n valores de la variable j con constantes de ponderación $a' = (a_1, \dots, a_n)'$ por:

$$X_j^* = a'X_j = \sum_{i=1}^n a_i x_{ij} \quad j = 1, \dots, p. \quad (13)$$

Ejemplo

El promedio de la variable j es una combinación lineal con constantes de ponderación $p' = (\frac{1}{n}, \dots, \frac{1}{n})$:

$$\bar{x}_j = p'X_j = \sum_{i=1}^n \frac{1}{n} x_{ij} \quad (14)$$

Combinación lineal de valores de p variables observadas sobre un mismo objeto

Para el objeto i cuyas observaciones están en la fila $x_{i.}$ de la matriz de datos, se define la combinación lineal de los valores de las p variables con ponderaciones $b' = (b_1, \dots, b_p)$ por:

$$z_i = b'x_{i.} = \sum_{j=1}^p b_j x_{ij} \quad i = 1, \dots, n \quad (15)$$

donde x_{ij} es como en (??). Conviene aclarar que este tipo de combinaciones lineales solo tienen sentido si las variables están estandarizadas, o cuando todas vienen medidas en las mismas escalas.

Ejemplo. El Academic Rank of World Universities

Uno de los más exigentes rankings del mundo es el Academic Rank of World Universities (ARWU) que utiliza los siguientes seis criterios (en paréntesis las ponderaciones de cada criterio)

- Premios Nobel de exalumnos (Score on Alumni: X_1) (10%)
- Premios Nobel de docentes de la universidad (Score on Award: X_2) (20%)
- Artículos altamente citados en 21 categorías temáticas (Score on HiCi: X_3) (20%)
- Artículos publicados en las reconocidas revistas Nature y Science (Score on N&S: X_4) (20%)
- Artículos indexados en alguno de los índices de citación como el Science Citation Index-expanded o en el Social Science Citation Index (Score on PUB: X_5) (20%)
- Productividad per cápita de los docentes de la universidad (Score on PCP: X_6) (10%)

Ejemplo. El Academic Rank of World Universities

Los valores de los rankings para las primeras 10 universidades en el año 2013

Table: Puntajes de las diez primeras universidades del ARWU

	Alumni	Award	HiCi	N.S	PUB	PCP	Total.Score
Harvard	100.0	100.0	100.0	100.0	100.0	69.2	100.0
California, Berkeley	67.6	79.3	69.0	70.9	70.6	54.2	72.4
Stanford	40.2	78.4	87.6	68.4	69.7	50.1	72.1
MIT	70.5	80.3	66.8	70.1	61.4	64.5	71.4
Cambridge	88.5	92.6	53.9	54.3	65.7	53.1	69.6
California I of Tech	50.3	68.8	56.7	64.8	46.9	100.0	64.4
Princeton	56.4	84.8	61.1	43.3	44.3	65.5	60.8
Columbia	70.7	67.4	56.2	47.6	69.9	32.1	60.4
Chicago	65.5	83.9	50.9	39.8	50.5	40.0	57.3
Oxford	56.2	57.6	48.8	49.8	68.5	41.1	56.4

Ejemplo. El Academic Rank of World Universities

El puntaje del ranking es una combinación lineal de los puntajes obtenidos por una universidad en los criterios, con ponderaciones $b' = (0.1, 0.2, 0.2, 0.2, 0.2, 0.1)$, de manera que por ejemplo para la universidad de Harvard, cuyos puntajes en los criterios que están en la fila uno de la tabla ?? son

$$x_1 = (100, 100, 100, 100, 100, 69.2),$$

de manera que el valor de su puntaje total en el ranking es:

$$y_i = 0.1 \times 100 + 0.2 \times 100 + 0.2 \times 100 + 0.2 \times 100 + 0.2 \times 100 + 0.1 \times 69.2 = 0.9692$$

Ajustado a 100 en la tabla como máximo valor de referencia.

Ejemplo. El Academic Rank of World Universities

Esto significa que para obtener los valores de la tabla hay que ajustar los valores que produce la combinación lineal. Por ejemplo, para la universidad de Cambridge:

$$\begin{aligned}x_5 &= 0.1 \times 88.5 + 0.2 \times 92.6 + 0.2 \times 53.9 + 0.2 \times 54.3 + 0.2 \times 65.7 \\ &\quad + 0.1 \times 53.1 = 0.6746\end{aligned}$$

y por tanto después de ajustado $67.46/0.9692 = 69.6$.

Combinación lineal que produce las componentes principales

Las componentes principales son combinaciones lineales de los valores de las variables para cuya construcción se utilizan unas ponderaciones $v'_1 = (v_{11}, \dots, v_{p1})$ tales que por ejemplo, la primera componente para el objeto i cuyas observaciones para las p variables están la i ésima fila de Y la matriz de datos centrados estandarizados y_i , tiene la forma:

$$z_{i1} = y'_i v_1 = \sum_{j=1}^p v_{j1} y_{ij}, i = 1, \dots, n \quad (16)$$

z_{i1} es un promedio ponderado de los valores de las variables observadas en el objeto i .

La primera componente para el objeto i es la proyección de los valores de las variables sobre el vector de ponderaciones v_1 .

En el siguiente capítulo se hace la construcción formal de las componentes y las ponderaciones.

Combinación lineal que produce las componentes principales

Como se verá en el siguiente capítulo, estas componentes tienen, entre otras, dos importantes propiedades:

van en direcciones que acumulan la mayor cantidad posible de varianza de la tabla de datos X , útil para reducir la dimensionalidad del problema en el sentido de que basta con unas cuantas de ellas para interpretar y descubrir asociaciones e información intrínseca en los datos.

que **todas las componentes son ortogonales entre sí**, que facilita representaciones gráficas de los datos.

Datos atípicos en una variable: Rango intercuartílico (IQR)

El rango intercuartílico es un indicador del grado de dispersión de los datos:

$$IQR = Q_{0.75} - Q_{0.25}$$

.

A partir de éste se construye un rango

$(Q_{0.25} - 1.5 * IQR, Q_{0.25} + 1.5 * IQR)$

por fuera del cual una observación se puede declarar atípica.

Datos atípicos en una variable: Rango intercuartílico (IQR)

Motivación (referencia normal). Esta regla es coherente con la idea de concentración de probabilidad en la distribución normal $N(\mu, \sigma^2)$: aproximadamente

el 68% de las obs. se encuentran en el intervalo $\mu \pm \sigma$,

el 95% en el intervalo $\mu \pm 2\sigma$

el 99% en el intervalo $\mu \pm 3\sigma$.

Indicadores de educación y número de habitantes ciudades colombianas

Ejemplo

El archivo ciudades contiene datos del número de habitantes y cuatro indicadores de educación en 22 ciudades colombianas. Tabla ??.

Ciudades atípicas


Ejemplo

Table: Ciudades atípicas por cada variable

	Ciudad	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	Armenia	284120	0.088	1.095	0.266	22.4
Barranquilla	Barranquilla	*	0.0922	1.083	0.306	22.5
Bogota	Bogota	*	0.0973	0.999	*	22.6
Bucaramanga	Bucaramanga	520080	0.076	1.192	0.326	22.2
Cali	Cali	*	0.0831	1.019	0.223	22.0
Cartagena	Cartagena	912674	0.1213	1.207	0.147	24.4
Cucuta	Cucuta	600049	0.1133	1.147	0.217	22.4
Ibague	Ibague	509796	0.1073	0.983	0.181	23.4
Manizales	Manizales	383483	0.0769	1.143	0.23	22.2
Medellin	Medellin	*	0.1256	1.219	0.3	26.3
Monteria	Monteria	390996	0.1587	1.109	0.151	26.1
Neiva	Neiva	322098	0.1131	1.1	0.179	23.3
Pasto	Pasto	394074	0.1115	1.052	0.128	21.8
Pereira	Pereira	448971	0.1007	1.124	0.283	22.6
Popayan	Popayan	261694	0.0915	1.135	0.163	21.5
Riohacha	Riohacha	184847	*	1	0.152	26.1
San Andres	San Andres	66675	0.0772	*	0.107	20.4
Santa Marta	Santa Marta	428374	0.1244	1.005	0.116	22.9
Sincalein	Sincalein	245180	0.1612	1.228	0.107	24.9

Ciudades atípicas por número de habitantes

Ejemplo



Datos atípicos en dos variables - Distancia de Mahalanobis

Ejemplo





Figure: ($r=0.76$). Se distinguen en los extremos las ciudades de San Andrés y Riohacha.


Ejemplo

Problema



Ejemplo

Otro problema



Distancia de Mahalanobis en dos variables

Es una medida de la distancia entre observaciones multivariadas con la propiedad de que incluye tanto las distancias euclidianas entre las variables, como el grado de correlación entre ellas.

Distancia de Mahalanobis entre observaciones de dos variables

Asumiendo que hay n observaciones para dos variables X_1 y X_2 :

$$\begin{bmatrix} x_{11} & x_{12} \\ \vdots & \vdots \\ x_{i1} & x_{i2} \\ \vdots & \vdots \\ x_{i'1} & x_{i'2} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{bmatrix}$$

$$d_M^2(i, i') = \frac{1}{(1 - r_{12}^2)} \left[\frac{(x_{i1} - x_{i'1})^2}{s_1^2} + \frac{(x_{i2} - x_{i'2})^2}{s_2^2} - 2r_{12} \frac{(x_{i1} - x_{i'1})(x_{i2} - x_{i'2})}{s_1 s_2} \right] \quad (17)$$

$\frac{(x_{i1} - x_{i'1})^2}{s_1^2}$ y $\frac{(x_{i2} - x_{i'2})^2}{s_2^2}$ son las distancias euclidianas estandarizadas entre los dos puntos y r_{12} es el coeficiente de correlación entre X_1 y X_2 . □

Interpretación de la distancia de Mahalanobis en dos variables

- **Cuando** $r_{12} \rightarrow 0$: las variables son aproximadamente incorrelacionadas y la distancia de Mahalanobis se reduce esencialmente a una suma de distancias euclidianas estandarizadas.
- **Cuando** $r_{12} \rightarrow 1$: las variables están fuertemente correlacionadas de forma positiva; las diferencias en la dirección común de variación aportan poco a la distancia, mientras que las desviaciones ortogonales se amplifican.
- **Cuando** $r_{12} \rightarrow -1$: existe una correlación negativa fuerte; las diferencias opuestas entre X_1 y X_2 se penalizan menos, y las discrepancias fuera de esa relación lineal incrementan la distancia.

Distancia de Mahalanobis y estimación de la varianza

● Distancia a la media multivariada

La distancia de Mahalanobis de la observación i al centro de los datos se obtiene reemplazando $x_{i'}$ por la media

$$\bar{\mathbf{x}} = (\bar{x}_1, \bar{x}_2),$$

lo que permite cuantificar la separación de cada individuo respecto a la estructura global de las variables.

● Estimación de las varianzas

Para cada variable se utiliza usualmente el estimador insesgado

$$s_j^2 = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2, \quad j = 1, 2.$$

En contextos poblacionales o para tamaños muestrales grandes puede emplearse el denominador n , ya que la diferencia entre n y $n-1$ resulta despreciable.

Caso particular: dos observaciones y dos variables

- **Matriz de datos reducida**

Cuando solo se dispone de dos observaciones, la matriz de datos es

$$\begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix}.$$

- **Varianzas como sumas de cuadrados**

Dado que $n = 2$, las varianzas se reducen a

$$s_j^2 = \sum_{i=1}^2 (x_{ij} - \bar{x}_j)^2, \quad j = 1, 2.$$

- Interpretación

Este caso es fundamentalmente ilustrativo y tiene escaso interés práctico, debido a la inestabilidad inherente a trabajar con un número extremadamente pequeño de observaciones.

Distancias entre observaciones multivariadas

Intuitivamente la distancia entre dos puntos A y B en una superficie plana es la longitud del espacio que hay entre ellos. Entonces si se desea ir de A hacia B la distancia se puede medir en metros y esto da idea de lo lejos (o cerca) que están.

Distancias o métricas entre observaciones multivariadas

Esta idea de distancia tiene las siguientes propiedades: Sean A , B y C dos puntos en el espacio R^2

- * Si los dos puntos están en el mismo sitio es decir son un mismo punto, naturalmente la distancia entre ellos es cero: $d(A,A) = 0$
- * de lo contrario la distancia entre A y B es mayor que cero:
 $d(A,B) \geq 0$
- * Además la distancia de A a B es la misma que de B a A :
 $d(A,B) = d(B,A)$
- * Adicionalmente si hay un tercer punto C , ir de A a B directamente tiene que ser más cerca que ir de A a B pasando primero por C , es decir, la distancia entre A y B tiene que ser menor o igual que la distancia entre A y C más la distancia entre C y B :
 $d(A,B) \leq d(A,C) + d(C,B)$

Ejemplo: Valor absoluto

Ejemplo de estas métricas es el valor absoluto o distancia entre dos números a y b . La distancia se mide por la diferencia entre ellos: $a - b$ o $b - a$, pero para evitar la ambigüedad que produce el signo de la diferencia, se utiliza como distancia el valor absoluto $|a - b|$ que siempre es positiva y cumple las propiedades mencionadas de una distancia.

Distancia euclidiana

En general para cualesquiera dos filas $x'_i = (x_{i1}, \dots, x_{ip})'$ y $x'_{i'} = (x_{i'1}, \dots, x_{i'p})'$ de la matriz de datos X la distancia euclidiana es la suma de las diferencias entre las coordenadas de cada variable:

$$d_e(x_i, x_{i'}) = \sqrt{(x_i - x_{i'})'(x_i - x_{i'})} = \sqrt{\sum_{i=1}^p (x_i - x'_{i'})^2} \quad (18)$$

Distancia euclidiana

Ejemplo: Ver tablas completas en el texto

Table: Cuatro ciudades más distantes en el sentido euclidiano

a) Más lejanas			Dist.	b) Más cercanas			Dist.
362	Medellin	San Andres	5.92	Armenia	Barranquilla		0.12
363	Monteria	San Andres	5.71	Barranquilla	Pereira		0.12
368	Riohacha	San Andres	5.71	Bucaramanga	Manizales		0.11
479	San Andres	Villavicencio	5.02	Armenia	Cucuta		0.08

Para el cálculo de las distancias se utiliza la proporción de población por ciudad en lugar de su valor debido a que la mayoría de las variables son indicadores con valores entre cero y uno o varían alrededor de uno, los cuales son pequeños con respecto a la variable Población.

Distancia de Mahalanobis

La distancia de Mahalanobis entre dos objetos o filas de la matriz de datos X $x'_i = (x_{i1}, \dots, x_{ip})'$ y $x'_j = (x_{j1}, \dots, x_{jp})'$ la distancia de Mahalanobis utiliza además de las distancias euclidianas, la estructura de correlación entre las variables involucradas al incluir la matriz de covarianzas entre ellas S^{-1} :

$$d_M(x_i, x_j) = \sqrt{(x_i - x_j)' S^{-1} (x_i - x_j)} \quad (19)$$

Distancia de Mahalanobis

Esta distancia se suele calcular también entre un objeto $x'_i = (x_{i1}, \dots, x_{ip})'$ y el vector de medias de las variables reemplazando en la definición el vector x' por el vector de medias $\bar{x} = (\bar{x}_1, \dots, \bar{x}_p)$:

$$d_M(x_i, \bar{x}) = \sqrt{(x_i - \bar{x})' S^{-1} (x_i - \bar{x})} \quad (20)$$

Distancia de Mahalanobis

Ejemplo: ver todas las distancias en el texto

Table: Cuatro ciudades más distantes en el sentido Mahalanobis

a) Más lejanas			Dist.	b) Más cercanas			Dist.
333	Bogota	Riohacha	5.81	Barranquilla	Pereira		0.74
355	Bogota	San Andres	5.55	Armenia	Tunja		0.74
368	Riohacha	San Andres	5.52	Armenia	Pereira		0.65
478	Riohacha	Villavicencio	5.49	Armenia	Barranquilla		0.63

Reconstrucción de la matriz de datos a partir del TDVS

Reconstrucción de la matriz de puntajes en los criterios del ranking ARWU a partir del TDVS

El ejercicio implica los siguientes pasos:

1 **Lectura de los datos** y construcción de la matriz $C \in \mathbb{R}^{n \times p}$.

2 **Cálculo de las matrices**

$$C'C \text{ y } CC'.$$

3 **Cálculo de**

- los valores propios de $C'C$,
- la matriz V de vectores propios de $C'C$.

4 **Selección de los valores propios estrictamente positivos** y construcción de la submatriz V_r con los vectores propios asociados.

5 **Cálculo de los valores singulares de C :**

Laboratorio

Utilizar el archivo `ciudades_completo_ago_2023` para calcular los solicitado en los siguientes ejercicios:

- 1 El vector de medias de todas las variables
- 2 La matriz de covarianzas
- 3 Varianza generalizada
- 4 Varianza total
- 5 La matriz de correlación
- 6 Calcular las componentes principales para el subarchivo que contiene las variables "Cobertura.ed.sup", "N.Gr.Inv..Colcienciasx10milH", "No.CeNTROS.Inv x10milH", "No.Prf..Doctoradox10milH" utilizando el comando `prcomp` de R.
- 7 Utilizar la función `biplot` de R para visualizar las ciudades en el plano de las dos primeras componentes del ejercicio 6.

Referencias de interés

Mardia, K., Kent, J. & BibbY, J. (1992), *Multivariate Analysis*, eighth printing edn, Academic Press, San Diego, CA 92101.

Fin Capitulo