

# Medidas descriptivas multivariadas

## Transcripción de las univariadas

Jimmy A Corzo S<sup>1 2</sup>

<sup>1</sup>Profesor Titular  
Departamento de Estadística

<sup>2</sup>Facultad de ciencias  
Universidad Nacional de colombia

Métodos multivariados aplicados LyX cap 3



Para la construcción de los análogos multivariados de las medidas descriptivas univariadas primero se requiere definir las observaciones multivariadas.

En el contexto multivariado en lugar de una se observan  $p$  variables  $X_1, \dots, X_p$  simultáneamente sobre mismo un objeto  $i$  (que puede ser una ciudad, una universidad, una planta, una persona), y por tanto una observación para el objeto  $i$  es un vector de  $p$  componentes

$$x_i = (x_{i1}, \dots, x_{ij}, \dots, x_{ip})',$$

donde  $x_{ij}$  es la observación de la variable  $j$  sobre el objeto  $i$ .

Para  $n$  objetos las observaciones se arreglan en una tabla de datos como la siguiente:

| Variables |          |          |          |          |
|-----------|----------|----------|----------|----------|
| Objeto    | $X_1$    | $X_2$    |          | $X_p$    |
| 1         | $x_{11}$ | $x_{12}$ | $\cdots$ | $x_{1p}$ |
| $\vdots$  | $\vdots$ | $\vdots$ | $\vdots$ | $\vdots$ |
| n         | $x_{n1}$ | $x_{n2}$ | $\cdots$ | $x_{np}$ |

# Media, Varianza, Covarianza y Coeficiente de correlación:

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij} \quad \text{media de } X_j$$

$$s_j^2 = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \quad \text{varianza de } X_j$$

$$\text{cov}(X_j, X_k) = s_{jk} = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k), \quad s_{jj} = s_j^2$$

$$\text{corr}(X_j, X_k) = r_{jk} = \frac{s_{jk}}{s_j s_k}, \quad s_j = \sqrt{s_j^2} \quad (1)$$

**tabla** para referirse a los datos con nombres en las filas y columnas

**matriz** cuando se van a utilizar las propiedades algebraicas de la tabla

$$X = \{x_{ij}\} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

Se asume que  $n \geq p$

# Columna de la tabla de datos

En esta matriz la columna  $j$ , o el punto variable  $j$ , representa las observaciones de la variable  $X_j$  sobre los  $n$  objetos y se denota como un vector columna:

$$X_j = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix}, j = 1, \dots, p$$

Análogamente, la fila  $i$ , o el punto objeto  $i$ , representa las observaciones de las  $p$  variables sobre el objeto  $i$  que se denota como un vector columna;

$$x_i = (x_{i1}, \dots, x_{ip})' = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix}, i = 1, \dots, n.$$

$$\bar{x} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix} \quad (2)$$

## Ejemplo Ciudades Colombianas

**Table:** Tabla de datos multivariados de ciudades colombianas

|              | Num.Hab | Analfabetismo | Cobertura.pria.y.secdaria | Cobertura.ed.sup | Rel.al.prof |
|--------------|---------|---------------|---------------------------|------------------|-------------|
| Armenia      | 284120  | 0.09          | 1.09                      | 0.27             | 22.4        |
| Barranquilla | 1163007 | 0.09          | 1.08                      | 0.31             | 22.5        |
| Bogota       | 7050228 | 0.10          | 1.00                      | 0.54             | 22.6        |
| Bucaramanga  | 520080  | 0.08          | 1.19                      | 0.33             | 22.2        |
| Cali         | 2169801 | 0.08          | 1.02                      | 0.22             | 22.0        |
| Cartagena    | 912674  | 0.12          | 1.21                      | 0.15             | 24.4        |
| Cucuta       | 600049  | 0.11          | 1.15                      | 0.22             | 22.4        |
| Ibague       | 509796  | 0.11          | 0.98                      | 0.18             | 23.4        |
| Manizales    | 383483  | 0.08          | 1.14                      | 0.23             | 22.2        |
| Medellin     | 2264776 | 0.13          | 1.22                      | 0.30             | 26.3        |
| Monteria     | 390996  | 0.16          | 1.11                      | 0.15             | 26.1        |
| Neiva        | 322098  | 0.11          | 1.10                      | 0.18             | 23.3        |
| Pasto        | 394074  | 0.11          | 1.05                      | 0.13             | 21.8        |
| Pereira      | 448971  | 0.10          | 1.12                      | 0.28             | 22.6        |
| Popayan      | 261694  | 0.09          | 1.14                      | 0.16             | 21.5        |
| Riohacha     | 184847  | 0.27          | 1.00                      | 0.15             | 26.1        |
| San Andres   | 66675   | 0.08          | 0.80                      | 0.11             | 20.4        |
| Santa Marta  | 428374  | 0.12          | 1.00                      | 0.12             | 22.9        |
| Sincelejo    | 245180  | 0.16          | 1.23                      | 0.11             | 24.9        |
| Tunja        | 161209  | 0.10          | 1.04                      | 0.24             | 22.1        |

La fila 5 de la Tabla ?? es la observación de las cinco variables para la ciudad de Cali (objeto 5):

$$x_5 = (2169801, 0.08, 1.02, 0.22, 22)' = \begin{bmatrix} 2168901 \\ 0.08 \\ 1.02 \\ 0.22 \\ 22 \end{bmatrix}$$

la variable  $X_4$  Cobertura en educación superior es la columna

$$X_4 = \begin{bmatrix} 0.27 \\ 0.31 \\ \vdots \\ 0.15 \\ 0.17 \end{bmatrix}$$

# Ejemplo vector de medidas

El vector de medias de las variables de la tabla de ciudades expresado como un vector es:

$\bar{x}' = (888021.77, 0.12, 1.09, 0.21, 23.27)'$ , el cual, en formato de tabla se muestra en la tabla?? :

**Table:** Vector de medias para variables de educación de la tabla de ciudades

|                           | Media     |
|---------------------------|-----------|
| Num.Hab                   | 888021.77 |
| Analfabetismo             | 0.12      |
| Cobertura.pria.y.secdaria | 1.09      |
| Cobertura.ed.sup          | 0.21      |
| Rel.al.prof               | 23.27     |

# Matriz de datos centrados

Contiene las observaciones centradas estandarizados

$$y_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

:

$$Y = \{y_{ij}\} = \frac{x_{ij} - \bar{x}_j}{s_j} = \begin{bmatrix} \frac{x_{11} - \bar{x}_1}{s_1} & \frac{x_{12} - \bar{x}_2}{s_2} & \dots & \frac{x_{1p} - \bar{x}_p}{s_p} \\ \frac{x_{21} - \bar{x}_1}{s_1} & \frac{x_{22} - \bar{x}_2}{s_2} & \dots & \frac{x_{2p} - \bar{x}_p}{s_p} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{x_{n1} - \bar{x}_1}{s_1} & \frac{x_{n2} - \bar{x}_2}{s_2} & \dots & \frac{x_{np} - \bar{x}_p}{s_p} \end{bmatrix}$$

de manera que  $med(\bar{Y}_j) = 0$  y  $var(Y_j) = 1$

# Matriz de datos centrados

Se puede comprobar fácilmente que todas las variables tienen media cero.

Table: Matriz de datos centrados

|              | Num.Hab    | Analfabetismo | Cobertura.pria.y.secdaria | Cobertura.ed.sup | Rel.al.prof |
|--------------|------------|---------------|---------------------------|------------------|-------------|
| Armenia      | -603901.77 | -0.028        | 0.009                     | 0.053            | -0.873      |
| Barranquilla | 274985.23  | -0.024        | -0.003                    | 0.093            | -0.773      |
| Bogota       | 6162206.23 | -0.019        | -0.087                    | 0.325            | -0.673      |
| Bucaramanga  | -367941.77 | -0.040        | 0.106                     | 0.113            | -1.073      |
| Cali         | 1281779.23 | -0.033        | -0.067                    | 0.010            | -1.273      |
| Cartagena    | 24652.23   | 0.005         | 0.121                     | -0.066           | 1.127       |
| Cucuta       | -287972.77 | -0.003        | 0.061                     | 0.004            | -0.873      |
| Ibague       | -378225.77 | -0.009        | -0.103                    | -0.032           | 0.127       |
| Manizales    | -504538.77 | -0.039        | 0.057                     | 0.017            | -1.073      |
| Medellin     | 1376754.23 | 0.010         | 0.133                     | 0.087            | 3.027       |
| Monteria     | -497025.77 | 0.043         | 0.023                     | -0.062           | 2.827       |
| Neiva        | -565923.77 | -0.003        | 0.014                     | -0.034           | 0.027       |
| Pasto        | -493947.77 | -0.005        | -0.034                    | -0.085           | -1.473      |
| Pereira      | -439050.77 | -0.015        | 0.038                     | 0.070            | -0.673      |
| Popayan      | -626327.77 | -0.025        | 0.049                     | -0.050           | -1.773      |
| Riohacha     | -703174.77 | 0.155         | -0.086                    | -0.061           | 2.827       |
| San Andres   | -821346.77 | -0.039        | -0.283                    | -0.106           | -2.873      |



# Matriz de covarianzas

Es una matriz simétrica que contiene en su diagonal las varianzas de las variables  $s_j^2$ , y por fuera de la diagonal las covarianzas  $s_{jk}$  entre ellas.

$$S = \begin{bmatrix} s_1^2 & s_{12} & \cdots & s_{1p} \\ s_{21} & s_2^2 & \cdots & s_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_p^2 \end{bmatrix}, \quad s_j^2 = s_{jj}$$

**Varianza generalizada** definida como el determinante de la matriz de covarianzas  $|S|$

**Varianza total** definida como  $\text{Traza}(S)$

Éstas se pueden expresar en términos de los valores propios de  $S$ , los cuales como se verá más adelante, son las varianzas de las componentes principales (factores).

Matriz de covarianzas entre las variables del archivo de ciudades.

**Table:** Matriz de covarianzas de las variables del archivo de ciudades

|                           | Num.Hab       | Analfabetismo | Cobertura.pria.y.secdaria | Cobertura.ed.sup | Rel.al.prof |
|---------------------------|---------------|---------------|---------------------------|------------------|-------------|
| Num.Hab                   | 2.228013e+12  | -9797.725     | -13331.063                | 116811.812       | -34962.921  |
| Analfabetismo             | -9.797725e+03 | 0.002         | 0.000                     | -0.001           | 0.050       |
| Cobertura.pria.y.secdaria | -1.333106e+04 | 0.000         | 0.010                     | 0.001            | 0.070       |
| Cobertura.ed.sup          | 1.168118e+05  | -0.001        | 0.001                     | 0.010            | -0.025      |
| Rel.al.prof               | -3.496292e+04 | 0.050         | 0.070                     | -0.025           | 2.721       |

# Matriz de correlación

Es una matriz simétrica que contiene unos en la diagonal que son las correlaciones de las variables consigo mismas y por fuera de la diagonal las correlaciones  $r_{ij}$  entre pares de variables.

$$R = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix}, \quad r_{ij} = \frac{s_{ij}}{s_i s_j}$$

Matriz correlación entre las variables de la tabla de ciudades.

**Table:** Matriz de correlación de las variables del archivo de ciudades

|                           | Num.Hab | Analfabetismo | Cobertura.pria.y.secdaria | Cobertura.ed.sup | Rel.al.prof |
|---------------------------|---------|---------------|---------------------------|------------------|-------------|
| Num.Hab                   | 1.00    | -0.15         | -0.09                     | 0.79             | -0.01       |
| Analfabetismo             | -0.15   | 1.00          | -0.01                     | -0.34            | 0.71        |
| Cobertura.pria.y.secdaria | -0.09   | -0.01         | 1.00                      | 0.09             | 0.42        |
| Cobertura.ed.sup          | 0.79    | -0.34         | 0.09                      | 1.00             | -0.15       |
| Rel.al.prof               | -0.01   | 0.71          | 0.42                      | -0.15            | 1.00        |

# Combinaciones lineales

Una combinación lineal es una suma ponderada de los valores de una variable observada en varios objetos, como lo es la media por ser la suma de los valores de la variable ponderados por  $1/n$ , o como la varianza que es la suma de los desvíos de los valores de la variable respecto a la media  $(x_i - \bar{x})^2$  ponderados por  $1/n$ .

# Combinaciones lineales

También es combinación lineal la una suma ponderada de los valores de varias variables observadas en un mismo objeto.

Por ejemplo:

Los rankings de universidades

El índice de pobreza multidimensional es una combinación lineal de indicadores de vivienda, servicios básicos, estándar de vida, educación y empleo, y protección social;

el índice de desarrollo humano que podera indicadores de dimensiones como la esperanza de vida, educación y riqueza.

la mayoría de los índices o indicadores utilizados en economía y finanzas para describir y comparar cantidades de diferente naturaleza.

# Combinaciones lineales

Las combinaciones lineales son útiles en muchos contextos estadísticos y especialmente en el caso de datos multivariados, donde por ejemplo, **las componentes principales son combinaciones lineales de los valores de las variables cuyas ponderaciones se construyen para que contengan la mayor cantidad posible de la varianza de las variables.**

# Combinación lineal de los valores de una variable observada en $n$ objetos

Para la variable cuyas observaciones están en la columna  $j$  de la matriz de datos se define la combinación de los  $n$  valores de la variable con constantes de ponderación  $a' = (a_1, \dots, a_n)$  por:

$$X_j^* = \sum_{i=1}^n a_i x_{ij} \quad j = 1, \dots, p \quad \text{vectorialmente} \quad (a' X_j) \quad (3)$$

En particular, el promedio de la variable  $j$  es una combinación lineal con constantes de ponderación  $p' = (\frac{1}{n}, \dots, \frac{1}{n})$ :

$$\bar{x}_j = \sum_{i=1}^n \frac{1}{n} x_{ij} \quad \text{vectorialmente} \quad (p' X_j)$$

.

# Combinación lineal de valores de $p$ variables observadas sobre un mismo objeto

Para el objeto  $i$  de la matriz de datos, cuyas observaciones están en la fila  $x'_i = (x_{i1}, \dots, x_{ip})'$  de la matriz de datos, se define la combinación lineal de los valores de las  $p$  variables con ponderaciones  $b' = (b_1, \dots, b_p)$  por:

$$z_i = \sum_{j=1}^p b_j x_{ij} \quad i = 1, \dots, n, \quad \text{vectorialmente} \quad (b'x_i) \quad (4)$$

Conviene aclarar que este tipo de combinaciones lineales solo tienen sentido si las variables están estandarizadas, o cuando todas vienen medidas en las mismas escalas.

# Ejemplo. El Academic Rank of World Universities

Uno de los más exigentes rankings del mundo es el Academic Rank of World Universities (ARWU) que utiliza los siguientes seis criterios de actividad académica e investigativa de las universidades (en paréntesis las ponderaciones de cada criterio)

- Premios Nobel de exalumnos (Score on Alumni:  $X_1$ ) (10%)
- Premios Nobel de docentes de la universidad (Score on Award:  $X_2$ ) (20%)
- Artículos altamente citados en 21 categorías temáticas (Score on HiCi:  $X_3$ ) (20%)
- Artículos publicados en las reconocidas revistas Nature y Science (Score on N&S:  $X_4$ ) (20%)
- Artículos indexados en alguno de los índices de citación como el Science Citation Index-expanded o en el Social Science Citation Index (Score on PUB:  $X_5$ ) (20%)
- Productividad per cápita de los docentes de la universidad (Score on PCP:  $X_6$ ) (10%)

# Ejemplo. El Academic Rank of World Universities

Los valores de los rankings para las primeras 10 universidades en el año 2013 se muestran en la tabla ??:

**Table:** Puntajes de las diez primeras universidades del ARWU

|                      | Alumni | Award | HiCi  | N.S   | PUB   | PCP   | Total.Score |
|----------------------|--------|-------|-------|-------|-------|-------|-------------|
| Harvard              | 100.0  | 100.0 | 100.0 | 100.0 | 100.0 | 69.2  | 100.0       |
| California, Berkeley | 67.6   | 79.3  | 69.0  | 70.9  | 70.6  | 54.2  | 72.4        |
| Stanford             | 40.2   | 78.4  | 87.6  | 68.4  | 69.7  | 50.1  | 72.1        |
| MIT                  | 70.5   | 80.3  | 66.8  | 70.1  | 61.4  | 64.5  | 71.4        |
| Cambridge            | 88.5   | 92.6  | 53.9  | 54.3  | 65.7  | 53.1  | 69.6        |
| California I of Tech | 50.3   | 68.8  | 56.7  | 64.8  | 46.9  | 100.0 | 64.4        |
| Princeton            | 56.4   | 84.8  | 61.1  | 43.3  | 44.3  | 65.5  | 60.8        |
| Columbia             | 70.7   | 67.4  | 56.2  | 47.6  | 69.9  | 32.1  | 60.4        |
| Chicago              | 65.5   | 83.9  | 50.9  | 39.8  | 50.5  | 40.0  | 57.3        |
| Oxford               | 56.2   | 57.6  | 48.8  | 49.8  | 68.5  | 41.1  | 56.4        |

# Ejemplo. El Academic Rank of World Universities

El puntaje del ranking es una combinación lineal de los puntajes obtenidos por una universidad en los criterios, con ponderaciones  $b' = (0.1, 0.2, 0.2, 0.2, 0.2, 0.1)$ , de manera que por ejemplo para la universidad de Harvard, cuyos puntajes en los criterios que están en la fila uno de la tabla ?? son

$$x_1 = (100, 100, 100, 100, 100, 69.2),$$

de manera que el valor de su puntaje total en el ranking es:

$$\begin{aligned} y_i &= 0.1 \times 100 + 0.2 \times 100 + 0.2 \times 100 + 0.2 \times 100 + 0.2 \times 100 \\ &\quad + 0.1 \times 69.2 = 0.9692 \end{aligned}$$

Ajustado a 100 en la tabla como máximo valor de referencia.

# Ejemplo. El Academic Rank of World Universities

Esto significa que para obtener los valores de la tabla hay que ajustar los valores que produce la combinación lineal. Por ejemplo, para la universidad de Cambridge:

$$\begin{aligned}x_5 &= 0.1 \times 88.5 + 0.2 \times 92.6 + 0.2 \times 53.9 + 0.2 \times 54.3 + 0.2 \times 65.7 \\ &\quad + 0.1 \times 53.1 = 0.6746\end{aligned}$$

y por tanto después de ajustado  $67.46/0.9692 = 69.6$ .

# Componentes principales: Combinaciones lineales de las variables

## Propiedades:

- Van en direcciones que acumulan la mayor cantidad posible de varianza de la tabla de datos  $X$ : Util para reducir la dimensionalidad
- Son independientes entre sí: facilita hacer representaciones gráficas de los datos.

# Componentes principales: Construcción

Asumiendo que los datos están centrados y estandarizados  
 $y_{ij} = (x_{ij} - \bar{x}_j) / s_j$ .

Se utilizan unas ponderaciones  $u'_1 = (u_{11}, \dots, u_{p1})$  tales que por ejemplo la primera componente es un conjunto de  $n$  puntos objeto (fila) de la forma:

$$z_{i1} = u_{11}y_{i1} + u_{21}y_{i2} + \dots + u_{p1}y_{ip} = \sum_{j=1}^p u_{j1}y_{ij}, \quad i = 1, \dots, n, \quad (5)$$

de manera que cada uno de los  $n$  puntos es una especie de promedio ponderado de las variables observadas para cada objeto.

# Componentes principales 1: Teorema de la descomposición espectral (**TDE**)

Este teorema garantiza que una matriz simétrica  $B_{p \times p}$  (generalmente la matriz de correlación  $R$  o la matriz de covarianzas  $S$ ) se puede reconstruir (o factorizar) a partir de sus **valores** y **vectores propios** como sigue:

$$B = U\Lambda U' \quad (6)$$

$U$  es una **matriz ortogonal** cuyas columnas son los **vectores propios estandarizados** de  $B$

$\Lambda = \text{diag}\{\lambda_\alpha\}$  con  $\lambda_1 \geq \dots \geq \lambda_p$  son los **valores propios** de  $B$  arreglados en forma descendente. (?), p. 469).

## Componentes principales 2: Teorema de la descomposición espectral (**TDE**)

En particular cuando  $B = R$  que es el caso más común

$$R = U\Lambda U',$$

$U$  contiene en sus columnas los vectores propios de  $R$  y en la diagonal de  $\Lambda$  están los valores propios de  $R$ .

Entonces la multiplicación de cada columna de  $U$  por cada fila de la matriz de datos centrada y estandarizada  $Y$  produce una componente principal del tipo (**??**).

Cuando cuando  $B = S$  es la matriz de covarianzas que es un caso menos común

$$S = U\Lambda U',$$

$U$  contiene los vectores propios de  $S$  y  $\Lambda$  contiene los valores propios de  $S$

Entonces tomando la  $j$ -ésima columna de  $U$  denotada por  $u'_j = (u_{1j}, \dots, u_{pj})'$ , la  $j$ -ésima componente principal se obtiene como el producto:

$$Yu_j = \begin{bmatrix} \sum_{k=1}^p u_{kj}y_{1k} \\ \vdots \\ \sum_{k=1}^p u_{kj}y_{ik} \\ \vdots \\ \sum_{k=1}^p u_{kj}y_{nk} \end{bmatrix} = \begin{bmatrix} z_{1j} \\ \vdots \\ z_{ij} \\ \vdots \\ z_{nj} \end{bmatrix}, \quad j = 1, \dots, p \quad (7)$$

y para  $j = 1$  corresponde a ??.

# Ejemplo RankinG ARWU

Aunque en la práctica no se justifica ACP con dos variables puesto que el coeficiente de correlación y una gráfica de los puntos bastan para encontrar y representar las relaciones entre ellas, se realiza un PCA de los ranking regional y mundial con el único objetivo de ilustrar cómo funcionan las componentes y el tipo de información que contienen

# Ejemplo RankinG ARWU





Figure: Arwu...

# Ejemplo RankinG ARWU



# Ejemplo Ciudades




Figure: Ciudades

# Ejemplo Ciudades




Figure: Ciudades

# Distancias entre observaciones multivariadas

Intuitivamente la distancia entre dos puntos A y B en una superficie plana es la longitud del espacio que hay entre ellos. Entonces si se desea ir de A hacia B la distancia se puede medir en metros y esto da idea de lo lejos (o cerca) que están.

# Distancias o métricas entre observaciones multivariadas

Esta idea de distancia tiene las siguientes propiedades: Sean  $A$ ,  $B$  y  $C$  dos puntos en el espacio  $R^2$

- \* Si los dos puntos están en el mismo sitio es decir son un mismo punto, naturalmente la distancia entre ellos es cero:  
 $d(A,A) = 0$
- \* de lo contrario la distancia entre  $A$  y  $B$  es mayor que cero:  
 $d(A,B) \geq 0$
- \* Además la distancia de  $A$  a  $B$  es la misma que de  $B$  a  $A$ :  
 $d(A,B) = d(B,A)$

# Ejemplo: Valor absoluto

Ejemplo de estas métricas es el valor absoluto o distancia entre dos números  $a$  y  $b$ . La distancia se mide por la diferencia entre ellos:  $a - b$  o  $b - a$ , pero para evitar la ambigüedad que produce el signo de la diferencia, se utiliza como distancia el valor absoluto  $|a - b|$  que siempre es positiva y cumple las propiedades mencionadas de una distancia.

En general para cualesquiera dos filas  $x'_i = (x_{i1}, \dots, x_{ip})'$  y  $x'_{i'} = (x_{i'1}, \dots, x_{i'p})'$  de la matriz de datos  $X$  la distancia euclidiana es la suma de las diferencias entre las coordenadas de cada variable:

$$d_e(x_i, x_{i'}) = \sqrt{(x_i - x_{i'})'(x_i - x_{i'})} = \sqrt{\sum_{i=1}^p (x_i - x'_{i'})^2} \quad (8)$$

# Distancia euclidiana

Ejemplo: Ver tablas completas en el texto

**Table:** Cuatro ciudades más distantes en el sentido euclidiano

| a) Más lejanas |            |               | Dist. | b) Más cercanas |              |  | Dist. |
|----------------|------------|---------------|-------|-----------------|--------------|--|-------|
| 362            | Medellin   | San Andres    | 5.92  | Armenia         | Barranquilla |  | 0.12  |
| 363            | Monteria   | San Andres    | 5.71  | Barranquilla    | Pereira      |  | 0.12  |
| 368            | Riohacha   | San Andres    | 5.71  | Bucaramanga     | Manizales    |  | 0.11  |
| 479            | San Andres | Villavicencio | 5.02  | Armenia         | Cucuta       |  | 0.08  |

Para el cálculo de las distancias se utiliza la proporción de población por ciudad en lugar de su valor debido a que la mayoría de las variables son indicadores con valores entre cero y uno o varían alrededor de uno, los cuales son pequeños con respecto a la variable Población.

# Distancia de Mahalanobis

La distancia de Mahalanobis entre dos objetos o filas de la matriz de datos  $X$   $x_i' = (x_{i1}, \dots, x_{ip})'$  y  $x_{i'}' = (x_{i'1}, \dots, x_{i'p})'$  la distancia de Mahalanobis utiliza además de las distancias euclidianas, la estructura de correlación entre las variables involucradas al incluir la matriz de covarianzas entre ellas  $S^{-1}$ :

$$d_M(x_i, x_{i'}) = \sqrt{(x_i - x_{i'})' S^{-1} (x_i - x_{i'})} \quad (9)$$

Esta distancia se suele calcular también entre un objeto  $x'_i = (x_{i1}, \dots, x_{ip})'$  y el vector de medias de las variables reemplazando en la definición el vector  $x'$  por el vector de medias  $\bar{x} = (\bar{x}_1, \dots, \bar{x}_p)$ :

$$d_M(x_i, \bar{x}) = \sqrt{(x_i - \bar{x})' S^{-1} (x_i - \bar{x})} \quad (10)$$

# Distancia de Mahalanobis

Ejemplo: ver todas las distancias en el texto

**Table:** Cuatro ciudades más distantes en el sentido Mahalanobis

| a) Más lejanas |          |               | Dist. | b) Más cercanas |              |  | Dist. |
|----------------|----------|---------------|-------|-----------------|--------------|--|-------|
| 333            | Bogota   | Riohacha      | 5.81  | Barranquilla    | Pereira      |  | 0.74  |
| 355            | Bogota   | San Andres    | 5.55  | Armenia         | Tunja        |  | 0.74  |
| 368            | Riohacha | San Andres    | 5.52  | Armenia         | Pereira      |  | 0.65  |
| 478            | Riohacha | Villavicencio | 5.49  | Armenia         | Barranquilla |  | 0.63  |



Utilizar el archivo `ciudades_completo_ago_2023` para calcular los solicitado en los siguientes ejercicios:

- 1 El vector de medias de todas las variables
- 2 La matriz de covarianzas
- 3 Varianza generalizada
- 4 Varianza total
- 5 La matriz de correlación
- 6 Calcular las componentes principales para el subarchivo que contiene las variables "Cobertura.ed.sup", "N.Gr.Inv..Colcienciasx10milH", "No.CeNTROS.Inv x10milH", "No.Prf..Doctoradox10milH" utilizando el comando `prcomp` de R.
- 7 Utilizar la función `biplot` de R para visualizar las ciudades en el plano de las dos primeras componentes del ejercicio ??.

# Referencias de interés

# Fin Capitulo