

Jimmy A Corzo S^{1 2}

¹Profesor Titular
Departamento de Estadística

²Facultad de ciencias
Universidad Nacional de colombia

Métodos multivariados aplicados LyX cap 3

- 1 Descripción del método
- 2 Descripción del método
- 3 Ejemplos
- 4 Guías para la interpretación del ACP

Dos enfoques de las componentes principales

La manera más común entre estadísticos de ver el Análisis de Componentes Principales es como un método de buscar ponderaciones apropiadas para construir combinaciones lineales (sumas ponderadas) de las variables $X_1, \dots, X_p$ que acumulan la mayor cantidad posible de varianza de la tabla de datos, combinaciones que son ortogonales por construcción, lo que garantiza que no están correlacionadas.

Un segundo enfoque es el desde el aprendizaje estadístico, en la cual la búsqueda de las componentes es un problema de optimización que consiste en encontrar la mejor aproximación de la matriz de datos, minimizando las sumas de cuadrados de las diferencias entre las observaciones y sus aproximaciones.

Dos enfoques de las componentes principales

Los dos enfoques producen la misma solución, debido a que la aproximación buscada por minimización de las sumas cuadrados, corresponde a la solución dada por el Teorema de la Descomposición en Valores Singulares para la reconstrucción de la matriz de datos a partir de los valores y vectores propios de $X'X$ y de XX' , la cual produce las componentes en las direcciones de máxima varianza de X .

Descripción del método

Éstas combinaciones lineales se denominan **componentes principales, factores o dimensiones**. Luego se utilizan unas cuantas de ellas para comprender mejor los datos, analizar y visualizar tablas de datos, para reducción de dimensiones, para visualización o imputación de datos faltantes entre otras de sus aplicaciones.

En el contexto de regresión las componentes suelen utilizarse como predictores cuando hay problemas de multicolinealidad.

El ACP es la base de los llamados Métodos Factoriales entre los que se cuentan también el Análisis de Correspondencias Simples, el Análisis de Correspondencias Múltiples (ACM) y varias generalizaciones de éstos para tablas múltiples o tablas de tres índices en las cuales se pueden mezclar tablas de variables cuantitativas y tablas de variables cualitativas.

Descripción del método

El ACP se cuenta entre los métodos no supervisados puesto que incluye solamente datos de las variables o características $X_1, \dots, X_p$ observadas en los objetos, sin una respuesta asociada sobre la cual se pueda supervisar la calidad de los resultados que producen, y por tanto tampoco se pueden hacer predicciones de ningún tipo.

Por esta razón, se muestra también un enfoque dentro del moderno aprendizaje estadístico no supervisado que utiliza las componentes para aproximar la matriz de datos y permite calcular los errores en la aproximación como errores residuales de ésta.

Utilidad del ACP

Suele ser útil entre muchas aplicaciones, para

- reducción de dimensiones
- imputación de datos faltantes
- en el contexto de regresión las componentes se pueden utilizar como predictores.
- para visualización de tablas de datos
- exploración y análisis de tablas de datos

Utilidad del ACP

El ACP es la base de los llamados Métodos Factoriales entre los que se cuentan también

- * Análisis de Correspondencias Simples (ACS)
- * Análisis de Correspondencias Múltiples (ACM)
- * Generalizaciones de ACP, ACS y ACM para tablas múltiples o de tres índices en las cuales se pueden mezclar tablas de variables cuantitativas y de variables cualitativas
- * Métodos de agrupamiento (Métodos Jerárquicos)

Definición y propiedades de las componentes principales como direcciones de máxima varianza de la matriz de datos

Matriz de datos centrados, estandarizados y normados

$$Y = \frac{1}{\sqrt{n}}\tilde{Y} = \frac{1}{\sqrt{n}}\tilde{X}D^{-1/2} \quad (1)$$

la cual también está centrada puesto que

$$\text{med}(Y) = \frac{1}{\sqrt{n}}\text{med}(\tilde{Y}) = 0$$

y por estar autoponderada por $\frac{1}{\sqrt{n}}$ el producto consigo misma es su matriz de covarianzas y también la matriz de correlación:

$$S_Y = Y'Y = \frac{1}{n}\tilde{Y}'\tilde{Y} = R. \quad (2)$$

Aplicación del TDVS

El TDVS aplicado a la matriz de datos centrados estandarizados y normados Y produce la siguiente expresión para reconstruirla:

$$Y = ULV', \quad (3)$$

donde

U y V son matrices con columnas ortonormales, lo cual implica $U'U = V'V = I$

$L_{p \times p} = \text{diag}(\sqrt{\lambda_\alpha}), \lambda_\alpha \geq 0, \lambda_1 \geq \dots \geq \lambda_p, \lambda_\alpha$ es el α -ésimo valor propio de $Y'Y$,

$V_{p \times p} = (v_1, \dots, v_p), \quad v_\alpha = (v_{1\alpha}, \dots, v_{p\alpha})'$ es el α -ésimo vector propio de $Y'Y = R$,

y define las *direcciones ortogonales de máxima varianza*

en el *espacio de las variables* (*cargas factoriales* o *loadings* de las variables);

$U_{n \times p} = (u_1, \dots, u_p), \quad u_\alpha = (u_{1\alpha}, \dots, u_{n\alpha})'$ es el α -ésimo vector propio de YY' ,

y define las *direcciones ortogonales de máxima varianza*

en el *espacio de los objetos*. (*cargas factoriales* o *loadings* de los objetos);

XXXX

Se define la matriz de componentes principales como el producto

$$Z = YV \quad (4)$$

donde las columnas de Z son las *componentes principales* (o *scores*) de los objetos, y V contiene las direcciones de máxima varianza. Este producto se denomina matriz de componentes principales para los objetos, pues representa las proyecciones de los valores de los objetos en las variables sobre los vectores propios de $Y'Y$.

XXXX

Nótese que las componentes principales están centradas

$$\text{med}(Z) = \frac{1}{n} Z' \mathbf{1}_n = V' \frac{1}{n} Y' \mathbf{1}_n = V' \cdot 0 = 0, \quad (5)$$

puesto que $\frac{1}{n} Y' \mathbf{1}_n = \text{med}(Y) = 0$.

También se puede demostrar que la matriz de covarianzas de Z es (ver por ejemplo ?):

$$Z'Z = \Lambda, \quad \text{donde} \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad (6)$$

lo cual indica que las componentes son incorrelacionadas y que sus varianzas son los valores propios de $Y'Y$.

Análisis para los objetos.

Particionando la matriz V por columnas,

$V = (v_1, \dots, v_p)$, donde $v_\alpha = (v_{1\alpha}, \dots, v_{p\alpha})$ se obtiene:

$$Z = YV = (Yv_1, \dots, Yv_p),$$

de manera que la α -ésima columna de Z es el vector:

$$z_\alpha = Yv_\alpha \quad \text{para } \alpha = 1, \dots, p \quad (7)$$

que se define como la α - ésima componente principal, en la cual se ve claramente que z_α es la proyección de las observaciones de los objetos (filas de Y) en la dirección de v_α . Por tanto, Z_1 va en la dirección de v_1 que es el vector propio asociado a λ_1 el mayor valor propio de $Y'Y$; Z_2 va en la dirección de v_2 el vector propio asociado a λ_2 el segundo mayor valor propio de $Y'Y$, y así sucesivamente.

Análisis para los objetos.

En particular, definiendo la i -ésima fila de Y por $y_i. = (y_{i1}, \dots, y_{ip})$, las coordenadas para el objeto i sobre la α -ésima componente principal son:

$$z_{i\alpha} = y_i'. v_\alpha = \sum_{j=1}^p y_{ij} v_{j\alpha}, \quad i = 1, \dots, n.$$

Finalmente, su varianza está dada por

$$\text{var}(Z_\alpha) = \frac{1}{n} \sum_{i=1}^n z_{i\alpha}^2 = \frac{1}{n} v_\alpha' Y' Y v_\alpha = \frac{1}{n} \lambda_\alpha,$$

lo cual es consistente con la normalización adoptada en la construcción de Y .

Análisis para las variables

Por otra parte, obsérvese que, a partir del TDVS de Y dado en (3),

$$Y = ULV',$$

se tiene

$$Y' = VLU'.$$

Entonces, al multiplicar Y' a derecha por U se obtiene

$$W = Y'U = VL \quad \text{para las variables.} \quad (8)$$

Por tanto, la α -ésima componente principal asociada al α -ésimo vector propio u_α de YY' viene dada por

$$W_\alpha = Y'u_\alpha, \quad \alpha = 1, \dots, p, \quad \text{para las variables.} \quad (9)$$

Análisis para las variables

Las coordenadas de las variables sobre la α -ésima componente principal son, por tanto,

$$w_{\alpha j} = \sum_{i=1}^n u_{i\alpha} y_{ij}, \quad j = 1, \dots, p. \quad (10)$$

En este caso, los elementos del vector

$$u_{\alpha} = (u_{1\alpha}, \dots, u_{n\alpha})'$$

definen las direcciones ortogonales de máxima varianza en el espacio de los objetos. Las cantidades $w_{\alpha j}$ representan las coordenadas de la variable j sobre la α -ésima componente principal, y describen cómo cada variable se asocia con las direcciones principales determinadas por la variabilidad conjunta de los objetos.

Proporción de varianza explicada por las primeras q componentes

Se obtiene utilizando el hecho de que la varianza total es la suma de los p valores propios de R y por tanto la proporción explicada por los primeros q es:

$$\tau_r = \frac{\sum_{\alpha=1}^q \lambda_{\alpha}}{\sum_{\alpha=1}^p \lambda_{\alpha}} \quad (11)$$

En este enfoque, el ACP consiste básicamente en buscar una representación óptima de la matriz de datos centrados, estandarizados y normados $Y_{n \times p}$ mediante q ($< p$) combinaciones lineales (o promedios ponderados) llamadas componentes principales¹.

¹El método fue presentado inicialmente por ? y desarrollada por ?

Proporción de varianza explicada por las primeras q componentes

Lo óptimo se refiere por una parte a que por estar calculadas en las direcciones de máxima varianza de Y las q componentes utilizadas para la representación contienen la mayor cantidad posible de la varianza de la matriz de datos $Y_{n \times p}$, y en segundo lugar a que dichas componentes son perpendiculares (ortogonales) entre sí. En este sentido, las componentes principales son una forma de reducir las dimensiones de análisis de p variables a q componentes que facilitan los análisis y la interpretación, y permiten visualizar objetos y variables.

Ecuaciones de transición entre el análisis para objetos y el análisis para variables

Para construir las ecuaciones de transición se requiere el siguiente resultado. Sea u_α es un vector propio de $Y'Y$ asociado a un valor propio no nulo λ_α , entonces:

$$Y'Y u_\alpha = \lambda_\alpha u_\alpha, \quad \text{con } \lambda_\alpha \neq 0 \quad (12)$$

Al multiplicar a izquierda por Y y reagrupar se obtiene

$$YY'(Yu_\alpha) = \lambda_\alpha (Yu_\alpha). \quad (13)$$

Como $\lambda_\alpha \neq 0$, se sigue que $Yu_\alpha \neq 0$, y por tanto λ_α es también un valor propio de YY' .

El razonamiento inverso se obtiene de manera análoga, lo que permite concluir que las matrices $Y'Y$ y YY' comparten los mismos valores propios no nulos. En consecuencia, denotando por λ_α y μ_α los valores propios no nulos de $Y'Y$ y YY' , respectivamente, se cumple que

$$\lambda_\alpha = \mu_\alpha, \quad \alpha = 1, \dots, r, \quad (14)$$

donde $r = \text{rango}(Y)$ (número de columnas linealmente independientes de Y).

Ecuaciones de transición entre el análisis para objetos y el análisis para variables

La transición entre los espacios de objetos y variables se obtiene utilizando el hecho de que

$$(Y'Y)u_{\alpha} = Ru_{\alpha} = \lambda_{\alpha}u_{\alpha} \quad (15)$$

Entonces multiplicando a izquierda por Y y reagrupando términos se obtiene:

$$YY'(Yu_{\alpha}) = \lambda_{\alpha}(Yu_{\alpha}) \quad (16)$$

lo cual indica que Yu_{α} es un vector propio de YY' respecto al valor propio λ_{α} . Por otra parte, como la norma de Yu_{α} es $u'_{\alpha}Y'Yu_{\alpha} = \lambda_{\alpha}$ entonces el vector:

$$v_{\alpha} = \frac{1}{\sqrt{\lambda_{\alpha}}}Yu_{\alpha} \quad (17)$$

es un vector propio normado de YY' respecto al valor propio λ_{α} .

Ecuaciones de transición entre el análisis para objetos y el análisis para variables

Análogamente, se utiliza el hecho de que

$$YY'v_{\alpha} = \mu_{\alpha}v_{\alpha}, \text{ donde } \mu_{\alpha} \text{ es un valor propio de } YY' \quad (18)$$

de manera que al premultiplicar por Y' y reagrupando se obtiene:

$$Y'Y(Y'v_{\alpha}) = \mu_{\alpha}(Y'v_{\alpha}) \quad (19)$$

y por tanto $Y'v_{\alpha}$ es un vector propio de $Y'Y$ respecto al valor propio μ_{α} . También en este caso la norma de $u_{\alpha} = Y'v_{\alpha}$ es $\mu_{\alpha} = \lambda_{\alpha}$. Entonces,

$$u_{\alpha} = \frac{1}{\sqrt{\lambda_{\alpha}}} Y'v_{\alpha} \quad (20)$$

es un vector propio normado de $Y'Y$ respecto al valor propio λ_{α} . Entonces

$$z_{\alpha} = Yu_{\alpha} = \frac{1}{\sqrt{\lambda_{\alpha}}} YY'v_{\alpha} = \sqrt{\lambda_{\alpha}} v_{\alpha} \quad (21)$$

La conclusión es que es suficiente con calcular valores y vectores propios de $Y'Y$, pues a partir de éstos se pueden obtener los de YY' y viceversa.

Ayudas para la interpretación

APLICACIONES

Ejemplo indicadores de invest. y cobertura en educ. superior ciudades

Para el archivo de indicadores de ciudades un ACP de los siguientes indicadores

"N.Gr.Inv..Colciencias",

"No.CeNTROS.Inv",

"No.Prf..Doctorado",

"Poblacion" y

"Cobertura.ed.sup".

Ejemplo indicadores de invest. y cobertura en educ. superior ciudades

Table: Indicadores de calidad de las componentes

	eigenvalue	percent of variance	cum percent of variance
comp 1	2.96	59.29	59.29
comp 2	1.40	27.91	87.20
comp 3	0.34	6.73	93.93
comp 4	0.17	3.46	97.39
comp 5	0.13	2.61	100.00

Las dos primeras dos comp aportan $\lambda = 87.2\%$ de la varianza indicando una buena aproximación (ver 3^a columna de la tabla 1).

Ejemplo indicadores de invest. y cobertura en educ. superior ciudades




Figure: Indicadores de educación superior sobre las dos primeras componentes

Guías para la interpretación del ACP

Guías para la interpretación del ACP

Guías para la interpretación del ACP: Calidad de la representación

- **Calidad de la representación.** Porcentaje de varianza acumulada por las Q componentes escogidas para la representación en menos dimensiones. Denotando por $\lambda_\alpha = v(z_\alpha)$ la varianza de la α - ésima componente, el porcentaje de varianza acumulado por las primeros Q componentes se calcula por:

$$\tau_Q = \frac{\sum_{\alpha=1}^Q \lambda_\alpha}{\sum_{i=1}^p \lambda_\alpha} \quad (22)$$

Guías: Calidad de la representación

Entonces la calidad depende de una buena selección de Q el número de factores, para lo cual existen variados criterios en la literatura entre los que se pueden mencionar dos frecuentemente utilizados:

- Utilizar tantos como sean necesarios para alcanzar un porcentaje de varianza prefijado;
- Escoger todos aquellos que sean mayores que uno. (Otros criterios se pueden ver en ?, ?);

Guías: Correlaciones variable-factor.

Correlaciones variable-factor. Son indicadores del grado en que una variable explica un factor.

Para el α - ésimo factor esta correlación es

$$\sqrt{\lambda_{\alpha}} u_{j\alpha}$$

.

Entre más alta la correlación variable-factor, mejor explicado queda el factor por la variable.

Guías: Tipificación de los factores

Tipificación de los factores (componentes) por las variables. Para la tipificación de los factores se utilizan los siguientes indicadores que relacionan las posiciones de las variables con respecto a los ejes que forman planos factoriales:

- *Coordenadas (scores)*: Posiciones de las variables en los planos factoriales definidas en **??**. Puesto que los factores se construyen sobre la matriz de correlación, coinciden con las correlaciones variable factor. La única forma que no coincidan es que el ACP sea realizado sobre la matriz de covarianzas.

- *Contribuciones a la varianza de los factores:*

Como $\lambda_\alpha = v(z_\alpha) = \sum_{j=1}^p z_{\alpha j}^2$ entonces

$$\frac{z_{\alpha j}^2}{\lambda_\alpha}$$

Es decir, la contribución de la variable j a la varianza del factor α es la proporción de varianza que aporta la variable j a la suma.

- *Cosenos cuadrados ($\cos^2$)*: Capacidad de los factores para predecir las variables. Sea $\theta_{j,\alpha}$ el ángulo entre la variable j y la componente z_α . Entonces el coseno al cuadrado $\cos^2(\theta_{j,\alpha})$ es la correlación variable-factor elevada al cuadrado representa la cantidad de varianza de la variable que está explicada por el factor:

$$\cos^2(\theta_{j,\alpha}) = \lambda_\alpha u_{j\alpha}^2 \quad (23)$$

Puede ocurrir en algunas aplicaciones que una variable tenga alta contribución y alta correlación con un factor, pero sus cosenos cuadrados no son suficientemente altos para que dicho factor sea un buen predictor de la variable.

- **Planos factoriales.** Una vez interpretados o tipificados los factores por las variables se construyen los planos factoriales contruidos por pares de factores (ejes o dimensiones). Las variables se representan por vectores que parten del origen del plano factorial. En los cuadrantes, o sobre los ejes, se pueden deducir propiedades de variables y objetos, a partir de las coordenadas, las contribuciones y los cosenos cuadrados, que tienen en los planos. La interpretación de los planos es por tanto un complemento a la interpretación de los factores.

- **Distancia entre variables.** Para medir la distancia entre dos variables X_j y $X_{j'}$, se aprovecha una relación del álgebra lineal según la cual el coseno del ángulo entre ellas sobre el plano factorial, es la correlación entre ellas y se calcula con:

$$d^2(X_j, X_{j'}) = 2(1 - \cos(\theta_{jj'})) \quad (24)$$

La interpretación ahora se puede hacer en términos de los cosenos entre los ángulos formados por las variables:

- variables directamente correlacionadas:

$$\cos(\theta_{jj'}) \rightarrow 1 \quad \text{entonces} \quad d(X_j, X_{j'}) \rightarrow 0$$

- variables no correlacionadas

$$\cos(\theta_{jj'}) \rightarrow 0 \quad \text{entonces} \quad d(X_j, X_{j'}) \rightarrow \sqrt{2}$$

- variables inversamente correlacionadas

$$\cos(\theta_{jj'}) \rightarrow -1 \quad \text{entonces} \quad d(X_j, X_{j'}) \rightarrow 2$$

cuando el análisis se lleva a cabo sobre la **matriz de covarianzas** la distancia euclídeana entre las variables X_j y $X_{j'}$ se transforma a:

$$d^2(X_j, X_{j'}) = \sum_{i=1}^n (x_{ij} - x_{ij'})^2 = s_j + s_{j'} - 2s_{jj'}$$

Así las cosas, la interpretación depende de la covarianza entre las variables, pero es muy similar a la que se dio arriba para los ángulos entre las variables cuando el análisis se hizo sobre la matriz de correlación, y por tanto cuando:

- $s_{jj'} < 0$ la distancia entre ellos es mayor y tenderán a formar un ángulo obtuso;
- $s_{jj'} = 0$ tenderán a formar un ángulo recto.
- $s_{jj'} > 0$ la distancia entre ellos es menor y tenderán a formar un ángulo agudo

..



Tipificación de los objetos. Tiene sentido cuando se trata de países, universidades, empresas, localidades etc., también suelen asociarse propiedades a los objetos a partir de los factores y de las variables que los definen. También, a partir de las coordenadas, contribuciones y cosenos cuadrados se pueden identificar tendencias o patrones inmersos en los objetos.

- **Distancia entre objetos.** Las interpretaciones en todo caso son análogas a las de las variables y se utilizan los mismos indicadores: coordenadas, contribuciones y cosenos cuadrados. Adicionalmente, conviene tener en cuenta también que:
 - Si dos objetos se encuentran cerca en cualquier parte del plano, es porque comparten características y por tanto son parecidos.
 - Recíprocamente, si dos objetos se encuentran lejanos en cualquier parte del plano, éstos no son parecidos y no comparten características.
 - Finalmente, si dos objetos se encuentran en cuadrantes opuestos del plano factorial, o coordenadas en los factores con signos opuestos, significa que tienen características o valores opuestos de las variables y por tanto perfiles antígonos.

- **Relaciones entre objetos y variables: biplots.** Un biplot es una representación simultánea de objetos y variables sobre el mismo plano factorial. Por tanto los biplots permiten asociar propiedades a los objetos por su cercanía con las variables.
Se establecen por cercanía de los objetos a los valores extremos de las variables y comprobando a partir de los mismos tres indicadores: coordenadas, contribuciones y cosenos cuadrados.

- **Factor tamaño.** En ocasiones en el primer plano factorial todas las variables están orientadas en la dirección del primer factor. Esto significa que dicho factor es una especie de promedio ponderado de todas ellas y puede utilizarse como indicador general. La interpretación de los demás factores se puede hacer normalmente teniendo la precaución de que las contribuciones a la varianza del segundo factor en adelante probablemente son muy pequeñas respecto al factor tamaño, pero no por esto pierden importancia en el análisis.

- **Variables suplementarias.** En algunos casos es necesario incluir variables que han sido observadas en otros contextos pero que no se desea que hagan parte de los cálculos de las componentes. A éstas variables se les llama variables suplementarias o ilustrativas y se pueden ver como si estuvieran yuxtapuestas a la tabla de variables originales o **variables activas**. Vistas así, las variables suplementarias, se pueden proyectar sobre los mismos planos factoriales e interpretar sus posiciones los planos como asociaciones entre éstas y las variables activas.

- **Objetos suplementarios.** Análogamente, cuando se dispone de objetos a los cuales se observaron las mismas variables que a los objetos originales, se les denomina objetos suplementarios o ilustrativos y se pueden considerar como si estuvieran apilados en la tabla de los objetos originales **activos**. Su proyección sobre los planos factoriales se interpreta como el grado de similitud entre ellos y los objetos activos.

Ejemplo

Table: Medias-país de los Rankings Scimago, Qs y Webranking

	MedPais.SC.Lac	MedPais.QS	MedPais.WEB
PRI	26.0	48.0	26.0
BRA	45.6	77.6	60.1
CUB	77.0	91.0	60.0
MEX	96.3	79.3	101.2
CRI	96.5	38.5	61.0
CHL	113.0	69.7	126.9
VEN	164.9	81.1	170.0
COL	169.1	63.9	143.9
ARG	179.4	68.3	195.5
BOL	207.0	112.0	125.0
PER	211.2	83.4	199.4
ECU	240.0	100.7	121.3
PY	253.0	78.0	204.0
URY	266.8	92.0	313.0
PAN	281.0	110.5	285.5

Ejemplo: ACP medias por país




Figure: Representación simultánea de países y rankings promedio por países. Izquierda con promedios originales: PRI, BRA, CUB, MEX y CRI se encuentran en el lado opuesto de las medias-país en el ranking Scimago. Derecha con los negativos de los promedios: estos mismos países se encuentran hacia el mismo lado que apuntan los vectores con las medias-país

ACP medias por país: Calidad de la representación

Table: Valores propios, porcentajes de varianza y de varianza acumulados

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.325	77.517	77.517
comp 2	0.562	18.723	96.240
comp 3	0.113	3.760	100.000

ACP medias por país: Plano 1-2 primeros dos factores




Figure: Proyección de los tres rankings sobre el plano formado por los dos primeros factores. Scimago y WebRanking muestran alta asociación entre ellos, pero asocian muy poco o nada con el Qs

ACP medias por país: tres indicadores básicos para las interpretaciones

Table: coordenadas de las variables (Cargas factoriales)

	Dim.1	Dim.2	Dim.3
MedPais.SC.Lac	0.954	-0.166	-0.251
MedPais.QS	0.772	0.633	0.058
MedPais.WEB	0.906	-0.364	0.215


Table: Contribuciones

	Dim.1	Dim.2	Dim.3
MedPais.SC.Lac	39.097	4.923	55.980
MedPais.QS	25.605	71.429	2.967
MedPais.WEB	35.298	23.648	41.054

Table: Cosenos cuadrados para las variables

	Dim.1	Dim.2	Dim.3
MedPais.SC.Lac	0.909	0.028	0.063
MedPais.QS	0.595	0.401	0.003
MedPais.WEB	0.821	0.133	0.046

Interpretación del plano 1-2



Tipificación de los objetos

Table: Coordenadas de los objetos (ciudades)

	Dim.1	Dim.2	Dim.3
PRI	2.77	0.24	-0.04
CRI	2.19	1.05	0.42
BRA	1.60	-0.76	-0.39
CUB	1.02	-1.24	-0.21
MEX	0.86	-0.44	-0.26
CHL	0.78	0.17	-0.22
COL	0.36	0.67	0.22
ARG	-0.22	0.83	-0.13
VEN	-0.24	0.09	-0.17
PER	-0.88	0.30	0.01
ECU	-0.97	-0.83	0.75
BOL	-1.02	-1.38	0.31
PY	-1.11	0.67	0.41
URY	-2.38	0.78	-0.45
PAN	-2.76	-0.14	-0.26

Table: Contribuciones de los países (objetos)

	Dim.1	Dim.2	Dim.3
PRI	21.928	0.666	0.118
BRA	7.364	6.908	8.982
CUB	2.961	18.386	2.579
MEX	2.099	2.338	3.846
CRI	13.790	13.100	10.539
CHL	1.741	0.337	2.838
VEN	0.165	0.091	1.803
COL	0.368	5.396	2.950
ARG	0.134	8.139	0.996
BOL	3.008	22.633	5.842
PER	2.220	1.065	0.003
ECU	2.688	8.147	33.509
PY	3.504	5.393	10.002
URY	16.218	7.180	12.056
PAN	21.812	0.222	3.936

Table: Cosenos cuadrados para los países (objetos)

	Dim.1	Dim.2	Dim.3
PRI	0.992	0.007	0.000
BRA	0.778	0.176	0.046
CUB	0.393	0.590	0.017
MEX	0.736	0.198	0.065
CRI	0.790	0.181	0.029
CHL	0.888	0.042	0.070
VEN	0.600	0.080	0.319
COL	0.203	0.718	0.079
ARG	0.063	0.915	0.022
BOL	0.343	0.624	0.032
PER	0.896	0.104	0.000
ECU	0.428	0.313	0.259
PY	0.662	0.246	0.092
URY	0.875	0.094	0.032
PAN	0.989	0.002	0.009

Distancia entre objetos




Figure: Proyección de los países sobre los dos primeros factores. Sobresalen en los extremos Cuba, Brasil, Puerto Rico, Costa Rica en el lado derecho del plano y Uruguay, Panamá y Bolivia en el lado izquierdo.

Relaciones entre objetos y variables: biplots




Figure: Representación simultánea de los rankings y los países

Objetos suplementarios o ilustrativos

Son objetos a los que se observaron las mismas variables que a los objetos activos, pero que posiblemente pertenecen a otra población objetivo.

Objetos suplementarios o ilustrativos

También se pueden utilizar como objetos ilustrativos algunos objetos que, siendo parte del grupo observado, son casos atípicos, como se muestra a continuación con algunos países de características especiales como Bolivia, Cuba, Puerto Rico y Paraguay, que solo tienen una universidad y que, por esta razón, podrían haber distorsionado los planos factoriales del análisis.

Objetos ilustrativos




Figure: Países con una sola universidad como objetos ilustrativos

Variables suplementarias o ilustrativas

Son variables que han sido observadas en los mismos objetos del análisis original, pero posiblemente con otros objetivos. Éstas naturalmente no hacen parte de la construcción de las componentes, pero pueden ilustrar, complementar y enriquecer el análisis.

También pueden utilizarse para la validación de índices o indicadores contruidos con criterios externos, como en el caso que se presenta en el ejemplo ??.

Ejemplo: Validación de indicadores como variables ilustrativas

(Variables suplementarias) La mayoría de los rankings de universidades se construyen a partir de unos criterios predefinidos por la entidad que los produce, criterios a los cuales **se asignan ponderaciones justificadas conceptualmente**, con la intención de que tanto los criterios como los rankings asignados a las universidades sean **comparables**.

Para validar dichas ponderaciones suelen utilizarse criterios estadísticos basados por ejemplo en el ACP como se ilustra en este ejemplo.

Se realiza un ACP a los criterios con los que se construye el ARWU y se proyectan como variables suplementarias los rankings nacional, regional y mundial, así como el puntaje total (Total Score) que da origen al ranking de las universidades.

Table: Correlaciones, contribuciones y cosenos cuadrados

	Coord		Contr		Cos2	
	Factor 1	Factor 2	Factor 1	Factor 2	Factor 1	Factor 2
Alumni	0.81	-0.29	16.75	7.48	0.65	0.09
Award	0.84	-0.40	18.18	14.03	0.70	0.16
HiCi	0.84	0.37	18.40	11.62	0.71	0.13
N.S	0.92	0.21	21.93	3.70	0.85	0.04
PUB	0.58	0.73	8.62	46.37	0.33	0.54
PCP	0.79	-0.44	16.12	16.80	0.62	0.19




Figura: Indicadores del APWU sobre el plano 1-2

Objetos ilustrativos

Table: Negativos de los puestos de las universidades colombianas que quedaron entre los primeros 149 puestos del ranking QS

	SC.Reord	Qs.Reord	Web.Reord	Estatus
LOS ANDES	-3	-1	-3	Pri
NACIONAL	-1	-2	-1	Pub
ANTIOQUIA	-2	-3	-2	Pub
JAVERIANA	-5	-4	-4	Pri
ROSARIO	-7	-5	-7	Pri
DEL VALLE	-4	-6	-5	Pub
LA SABANA	-10	-7	-10	Pri
UIS	-6	-8	-6	Pub
DEL NORTE	-14	-9	-11	Pri
EAFIT	-9	-10	-8	Pri
PT BOLIVARIA	-8	-11	-9	Pri
EXTERNADO	-13	-12	-14	Pri
TADEO	-11	-13	-12	Pri
LA SALLE	-12	-14	-13	Pri

Objetos ilustrativos




Figure: Universidades privadas proyectadas como ilustrativas sobre el plano 1-2,

Construcción y obtención de las componentes. Método de multiplicadores de Lagrange:

Para una matriz simétrica B , consiste en buscar inicialmente un valor λ_1 y un vector u_1 que maximice una forma cuadrática $u_1' Bu_1$ sujeto a la restricción $\lambda_1 u_1' u_1$:

$$\mathcal{L} = u_1' Bu_1 - \lambda_1 u_1' u_1 = u_1' (Bu_1 - \lambda_1 u_1) = 0 \quad (25)$$

la cual permite encontrar un vector $u_1 \neq 0$ normado $u_1' u_1 = 1$. Si $u_1 \neq 0$ entonces (25) se cumple cuando $Bu_1 - \lambda_1 u_1 = 0$ y por tanto cuando:

$$Bu_1 = \lambda_1 u_1 \quad (26)$$

expresión que coincide con la definición de λ_1 y u_1 como valor y vector propio de B respectivamente.

Método de multiplicadores de Lagrange:

Procediendo iterativamente se puede encontrar el segundo vector u_2 ortogonal a u_1 ($u_2' u_1 = 0$) que maximiza $u_2' B u_2$ sujeto a las restricciones $u_2' u_1 = 0$ y $u_2' u_2 = 1$, cuya solución u_2 es aquel vector propio B que corresponde a su segundo mayor valor propio de B que satisface

$$\lambda_1 \geq \lambda_2.$$

y por tanto

$$B u_2 = u_2 \lambda_2$$

Este proceso se puede continuar hasta encontrar $u_1, \dots, u_p$ vectores propios de B unitarios y ortogonales con sus correspondientes valores propios no nulos con la propiedad:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

Cálculo de los valores y vectores propios de la matriz de correlación

Reemplazando B en (26) por la matriz de correlación $\mathcal{R}$ se obtiene en general para el α -ésimo vector y valor propio (eigenvalue):

$$Ru_{\alpha} = \lambda_{\alpha}u_{\alpha}, \quad \alpha = 1, \dots, p$$

Cálculo de las componentes

Se define la α -ésima componente principal como la proyección de la matriz de datos estandarizados $\tilde{X}$ sobre el α -ésimo vector propio

$$\dot{Z}_\alpha = \tilde{X}' u_\alpha \quad (27)$$

La cual tiene varianza

$$V(\dot{Z}_\alpha) = \lambda_\alpha$$

y se puede demostrar que la

$$\text{Varianza total} = \sum_{j=1}^p s_j^2 = \sum_{\alpha=1}^p \lambda_\alpha$$

LABORATORIO

El archivo ciudades_completo_ago_2023 tiene las siguientes variables:

Table: Variables del archivo ciudades completo

nom1	nom2
CIUDADES	Basura.desechos.Ton
Region	PIB.per.capita
Poblacion	NBI
Analfabetismo	LinTelx10milH
Cobertura.pria.y.secdaria	EElec10milH
Cobertura.ed.sup	Acuex10milH
Rel.al.prof	Alcantx10milH
N.Gr.Inv..Colcienciasx10milH	GasNatx10milH
No.CeNTROS.Inv10milH	Camasx10milH
No.Prf..Doctoradox10milH	HospClinx10milH
Delitos.M.aMB.y.REC.nat	ClientesInternx10milH
Consum.agua.M3	ProveedInternx10milH

LAB

La función PCA del paquete FactoMineR produce entre otros los siguientes resultados:

LAB continuación

Utilizar la funcion PCA para contestar las siguientes preguntas:

- 1 Realizar un ACP para la tabla de ciudades con las siguientes variables:
LinTelx10milH, , EElecx10milH, , Acuex10milH, , Alcantx10milH,
GasNatx10milH, Camasx10milH, HospClinx10milH,
ClientesInternx10milH, ProveedInternx10milH .
- 2 Incluir la variable **Poblacion** en el análisis y repetir los ejercicios (??) a (??) indicando en cada caso si hubo cambios con la inclusión de la nueva variable.
- 3 Incluir como ilustrativas las variables Poblacion, Analfabetismo, Cobertura.pria.y.secdaria, Cobertura.ed.sup, Rel.al.prof, y repetir los ejercicios (??) a (??) (Sugerencia: para incluir las ilustrativas usar el comando **quanti.sup** = de la función PCA)