

Análisis de Correspondencias Múltiples (ACM) Introducción

Jimmy A Corzo S^{1 2}

¹Profesor Titular
Departamento de Estadística

²Facultad de ciencias
Universidad Nacional de colombia

Métodos multivariados aplicados LyX cap 3

- 1 Descripción del método
- 2 Obtención de las componentes
- 3 Varianza (inercia) de opciones de respuesta y de las preguntas
- 4 Guías para la interpretación del ACM

Introducción

El ACM es una generalización natural del ACS a más de dos variables cualitativas. El método se realiza sobre una **Tabla de Tablas de contingencia** llamada también tabla de Burt, que es una tabla formada por bloques, cada uno de los cuales es una tabla de frecuencias entre un par de variables¹.

¹La equivalencia entre un ACM entre dos preguntas y un ACS se puede consultar en Lebart et al. (1984), secc IV.2, pág 84.

Introducción

El contexto a que se refiere el ACM asume que n individuos contestan un instrumento de Q preguntas, cada una de las cuales tiene p_q opciones o modalidades de respuesta. Las respuestas para la pregunta q se encuentran almacenadas en una matriz disyuntiva Z_q de dimensiones $n \times p_q$ cuyos elementos son:

$$Z_q = \{z_{q(ik)}\}, i = 1, \dots, n, \quad k = 1, \dots, p_q \quad q = 1, \dots, Q,$$

donde

$$z_{q(ik)} = \begin{cases} 1 & \text{si el } i\text{-ésimo individuo seleccionó la opción } k \text{ de la pregunta } q \\ 0 & \text{si no} \end{cases}$$

Ejemplo

Por ejemplo, si la pregunta q con $p_q = 3$ opciones de respuesta ($o1, o2$ y $o3$), la tabla disyuntiva z_q tiene la forma:

ind	$p_q o1$	$p_q o2$	$p_q o3$	$Suma$
1	1	0	0	1
2	0	0	1	1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
j	1	0	0	1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	0	1	0	1

Descripción y tabla de datos

Sea $p = \sum_{q=1}^Q p_q$ el número total de modalidades de respuesta en todo el instrumento. Ahora se arreglan las respuestas a todas las preguntas de la encuesta en una **matriz disyuntiva completa** de dimensiones $n \times p$:

$$Z = [Z_1, Z_2, \dots, Z_Q]$$

La estructura de la tabla correspondiente a la matriz disyuntiva completa Z con los totales por fila que producen el número de preguntas y por columna que producen el número de individuos que contestaron cada opción de respuesta es la siguiente:

i	$p_1 o1$	$p_1 o2$	$p_1 o3$	$p_2 o1$	$p_2 o2$	$\dots$	$p_q o1$	$p_q o2$	$p_q o3$	$z_i.$
1	1	0	0	1	0	$\dots$	1	0	0	Q
2	0	0	1	0	1	$\dots$	1	0	0	Q
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
n	0	1	0	1	0	$\dots$	0	1	0	Q
	$z_{1(\cdot 1)}$	$z_{1(\cdot 2)}$	$z_{1(\cdot 3)}$	$z_{2(\cdot 1)}$	$z_{2(\cdot 2)}$	$\dots$	$z_{q(\cdot 1)}$	$z_{q(\cdot 2)}$	$z_{q(\cdot 3)}$	nQ

Tabla disyuntiva completa

En la tabla disyuntiva completa se observa que

la suma por filas produce el # de preguntas: $z_{i.} = Q = \sum_{j=1}^p z_{ij}$

la suma por columnas produce el # de individuos que contestaron

la modalidad j de pregunta q : $z_{q(.j)} = \sum_{i=1}^n z_{q(ij)}$

Paso de tabla disyuntiva completa a tabla de códigos

Table: Paso de tabla disyuntiva completa a tabla en códigos

ind	Tabla disyuntiva completa										Tabla en códigos		
	o_1	o_2	o_3	o_4	p_1	p_2	p_3	p_4	p_5	p_6	p_1	p_2	p_3
1	1	0	0	0	1	0	1	0	0		1	1	1
2	0	1	0	0	0	1	0	0	1		2	2	3
3	0	0	1	0	0	1	0	1	0		3	2	2
4	0	0	0	1	1	0	0	1	0		4	1	2
5	0	0	1	0	1	0	1	0	0		3	1	1
6	0	1	0	0	0	1	0	0	1		2	2	3
7	1	0	0	0	0	1	0	1	0		1	2	2
8	1	0	0	0	1	0	1	0	0		1	1	1
9	0	0	1	0	0	1	0	1	0		3	2	2

Tabla de Burt

Esta tabla se obtiene con el producto de la matriz disyuntiva completa:

$$B = Z'Z = \begin{bmatrix} Z'_1Z_1 & Z'_1Z_2 & \cdots & Z'_1Z_Q \\ Z'_2Z_1 & Z'_2Z_2 & \cdots & Z'_2Z_Q \\ \vdots & \vdots & \vdots & \vdots \\ Z'_QZ_1 & Z'_QZ_2 & \cdots & Z'_QZ_Q \end{bmatrix} \quad (1)$$

Simetría de la tabla de Burt

Como se observa la tabla de Burt es una matriz simétrica **por bloques** tales que: en la diagonal están las tablas de contingencia de la pregunta q :

$$D_q = Z'_q Z_q = \begin{bmatrix} z_{q(\cdot 1)} & 0 & \dots & 0 \\ 0 & z_{q(\cdot 2)} & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & z_{q(\cdot p_q)} \end{bmatrix}, \quad q = 1, \dots, Q \quad (2)$$

mientras que por encima y debajo de la diagonal se encuentran las tablas de contingencia $Z'_q Z_{q'}$ entre las preguntas q y q' de dimensiones $p_q \times p_{q'}$ que tienen la siguiente estructura:

$$Z'_q Z_{q'} = \begin{bmatrix} z_{q(1,1)} & z_{q(2,1)} & \cdots & z_{q(n,1)} \\ z_{q(1,2)} & z_{q(2,2)} & \cdots & z_{q(n,2)} \\ \vdots & \vdots & \vdots & \vdots \\ z_{q(1,p_q)} & z_{q(2,p_q)} & \cdots & z_{q(n,p_q)} \end{bmatrix} \begin{bmatrix} z_{q'(1,1)} & z_{q'(1,2)} & \cdots & z_{q'(1,p_{q'})} \\ z_{q'(2,1)} & z_{q'(2,2)} & \cdots & z_{q'(2,p_{q'})} \\ \vdots & \vdots & \vdots & \vdots \\ z_{q'(n,1)} & z_{q'(n,2)} & \cdots & z_{q'(n,p_{q'})} \end{bmatrix} \quad (3)$$

cuyos elementos tienen la forma genérica:

$$\left\{ \sum_{i=1}^n z_{q(ij)} z_{q'(ik)} \right\}$$

Entonces, como $z_{q(ij)} z_{q'(ik)} = 1$ solamente cuando el individuo i contestó j de la pregunta q y k de la pregunta q' la suma produce el número de individuos que contestaron la opción j de la pregunta q y la opción k de la pregunta q'

Distancia entre modalidades de las preguntas

Modalidades j y j'

$$d(j, j') = \sum_{i=1}^n n \left(\frac{z_{ij}}{z_{.j}} - \frac{z_{ij'}}{z_{.j'}} \right)^2,$$

Entonces dos modalidades dos modalidades están cerca si fueron contestadas aproximadamente por los mismos individuos estarán muy cerca, y de lo contrario estarán lejos.

Distancia entre objetos

individuos i e i'

$$d(i, i') = \frac{1}{Q} \sum_{j=1}^P \frac{n}{z_{.j}} (z_{ij} - z_{i'j})^2.$$

Entonces dos individuos están cerca si contestaron aproximadamente las mismas modalidades y estarán lejos si no coinciden mucho en sus respuestas.

Obtención de las componentes

De manera similar al ACS, el análisis en el ACM se hace sobre las tablas de perfiles fila y columna pero de la matriz disyuntiva completa.

Por esta razón, dichos perfiles tienen que ser calculados tanto con respecto al número de preguntas Q como respecto a las frecuencias de respuesta de las preguntas.

Para el ACM se usan entonces los perfiles fila y columna de la tabla disyuntiva completa, se mantiene el criterio de distancia χ^2 y las interpretaciones son las mismas que las del ACS.

Para saber cómo están formadas las componentes y qué es lo que representan se muestra la matriz a la que se calculan los valores y vectores propios:

$$S = \frac{1}{Q} Z' Z D^{-1} = \frac{1}{Q} B D^{-1} \quad (4)$$

donde

$$D^{-1} = \begin{bmatrix} D_1^{-1} & 0 & \dots & 0 \\ 0 & D_2^{-1} & \dots & 0 \\ \vdots & & & \\ 0 & & \dots & D_Q^{-1} \end{bmatrix} \quad (5)$$

$$D_q^{-1} = (Z_q' Z_q)^{-1} = \begin{bmatrix} 1/z_{q(\cdot 1)} & 0 & \dots & 0 \\ 0 & 1/z_{q(\cdot 2)} & \dots & 0 \\ \vdots & & & \\ 0 & & \dots & 1/z_{q(\cdot p_q)} \end{bmatrix}, \quad q = 1, \dots, Q$$

(6)

Entonces como B es una matriz por bloques definidos en (1) a (3), los elementos de S tienen la forma:

$$s_{jk} = \frac{1}{Q} \sum_{i=1}^n \frac{z_{q(ij)} z_{q'(ik)}}{z_{q(.k)}}$$

donde cada sumando es la proporción de respuestas simultáneas a la opción j de la pregunta q y la opción k de la pregunta q' . Y al estar dividida por Q , la suma es la proporción de la proporción de respuestas simultáneas de las modalidades j y k con respecto al total de preguntas.

Varianza o Inercia

En el contexto del ACS y ACM suele asociarse la varianza de las opciones de respuesta con el concepto físico de **inercia**, debido a que una mayor varianza implica un grado de dispersión grande de los datos, idea que se puede asociar con la inercia debido a que una varianza grande implica un mayor radio de acción o de influencia tiene la modalidad o la pregunta (ver por ejemplo Lebart et al. (2006)):

Inercia

- La varianza (inercia) de una modalidad se define por:

$$I(j) = \frac{1}{Q} \left(1 - \frac{z_j}{n} \right) \quad (7)$$

Aumenta cuando pocos individuos la contesten (z_j pequeño). Disminuye con el número de preguntas Q .

- La varianza (inercia) de una pregunta completa es el acumulado de las varianzas de las modalidades:

$$I(q) = \sum_{j=1}^{pq} I(j) = \frac{1}{Q} \sum_{j=1}^{pq} \left(1 - \frac{z_j}{n} \right) = \frac{1}{Q} (pq - 1).$$

Solo depende del # de modalidades y # de respuestas, se puede fijar independiente de las proporciones de respuesta. **no es de interés estadístico**. Ventaja: se puedan diseñar instrumentos con varianza conocida de antemano.

- La varianza (inercia) total definida como la suma de las varianzas de las preguntas:

$$IT = \sum_q I(q) = \frac{p}{Q} - 1$$

es función del # de modalidades y # de preguntas y **no de la relación entre ellas**, razón por la que **tampoco es de interés estadístico**.

Inercia

La conclusión es que la única varianza (inercia) que tiene interés real para la interpretación es la de las modalidades, porque depende del número o proporción de respuestas que tuvo en la encuesta.:

$$I(j) = \frac{1}{Q} \left(1 - \frac{z_{.j}}{n} \right)$$

Guías para la interpretación

- Todas las reglas de interpretación del ACS en cuanto a las coordenadas, las contribuciones y los cosenos cuadrados son aplicables directamente al ACM.
- La proximidad entre individuos indica semejanzas entre ellos en el sentido de que éstos seleccionaron aproximadamente las mismas opciones de respuesta.
- La proximidad entre opciones de respuesta de preguntas diferentes indica asociación entre éstas debido a que son los puntos medios de los individuos que las seleccionaron. Además, por estar próximas también indican que fueron seleccionadas aproximadamente por los mismos individuos, lo cual indica que éstos tienen opiniones parecidas.
- La proximidad entre opciones de respuesta de una misma pregunta también indican semejanzas entre los individuos que las contestaron, debido a que por ser de la misma pregunta son excluyentes y por tanto estar próximas indica que los grupos de individuos que las seleccionaron son parecidos.

Ejemplo

La ECC incluye entre sus preguntas una referida si se justifica o no desobedecer la ley en ciertas circunstancias La pregunta consta de 11 enunciados (items) a los cuales el encuestado debe contestar si o no según opine si justifica o no desobedecer la ley por la razón mencionada. Se incluyó también la ciudad y el nivel educativo como variables suplementarias.

Ejemplo

20. Dígame si en su opinión se justifica o no desobedecer la ley:

- a. Cuando es la única manera de alcanzar sus objetivos
- b. Cuando es la única manera de ayudarle a la familia
- c. Cuando es la única manera de luchar públicamente contra una ley o un régimen injusto
- d. Cuando es muy provechoso económicamente
- e. Cuando la creencia religiosa lo permite

Si	No
☐	☐
☐	☐
☐	☐
☐	☐
☐	☐
☐	☐

- f. Cuando se hace para responder a una ofensa al honor
- g. Cuando es bastante seguro que uno no será castigado
- h. Cuando alguien lo ha hecho le ha ido bien
- i. Cuando es lo acostumbrado
- j. Para pagar un favor
- k. Para defender propiedades o bienes

Si	No
☐	☐
☐	☐
☐	☐
☐	☐
☐	☐
☐	☐

En la tabla de valores propios 2 visualizada en la gráfica, se observa que el primer valor propio es casi 3.5 veces el segundo, mientras que segundo es un poco más de 1.3 veces el tercero. De ahí en adelante, las variaciones son más pequeñas y por tanto resulta difícil escoger el número de componentes a interpretar. Por esta razón para este ejemplo se escogen para el análisis las primeras cuatro componentes que acumulan casi el 63.5% de la varianza.

```

> require(FactoMineR)
> # mcap20<-MCA(CCLatin[,c(4,8,64:74)], quali.sup = c(1,2))
> cclp20 = CCLatin[,c(4,8,64:74)]
> cclp20$P20_a[cclp20$P20_a == "p20a_RDL_AO=1_si"] = "Si alcazar objet
> cclp20$P20_b[cclp20$P20_b == "p20b_RDL_AF=1_si"] = "Si ayudar famili
> cclp20$P20_c[cclp20$P20_c == "p20c_RDL_RI=1_si"] = "Si lucha ley reg
> cclp20$P20_d[cclp20$P20_d == "p20d_RDL_PE=1_si"] = "Si por provecho
> cclp20$P20_e[cclp20$P20_e == "p20e_RDL_CR=1_si"] = "Si creencia reli
> cclp20$P20_f[cclp20$P20_f == "p20f_RDL_OH=1_si"] = "Si resp. Ofensa
> cclp20$P20_g[cclp20$P20_g == "p20g_RDL_NC=1_si"] = "Si no hay castig
> cclp20$P20_h[cclp20$P20_h == "p20h_RDL_IB=1_si"] = "Si alg ha hecho
> cclp20$P20_i[cclp20$P20_i == "p20i_RDL_LA=1_si"] = "Si es lo acostum
> cclp20$P20_j[cclp20$P20_j == "p20j_RDL_PF=1_si"] = "Si pagar favor"
> cclp20$P20_k[cclp20$P20_k == "p20k_RDL_DPB=1_si"] = "Si defender pro
> mcap20<-MCA(cclp20, quali.sup = c(1,2))


```

```
> vp<-xtable(mcap20$eig, caption = "Valores propios", label =
> print(vp)
```

	eigenvalue	percentage of variance	cumulative percentage of variance
dim 1	0.38	37.69	37.6
dim 2	0.11	10.81	48.5
dim 3	0.08	8.04	56.5
dim 4	0.07	7.04	63.5
dim 5	0.06	6.33	69.9
dim 6	0.06	5.88	75.7
dim 7	0.05	5.46	81.2
dim 8	0.05	5.16	86.4
dim 9	0.05	4.77	91.1
dim 10	0.05	4.74	95.9
dim 11	0.04	4.07	100.0

Table: Valores propios

Gráfico de saturación de los valores propios



R Code

	Co0 F1	Co0 F2	Co0 F3	Con F1	Con F2	Con F3	Cos F1	Cos F2	Cos F3
Si no hay castigo	1.58	0.39	0.18	9.49	2.01	0.56	0.47	0.03	0.01
Si por provecho económico	1.60	0.19	0.64	9.29	0.47	7.01	0.45	0.01	0.07
Si es lo acostumbrado	1.82	1.09	-0.33	9.29	11.62	1.45	0.44	0.16	0.01
Si alg ha hecho y ha ido bien	1.86	1.17	0.34	8.37	11.64	1.32	0.39	0.15	0.01
Si pagar favor	1.71	1.10	-0.97	8.02	11.58	12.08	0.37	0.16	0.12
Si creencia religiosa	1.57	0.20	1.21	7.36	0.43	20.43	0.35	0.01	0.21
Si resp. Ofensa honor	1.09	-0.30	-0.08	6.96	1.88	0.16	0.38	0.03	0.00
Si alcanzar objetivos	1.11	-0.59	0.32	6.86	6.81	2.64	0.37	0.11	0.03
Si defender prop o bienes	0.73	-0.21	-0.82	4.76	1.39	27.69	0.31	0.03	0.39
Si lucha ley reg injusto	0.72	-0.63	0.15	4.67	12.52	0.93	0.31	0.24	0.01
Si ayudar familia	0.62	-0.60	-0.16	4.14	13.29	1.25	0.31	0.28	0.02
p20b_RDL_AF=2_no	-0.50	0.48	0.13	3.30	10.60	1.00	0.31	0.28	0.02
p20c_RDL_RI=2_no	-0.43	0.38	-0.09	2.78	7.47	0.56	0.31	0.24	0.01
p20k_RDL_DPB=2_no	-0.42	0.12	0.47	2.74	0.80	15.95	0.31	0.03	0.39
p20f_RDL_OH=2_no	-0.35	0.10	0.02	2.21	0.60	0.05	0.38	0.03	0.00
p20a_RDL_AO=2_no	-0.34	0.18	-0.10	2.08	2.07	0.80	0.37	0.11	0.03
p20g_RDL_NC=2_no	-0.30	-0.07	-0.03	1.79	0.38	0.11	0.47	0.03	0.01
p20d_RDL_PE=2_no	-0.28	-0.03	-0.11	1.65	0.08	1.25	0.45	0.01	0.07
p20i_RDL_LA=2_no	-0.24	-0.14	0.04	1.23	1.53	0.19	0.44	0.16	0.01
p20e_RDL_CR=2_no	-0.22	-0.03	-0.17	1.04	0.06	2.90	0.35	0.01	0.21
p20j_RDL_PF=2_no	-0.22	-0.14	0.12	1.02	1.48	1.54	0.37	0.16	0.12
p20h_RDL_IB=2_no	-0.21	-0.13	-0.04	0.94	1.30	0.15	0.39	0.15	0.01

Table: Indicadores para análisis ordenados por contribución al F 1



Interpretación del Factor 1

En primer lugar se observa que que todas las respuestas “Sí” tienen coordenadas positivas sobre el primer factor, mientras que las respuestas “No” las tienen negativas.

Las mayores contribuciones y las que están mejor representadas son las respuestas “Si no hay castigo” y “Si por provecho económico”, aunque no son las que tienen las mayores coordenadas sobre dicho factor.

Las segundas mayores contribuciones y también las segundas mejor representadas son las respuestas “Si es lo acostumbrado”, “Si alg ha hecho y ha ido bien” y “Si pagar favor”. Éstas tres respuestas tienen mayores contribuciones al factor 2, pero están muy mal representadas sobre él. Por tanto se consideran más como parte del factor 1 que del factor 2.


Interpretación del Factor 2


Las mayores contribuciones son de las respuestas “Si ayudar familia” y “Si lucha ley reg injusto ” y también son las mejor representadas. Las siguientes dos respuestas con altas contribuciones son “Si es lo acostumbrado”, “Si alg ha hecho y ha ido bien”, pero éstas están muy mal representadas sobre este factor y por eso se consideraron parte del factor 1.

Interpretación del Factor 3

En el factor 3 predominan las altas contribuciones de las respuestas “Si defender prop o bienes”, “Si creencia religiosa”, “No por defender prop o bienes” con coordenada negativa y “Si pagar favor”, de las cuales las tres primeras son las mejor representadas sobre dicho factor.

```
> plot.MCA(mcap20, axes = c(1,2),  
+          invisible = c("ind", "quali.sup"),  
+          cex=0.75, title = "Plano 1-2 con suplementari
```





Referencias bibliográficas

Lebart, L., Morineau, A. & Warwick, K. (1984), 'Multivariate descriptive statistical analysis', *New York ua* .

Lebart, L., Piron, M. & Morineau, A. (2006), *Statistique exploratoire multidimensionnelle: visualisation et inférences en fouilles de données*.