

Métodos de agrupamiento (AGRP)

Introducción

Jimmy A Corzo S^{1 2}

¹Profesor Titular
Departamento de Estadística

²Facultad de ciencias
Universidad Nacional de colombia

Métodos multivariados aplicados LyX cap 3

- 1 Métodos de agrupamiento
- 2 Agrupación por particiones
- 3 Agrupaciones jerárquicas
- 4 Agrupación jerárquica a partir componentes principales

Introducción

Los métodos de agrupamiento consisten en la búsqueda de subconjuntos o grupos de objetos similares, y tales que entre grupos haya las mayores diferencias posibles.

La idea principal es encontrar las características que hacen similares a los objetos y luego describir los grupos de acuerdo con esas características.

Los grupos deben ser disyuntos y la unión de todos debe producir el conjunto completo de datos utilizados, es decir los grupos deben ser particiones.

Segmentación

En mercadeo los métodos de agrupación suelen llamarse métodos de segmentación y se refieren principalmente a la búsqueda de grupos de clientes con hábitos de compra similares llamados segmentos de mercado.

Reconocimiento de patrones

Existen también métodos cercanos denominados “reconocimiento de patrones” para datos no estructurados, que consisten en identificar figuras, o reconocer formas, para obtener información con la que se puedan asignar a grupos.

Éstos métodos se pueden llevar a cabo de manera supervisada, no supervisada o parcialmente supervisada (Ver por ejemplo Liu et al. (2006)).

En el caso supervisado por ejemplo, cuando se trata de imágenes satelitales suelen utilizarse las redes neuronales convolucionales, o el Modelo de Regresión Tensorial Generalizada Liu et al. (2019).

Reconocimiento de audio, sonido, video

Existen también modelos más generales para cuando los datos de entrada son textos, audios, música, videos, etc, llamados Redes Neuronales Recurrentes como las utilizadas para reconocimiento de escritura para Android de Google, Comprensión de lenguaje (Microsoft) y decidir ciertas acciones, Análisis de sentimientos, Indexación de videos que transcribe a texto y traduce lo que se habla en un video, generación de música donde se incluyen algunas notas y el sistema produce la melodía, detección de modificaciones en secuencias del ADN.

Construcción de los grupos

Construcción de los grupos


Dos maneras de construir los grupos:

→ una en la que se fija de antemano los grupos por **particiones** y luego se asignan los objetos a los grupos de acuerdo con las características que hacen similares a los objetos

→ otra en la que los grupos se construyen por **jerarquías** ascendentes hasta reconstruir el conjunto completo, o descendentes que comienzan con todo el grupo y lo van subdividiendo hasta encontrar un número óptimo de grupos.

En el moderno contexto del aprendizaje estadístico se les conoce como métodos de aprendizaje no supervisado debido a que los grupos no se encuentran predefinidos sino que se construyen con los datos. En la gráfica 1 se ilustran estos dos métodos.

Particiones



Jerarquías




Figure: Particiones y Jerarquías

Construcción de los grupos

Agrupación por particiones (K-medias)

Particiones

Los datos para éste método son tablas con observaciones de variables de naturaleza continua o cuantitativas, y también se pueden utilizar las coordenadas obtenidas por un *ACP*, *ACS*, *ACM*.

Este método consiste en dividir el conjunto de objetos que se van a agrupar en un numero de grupos prefijado de manera que (Peña (2003)):

- Cada objeto pertenezca a uno y solo uno de los grupos.
- Todo objeto quede en algún grupo
- Cada grupo sea lo más homogéneo posible.
- Los grupos se distingan entre si lo máximo posible.

Algoritmo K medias

- * Seleccionar un numero prefijado K de puntos o centros iniciales y conformar el mismo número de grupos asignando los objetos al grupo más cercano,
- * Calcular los centros o promedios de cada grupo formado y luego reasignar los objetos a los nuevos grupos de acuerdo con su cercanía al centro de cada nuevo grupo, hasta que se establezca la asignación con respecto a algún criterio de homogeneidad (optimalidad). En forma de algoritmo el procedimiento es como sigue¹:

¹Adaptado de <https://www.thoughtco.com/k-means-clustering-1019648>

- 1 Seleccionar aleatoriamente (o con algún criterio apropiado) K puntos como centros de los grupos iniciales.
- 2 Utilizar algún criterio de distancia para asignar cada objeto al grupo cuyo centro se encuentre más cercano .
- 3 Recalcular los centros de los grupos como los promedios de los objetos del grupo.
- 4 Repetir los pasos (2) y (3) hasta que algún **criterio de optimalidad** (por ejemplo, mayor homogeneidad dentro de los grupos y mayor heterogeneidad entre grupos) indique que no es posible mejorar los grupos.
- 5 Si no es posible mejorar suficientemente el criterio de optimalidad, terminar el proceso.

Los pasos 2. y 3. garantizan que los centros se vayan desplazando en la dirección deseada para que los grupos sean cada vez más homogéneos.

Criterio de homogeneidad de Ward (optimalidad) para el algoritmo de K-medias

Consiste básicamente en minimizar la varianza dentro de los grupos y maximizar la varianza entre grupos.

Criterio de homogeneidad de Ward (optimalidad) para el algoritmo de K-medias

Se definen las sumas de cuadrados dentro de grupos (SCDG):

$$SCDG_j = \sum_{k=1}^K \sum_{i=1}^{n_K} (x_{ij,k} - \bar{x}_{j,k})^2 \quad (1)$$

El criterio de Ward o criterio de la traza, consiste en minimizar la SCDG:

$$\min \sum_{j=1}^p SCDG_j$$

Indicadores para calcular el numero de grupos para el k - means

Índice de Carlinski- Habasz

Carlinski- Habasz También llamado criterio de razón de varianzas ² que utiliza el índice:

$$CH_K = \frac{SCEG/(K-1)}{SCDG/(n-K)} = \frac{SCEG}{SCDG} \frac{n-K}{K-1}$$

donde

$$SCEG = \sum_{k=1}^K \sum_{j=1}^p n_k (\bar{x}_{jk} - \bar{x}_j)^2$$

el número óptimo de grupos se obtiene maximizando CH_K con respecto a K

²Se encuentra entre otros en el paquete **fpc** de R “Flexible Procedures of Clustering”.

Índice de Hartigan

El criterio de Hartigan incluye un nuevo grupo si:

$$Hrt = \frac{SCDG(k) - SCDG(k+1)}{SCDG(k+1)/(n-k+1)} > 10$$

donde como las sumas de cuadrados involucradas generalmente no satisfacen los supuestos requeridos para que el cociente tenga distribución F suele utilizarse el valor empírico 10 propuesto por Hartigan.

Algunas características del algoritmo K – means

El algoritmo de K -medias se conoce en el contexto del aprendizaje estadístico como un **algoritmo no supervisado** por utilizar solo características de la **estructura interna de los objetos a agrupar**, es decir por sus propiedades o características.

Ventaja: Muy **rápido y sencillo** de aplicar.

Ventaja: **Se puede optimizar** por la búsqueda de grupos estables, algoritmo que consiste en construir muchas Agrupaciones e identificar como grupos estables aquellos formados por objetos que quedan siempre en los mismos grupos. Este algoritmo se utiliza también posteriormente para agrupaciones mixtas.

Desventaja: El hecho de que los centros móviles para la primera etapa sean elegidos de manera arbitraria hace que las agrupaciones sean dependientes de éstos y a su vez hace **inestable** el método.

Desventaja: Como el número de grupos es prefijado, la agrupación puede conducir a **grupos difíciles de tipificar**, por ejemplo, si se va a agrupar un grupo de huesos de dos clases mamíferos como perros y lobos por la especie y se escoge $K > 2$ los resultados muy seguramente son inconsistentes.

Desventaja: No es robusto cuando hay observaciones atípicas

Ejemplo: Indicadores del Sistema Universitario Estatal (SUE)

Que contiene datos de alrededor de 32 indicadores de educación superior para las 32 universidades estatales entre 2003 y 2012

Ejemplo

Agrupación de universidades del Sistema Universitario Estatal (SUE)

Se utilizan seis de los 32 indicadores del SUE

- Docentes de tiempo completo o equivalente (DCTC2012)
- Gastos en personal administrativo (GPA2012)
- Matrícula de pregrado (MPRE2012)
- Matrícula de posgrado (MPOS2012)
- Graduados de pregrado (GrPre2012)
- Graduados de posgrado (GrPos2012).

Agrupación de universidades DEL Sistema Universitario Estatal (SUE)

Algunos indicadores del SUE

Table: Primeras seis filas de indicadores del SUE

Universidades	DCTC2012	GPA2012	MPRE2012	MPOS2012	GrPre2012	GrPos2012
NACIONAL	2161	347233353	42120	9299	4903	3181
PEDAG<d3>GICA	440	7986738	9321	1614	1186	362
UPTC	828	20641880	24644	2360	3190	1225
CAUCA	550	28539431	12859	700	1372	303
TEC DE PEREIRA	442	15343348	15423	1319	1532	299
CALDAS	418	12877924	12261	971	1953	266


Cálculo del indicador de Calinski-Harabasz para decidir el numero de grupos

Table: Valores del índice de Carlinski-Habasz

	2	3	4	5	6	7	8	9	10
res.sue\$All.index	371.8109	1098.372	1332.701	1304.734	1124.575	945.2354	790.8089	2852.949	3474.023

$$CH_K = \frac{SCEG / (K - 1)}{SCDG / (n - K)} = \frac{SCEG}{SCDG} \frac{(n - K)}{(K - 1)}$$

Cálculo del indicador de Calinski-Harabasz para decidir el numero de grupos



Grupos por el C-H

Table: Grupos sugeridos por el índice de CH

Universidad	grupo	Universidad	grupo
POPU DEL CESAR	1	CALDAS	6
PACIFICO	1	LLANOS	6
UFPS_OCA<d1>A	1	ATLANTICO	6
MAGDALENA	1	QUINDIO	6
SUCRE	1	CUNDINAMARCA	6
CAUCA	2	UPTC	7
TEC DE PEREIRA	3	TEC DEL CHOC<d3>	7
C<d3>RDOBA	3	TOLIMA	7
DISTRITAL	3	PEDAG<d3>GICA	8
UNAD	3	AMAZONIA	8
NACIONAL	4	MAY DE CNAMARCA	8
SURCOLOMBIANA	5	UFPS_CUCUTA	8
MILITAR	5	ANTIOQUIA	9
NARI<d1>O	5	VALLE	9
PAMPLONA	5	UUIS	10

Grados de homogeneidad de los grupos sugeridos por el C-H

Table: Desviación estándar de los grupos sugeridos por el índice de CH

	Group.1	DCTC2012	GPA2012	MPRE2012	MPOS2012	GrPre2012	GrPos2012
6	6	95.49	762449.8	5533.96	355.21	593.74	79.13
1	1	103.59	702042.7	7483.67	262.22	1154.06	146.90
8	8	112.98	809507.4	6956.78	634.31	700.24	82.46
5	5	116.16	758930.3	6270.40	1026.74	1942.13	466.52
10	10	139.30	3018201.1	772.87	712.76	1053.59	202.94
3	3	213.24	1143153.2	24048.97	618.54	915.35	297.47
7	7	318.68	1386434.1	13213.48	1158.55	1484.84	589.02
9	9	645.59	7383788.6	7455.03	338.00	161.22	10.61
2	2	NA	NA	NA	NA	NA	NA
4	4	NA	NA	NA	NA	NA	NA

A manera de conclusión, el hecho de que el índice de Carlinski - Habasz sugiera 10 grupos en un conjunto de 32 universidades, no parece muy eficiente.

No obstante, éste índice muestra un segundo valor alto (mínimo local) en 4 grupos como se observa en la Tabla tabla 2, lo cual podría sugerir solo 4 grupos, pero este agrupamiento no sería el sugerido estrictamente por el criterio CH_K .

Ejemplo: Construcción de grupos por el índice de Hartigan

En este ejemplo se muestra cómo pueden variar los agrupamientos dependiendo del índice que se utilice para seleccionar el número de grupos. Ahora se van a construir los grupos de universidades del SUE, pero utilizando el índice de Hartigan.

```
> res.sue.hart<-NbClust(xsue, distance = "euclidean"  
+                        min.nc = 2, max.nc = 10,  
+                        method = "kmeans", index = "hart"  
> # names(res.sue.hart) # contenido del archivo de  
>
```

Índice de Hartigan

Table: Valores del índice de Hartigan por número de grupos

2	3	4	5	6	7	8	9	10
141.9087	25.331	9.8347	3.1921	1.2675	0.4165	78.9124	9.93	0.7751

Table: Número de grupos sugerido por el índice de Hartigan paso de 2 a 3

Number_clusters	Value_Index
3	116.5777




Figure: Valores del índice de Hartigan

Miembros de los grupos sugeridos por el índice de Hartigan

Table: Grupos sugeridos por el índice de Hartigan

Universidades	Grupos	Universidades	Grupos
PEDAG<d3>GICA	1	TOLIMA	1
UPTC	1	QUINDIO	1
CAUCA	1	UFPS_CUCUTA	1
TEC DE PEREIRA	1	UFPS_OCA<d1>A	1
CALDAS	1	PAMPLONA	1
C<d3>RDOBA	1	MAGDALENA	1
SURCOLOMBIANA	1	CUNDINAMARCA	1
AMAZONIA	1	SUCRE	1
MILITAR	1	GUAJIRA	1
TEC DEL CHOC<d3>	1	DISTRITAL	1
LLANOS	1	UNAD	1
POPU DEL CESAR	1	NACIONAL	2
MAY DE CNAMARCA	1	ANTIOQUIA	3
PACIFICO	1	VALLE	3
ATLANTICO	1	UIS	3
NARI<d1>O	1	CARTAGENA	3

Promedios por grupos

Table: Promedios de las variables para los grupos sugeridos por el índice de Hartigan

Group.1	DCTC2012	GPA2012	MPRE2012	MPOS2012	GrPre2012	GrPos2012
1	352.41	11858166	15566.93	697.19	1679.33	282.22
2	2161.00	347233353	42120.00	9299.00	4903.00	3181.00
3	962.50	56712125	25433.50	2182.00	2652.00	635.50

Desviaciones estándar por grupos

Table: Desviaciones estándar de las variables para los grupos sugeridos por el índice de Hartigan

Group.1	DCTC2012	GPA2012	MPRE2012	MPOS2012	GrPre2012	GrPos2012
1	197.12	6329666	12664.44	742.21	1222.73	317.59
2	NA	NA	NA	NA	NA	NA
3	625.13	12111532	8249.98	1047.57	989.45	230.68

Ejemplo: Comparación de las clasificaciones sugeridas por los índices de Carlinski-Harabasz y Hartigan.

La otra clasificación sugerida por el índice de Hartigan, aunque no es la que este índice sugiere estrictamente por no ser el número de grupos donde aparece el primer máximo, es en 8 grupos y se muestran en la Tabla 11.

Table: Ocho grupos sugeridos por el máximo local del índice de Hartigan


Universidades	Grupos	Universidades	Grupos
POPU DEL CESAR	1	NARI<d1>O	5
PACIFICO	1	PAMPLONA	5
UFPS_OCA<d1>A	1	GUAJIRA	5
MAGDALENA	1	CALDAS	6
SUCRE	1	LLANOS	6
ANTIOQUIA	2	ATLANTICO	6
VALLE	2	QUINDIO	6
UIS	2	CUNDINAMARCA	6
CARTAGENA	2	UPTC	7
TEC DE PEREIRA	3	CAUCA	7
C<d3>RDOBA	3	TEC DEL CHOC<d3>	7
DISTRITAL	3	TOLIMA	7
UNAD	3	PEDAG<d3>GICA	8
NACIONAL	4	AMAZONIA	8
SURCOLOMBIANA	5	MAY DE CNAMARCA	8
MILITAR	5	UFPS_CUCUTA	8

Table: Comparación de grupos sugridos por CH y Hartigan

	Universidad_1	Grupos C-H_1	Grupos Hrti_1	Universidad_2	Grupos C-H_2	Grupos Hrti_2
12	MAGDALENA	1	1	ATLANTICO	6	6
17	PACIFICO	1	1	CALDAS	6	6
20	POPU DEL CESAR	1	1	CUNDINAMARCA	6	6
22	SUCRE	1	1	LLANOS	6	6
28	UFPS_OCANA	1	1	QUINDIO	6	6
6	CAUCA	2	7	TEC DEL CHOCO	7	7
7	CORDOBA	3	3	TOLIMA	7	7
9	DISTRITAL	3	3	UPTC	7	7
24	TEC DE PEREIRA	3	3	AMAZONIA	8	8
30	UNAD	3	3	MAY DE CNAMARCA	8	8
15	NACIONAL	4	4	PEDAGOGICA	8	8
10	GUAJIRA	5	5	UFPS_CUCUTA	8	8
14	MILITAR	5	5	ANTIOQUIA	9	2
16	NARINO	5	5	VALLE	9	2
18	PAMPLONA	5	5	CARTAGENA	10	2
23	SURCOLOMBIANA	5	5	UIS	10	2


Agrupaciones jerárquicas

Categorías taxonómicas principales definidas en el Sistema de Información de la Naturaleza: Reino, Filo, Clase, Orden, Familia, Género, Especie.



Agrupaciones jerárquicas

Consiste construir grupos por aglomeración (ascendente) o por división (descendente) hasta conseguir grupos de objetos tan similares como sea posible dentro de los grupos.



Divisiones

División descendente del total a subgrupos hacia los objetos

División ascender de los objetos al total

Algoritmo para el método de aglomeración ascendente

- 1 Comenzar con tantos grupos como objetos, $G = n$, de manera que las distancias entre grupos en este paso son las distancias entre los objetos originales.
- 2 Identificar los dos objetos cercanos y formar con ellos un grupo.
- 3 Representar el nuevo grupo construido en (2) por un nuevo objeto, por ejemplo por el promedio del grupo y buscar nuevamente el objeto cercano a éste para construir un nuevo grupo.
- 4 Repetir (2) y (3) hasta que todos los objetos queden agrupados en un único grupo.

Criterios para definir distancias entre grupos:

A y B grupos con n_a y n_b objetos, (AB) fusión de A y B con $n_a + n_b$ objetos. Entonces la distancia del nuevo grupo (AB) , a otro grupo C con n_c objetos se define por alguno de los siguientes criterios:

Vecino cercano:

$$d(C;AB) = \min(d_{CA}, d_{CB})$$

Vecino lejano:

$$d(C;AB) = \max(d_{CA}, d_{CB})$$

Media de grupos:

$$d(C;AB) = \frac{n_a}{n_a + n_b} d_{CA} + \frac{n_b}{n_a + n_b} d_{CB}$$

Método del centroide:

$$d^2(C;AB) = \frac{n_a}{n_a + n_b} d_{CA}^2 + \frac{n_b}{n_a + n_b} d_{CB}^2 - \frac{n_a n_b}{(n_a + n_b)^2} d_{AB}^2$$

Método de Ward:

Sumas de cuadrados dentro de grupos (SCDG):

$$W = \sum_{k=1}^K \sum_{i=1}^{n_K} (x_{ij,k} - \bar{x}_{j,k})^2 \quad (2)$$

- 1 Suponer que cada objeto forma un grupo de manera que $K = n$ y por tanto $W = 0$.
- 2 Unir los objetos que tengan la menor distancia euclídea entre ellos de manera que la unión aumente lo mínimo posible el valor de W . Entonces quedan $n - 1$ grupos de un objeto y un grupo de dos objetos.
- 3 Calcular W para la nueva agrupación y unir los grupos que tengan la menor distancia euclídea entre ellos de manera que la unión aumente lo mínimo posible el valor de W .
- 4 Repetir el paso (3) hasta que se obtenga un solo grupo.

El algoritmo para construir los grupos con el método de Ward se puede representar gráficamente en un **Dendrograma** de la siguiente manera:

- 1 Ubicar los objetos iniciales en la parte inferior del gráfico.
- 2 Trazar líneas verticales entre objetos con alturas **proporcionales a las distancias** entre éstos y líneas horizontales que indiquen las uniones entre ellos.
- 3 Repetir (1) y (2) hasta que todos los objetos estén conectados.

Ejemplo

En este ejemplo se utiliza nuevamente el archivo de indicadores del SUE del ejemplo ?? para construir una agrupación jerárquica de universidades por aglomeración con el método de ward y se compara con las dos obtenidas por el método K-means.

Métodos de agrupamiento

Agrupación por particiones

Agrupaciones jerárquicas


Agrupación jerárquica a partir componentes principales

References

Agrupamiento en tres clases



Agrupamiento en cuatro clases



Promedios de los grupos

Table: Medias

	Group.1	DCTC2012	GPA2012	MPRE2012	MPOS2012	GrPre2012	GrPos2012
2	2	241.8333	6569468	10785.50	384.5833	1496.083	175.6667
3	3	440.8667	16089124	19392.07	947.2667	1825.933	367.4667
4	4	962.5000	56712125	25433.50	2182.0000	2652.000	635.5000
1	1	2161.0000	347233353	42120.00	9299.0000	4903.000	3181.0000

Agrupaciones mixtas

Utilización de una mezcla iterativa del método K -medias y el método de Agrupación jerárquica.

Algoritmo

- Hacer una partición inicial alrededor de centros móviles (k-means) para obtener unos cuantos grupos o incluso decenas de grupos homogéneos
- Hacer una partición jerárquica de estos grupos
- Utilizar el Dendrograma para escoger la partición (o particiones) a realizar
- Utilizar nuevamente los centros móviles para optimizar la partición escogida utilizando los grupos estables contruidos a partir del k-means.

También se puede aplicar sobre los factores obtenidos por medio de ACP , ACS o ACM para producir agrupaciones más

Ejemplo ARWU por países

Indicadores:

Alumni: Número de egresados han recibido premios Nobel o medallas Field (Alumni y Award respectivamente),

Award: Número de docentes o investigadores (D-I) activos que han recibido premios Nobel o medallas Field

HiCi: número de investigadores altamente citados seleccionados por el Thomson Reuters (),

N.S: número de artículos publicados en las revistas Nature y Science (),

PUB: número de artículos citados en el Science Citation Index () y

PCP: rendimiento (producción de artículos por D-I) per cápita de una universidad ().

El ranking agrupar alrededor de 1200 universidades de todo el mundo y publica los resultados de las primeras 500 anualmente desde 2003. Para este ejemplo se calcularon los promedios de los


[1]	"Institution"	"Region"	"Country"	"Regional"
[5]	"World.Rank"	"National.Rank"	"Alumni"	"Award"
[9]	"HiCi"	"N.S"	"PUB"	"PCP"
[13]	"Total.Score"			

Promedios por país


Table: Promedio de indicadores del ARWU por país

	Alumni	Award	HiCi	N.S	PUB	PCP
AS	17.30	8.90	26.40	21.63	56.10	27.73
BE	7.50	15.40	17.60	15.10	54.40	30.40
CA	21.68	14.25	31.50	26.70	63.23	24.92
DE	19.60	21.50	16.60	24.75	52.40	28.85
FI	16.00	17.80	22.80	20.60	52.70	28.20
FR	39.10	31.30	16.63	22.77	45.90	34.07
GE	27.48	22.62	17.48	21.86	46.96	27.42
IR	31.50	19.90	24.90	20.80	41.60	26.50
JP	23.62	12.58	28.94	32.20	63.32	29.36
NL	23.70	18.15	27.90	25.15	48.00	29.25
NW	22.00	33.30	17.60	13.50	46.60	24.30
RU	46.80	34.10	0.00	9.60	52.40	31.20
SE	24.37	29.60	20.63	20.27	45.63	29.63
SW	22.27	26.60	28.50	30.57	46.80	36.20
UK	28.66	30.97	33.10	31.56	55.47	29.10

Hierarchical Clustering



Hierarchical Classification



inertia g

Indicadores para la descripción de los grupos

- **Mean in category:** Media de la variable en el grupo
- **Overall mean:** Promedio general de la variable
- **v.test:** Indicador de la diferencia entre la media del grupo y la media general. Entre mayor sea su valor mayor será la distancia entre la media del grupo y la media de todas las universidades.
- **sd in category:** Desviación estándar de la variable en el grupo
- **Overall sd:** Desviación estándar general
- **p.value:** Valor con el que se rechazaría la hipótesis de igualdad de media del grupo y media general.

Valor test y valor p

Éstas tablas también incluyen el valor test para la prueba de la hipótesis de que la media de la clase k (μ_k) es igual a la media general (μ) ($H_o : \mu_k = \mu$), el cual para la clase k y la variable X_j se define por:

$$v.test = t_k = \frac{\bar{x}_{j,k} - \bar{x}}{s_{j,k}}$$

donde $\bar{x}_{j,k}$ es la media de X_j en la clase k , $\bar{x}$ es la media general de todo el conjunto de datos y

$$s_{j,k} = \frac{n - n_k}{n - 1} s^2(x_j)$$

La última columna de las tablas muestra el valor p con el que se rechaza $H_o : \mu_k = \mu$

Métodos de agrupamiento

Agrupación por particiones

Agrupaciones jerárquicas

Agrupación jerárquica a partir componentes principales

References

Grupo1

Table: Indicadores para descripción del Grupo 1

	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
Alumni	2.49	46.8	24.83	0	8.81	0.01
Award	1.44	34.1	22.91	0	7.77	0.15
N.S	-1.96	9.6	23.40	0	7.04	0.05
HiCi	-2.47	0.0	23.44	0	9.49	0.01

Grupo2

Table: Indicadores para descripción del Grupo 2

	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
Award	1.49	27.34	22.91	5.18	7.77	0.14
PUB	-2.74	45.34	51.68	1.93	6.04	0.01

Grupo2

Table: Indicadores para descripción del Grupo 3


	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
PUB	2.29	55.74	51.68	5.29	6.04	0.02
Alumni	-2.46	18.49	24.83	5.25	8.81	0.01
Award	-3.25	15.51	22.91	3.82	7.77	0.00

Grupo2

Table: Indicadores para descripción del Grupo 4

	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
N.S	2.58	33.17	23.40	3.00	7.04	0.01
HiCi	2.33	35.34	23.44	6.69	9.49	0.02
PCP	1.77	32.03	29.25	3.03	2.92	0.08
Award	1.47	29.06	22.91	1.83	7.77	0.14

Cluster plot



Agrupación jerárquica a partir de componentes principales

Algoritmo

- Realizar un método factorial a los datos originales con lo cual se reduce la dimensionalidad y se identifican los factores que se utilizarán para el agrupamiento.
- Seleccionar $q \leq p$ factores para usarlos como información de arranque para la agrupación
- Tipificar las grupos comparando las estadísticas básicas de las variables originales por grupos con las mismas estadísticas pero calculadas para el conjunto completo de datos.
- Posicionar las grupos en los planos factoriales.

Ejemplo Arwu 2

Agrupamiento de países por puntajes promedio de los indicadores del ARWU a partir de un ACP.

ARWU

Table: Valores propios y varianzas del ACP de indicadores del SUE

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.57	42.75	42.75
comp 2	1.60	26.66	69.41
comp 3	0.73	12.19	81.60
comp 4	0.71	11.82	93.42
comp 5	0.33	5.49	98.91
comp 6	0.07	1.09	100.00

Ejemplo Arwu 2

Agrupamiento de países por puntajes promedio de los indicadores del ARWU a partir de un ACP.

ARWU

Table: Coordenadas sobre los primeros cuatro factores del ACP de indicadores del SUE

	Dim.1	Dim.2	Dim.3	Dim.4
HiCi	0.7940681	0.4657882	0.0767951	-0.3426638
PUB	0.6861647	-0.0943919	0.3739958	0.5774505
N.S	0.6773997	0.7013240	0.0762402	-0.0739793
PCP	-0.2382619	0.6933177	-0.5263108	0.4275308
Alumni	-0.6725637	0.4023454	0.5033715	0.1706912
Armed	0.7041007	0.4001000	0.0010005	0.0005000

Ejemplo Arwu 2

Agrupamiento de países por puntajes promedio de los indicadores del ARWU a partir de un ACP.

ARWU

Table: Contribuciones a la varianza de los primeros cuatro factores del ACP de indicadores del SUE

	Dim.1	Dim.2	Dim.3	Dim.4
HiCi	24.581571	13.5639819	0.8066381	16.5540208
Award	19.327132	14.9560637	6.7226040	5.7868555
PUB	18.354852	0.5570311	19.1313383	47.0106674
N.S	17.888922	30.7501777	0.7950239	0.7715921
Alumni	17.634412	10.1206471	34.6568522	4.1076114
BCP	0.010111	00.0500005	07.0075105	05.7000500

Ejemplo Arwu 2

Agrupamiento de países por puntajes promedio de los indicadores del ARWU a partir de un ACP.

ARWU

Table: Cosenos cuadrados sobre los primeros cuatro factores del ACP de indicadores del SUE

	Dim.1	Dim.2	Dim.3	Dim.4
HiCi	0.6305441	0.2169586	0.0058975	0.1174185
Award	0.4957620	0.2392253	0.0491502	0.0410465
PUB	0.4708220	0.0089098	0.1398729	0.3334490
N.S	0.4588704	0.4918553	0.0058126	0.0054729
Alumni	0.4523419	0.1618818	0.2533829	0.0291355
PCP	0.0567687	0.4806894	0.2770031	0.1827826


Para utilizar solamente los dos primeros factores es necesario correr de nuevo el PCA para retener solo éstos dos.

```
> res.PCA2<-PCA(mediaspais, ncp = 2)
```

Entonces se utiliza la salida del PCA con estas dos primeras componentes:

```
> res.hcpc<-HCPC(res.PCA2,  
+                 nb.clust = -1, min = 3, max = 6, ,
```

grupamiento Jerárquico



Tipificación de los grupos

Datos originales y pertenencia a los grupos

	Alumni	Award	HiCi	N.S	PUB	PCP	clust
FR	39.10000	31.30000	16.63333	22.76667	45.90000	34.06667	1
RU	46.80000	34.10000	0.00000	9.60000	52.40000	31.20000	1
BE	7.50000	15.40000	17.60000	15.10000	54.40000	30.40000	2
DE	19.60000	21.50000	16.60000	24.75000	52.40000	28.85000	2
FI	16.00000	17.80000	22.80000	20.60000	52.70000	28.20000	2
GE	27.48000	22.62000	17.48000	21.86000	46.96000	27.42000	2
IR	31.50000	19.90000	24.90000	20.80000	41.60000	26.50000	2
NL	23.70000	18.15000	27.90000	25.15000	48.00000	29.25000	2
NW	22.00000	33.30000	17.60000	13.50000	46.60000	24.30000	2
SE	24.36667	29.60000	20.63333	20.26667	45.63333	29.63333	2
SW	22.26667	26.60000	28.50000	30.56667	46.80000	36.20000	3
UK	28.66364	30.97273	33.10000	31.56364	55.47273	29.10000	3
US	25.65556	29.60926	44.42407	37.37037	55.42963	30.79074	3
AS	17.30000	8.90000	26.40000	21.63333	56.10000	27.73333	4
CA	21.67500	14.25000	31.50000	26.70000	63.22500	24.92500	4

Descripción de los grupos por las variables

Table: Grupo 1: FR, RU

	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
Alumni	3.009886	42.950000	24.82672	3.850000	8.814208	0.0026135
Award	1.844021	32.700000	22.91137	1.400000	7.770565	0.0651801
PCP	1.695601	32.633333	29.24557	1.433333	2.924735	0.0899616
HiCi	-2.333446	8.316667	23.43817	8.316667	9.486235	0.0196248

Table: Grupo 2: BE, FI, GE, IR, NL, NW SE

	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
N.S	-1.730892	20.25333	23.40171	3.862679	7.044696	0.0834711
PUB	-2.018794	48.53667	51.68379	4.026609	6.037650	0.0435087

Descripción de los grupos por las variables

Table: Grupo 3: SW, UK, USA

	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
N.S	2.579008	33.16689	23.40171	3.000046	7.044696	0.0099085
HiCi	2.334554	35.34136	23.43817	6.691377	9.486235	0.0195667
PCP	1.771427	32.03025	29.24557	3.028177	2.924735	0.0764897

Table: Grupo 4: JP, AS, CA

	v.test	Mean in category	Overall mean	sd in category	Overall sd	p.value
PUB	2.834354	60.88167	51.68379	3.381371	6.037650	0.0045918
Award	-2.634080	11.91000	22.91137	2.234920	7.770565	0.0084366





Figure: Proyección de los grupos sobre el plano 1-2



Referencias bibliográficas

- Liu, J., Sun, J. & Wang, S. (2006), 'Pattern recognition: An overview', *IJCSNS International Journal of Computer Science and Network Security* **6**(6), 57–61.
- Liu, J., Wu, Z., Xiao, L., Sun, J. & Yan, H. (2019), 'Generalized tensor regression for hyperspectral image classification', *IEEE Transactions on Geoscience and Remote Sensing* **58**(2), 1244–1258.
- Peña, D. (2003), *Análisis de datos multivariantes*, 1a edn, McGraw-Hill, Interamericana de Espana, S.A.U.