

Laboratorio B: Estadística Descriptiva Multivariada

Tema 1: Panorama y medidas descriptivas

Jimmy A Corzo S., PhD · Giovany Babativa-Márquez, PhD

27 de abril de 2026

Contenido

PARTE I: Repaso de Álgebra Matricial	3
PARTE II: Medidas Descriptivas Multivariadas	7
0.1 Ejercicio 13: Ciudades Colombianas — Vector de Medias y Variabilidad	7
0.2 Ejercicio 14: Sistema Universitario Estatal (SUE) — Combinaciones Lineales	8
0.3 Ejercicio 15: Rankings Latinoamericanos — Distancias	9
PARTE III: Análisis Descriptivo	10
0.4 Ejercicio 16: Indicadores Educativos y de Bienestar en Ciudades Colombianas	10
0.4.1 Contexto	10
0.4.2 Variables a utilizar	10
0.4.3 Instrucciones	10
0.4.4 Preguntas guía	12
0.5 Ejercicio 17: Universidades Públicas Colombianas — Tamaño vs. Producción	12
0.5.1 Contexto	12
0.5.2 Variables a utilizar	13
0.5.3 Instrucciones	13
0.5.4 Preguntas guía	15
0.6 Ejercicio 18: Rankings Universitarios Latinoamericanos — ¿Miden lo mismo?	15
0.6.1 Contexto	15
0.6.2 Variables a utilizar	16
0.6.3 Instrucciones	16
0.6.4 Preguntas guía	18
0.7 Ejercicio 19: Precipitaciones en Colombia — Variabilidad Espacio-Temporal	20

0.7.1	Contexto	20
0.7.2	Variables a utilizar	20
0.7.3	Instrucciones	20
0.7.4	Preguntas guía	24
0.8	Ejercicio 20: Universidades Latinoamericanas — Perfil Multidimensional	24
0.8.1	Contexto	24
0.8.2	Variables a utilizar	24
0.8.3	Instrucciones	24
0.8.4	Preguntas guía	27

PARTE I: Repaso de Álgebra Matricial

Ejercicio 1. Sean las matrices

$$A = \begin{pmatrix} 2 & -1 & 0 \\ 3 & 4 & 1 \\ -1 & 2 & 5 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 2 & -1 \\ 0 & 3 & 4 \\ 2 & -1 & 1 \end{pmatrix}, \quad \mathbf{c} = \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix}.$$

Calcule:

- a) $A + B$, $A - B$, $3A - 2B$.
 - b) AB y BA . ¿Son iguales? ¿Qué propiedad ilustra este resultado?
 - c) $A\mathbf{c}$ y $B\mathbf{c}$.
 - d) $(AB)\mathbf{c}$ y $A(B\mathbf{c})$. ¿Qué propiedad verifica este cálculo?
-

Ejercicio 2. Dada la matriz

$$C = \begin{pmatrix} 4 & 2 & 1 \\ 2 & 6 & 3 \\ 1 & 3 & 5 \end{pmatrix}.$$

- a) Calcule C^T . ¿Qué tipo de matriz es C ? Justifique.
 - b) Calcule $\det(C)$.
 - c) Calcule C^{-1} y verifique que $C \cdot C^{-1} = I$.
 - d) ¿Es C definida positiva? Compruébelo usando los menores principales.
-

Ejercicio 3. Sea

$$D = \begin{pmatrix} 5 & 3 \\ 3 & 2 \end{pmatrix}.$$

- a) Calcule los valores propios λ_1, λ_2 y los vectores propios asociados $\mathbf{e}_1, \mathbf{e}_2$.
 - b) Verifique que los vectores propios son ortogonales: $\mathbf{e}_1^T \mathbf{e}_2 = 0$.
 - c) Normalice los vectores propios ($\|\mathbf{e}_i\| = 1$) y forme la matriz ortogonal $E = [\mathbf{e}_1 \mid \mathbf{e}_2]$.
 - d) Construya la **descomposición espectral**: $D = E\Lambda E^T$, donde $\Lambda = \text{diag}(\lambda_1, \lambda_2)$.
 - e) Interprete: ¿qué información aportan los valores propios sobre la variabilidad de los datos representados por D ?
-

Ejercicio 4. Considere la forma cuadrática $Q(\mathbf{x}) = \mathbf{x}^\top D \mathbf{x}$, donde D es la matriz del ejercicio anterior.

- Expandir $Q(\mathbf{x})$ en función de x_1 y x_2 .
 - Evalúe Q en $\mathbf{x}_1 = (1, 0)^\top$, $\mathbf{x}_2 = (0, 1)^\top$ y $\mathbf{x}_3 = (1, 1)^\top$.
 - ¿Para qué valores de $\mathbf{x}$ se alcanza el máximo de $Q(\mathbf{x})$ sujeto a $\|\mathbf{x}\| = 1$? Relacione su respuesta con los vectores propios de D .
-

Ejercicio 5. Sea

$$M = \begin{pmatrix} 3 & 1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 3 \end{pmatrix}.$$

- Encuentre los valores y vectores propios de M .
 - Calcule $\text{tr}(M)$ y $\det(M)$. Relacione estos con los valores propios.
 - Expresar M mediante la descomposición espectral.
 - Calcule M^{-1} usando los valores y vectores propios ($M^{-1} = E\Lambda^{-1}E^\top$).
-

Ejercicio 6. Considere la matriz rectangular

$$X = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}.$$

- Calcule $X^\top X$ y $XX^\top$. ¿Son cuadradas? ¿De qué tamaño?
 - Obtenga la **Descomposición en Valores Singulares (SVD)**: $X = U\Sigma V^\top$.
 - Verifique que Σ^2 contiene los valores propios de $X^\top X$.
 - Reconstruya X a partir de U , Σ y $V^\top$.
-

Ejercicio 7 (computacional en R). Usando R, realice las siguientes operaciones:

```
# a) Defina las matrices A, B, C, D, M, X de los ejercicios anteriores
A <- matrix(c(2,-1,0, 3,4,1, -1,2,5), nrow=3, byrow=TRUE)
# ... complete con las demás matrices

# b) Verifique los cálculos de los ejercicios 1 a 6:
#   - Productos matriciales: A %*% B
#   - Determinante: det(C)
```

```
# - Inversa: solve(C)
# - Valores propios: eigen(D)
# - SVD: svd(X)

# c) Para la matriz M del ejercicio 5, grafique los vectores propios
# como flechas en el plano (use las dos primeras componentes)
```

Ejercicio 8. La **traza** de una matriz cuadrada $A_{p \times p}$ se define como $\text{tr}(A) = \sum_{i=1}^p a_{ii}$.

- Demuestre que $\text{tr}(AB) = \text{tr}(BA)$ para matrices compatibles.
- Si A tiene valores propios $\lambda_1, \dots, \lambda_p$, demuestre que $\text{tr}(A) = \sum_{i=1}^p \lambda_i$.
- En estadística multivariada, $\text{tr}(\mathbf{S})$ (traza de la matriz de covarianzas) se interpreta como la **varianza total**. ¿Por qué?

Ejercicio 9. Dados los vectores $\mathbf{u} = (2, -1, 3)^\top$ y $\mathbf{v} = (1, 4, -2)^\top$:

- Calcule $\mathbf{u}^\top \mathbf{v}$ (producto interno).
- Calcule $\|\mathbf{u}\|$ y $\|\mathbf{v}\|$.
- Calcule el ángulo entre $\mathbf{u}$ y $\mathbf{v}$.
- Calcule $\mathbf{u}\mathbf{v}^\top$ (producto externo). ¿De qué tamaño es el resultado?

Ejercicio 10. Sea $\mathbf{S}$ la siguiente matriz de covarianzas de tres variables:

$$\mathbf{S} = \begin{pmatrix} 9 & 3 & -6 \\ 3 & 4 & 2 \\ -6 & 2 & 16 \end{pmatrix}.$$

- Obtenga la matriz de desviaciones estándar $\mathbf{D}_s = \text{diag}(s_1, s_2, s_3)$.
- Calcule la **matriz de correlaciones**: $\mathbf{R} = \mathbf{D}_s^{-1} \mathbf{S} \mathbf{D}_s^{-1}$.
- Verifique que los elementos diagonales de $\mathbf{R}$ son iguales a 1.
- Interprete el signo de las correlaciones.

Ejercicio 11. La **distancia de Mahalanobis** entre un vector $\mathbf{x}$ y el centroide $\boldsymbol{\mu}$ es:

$$d_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{S}^{-1} (\mathbf{x} - \boldsymbol{\mu})}.$$

Con $\boldsymbol{\mu} = (5, 3)^\top$ y $\mathbf{S} = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$, calcule d_M para: a) $\mathbf{x}_1 = (7, 5)^\top$ b) $\mathbf{x}_2 = (5, 6)^\top$ c) $\mathbf{x}_3 = (3, 0)^\top$ d) ¿Cuál punto está más “alejado” del centroide en el sentido multivariado?

Ejercicio 12. Demuestre las siguientes propiedades de la matriz de covarianzas $\mathbf{S}$:

- a) $\mathbf{S}$ es simétrica: $\mathbf{S} = \mathbf{S}^\top$.
 - b) $\mathbf{S}$ es semidefinida positiva: $\mathbf{a}^\top \mathbf{S} \mathbf{a} \geq 0$ para todo vector $\mathbf{a}$.
 - c) Si $\mathbf{y} = A\mathbf{x} + \mathbf{b}$, entonces $\mathbf{S}_y = A\mathbf{S}_x A^\top$.
-

PARTE II: Medidas Descriptivas Multivariadas

Los siguientes ejercicios trabajan con conjuntos de datos reales de contexto colombiano.

0.1 Ejercicio 13: Ciudades Colombianas — Vector de Medias y Variabilidad

Contexto. El archivo `ciudades_ATM.csv` contiene indicadores socioeconómicos para 22 ciudades colombianas, incluyendo variables de educación, infraestructura, salud, tecnología y producción económica.

Variables seleccionadas:

Variable	Descripción
Poblacion	Número de habitantes
Analfabetismo	Tasa de analfabetismo (proporción)
Cobertura ed sup	Tasa de cobertura en educación superior
PIB per capita	PIB per cápita (pesos)
NBI	Índice de Necesidades Básicas Insatisfechas
Camas	Camas hospitalarias por 1000 hab

```
ciudades <- read_delim(  
  here("datos", "ciudades_ATM.csv"),  
  delim = ";", locale = locale(decimal_mark = ",", encoding = "latin1")  
)  
  
# Seleccionar variables de interés  
vars_sel <- c("Analfabetismo", "Cobertura ed sup",  
              "PIB per capita", "NBI", "Camas")  
X <- ciudades |> select(all_of(vars_sel))
```

a) Calcule el **vector de medias** $\bar{x}$ y el **vector de desviaciones estándar** s .

```
# Complete el código:  
x_bar <- colMeans(X, na.rm = TRUE)  
s_vec <- apply(X, 2, sd, na.rm = TRUE)
```

b) Calcule la **matriz de covarianzas** S y la **matriz de correlaciones** R .

```
S <- cov(X, use = "complete.obs")  
R <- cor(X, use = "complete.obs")
```

c) Calcule e interprete: - La **varianza total**: $\text{tr}(S) = \sum_{j=1}^p s_j^2$. - La **varianza generalizada**: $|S| = \det(S)$.

d) Construya el **gráfico de correlaciones** con `corrplot`. ¿Qué pares de variables tienen mayor correlación positiva? ¿Negativa?

```
corrplot(R, method = "color", type = "upper",
         addCoef.col = "black", tl.col = "black",
         col = colorRampPalette(c("#2c7bb6", "white", "#d7191c"))(200),
         number.cex = 0.8, tl.srt = 45, diag = FALSE)
```

e) Identifique los dos pares con mayor y menor correlación. Formule una hipótesis descriptiva que explique cada relación.

0.2 Ejercicio 14: Sistema Universitario Estatal (SUE) — Combinaciones Lineales

Contexto. El archivo `SUEsolo2012.csv` registra indicadores de las 32 universidades públicas colombianas en 2012. Las variables capturan su tamaño (docentes, presupuesto), oferta (matriculados en pregrado y posgrado) y producción (graduados).

Variable	Descripción
DCTC2012	Número de docentes tiempo completo
GPA2012	Gastos de personal académico (pesos)
MPRE2012	Matriculados en pregrado
MPOS2012	Matriculados en posgrado
GrPre2012	Graduados de pregrado
GrPos2012	Graduados de posgrado

```
sue <- read_delim(
  here("datos", "SUEsolo2012.csv"),
  delim = ";", locale = locale(decimal_mark = ",", encoding = "latin1")
)
```

a) Calcule el vector de medias y la matriz de covarianzas. ¿Cuál variable tiene mayor varianza? ¿Por qué?

b) Considerando que los datos tienen escalas muy diferentes, estandarice la matriz de datos:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

y calcule la nueva matriz de covarianzas. ¿En qué se convierte?

c) Construya el siguiente **índice de tamaño universitario** como combinación lineal:

$$I_{\text{tamaño}} = 0.4 \cdot (\text{DCTC estand.}) + 0.3 \cdot (\text{MPRE estand.}) + 0.3 \cdot (\text{MPOS estand.})$$

Calcule el índice para cada universidad y ordénelas de mayor a menor.

d) ¿Qué relación esperaría entre DCTC2012 y GrPre2012? Verifíquela con la correlación. ¿Y entre MPRE2012 y GrPos2012?

0.3 Ejercicio 15: Rankings Latinoamericanos — Distancias

Contexto. El archivo `r14_Sci_Qs_Webometrics.csv` contiene indicadores de posicionamiento de 74 universidades latinoamericanas según tres sistemas: Scimago (SC), QS y Webometrics (WEB).

a) Seleccione las variables `QS.Puntuacion`, `SC.Productividad`, `SC.Impacto.normalizado` y `WEB.Impacto`. Calcule el vector de medias y la matriz de correlaciones.

b) Calcule la **distancia euclídea estandarizada** entre las primeras 5 universidades. Para ello use la matriz de datos estandarizados Z .

c) Calcule la **distancia de Mahalanobis** de cada universidad respecto al centroide. Identifique las tres universidades más atípicas. ¿A qué países pertenecen?

```
rankings <- read_delim(here("datos", "r14_Sci_Qs_Webometrics.csv"),
                      delim = ";")

vars_rank <- c("QS.Puntuacion", "SC.Productividad",
              "SC.Impacto.normalizado", "WEB.Impacto")

X_rank <- rankings |> select(all_of(vars_rank)) |>
  drop_na() |> as.matrix()

# Distancia de Mahalanobis
centro <- colMeans(X_rank)
S_rank <- cov(X_rank)
d_mah <- mahalanobis(X_rank, center = centro, cov = S_rank)
```

d) Compare las distancias euclídeas y de Mahalanobis. ¿Por qué son diferentes? ¿Cuál es más apropiada para datos con diferente escala y correlación?

PARTE III: Análisis Descriptivo

Objetivo: Explorar conjuntos de datos multivariados a través de diagramas de dispersión, identificar tendencias, agrupamientos y relaciones, y formular hipótesis descriptivas que motiven naturalmente el uso de métodos multivariantes.

Instrucción: Para cada ejercicio, construya los gráficos solicitados en R, responda las preguntas guía y complete la sección *¿Por qué aquí sería útil un método multivariante?*

0.4 Ejercicio 16: Indicadores Educativos y de Bienestar en Ciudades Colombianas

0.4.1 Contexto

El conjunto de datos `ciudades_ATM.csv` contiene información socioeconómica de 22 ciudades capitales de Colombia. Exploraremos la relación entre la tasa de analfabetismo, la cobertura en educación superior y el bienestar económico.

0.4.2 Variables a utilizar

- Analfabetismo: tasa de analfabetismo (eje x)
- Cobertura ed sup: tasa de cobertura en educación superior (eje y)
- NBI: Índice de Necesidades Básicas Insatisfechas (tamaño o color del punto)
- PIB per capita: PIB por habitante

0.4.3 Instrucciones

Paso 1. Cargue y prepare los datos:

```
ciudades <- read_delim(  
  here("datos", "ciudades_ATM.csv"),  
  delim = ";", locale = locale(decimal_mark = ",", encoding = "latin1")  
)  
  
# Renombrar para facilitar el uso  
ciudades <- ciudades |>  
  rename(  
    ciudad      = CIUDADES,  
    analfabetismo = Analfabetismo,  
    cob_sup      = `Cobertura ed sup`,  
    nbi          = NBI,  
    pib_pc       = `PIB per capita`,  
    poblacion    = Poblacion  
  )
```

Paso 2. Construya el diagrama de dispersión básico:

```
ggplot(ciudades, aes(x = analfabetismo, y = cob_sup)) +
  geom_point(aes(color = nbi, size = poblacion), alpha = 0.8) +
  geom_smooth(method = "lm", se = TRUE, color = "#0077b6", linetype = "dashed") +
  geom_text_repel(aes(label = ciudad), size = 2.8, max.overlaps = 15) +
  scale_color_gradient(low = "#2dc653", high = "#d62728",
                      name = "NBI (%)") +
  scale_size_continuous(name = "Población", labels = label_comma()) +
  labs(
    title = "Educación y Bienestar en Ciudades Colombianas",
    subtitle = "Tamaño proporcional a la población; color indica NBI",
    x = "Tasa de analfabetismo",
    y = "Cobertura educación superior",
    caption = "Fuente: DANE - ciudades_ATM.csv"
  ) +
  theme_minimal(base_size = 11) +
  theme(legend.position = "right")
```




Figure 1: Cobertura en educación superior vs. tasa de analfabetismo en ciudades colombianas

Paso 3. Añada la variable PIB per capita creando cuartiles y repita el gráfico coloreando por grupo de PIB:

```

ciudades <- ciudades |>
  mutate(grupo_pib = ntile(pib_pc, 4),
         grupo_pib = factor(grupo_pib,
                           labels = c("Q1 (menor)", "Q2", "Q3", "Q4 (mayor)")))

ggplot(ciudades, aes(x = analfabetismo, y = cob_sup, color = grupo_pib)) +
  geom_point(size = 3, alpha = 0.9) +
  geom_text_repel(aes(label = ciudad), size = 2.5) +
  scale_color_brewer(palette = "RdYlBu", name = "Cuartil PIB p.c.") +
  labs(title = "Educación por nivel de PIB per cápita",
       x = "Tasa de analfabetismo", y = "Cobertura ed. superior") +
  theme_minimal()

```

0.4.4 Preguntas guía

1. ¿Existe una tendencia entre la tasa de analfabetismo y la cobertura en educación superior? ¿En qué dirección?
2. ¿Las ciudades con mayor NBI tienden a tener mayor o menor cobertura en educación superior?
3. ¿Hay ciudades que “rompen” el patrón general? ¿Cuáles son y qué podría explicarlo?
4. ¿El PIB per cápita parece asociado con los indicadores educativos?
5. ¿Observa alguna agrupación natural de ciudades? ¿Qué criterio parece separarlas?

¿Por qué aquí sería útil un método multivariante?

Los patrones observados muestran que las ciudades no se pueden clasificar adecuadamente solo con dos variables: para caracterizar de manera completa el *desarrollo socioeducativo* de una ciudad se necesitan múltiples indicadores simultáneos. Un **Análisis de Componentes Principales (ACP)** permitiría resumir las variables (analfabetismo, NBI, cobertura, PIB) en pocas dimensiones sin perder información relevante, y revelaría qué variables "van juntas". Un **análisis de clúster** identificaría formalmente los grupos de ciudades con perfiles similares que usted intuyó visualmente.

0.5 Ejercicio 17: Universidades Públicas Colombianas — Tamaño vs. Producción

0.5.1 Contexto

El SUE (Sistema Universitario Estatal) agrupa las universidades públicas colombianas. El archivo `SUEsolo2012.csv` contiene indicadores de tamaño y producción académica para el año 2012. La pregunta es: ¿el tamaño de una universidad (en términos de docentes y presupuesto) se traduce en mayor producción de graduados?

0.5.2 Variables a utilizar

- DCTC2012: Docentes tiempo completo (indicador de tamaño académico)
- GPA2012: Gastos de personal académico (indicador financiero)
- GrPre2012: Graduados de pregrado (producción)
- GrPos2012: Graduados de posgrado (producción avanzada)

0.5.3 Instrucciones

Paso 1. Cargue los datos y aplique transformación logarítmica para reducir la asimetría:

```
sue <- read_delim(  
  here("datos", "SUEsolo2012.csv"),  
  delim = ";", locale = locale(decimal_mark = ",", encoding = "latin1")  
) |>  
  mutate(  
    log_dctc = log(DCTC2012),  
    log_gpa  = log(GPA2012),  
    log_grpre = log(GrPre2012),  
    log_grpos = log(GrPos2012 + 1) # +1 para evitar log(0)  
  )
```

Paso 2. Construya la matriz de diagramas de dispersión (scatterplot matrix):

```
sue |>  
  select(log_dctc, log_gpa, log_grpre, log_grpos) |>  
  rename(  
    "Log(Docentes TC)" = log_dctc,  
    "Log(Gasto Pers.)" = log_gpa,  
    "Log(Grad. Pregrado)" = log_grpre,  
    "Log(Grad. Posgrado)" = log_grpos  
  ) |>  
  ggpairs(  
    lower = list(continuous = wrap("smooth", alpha = 0.6,  
                                   color = "#0077b6", size = 0.8)),  
    diag = list(continuous = wrap("densityDiag", fill = "#90e0ef")),  
    upper = list(continuous = wrap("cor", size = 4, color = "#023e8a"))  
  ) +  
  theme_minimal(base_size = 10) +  
  labs(title = "Sistema Universitario Estatal (SUE) - 2012",  
       subtitle = "Variables en escala logarítmica")
```

Paso 3. Resalte la Universidad Nacional y otras grandes universidades:

```
sue_top <- sue |>  
  mutate(es_grande = DCTC2012 > quantile(DCTC2012, 0.75, na.rm=TRUE))
```

Sistema Universitario Estatal (SUE) — 2012

Variables en escala logarítmica




Figure 2: Relaciones entre indicadores del SUE — escala logarítmica

```
ggplot(sue, aes(x = log_dctc, y = log_grpre)) +
  geom_point(aes(color = log_grpos), size = 3, alpha = 0.9) +
  geom_smooth(method = "lm", se = TRUE, color = "gray40",
              linetype = "dashed") +
  geom_text_repel(data = filter(sue, es_grande),
                  aes(label = Universidades), size = 2.8) +
  scale_color_viridis_c(name = "Log(Grad. Posgrado)", option = "C") +
  labs(title = "Tamaño docente vs. graduados de pregrado",
       subtitle = "Color: producción de graduados de posgrado",
       x = "Log(Docentes TC)", y = "Log(Graduados pregrado)") +
  theme_minimal()
```

0.5.4 Preguntas guía

1. ¿Existe una relación lineal clara entre el número de docentes y los graduados de pregrado? ¿Y con los de posgrado?
2. ¿Las universidades con mayor gasto de personal académico producen más graduados de posgrado?
3. ¿Hay alguna universidad que produzca muchos graduados de posgrado en relación con su tamaño (puntos en la parte superior del gráfico relativo)? ¿Y lo contrario?
4. ¿La transformación logarítmica cambia la forma de la nube de puntos? ¿Por qué es útil en este caso?
5. ¿Nota algún agrupamiento de universidades en la matriz de dispersión?

¿Por qué aquí sería útil un método multivariante?

La matriz de dispersión muestra que las variables están correlacionadas entre sí: no es suficiente analizar cada par de forma aislada. Un **ACP** construiría un *índice de capacidad universitaria* que combina óptimamente todas las variables, eliminando la redundancia de las correlaciones altas. Asimismo, un **análisis de clúster** agruparía las universidades según su perfil multidimensional, distinguiendo entre universidades de investigación intensiva vs. universidades más orientadas a la docencia.

0.6 Ejercicio 18: Rankings Universitarios Latinoamericanos — ¿Miden lo mismo?

0.6.1 Contexto

Tres sistemas internacionales clasifican las universidades latinoamericanas: **Scimago** (enfocado en productividad científica), **QS** (reputación académica y empleabilidad) y **Webometrics** (presencia e impacto en la web). El archivo `r14_Sci_Qs_Webometrics.csv` contiene datos de 74 universidades de la región. La pregunta central: ¿coinciden los tres rankings al clasificar las mejores universidades?

0.6.2 Variables a utilizar

- QS.Puntuacion y QS.Reputacion.academica
- SC.Productividad y SC.Impacto.normalizado
- WEB.Impacto y WEB.Presencia
- Pais: país de la universidad

0.6.3 Instrucciones

Paso 1. Cargue los datos e identifique las variables:

```
rankings <- read_delim(  
  here("datos", "r14_Sci_Qs_Webometrics.csv"),  
  delim = ";", locale = locale(encoding = "latin1", decimal_mark = ",")  
)  
  
# Separar nombre de universidad y país  
rankings <- rankings |>  
  mutate(  
    pais_cod = str_extract(UniPais, "(?<=- )\\w+$"),  
    univ_nom = str_remove(UniPais, " - \\w+$")  
  )
```

Paso 2. Compare los rankings QS vs. Scimago:

```
ggplot(rankings, aes(x = SC.Productividad, y = QS.Puntuacion)) +  
  geom_point(aes(color = Pais), size = 2.8, alpha = 0.85) +  
  geom_smooth(method = "loess", se = TRUE, color = "gray30",  
             linetype = "dashed", linewidth = 0.8) +  
  geom_text_repel(  
    data = rankings |> filter(QS.Puntuacion > 85 | SC.Productividad > 30000),  
    aes(label = str_wrap(univ_nom, 20)), size = 2.2, max.overlaps = 12  
  ) +  
  scale_color_brewer(palette = "Set1", name = "País") +  
  labs(  
    title = "¿Coinciden QS y Scimago al evaluar universidades?",  
    subtitle = "Cada punto es una universidad latinoamericana",  
    x = "Productividad Scimago (n.º publicaciones)",  
    y = "Puntuación QS",  
    caption = "Fuente: r14_Sci_Qs_Webometrics.csv"  
  ) +  
  theme_minimal(base_size = 11)
```

Paso 3. Construya una matriz de dispersión para los 6 indicadores de los tres rankings:




Figure 3: Puntuación QS vs. Productividad Scimago en universidades latinoamericanas

```
rank_sub <- rankings |>
  transmute(
    QS.Punt = as.numeric(QS.Puntuacion),
    QS.Rep  = as.numeric(QS.Reputacion.academica),
    SC.Prod = as.numeric(SC.Productividad),
    SC.Imp  = as.numeric(SC.Impacto.normalizado),
    WEB.Imp = as.numeric(WEB.Impacto),
    WEB.Pres = as.numeric(WEB.Presencia)
  ) |>
  drop_na()

ggpairs(rank_sub,
  lower = list(continuous = wrap("points", size = 1.2, alpha = 0.6,
                                color = "#0077b6")),
  upper = list(continuous = wrap("cor", size = 3.5)),
  diag  = list(continuous = wrap("densityDiag", fill = "#90e0ef"))
) +
  theme_minimal(base_size = 9) +
  labs(title = "Indicadores de rankings - Universidades Latinoamericanas")
```

Paso 4. Construya un diagrama de dispersión de los dos primeros rankings (posición ordinal) coloreando por país:

```
ggplot(rankings, aes(x = SC.Lac.Ranking, y = QS.Ranking, color = Pais)) +
  geom_point(size = 3, alpha = 0.8) +
  geom_abline(slope = 1, intercept = 0, linetype = "dotted", color = "gray50") +
  geom_text_repel(aes(label = pais_cod), size = 2.5, max.overlaps = 10) +
  labs(title = "Posición en ranking Scimago vs. QS",
       subtitle = "Línea punteada = posición idéntica en ambos rankings",
       x = "Posición Scimago (América Latina)",
       y = "Posición QS") +
  theme_minimal()
```

0.6.4 Preguntas guía

1. ¿Existe correspondencia entre la posición de una universidad en el ranking QS y en Scimago? ¿La relación es perfectamente lineal?
2. ¿Hay universidades que tienen muy buen desempeño en Scimago (alta productividad) pero baja puntuación en QS (o viceversa)? ¿A qué países pertenecen estas universidades?
3. En la línea punteada del paso 4, los puntos por encima indican universidades mejor posicionadas en QS que en Scimago. ¿Hay algún patrón por país?
4. ¿Los indicadores de Webometrics correlacionan con los de QS y Scimago? ¿Qué sugiere esto sobre lo que mide cada sistema?
5. Si tuviera que construir un *ranking único*, ¿qué dificultades observa al intentar combinar estos indicadores visualmente?

Indicadores de rankings — Universidades Latinoamericanas




Figure 4: Comparación de indicadores de los tres rankings

¿Por qué aquí sería útil un método multivariante?

La proliferación de indicadores hace casi imposible la comparación visual simultánea. El **Análisis de Componentes Principales** permitiría reducir los 6+ indicadores a 2 o 3 componentes interpretables (ej., una componente de "productividad científica" y otra de "visibilidad institucional"), representando todas las universidades en un plano bidimensional sin perder información esencial. Un **biplot** mostraría simultáneamente las universidades y los indicadores, revelando qué dimensiones distinguen a los sistemas de ranking. Esta motivación es precisamente la que llevó a usar ACP en las diapositivas del curso con estos mismos datos.

0.7 Ejercicio 19: Precipitaciones en Colombia — Variabilidad Espacio-Temporal

0.7.1 Contexto

El archivo `Precipitaciones_Totales_Mensuales_20241008.csv` contiene registros históricos de precipitación mensual (mm) en estaciones meteorológicas del IDEAM distribuidas en Colombia. La precipitación en Colombia varía según la región geográfica y el mes del año, siguiendo patrones unimodales (en el Pacífico y la Amazonia) o bimodales (en los Andes).

0.7.2 Variables a utilizar

- ENERO a DICIEMBRE: precipitación mensual total (mm)
- MUNICIPIO: municipio de la estación
- CUENCA: cuenca hidrográfica
- X, Y: coordenadas geográficas (longitud, latitud aproximadas)

0.7.3 Instrucciones

Paso 1. Cargue y prepare los datos:

```
precip <- read_delim(  
  here("datos", "Precipitaciones_Totales_Mensuales_20241008.csv"),  
  delim = ";", locale = locale(encoding = "latin1", decimal_mark = ",")  
) |>  
  drop_na(ENERO:DICIEMBRE) |>  
  mutate(across(ENERO:DICIEMBRE, as.numeric),  
         precip_anual = rowSums(across(ENERO:DICIEMBRE), na.rm = TRUE))
```

Paso 2. Diagrama de dispersión: precipitación en meses contrastantes:

```
meses_col <- c("ENERO", "FEBRERO", "MARZO", "ABRIL", "MAYO", "JUNIO",  
              "JULIO", "AGOSTO", "SEPTIEMBRE", "OCTUBRE", "NOVIEMBRE", "DICIEMBRE")
```

```

# Promedio por estación (si hay varios años)
precip_media <- precip |>
  group_by(ESTACION, MUNICIPIO, CUENCA, X, Y) |>
  summarise(across(all_of(meses_col), mean, na.rm = TRUE),
    .groups = "drop") |>
  mutate(precip_anual = rowSums(across(all_of(meses_col)), na.rm = TRUE))

ggplot(precip_media, aes(x = ENERO, y = JULIO)) +
  geom_point(aes(color = precip_anual, size = precip_anual), alpha = 0.6) +
  geom_abline(slope = 1, intercept = 0, color = "gray50", linetype = "dashed") +
  scale_color_gradient2(
    low = "#fee090", mid = "#4575b4", high = "#313695",
    midpoint = median(precip_media$precip_anual, na.rm = TRUE),
    name = "Precip. anual (mm)"
  ) +
  scale_size_continuous(guide = "none") +
  labs(
    title = "Precipitación: Enero vs. Julio",
    subtitle = "Línea punteada = igual precipitación en ambos meses",
    x = "Precipitación enero (mm)",
    y = "Precipitación julio (mm)",
    caption = "Fuente: IDEAM - Precipitaciones_Totales_Mensuales_20241008.csv"
  ) +
  theme_minimal(base_size = 11)

```

Paso 3. Compare el patrón estacional de dos cuencas contrastantes:


```

# Seleccione dos cuencas con patrones diferentes
cuencas_sel <- precip_media |>
  count(CUENCA) |>
  slice_max(n, n = 4) |>
  pull(CUENCA)

precip_long <- precip_media |>
  filter(CUENCA %in% cuencas_sel[1:2]) |>
  pivot_longer(cols = all_of(meses_col),
    names_to = "mes", values_to = "precip_mm") |>
  mutate(mes = factor(mes, levels = meses_col))

ggplot(precip_long, aes(x = mes, y = precip_mm, group = ESTACION)) +
  geom_line(alpha = 0.3, color = "#0077b6") +
  stat_summary(aes(group = CUENCA), fun = mean, geom = "line",
    color = "#d62728", linewidth = 1.2) +
  facet_wrap(~CUENCA) +
  labs(title = "Régimen de precipitaciones por cuenca",
    subtitle = "Línea roja = media; líneas azules = estaciones individuales",
    x = "Mes", y = "Precipitación (mm)") +

```



Fuente: IDEAM – Precipitaciones_Totales_Mensuales_20241008.csv

Figure 5: Precipitación en enero vs. julio — ¿meses espejo?

```
theme_minimal(base_size = 10) +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

Régimen de precipitaciones por cuenca

Línea roja = media; líneas azules = estaciones individuales




Figure 6: Patrón estacional: dos cuencas colombianas

Paso 4. Diagrama de dispersión de los 12 meses tomados de a pares (matriz):

```
precip_media |>
  select(ENERO, ABRIL, JULIO, OCTUBRE) |>
  rename("Enero" = ENERO, "Abril" = ABRIL,
         "Julio" = JULIO, "Octubre" = OCTUBRE) |>
  ggpairs(
    lower = list(continuous = wrap("points", alpha = 0.4, size = 0.8,
                                   color = "#0077b6")),
    diag = list(continuous = wrap("densityDiag", fill = "#90e0ef")),
    upper = list(continuous = wrap("cor", size = 4))
  ) +
  theme_minimal() +
  labs(title = "Precipitaciones mensuales seleccionadas - Colombia")
```

0.7.4 Preguntas guía

1. ¿Las estaciones con alta precipitación en enero tienden a tener alta o baja precipitación en julio? ¿Qué explica este patrón en Colombia?
2. ¿Observa estaciones que tienen precipitación alta en ambos meses? ¿Y en ninguno? ¿A qué regiones podría corresponder cada grupo?
3. ¿Las correlaciones entre meses son todas positivas o hay meses “opuestos” (correlación negativa)?
4. En la gráfica de cuencas, ¿cómo difieren los regímenes? ¿Cuál parece más bimodal?
5. Si clasificara las estaciones por su perfil anual de precipitación, ¿cuántos grupos distintos identificaría visualmente?

¿Por qué aquí sería útil un método multivariante?

Cada estación meteorológica tiene 12 mediciones mensuales: los datos son inherentemente multivariados. Los gráficos pares nos permiten explorar relaciones entre meses individuales, pero no capturan el patrón temporal completo. Un **ACP aplicado a los 12 meses** como variables resumiría el régimen anual en pocas componentes: la primera probablemente capturaría el nivel medio anual (precipitación total), y la segunda el contraste entre temporadas seca/lluviosa. Un **análisis de clúster** basado en el perfil de los 12 meses agruparía automáticamente las estaciones por su régimen climático (pacífico, andino, llanero, etc.), validando la regionalización empírica que usted intuye en los gráficos.

0.8 Ejercicio 20: Universidades Latinoamericanas — Perfil Multidimensional

0.8.1 Contexto

Retomamos el archivo `r14_Sci_Qs_Webometrics.csv` para una exploración más profunda. En este ejercicio explorará si las universidades forman grupos “naturales” según su perfil en múltiples dimensiones: productividad científica, impacto, reputación y visibilidad web. Además, analizará si estos grupos coinciden con la distribución geográfica (país).

0.8.2 Variables a utilizar

Todas las numéricas del archivo: indicadores de QS, Scimago y Webometrics (ver cabecera del archivo).

0.8.3 Instrucciones

Paso 1. Estandarice las variables y construya el diagrama de dispersión de Scimago vs. QS enriquecido:

```

rankings <- read_delim(
  here("datos", "r14_Sci_Qs_Webometrics.csv"),
  delim = ";", locale = locale(encoding = "latin1", decimal_mark = ",")
) |>
  mutate(
    pais = str_extract(UniPais, "(?<=-)\\w+$"),
    univ = str_remove(UniPais, "-\\w+$")
  )

vars_num <- c("QS.Puntuacion", "QS.Reputacion.academica",
             "SC.Productividad", "SC.Colaboracion.Interciol",
             "SC.Impacto.normalizado", "SC.Indice.de.excelencia",
             "WEB.Impacto", "WEB.Apertura")

X_rank <- rankings |>
  select(all_of(vars_num)) |>
  drop_na() |>
  scale() |>
  as.data.frame()

```

Paso 2. Construya un gráfico de burbujas combinando tres dimensiones:

```

rankings_comp <- rankings |>
  select(univ, pais, all_of(vars_num)) |>
  drop_na()

ggplot(rankings_comp,
  aes(x = SC.Impacto.normalizado, y = QS.Reputacion.academica)) +
  geom_point(aes(size = SC.Productividad,
                 color = WEB.Impacto), alpha = 0.75) +
  geom_text_repel(
    data = rankings_comp |>
      filter(QS.Reputacion.academica > 80 | SC.Impacto.normalizado > 1.2),
    aes(label = str_wrap(univ, 25)), size = 2, max.overlaps = 15
  ) +
  scale_size_continuous(name = "Productividad\nScimago",
    range = c(1.5, 12),
    labels = label_comma()) +
  scale_color_viridis_c(name = "Impacto\nWeb", option = "plasma") +
  labs(
    title = "Perfil multidimensional de universidades latinoamericanas",
    subtitle = "Tamaño: productividad Scimago · Color: impacto web",
    x = "Impacto normalizado Scimago",
    y = "Reputación académica QS",
    caption = "Fuente: r14_Sci_Qs_Webometrics.csv"
  ) +
  theme_minimal(base_size = 11) +

```

```
theme(legend.position = "right")
```




Figure 7: Perfil científico vs. reputación académica en universidades latinoamericanas

Paso 3. Agregue facetas por país:

```
ggplot(rankings_comp,
       aes(x = SC.Productividad, y = QS.Puntuacion)) +
  geom_point(aes(color = SC.Impacto.normalizado), size = 2.5, alpha = 0.8) +
  geom_smooth(method = "lm", se = FALSE, color = "gray40", linewidth = 0.7) +
  facet_wrap(~ pais, scales = "free") +
  scale_color_viridis_c(name = "Impacto\nnormalizado") +
  labs(title = "Productividad vs. Puntuación QS por país",
       x = "Productividad Scimago", y = "Puntuación QS") +
  theme_minimal(base_size = 9)
```

Paso 4. Construya la matriz de correlaciones y visualícela:

```
R_rank <- cor(rankings_comp[vars_num], use = "complete.obs")
corrplot(R_rank, method = "color", type = "full",
        addCoef.col = "black", tl.col = "black", tl.srt = 45,
        col = colorRampPalette(c("#2c7bb6", "white", "#d7191c"))(200),
        number.cex = 0.65, diag = TRUE,
```

```
title = "Correlaciones entre indicadores de rankings",
mar = c(0,0,2,0))
```

Correlaciones entre indicadores de rankings




Figure 8: Mapa de correlaciones — indicadores de rankings

0.8.4 Preguntas guía

1. ¿Existe una relación entre el impacto científico (Scimago) y la reputación académica (QS)?
¿Es perfectamente lineal?
2. ¿Las universidades con mayor productividad también tienen mayor impacto normalizado?
¿Hay excepciones notables?
3. En las facetas por país, ¿la pendiente de la relación productividad-reputación es similar en todos los países? ¿Qué sugiere esto?
4. En el mapa de correlaciones, ¿qué grupo de variables está más correlacionado entre sí: los indicadores QS, los de Scimago o los de Webometrics?
5. Si quisiera representar la “calidad integral” de una universidad en un solo número, ¿qué variables incluiría y cómo las combinaría? ¿Observa alguna redundancia?
6. ¿Identifica grupos de países con perfiles similares? Describa las características del grupo.

¿Por qué aquí sería útil un método multivariante?

Este ejercicio muestra con claridad los límites del análisis visual: con 8 variables es imposible visualizar simultáneamente todas las relaciones. El **ACP** construirá componentes ortogonales interpretables (ej., "capacidad científica" vs. "visibilidad internacional") que resumen la información en 2 o 3 dimensiones sin perder el patrón central. Un **biplot** superpondrá universidades e indicadores en el mismo plano. El **análisis de clúster** formalizará los grupos de universidades que usted identificó intuitivamente, mientras que el **análisis de correspondencias** (si se trabajan variables cualitativas como país y tipo de institución) revelaría asociaciones entre perfiles de universidades y sus características institucionales.

Documento preparado por Jimmy Corzo y Giovany Babativa · Estadística Descriptiva Multivariada