

LABORATORIO PRE-PARCIAL EDM

Jimmy Corzo Giovany Babativa

1. En la tabla 1 se presentan los resultados, expresados en miles de votos, obtenidos por los tres partidos más votados a nivel nacional en las elecciones al Senado de la República de Colombia de 2026: Pacto Histórico, Centro Democrático y Partido Liberal, discriminados para ocho departamentos.

	Pacto Histórico	Centro Democrático	Liberal	Total
Bogotá D.C.	130	43	43	216
Antioquia	148	212	63	423
Valle del Cauca	103	38	47	188
Atlántico	101	45	78	224
Santander	43	64	35	142
Bolívar	51	26	51	128
Cundinamarca	64	35	43	142
Córdoba	35	28	52	115
Total	675	491	412	1578

Tabla 1: Votos (en miles) de los tres partidos más votados al Senado en ocho departamentos seleccionados.

Observe en los totales marginales que el Centro Democrático concentra buena parte de su votación en Antioquia y Santander, el Pacto Histórico en Bogotá y Valle del Cauca, mientras que el Partido Liberal mantiene votaciones importantes en la Costa Caribe (Atlántico, Bolívar) y en Córdoba. El propósito de este ejercicio es verificar estas afinidades mediante un Análisis de Correspondencias Simples (ACS) realizado paso a paso de manera **manual**.

Sea $N = (n_{ij})$ la tabla anterior, con $I = 8$ filas (departamentos), $J = 3$ columnas (partidos) y $n = \sum_{i,j} n_{ij}$ el total general. Realice los siguientes pasos:

- a. Calcule la matriz de frecuencias relativas $F = (f_{ij})$, con $f_{ij} = n_{ij}/n$.
- b. Calcule las masas marginales de fila $f_{i\bullet} = \sum_j f_{ij}$ y de columna $f_{\bullet j} = \sum_i f_{ij}$ (los *centroides* o perfil medio de filas y columnas) y **construya las correspondientes** matrices diagonales $D_I = \text{diag}(f_{1\bullet}, \dots, f_{8\bullet})$ (8×8) y $D_J = \text{diag}(f_{\bullet 1}, f_{\bullet 2}, f_{\bullet 3})$ (3×3).
- c. Obtenga la matriz de perfiles fila (frecuencias condicionadas $f_{ij}/f_{i\bullet}$): $R = D_I^{-1}F$. Verifique que cada fila de R suma 1 e interprete cada fila como la distribución porcentual del voto de cada departamento entre los tres partidos.
- d. Obtenga la matriz de perfiles columna (frecuencias condicionales $f_{ij}/f_{\bullet j}$): $C = D_J^{-1}F^T$ (equivalentemente $C^T = FD_J^{-1}$). Verifique que cada **columna** de C suma 1 e interprete cada perfil como la distribución geográfica de la votación de cada partido entre los ocho departamentos.
- e. Calcule la matriz de desviaciones respecto a la independencia

$$Z = D_I^{-1/2} (F - f_{i\bullet} f_{\bullet j}^T) D_J^{-1/2},$$

donde $f_{i\bullet}f_{\bullet j}^\top$ es la tabla de independencia (producto de las masas marginales). Cada elemento z_{ij} mide, **en términos de la inercia**, qué tan lejos está la frecuencia observada de la esperada bajo independencia.

- f. Realice la descomposición en valores singulares (SVD) de Z : $Z = U\Lambda V^\top$, con U ($8 \times r$) y V ($3 \times r$) de columnas ortonormales y $\Lambda = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_r})$, $r = \min(I - 1, J - 1)$.
 - g. A partir de los valores singulares obtenga los valores propios (inercias) λ_α . Verifique que $\sum_\alpha \lambda_\alpha = \chi^2/n$ (inercia total) y calcule el porcentaje de inercia explicado por cada eje y el acumulado.
 - h. Calcule las coordenadas principales de las filas (departamentos), $\Psi = D_I^{-1/2}U\Lambda$, y de las columnas (partidos), $\Phi = D_J^{-1/2}V\Lambda$.
 - i. Para cada departamento y cada partido calcule el coseno cuadrado respecto a cada eje (calidad de representación), $\cos_{i\alpha}^2 = \psi_{i\alpha}^2 / \sum_\alpha \psi_{i\alpha}^2$, y la contribución absoluta a la formación de cada eje, $\text{CTR}_{i\alpha} = f_{i\bullet} \psi_{i\alpha}^2 / \lambda_\alpha$ (análogamente para las columnas, usando $f_{\bullet j}$ y $\phi_{j\alpha}$).
 - j. Construya el mapa factorial (plano 1-2) representando simultáneamente departamentos y partidos. Con base en las contribuciones y cosenos obtenidos, concluya qué departamentos están más asociados con cada partido y compare estas afinidades con los patrones regionales descritos arriba.
2. La base de datos `publicidad.xlsx` (disponible en https://github.com/jgbabativam/Curso_Multivariado/tree/main/Datos) proviene de una encuesta sobre hábitos de consumo de medios de comunicación con fines publicitarios: Radio, TV, Diario Nacional, Diario Regional, Revista e Internet. La hoja **Profesion** cruza estos seis medios con ocho categorías ocupacionales (tabla 2) y será la tabla activa del Análisis de Correspondencias Simples (ACS). Las hojas **Sexo**, **Edad** y **Educacion** (tablas 3, 4 y 5) cruzan los mismos seis medios con el sexo, el rango de edad y el nivel educativo de los encuestados, y se utilizarán más adelante como **filas suplementarias**.

	Radio	TV	Diario Nal	Diario Reg.	Revista	Internet	Total
Agricultor	96	148	2	71	50	17	384
Microemp.	123	136	11	76	149	41	536
Ejecutivo	193	184	74	63	103	79	696
Profesional	360	360	63	145	141	184	1 253
Empleado	511	593	57	217	192	306	1 876
Estudiante	385	457	42	174	104	220	1 382
Conductor	156	185	8	69	42	35	495
Inactivo	1 474	1 931	181	852	642	762	5 842
Total	3 298	3 994	438	1 667	1 423	1 644	12 464

Tabla 2: Tabla activa: número de personas según medio de comunicación y categoría ocupacional.

Las siguientes tablas 3, 4 y 5 cruzan los mismos seis medios de comunicación con el sexo, la edad y el nivel educativo de los encuestados. Éstas se usarán únicamente como filas suplementarias: no intervienen en el cálculo de F , D_I , D_J ni en la SVD, pero se proyectarán sobre los ejes obtenidos a partir de la tabla 2.

	Radio	TV	Diario Nal	Diario Reg.	Revista	Internet	Total
Hombre	1 630	1 900	285	854	621	776	6 066
Mujer	1 667	2 069	152	815	683	938	6 324

Tabla 3: Fila suplementaria: medio de comunicación según sexo.

	Radio	TV	Diario Nal	Diario Reg.	Revista	Internet	Total
15-24	660	713	69	216	234	360	2 252
25-34	640	719	84	230	212	320	2 205
34-49	888	1 000	130	429	345	466	3 258
50-64	617	774	84	391	262	263	2 391
>64	491	761	70	402	251	245	2 220

Tabla 4: Fila suplementaria: medio de comunicación según rango de edad.

	Radio	TV	Diario Nal	Diario Reg.	Revista	Internet	Total
Primaria	908	1 307	73	642	360	435	3 725
Secundaria	869	1 008	101	408	336	494	3 216
Tecn. o Prof.	901	1 035	80	440	311	504	3 271
Postgrado	619	612	177	209	298	281	2 196

Tabla 5: Fila suplementaria: medio de comunicación según nivel educativo.

Sea $N = \{n_{ij}\}$ la tabla 2 (tabla activa), con $I = 8$ categorías ocupacionales (filas), $J = 6$ medios de comunicación (columnas) y $n = \sum_{i,j} n_{ij}$.

y luego proyecte las filas suplementarias:

- Repita, de manera manual, los pasos 1a a 1j del ejercicio 1
- Proyecte como **filas suplementarias** las categorías de las tablas 3 (sexo), 4 (edad) y 5 (nivel educativo). Para cada categoría suplementaria s , con vector de conteos $(n_{s1}, \dots, n_{s6})$ y total $n_{s\bullet} = \sum_j n_{sj}$, calcule su perfil $r_{sj} = n_{sj}/n_{s\bullet}$ y sus coordenadas sobre cada eje retenido mediante la fórmula de transición

$$\psi_{s\alpha} = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{j=1}^6 r_{sj} \phi_{j\alpha}.$$

Calcule también su distancia al centroide, $d^2(s, G) = \sum_j (r_{sj} - f_{\bullet j})^2 / f_{\bullet j}$, y su calidad de representación $\cos_{s\alpha}^2 = \psi_{s\alpha}^2 / d^2(s, G)$. Ubique estos puntos suplementarios en el plano factorial obtenido en el literal anterior e interprete: ¿qué perfiles de sexo, edad y nivel educativo se asocian con cada categoría ocupacional y cada medio?

- Repita todo el ACS de la tabla 2 con las tablas 3, 4 y 5 como filas suplementarias usando R (`FactoMineR::CA(tabla, row.sup=...)`). Compare valores propios, % de inercia, coordenadas, $\cos^2$ y contribuciones (incluyendo las de las filas suplementarias) con los obtenidos manualmente y valide sus resultados.
3. La base de datos `Credito.sav` (disponible en el repositorio del curso, carpeta `Datos`) contiene información de 468 clientes de una entidad bancaria, descritos por 12 variables categóricas (las etiquetas de las variables y de sus categorías están documentadas en el archivo). En la tabla 6 se resumen las variables que se usarán como **activas** (perfil sociodemográfico y financiero) y como **suplementarias** (`Tip_Cli` y `Creditos`), las cuales no participan en la construcción de los ejes pero se proyectarán a posteriori para caracterizar qué perfil corresponde a un buen/mal cliente y a la autorización o no de un crédito.

Las $Q = 10$ **variables variables activas suman 34 categorías en total**. Realice un Análisis de Correspondencias Múltiples (ACM) usando `FactoMineR` en R. Como punto de partida puede usar el siguiente esqueleto:

Variable	Descripción	Categorías	Tipo
Edad	Edad del cliente	menos de 23 / 23 a 39 / 40 a 50 / más de 50 años	Activa
Est_Civil	Estado civil	Soltero / Casado / Divorciado / Viudo	Activa
Antig	Antigüedad como cliente	menos de 1 / 1 a 4 / 4 a 6 / 6 a 12 / más de 12 años	Activa
Salar_Prest	Salario domiciliado	domiciliado / no domiciliado	Activa
Ahorro	Ahorro mensual	sin ahorro / menos de 100 mil / 100 mil a 1 millón / más de 1 millón	Activa
Profesion	Profesión	Empresario / Empleado / Otro	Activa
Media	Saldo medio actual	menos de 200 mil / 200 a 500 mil / más de 500 mil	Activa
Movim	Movimientos promedio	menos de 100 mil / 100 a 300 mil / 300 mil a 1 millón / más de 1 millón	Activa
AcumD	Acumulación de débitos	menos de 400 mil / 400 mil a 1 millón / más de 1 millón	Activa
Chequera	Tiene chequera	con chequera / sin chequera	Activa
Tip_Cli	Tipo de cliente	Buen cliente / Mal cliente	Suplementaria
Creditos	Autorización de crédito	Si autorizado / No autorizado	Suplementaria

Tabla 6: Variables activas y suplementarias del archivo `Credito.sav`.

```
library(pacman)
p_load(FactoMineR, factoextra, haven)

credito <- read_sav("Credito.sav")
credito <- as.data.frame(lapply(credito, as_factor))
credito$ident <- NULL

activas <- c("Edad", "Est_Civil", "Antig", "Salar_Prest", "Ahorro",
             "Profesion", "Media", "Movim", "AcumD", "Chequera")
sup      <- c("Tip_Cli", "Creditos")
credito <- credito[, c(activas, sup)]

res.mca <- MCA(credito, graph = FALSE,
               quali.sup = which(names(credito) %in% sup))

res.mca$eig           # valores propios e inercia
res.mca$var$coord     # coordenadas de las modalidades activas
res.mca$var$contrib   # contribuciones
res.mca$var$cos2      # calidad de representacion
res.mca$quali.sup     # modalidades suplementarias
```

- Importe la base en R, convierta las variables en factores con las etiquetas de las categorías y verifique las frecuencias de cada categoría (`summary` o `table`). ¿Hay categorías con muy pocos individuos que puedan ser problemáticas para el ACM?
- Ejecute `MCA()` con las 10 variables activas y `Tip_Cli` y `Creditos` como `quali.sup`. Examine `res.mca$eig`: calcule el porcentaje de inercia de cada eje y el acumulado. Compare cada valor propio con la inercia media de Benzécri ($1/Q = 0,1$). ¿Cuántos ejes recomienda interpretar?
- Para los dos primeros ejes, identifique con `res.mca$var$contrib` las categorías activas cuya contribución supera el promedio ($100/34 \approx 2,9\%$). Indique el signo de su coordenada (`res.mca$var$coord`) e interprete cada eje.
- Grafique el plano factorial de las modalidades activas (ejes 1-2 y, si procede, 1-3 u otros).

Apoyándose en las contribuciones del literal anterior y en el $\cos^2$ (`res.mca$var$cos2`), describa los grupos o “perfiles” de clientes que se observan.

- e. Agregue al gráfico anterior las modalidades suplementarias `Tip_Cli` y `Creditos`. ¿Hacia qué zona del plano se ubican “Buen cliente”/“Mal cliente” y “Si Autorizado”/“No autorizado”? ¿Con cuáles categorías activas coinciden?
- f. Grafique los individuos coloreados por `Tip_Cli`. ¿Se observa alguna separación entre buenos y malos clientes en el primer plano factorial?
- g. A partir de los resultados anteriores, proponga un perfil típico de “buen cliente” (en términos de antigüedad, ahorro, movimientos, saldo medio, etc.) susceptible de obtener autorización de crédito, y un perfil de “mal cliente”. Concluya.
- h. La categoría “más de 1 millón” de `Ahorro` reúne solo 8 de los 468 clientes (1,7%). Revise su contribución y su $\cos^2$ en los primeros ejes y discuta qué efecto puede tener una categoría tan poco frecuente sobre la nube de modalidades y si valdría la pena agruparla con otra categoría cercana.

EJERCICIOS CON BASES REALES

Para los siguientes tres ejercicios deben utilizar el microdato anonimizado de la Encuesta de Convivencia y Seguridad Ciudadana (ECSC) 2024 del DANE. La base de datos puede descargarse del portal de microdatos del DANE (aquí), y el cuestionario completo, necesario para identificar el nombre, la redacción exacta y las categorías de respuesta de cada variable, puede consultarse (aquí).

4. Con la pregunta 1 del módulo C (“Durante 2023, es decir, de enero a diciembre de 2023, ¿cuáles de los siguientes problemas sabe usted se presentaron en su barrio, centro poblado o vereda?”), realice un ACM utilizando las distintas situaciones como variables activas y el departamento como variable suplementaria. ¿Cuántos factores es conveniente interpretar?, ¿qué representa cada factor y cómo se relaciona con el departamento?
5. Realice un ACM con las preguntas 6 y 11 del módulo E:
 - Pregunta 6: “¿Por cuáles de los siguientes aspectos relacionados con la delincuencia o el conflicto armado se siente inseguro en su municipio?”
 - Pregunta 11: “¿Cuál de las siguientes medidas tomó para su seguridad?”

usando como variables suplementarias el estrato, la edad (construya rangos de edad), el departamento y el sexo. ¿Cuántos factores se deben interpretar?, ¿qué tipos de inseguridad y qué medidas de autoprotección se asocian entre sí?, ¿cómo se relacionan estos perfiles con las variables suplementarias?

6. Haga un ACM de la pregunta 12 del módulo E (“¿En cuáles de las siguientes situaciones usted justificaría el uso de la violencia?”), usando el sexo, la edad y el departamento como variables suplementarias. Interprete los factores obtenidos y describa el perfil de las personas que justificarían el uso de la violencia en cada situación.