

INTRODUCCIÓN AL
APRENDIZAJE ESTADÍSTICO NO SUPERVISADO:
Análisis de componentes principales

Por:
Jimmy A. Corzo S.
Profesor Titular
Departamento de Estadística
Facultad de Ciencias
Universidad Nacional de Colombia- Sede Bogotá

10 de mayo de 2026

Índice general

1. Análisis de componentes principales (ACP)	5
1.0.1. El contexto de las componentes principales. Definiciones básicas	6
1.0.2. Definición y propiedades de las componentes principales como direcciones de máxima varianza de la matriz de datos	6
1.1. Elementos para la interpretación de un ACP	10
1.2. Ejemplo cálculos e interpretación del ACP	13
Variables suplementarias o ilustrativas	19
1.3. Dos aplicaciones de las componentes principales para apoyo de métodos estadísticos	22
Regresión con componentes principales	22
Imputación: estimación de datos perdidos	22
1.4. Laboratorio	24
En todos los casos entregar resultados respecto a las variables	24
Resultados requeridos respecto a las ciudades (objetos)	24
Tablas y gráficas	24
1.5. ANEXO: Búsqueda de las componentes principales en las direcciones de máxima varianza de Y por los valores y vectores propios de la matriz de correlación	25

```
> confianza = read.csv2(paste0(rut_archv, "Confianza.csv"))
```


Capítulo 1

Análisis de componentes principales (ACP)

La manera más común entre estadísticos de ver el Análisis de Componentes Principales es como un método de buscar ponderaciones apropiadas para construir combinaciones lineales (sumas ponderadas) de las variables $X_1, \dots, X_p$ que acumulan la mayor cantidad posible de varianza de la tabla de datos, combinaciones que son ortogonales por construcción, lo que garantiza que no están correlacionadas. Un segundo enfoque es el desde el aprendizaje estadístico, en la cual la búsqueda de las componentes es un problema de optimización que consiste en encontrar la mejor aproximación de la matriz de datos, minimizando las sumas de cuadrados de las diferencias entre las observaciones y sus aproximaciones.

Los dos enfoques producen la misma solución, debido a que la aproximación buscada por minimización de las sumas cuadrados, corresponde a la solución dada por el Teorema de la Descomposición en Valores Singulares para la reconstrucción de la matriz de datos a partir de los valores y vectores propios de $X'X$ y de XX' , la cual produce las componentes en las direcciones de máxima varianza de X .

Éstas combinaciones lineales se denominan **componentes principales, factores o dimensiones**. Luego se utilizan unas cuantas de ellas para comprender mejor los datos, analizar y visualizar tablas de datos, para reducción de dimensiones, para visualización o imputación de datos faltantes entre otras de sus aplicaciones. En el contexto de regresión las componentes suelen utilizarse como predictores cuando hay problemas de multicolinealidad. El ACP es la base de los llamados Métodos Factoriales entre los que se cuentan también el Análisis de Correspondencias Simples, el Análisis de Correspondencias Múltiples (ACM) y varias generalizaciones de éstos para tablas múltiples o tablas de tres índices en las cuales se pueden mezclar tablas de variables cuantitativas y tablas de variables cualitativas.

El ACP se cuenta entre los métodos no supervisados puesto que incluye solamente datos de las variables o características $X_1, \dots, X_p$ observadas en los objetos, sin una respuesta asociada sobre la cual se pueda supervisar la calidad de los resultados que producen, y por tanto tampoco se pueden hacer predicciones de ningún tipo. Por esta razón, se muestra también un enfoque dentro del moderno aprendizaje estadístico no supervisado que utiliza las componentes para aproximar la matriz de datos y permite calcular los errores en la aproximación como errores residuales de ésta.

Algunas aplicaciones del ACP son:

- reducción de dimensiones
- imputación de datos faltantes
- en el contexto de regresión las componentes se pueden utilizar como predictores.
- para visualización de tablas de datos
- exploración y análisis de tablas de datos

Se definen primero las componentes principales como direcciones en las que la matriz de datos tiene las máximas varianzas, se muestran sus principales propiedades analíticamente y se incluyen varios ejemplos con datos reales para ilustrar su utilidad.

1.0.1. El contexto de las componentes principales. Definiciones básicas

Para definir las componentes principales se utiliza con frecuencia la **matriz de correlaciones**, ya que en este caso las variables se encuentran estandarizadas, lo cual permite la comparabilidad entre variables medidas en diferentes unidades. Además, al trabajar con la matriz de correlaciones, la varianza total es fija e igual p , de modo que la importancia relativa de cada componente principal puede interpretarse directamente en términos de **proporciones de varianza explicada**.

Alternativamente, puede utilizarse la **matriz de covarianzas** cuando todas las variables están medidas en las mismas unidades y presentan escalas comparables. No obstante, dado que las covarianzas no están acotadas y dependen de las unidades de medición, su uso puede dificultar la comparación relativa de la contribución de las variables cuando existen diferencias importantes de escala, razón por la cual en aplicaciones multivariadas es habitual preferir la matriz de correlaciones.

1.0.2. Definición y propiedades de las componentes principales como direcciones de máxima varianza de la matriz de datos

Las componentes principales se construyen como un subproducto de la aplicación del TDVS a la matriz Y (matriz de datos centrada, estandarizada y normada). En efecto, el TDVS de Y produce la siguiente expresión para reconstruirla:

$$Y = ULV', \quad (1.1)$$

donde

U y V son matrices con columnas ortonormales, lo cual implica $U'U = V'V = I$

$L_{p \times p} = \text{diag}(\sqrt{\lambda_\alpha}), \lambda_\alpha \geq 0, \lambda_1 \geq \dots \geq \lambda_p, \lambda_\alpha$ es el α -ésimo valor propio de $Y'Y$, $\alpha = 1, \dots, p$,

$V_{p \times p} = (v_1, \dots, v_p), v_\alpha = (v_{1\alpha}, \dots, v_{p\alpha})'$ es el α -ésimo vector propio de $Y'Y = R$,

y define las *direcciones ortogonales de máxima varianza*

en el *espacio de las variables* (cargas factoriales o *loadings* de las variables);

$U_{n \times p} = (u_1, \dots, u_p), u_\alpha = (u_{1\alpha}, \dots, u_{n\alpha})'$ es el α -ésimo vector propio de YY' ,

y define las *direcciones ortogonales de máxima varianza*

en el *espacio de los objetos*. (cargas factoriales o *loadings* de los objetos);

Análisis para los objetos.

Puesto que la matriz de datos contiene en sus filas los objetos observados, el análisis de los objetos corresponde al análisis de las filas $y_{i.}$ de Y . Se define la matriz de componentes principales como el producto

$$Z = YV \quad (1.2)$$

donde las columnas de Z son las *componentes principales* (o *scores*) de los objetos, y V contiene las direcciones de máxima varianza. Este producto se denomina matriz de componentes principales para los objetos, pues representa las proyecciones de los valores de las variables observadas en los objetos, sobre los vectores propios de $Y'Y$.

Nótese que las componentes principales estan centradas

$$\text{med}(Z) = \frac{1}{n} Z' \mathbf{1}_n = V' \frac{1}{n} Y' \mathbf{1}_n = V' \cdot 0 = 0, \quad (1.3)$$

puesto que $\frac{1}{n} Y' \mathbf{1}_n = \text{med}(Y) = 0$.

Particionando la matriz V por columnas, $V = (v_1, \dots, v_p)$, donde $v_\alpha = (v_{1\alpha}, \dots, v_{p\alpha})$ se obtiene:

$$Z = YV = (Yv_1, \dots, Yv_p),$$

de manera que la α -ésima columna de Z es el vector:

$$z_\alpha = Yv_\alpha \quad \text{para } \alpha = 1, \dots, p \quad (1.4)$$

que se define como la α - ésima componente principal, en la cual se ve claramente que z_α es la proyección de las observaciones de los objetos (filas de Y) en la dirección de v_α . En particular, para el objeto i es decir para la i -ésima fila de Y , $y_i = (y_{i1}, \dots, y_{ip})$, las **coordenadas para el objeto i sobre la α - ésima componente principal** son:

$$z_{i\alpha} = y'_i v_\alpha = \sum_{j=1}^p y_{ij} v_{j\alpha}, \quad i = 1, \dots, n.$$

Finalmente, debido a que Y está autoponderada por $\frac{1}{\sqrt{n}}$ la varianza de z_α y puesto que v_α es vector propio de $Y'Y$ y a que $v'_\alpha v_\alpha = 1$ se obtiene:

$$z'_\alpha z_\alpha = v'_\alpha Y'Y v_\alpha = \lambda_\alpha v'_\alpha v_\alpha = \lambda_\alpha, \quad (1.5)$$

Por otra parte reemplazando $Y = ULV'$ de 1.1 en (1.2) se obtiene otra expresión para la matriz de componentes principales:

$$Z = YV = ULV'V = UL,$$

de modo que la α -ésima componente principal también tiene la siguiente expresión:

$$z_\alpha = \sqrt{\lambda_\alpha} u_\alpha, \quad \alpha = 1, \dots, p.$$

Varianza e incorrelación de las componentes principales

Alternativamente, la matriz de covarianzas se puede obtener como sigue: sea S_Z la matriz de covarianzas de las componentes. La matriz de covarianzas de las componentes se obtiene por aplicación directa del TDE a la matriz de covarianzas ($B = S_Z$), el cual produce la siguiente expresión

$$S_Z = URU' = \Lambda. \quad (1.6)$$

donde $U_{p \times p}$ es una **matriz ortogonal cuyas columnas son los vectores propios estandarizados de S_Z** y $\Lambda = \text{diag}\{\lambda_\alpha\}$ con $\lambda_1 \geq \dots \geq \lambda_p$ son los **valores propios de S_Z** arreglados en forma descendente. Para la demostración de (1.6) ver por ejemplo Husson et al. (2017).

El hecho de que la matriz de covarianzas de las componentes sea diagonal implica que las **componentes principales son incorrelacionadas** y además que sus valores propios son las varianzas de las componentes principales como se mostró en 1.5.

Análisis para las variables

Análogamente que para los objetos, la matriz de componentes principales para las variables se define por:

$$W = Y'U = VL \quad (1.7)$$

Por tanto, la α -ésima componente principal asociada al α -ésimo vector propio u_α de YY' viene dada por

$$W_\alpha = Y' u_\alpha, \quad \alpha = 1, \dots, p, \quad \text{para las variables.} \quad (1.8)$$

Y particionando la matriz $U = (u_1, \dots, u_p)$ se obtiene la siguiente expresión para la α ésima componente principal de las variables:

$$w_\alpha = Y' u_\alpha \quad (1.9)$$

Efectuando el producto en 1.9 se obtienen las coordenadas de las variables sobre la α -ésima componente principal:

$$w_{\alpha j} = \sum_{i=1}^n u_{i\alpha} y_{ij}, \quad j = 1, \dots, p. \quad (1.10)$$

Las cantidades $w_{\alpha j}$ representan **las coordenadas de la variable j sobre la α -ésima componente principal**, y describen cómo cada variable se asocia con las direcciones principales determinadas por la variabilidad conjunta de los objetos.

En adelante se deducen varias propiedades de las componentes Z_α , las cuales, con las correspondientes adaptaciones, son también válidas para las componentes W_α de las variables.

Proporción de varianza explicada por las primeras q compontes

Se obtiene utilizando el hecho de que la varianza total es la suma de los p valores propios de R y por tanto la proporción explicada por los primeros q es:

$$\tau_r = \frac{\sum_{\alpha=1}^q \lambda_\alpha}{\sum_{\alpha=1}^p \lambda_\alpha} \quad (1.11)$$

En este enfoque, el ACP consiste básicamente en buscar una representación óptima de la matriz de datos centrados, estandarizados y normados $Y_{n \times p}$ mediante q ($< p$) combinaciones lineales (o promedios ponderados) llamadas componentes principales¹. Lo óptimo se refiere por una parte a que por estar calculadas en las direcciones de máxima varianza de Y las q componentes utilizadas para la representación contienen la mayor cantidad posible de la varianza de la matriz de datos $Y_{n \times p}$, y en segundo lugar a que dichas componentes son perpendiculares (ortogonales) entre sí. En este sentido, las componentes principales son una forma de reducir las dimensiones de análisis de p variables a q componentes que facilitan los análisis y la interpretación, y permiten visualizar objetos y variables.

Ecuaciones de transición entre el análisis para objetos y el análisis para variables

Para construir las ecuaciones de transición se requiere el siguiente resultado. Sea u_α es un vector propio de $Y'Y$ asociado a un valor propio no nulo λ_α , entonces:

$$Y'Y u_\alpha = \lambda_\alpha u_\alpha, \quad \text{con } \lambda_\alpha \neq 0 \quad (1.12)$$

Al multiplicar a izquierda por Y y reagrupar se obtiene

$$YY'(Y u_\alpha) = \lambda_\alpha (Y u_\alpha). \quad (1.13)$$

Como $\lambda_\alpha \neq 0$, se sigue que $Y u_\alpha \neq 0$, y por tanto λ_α es también un valor propio de YY' .

¹El método fue presentado inicialmente por Pearson (1901) y desarrollada por Hotelling (1933)

El razonamiento inverso se obtiene de manera análoga, lo que permite concluir que las matrices $Y'Y$ y YY' comparten los mismos valores propios no nulos. En consecuencia, denotando por λ_α y μ_α los valores propios no nulos de $Y'Y$ y YY' , respectivamente, se cumple que

$$\lambda_\alpha = \mu_\alpha, \quad \alpha = 1, \dots, r, \quad (1.14)$$

donde $r = \text{rango}(Y)$ (número de columnas linealmente independientes de Y).

Una demostración formal de este resultado puede encontrarse en Mardia et al. (1979), Teorema A.6.2.

La transición entre los espacios de objetos y variables se obtiene utilizando el hecho de que

$$(Y'Y)u_\alpha = Ru_\alpha = \lambda_\alpha u_\alpha \quad (1.15)$$

Entonces multiplicando a izquierda por Y y reagrupando términos se obtiene:

$$YY'(Yu_\alpha) = \lambda_\alpha(Yu_\alpha) \quad (1.16)$$

lo cual indica que Yu_α es un vector propio de YY' respecto al valor propio λ_α . Por otra parte, como la norma de Yu_α es $u'_\alpha Y'Y u_\alpha = \lambda_\alpha$ entonces el vector:

$$v_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} Yu_\alpha \quad (1.17)$$

es un vector propio normado de YY' respecto al valor propio λ_α .

Entonces, reemplazando esta expresión en (??) se muestra que W_α está en la dirección del vector propio u_α ponderado por $\sqrt{\lambda_\alpha}$:

$$W_\alpha = Y'v_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} Y'Y u_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} \lambda_\alpha u_\alpha = \sqrt{\lambda_\alpha} u_\alpha \quad (1.18)$$

En particular, las coordenadas de W_α son:

$$w_{j\alpha} = \sqrt{\lambda_\alpha} u_{j\alpha} \quad (1.19)$$

Análogamente, se utiliza el hecho de que

$$YY'v_\alpha = \mu_\alpha v_\alpha, \text{ donde } \mu_\alpha \text{ es un valor propio de } YY' \quad (1.20)$$

de manera que al premultiplicar por Y' y reagrupando se obtiene:

$$Y'Y(Y'v_\alpha) = \mu_\alpha(Y'v_\alpha) \quad (1.21)$$

y por tanto $Y'v_\alpha$ es un vector propio de $Y'Y$ respecto al valor propio μ_α . También en este caso la norma de $u_\alpha = Y'v_\alpha$ es $\mu_\alpha = \lambda_\alpha$. Entonces,

$$u_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} Y'v_\alpha \quad (1.22)$$

es un vector propio normado de $Y'Y$ respecto al valor propio λ_α . Entonces

$$z_\alpha = Yu_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} YY'v_\alpha = \sqrt{\lambda_\alpha} v_\alpha \quad (1.23)$$

En particular, para el i -ésimo objeto:

$$z_{i\alpha} = \sqrt{\lambda_\alpha} v_{i\alpha} \quad (1.24)$$

De (1.16) y (1.22) se concluye que es suficiente con calcular valores y vectores propios de $Y'Y$, pues a partir de éstos se pueden obtener los de YY' y viceversa.

1.1. Elementos para la interpretación de un ACP

Para la interpretación de un análisis de componentes principales se utilizan varios indicadores que se complementan y por esto, aunque tengan que separarse temporalmente para facilitar su lectura, la interpretación final debe incluir, la conjunción de todas las lecturas parciales de dichos indicadores.

Se presentan aquí una serie de pasos que incluyen, la calidad de la representación, la interpretación de las componentes, la construcción e interpretación de los planos factoriales, la asociación de características a los objetos a partir de la interpretación de los factores, entre otros. Conviene aclarar que el orden en que se llevan a cabo estos pasos puede ayudar, pero no es obligatorio puesto que depende de la temática y los objetivos de cada aplicación.

- **Calidad de la representación.** Se refiere al porcentaje de varianza acumulada por las q componentes escogidas para la representación en menos dimensiones expresado en ?? y por tanto, la calidad depende de una buena selección de q el número de factores. Para esto existen variados criterios en la literatura entre los que se pueden mencionar dos frecuentemente utilizados: a) Utilizar tantos como sean necesarios para alcanzar un porcentaje de varianza prefijado; b) Escoger todos aquellos que sean mayores que uno. (Otros criterios se pueden ver en Eastment & Krzanowski (1982), Josse & Husson (2012));
- **Correlaciones variable-factor.** Son indicadores del grado en que una variable explica un factor. Para z_α - como en (??) esta correlación es $\sqrt{\lambda_\alpha} u_{j\alpha}$. Para probarlo se reemplaza (1.17) en (1.9) y su utiliza el hecho de que $z_\alpha = Y u_\alpha$, para obtener la expresión:

$$w_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} Y' Y u_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} Y' z_\alpha.$$

Al realizar el producto se observa que los elementos de w_α tienen la forma

$$w_{j\alpha} = \sum_{i=1}^n y_{ij} \frac{z_{i\alpha}}{\sqrt{\lambda_\alpha}} = \sqrt{\lambda_\alpha} u_{j\alpha}.$$

Entonces como $V(Y_j) = 1$ y $V(Z_\alpha) = \lambda_\alpha$, la expresión corresponde a la correlación entre la variable y el factor. Aquí se utilizó la expresión (1.19) para $w_{j\alpha}$

Entre más alta la correlación variable-factor, mejor explicado queda el factor por la variable.

- **Tipificación de los factores (componentes) por las variables.** Para la tipificación de los factores se utilizan los siguientes indicadores que relacionan las posiciones de las variables con respecto a los ejes que forman planos factoriales:

- *Coordenadas de las variables* $w_\alpha = Y' v_\alpha$ (scores): definidas en 1.9 son las posiciones de las variables sobre el factor α , $\alpha = 1, \dots, p$. Éstas tienen la expresión (1.18) y por tanto coinciden con la correlación variable factor. La única forma que no coincidan es que el ACP sea realizado sobre la matriz de covarianzas.
- *Contribuciones a la varianza de los factores:* Como $\lambda_\alpha = v(z_\alpha) = \sum_{j=1}^p z_{\alpha j}^2$, entonces la contribución de la variable j a la varianza del factor α es la proporción de varianza que aporta la variable j a la suma.

$$\frac{z_{\alpha j}^2}{\lambda_\alpha}$$

- *Cosenos cuadrados (cos2):* Representan la cantidad de varianza de la variable que está explicada en el factor, es decir la capacidad de los factores para predecir las variables. Son las correlaciones variable factor elevadas al cuadrado definidas arriba. Sea $\theta_{j,\alpha}$ el ángulo entre la variable j y la componente z_α . Entonces el coseno al cuadrado $\theta_{j,\alpha}$ es la correlación variable-factor elevada al cuadrado:

$$\cos^2(\theta_{j,\alpha}) = \lambda_\alpha u_{j\alpha}^2 \quad (1.25)$$

Puede ocurrir en algunas aplicaciones que una variable tenga alta contribución y alta correlación con un factor, pero sus cosenos cuadrados no son suficientemente altos para que dicho factor sea un buen predictor de la variable.

- **Planos factoriales.** Una vez interpretados o tipificados los factores por las variables se construyen los planos factoriales contruidos por pares de factores (ejes o dimensiones). Las variables se representan por vectores que parten del origen del plano factorial. En los cuadrantes, o sobre los ejes, se pueden deducir propiedades de variables y objetos, a partir de las coordenadas, las contribuciones y los cosenos cuadrados, que tienen en los planos. La interpretación de los planos es por tanto un complemento a la interpretación de los factores.
- **Distancia entre variables.** Para medir la distancia entre dos variables Y_j y $Y_{j'}$ se puede expresar en términos del coseno del ángulo entre las dos variables $\theta_{jj'}$, y utilizando ?? como sigue:

$$\begin{aligned} d^2(Y_j, Y_{j'}) &= \frac{1}{n} \sum_{i=1}^n (y_{ij} - y_{ij'})^2 \\ &= \frac{1}{n} \sum_{i=1}^n y_{ij}^2 + \frac{1}{n} \sum_{i=1}^n y_{ij'}^2 - 2 \frac{1}{n} \sum_{i=1}^n y_{ij} y_{ij'} \\ &= \text{var}(Y_j) + \text{var}(Y_{j'}) - 2r_{jj'} \\ &= 2(1 - \cos(\theta_{jj'})) \end{aligned} \quad (1.26)$$

La interpretación ahora se puede hacer en términos de los cosenos entre los ángulos formados por las variables:

- variables directamente correlacionadas:

$$\cos(\theta_{jj'}) \rightarrow 1 \quad \text{entonces} \quad d(X_j, X_{j'}) \rightarrow 0$$

- variables no correlacionadas

$$\cos(\theta_{jj'}) \rightarrow 0 \quad \text{entonces} \quad d(X_j, X_{j'}) \rightarrow \sqrt{2}$$

- variables inversamente correlacionadas

$$\cos(\theta_{jj'}) \rightarrow -1 \quad \text{entonces} \quad d(X_j, X_{j'}) \rightarrow 2$$

Por otra parte, cuando el análisis se lleva a cabo sobre la **matriz de covarianzas** la distancia euclidiana entre las variables X_j y $X_{j'}$ se transforma a:

$$d^2(X_j, X_{j'}) = \sum_{i=1}^n (x_{ij} - x_{ij'})^2 = s_j + s_{j'} - 2s_{jj'}$$

Así las cosas, la interpretación depende de la covarianza entre las variables, pero es muy similar a la que se dio arriba para los ángulos entre las variables cuando el análisis se hizo sobre la matriz de correlación, y por tanto cuando:

- $s_{jj'} < 0$ la distancia entre ellos es mayor y tenderán a formar un ángulo obtuso;
- $s_{jj'} = 0$ tenderán a formar un ángulo recto.
- $s_{jj'} > 0$ la distancia entre ellos es menor y tenderán a formar un ángulo agudo

- **Tipificación de los objetos.** Tiene sentido cuando se trata de países, universidades, empresas, localidades etc., también suelen asociarse propiedades a los objetos a partir de los factores y de las variables que los definen. También, a partir de las coordenadas, contribuciones y cosenos cuadrados se pueden identificar tendencias o patrones inmersos en los objetos.

- **Distancia entre objetos.** Estas distancias tienen sentido principalmente cuando los objetos no son anónimos, como cuando se trata de ciudades, departamentos, universidades, colegios, etc. Las interpretaciones en todo caso son análogas a las de las variables y se utilizan los mismos indicadores: coordenadas, contribuciones y cosenos cuadrados. Adicionalmente, conviene tener en cuenta también que:
 - Si dos objetos se encuentran cerca en cualquier parte del plano, es porque comparten características y por tanto son parecidos. Recíprocamente, si dos objetos se encuentran lejanos en cualquier parte del plano, éstos no son parecidos y no comparten características.
 - Si dos objetos se encuentran en cuadrantes opuestos del plano factorial, o tienen coordenadas en los factores con signos opuestos, significa que tienen características o valores opuestos de las variables y por tanto perfiles antígonos.

- **Relaciones entre objetos y variables: biplots.** Un biplot es una representación simultánea de objetos y variables sobre el mismo plano factorial. Por tanto los biplots permiten asociar propiedades a los objetos por su cercanía con las variables.

Se establecen por cercanía de los objetos a los valores extremos de las variables y comprobando a partir de los mismos tres indicadores: coordenadas, contribuciones y cosenos cuadrados.

- **Factor tamaño.** En ocasiones en el primer plano factorial todas las variables están orientadas en la dirección del primer factor. Esto significa que dicho factor es una especie de promedio ponderado de todas ellas y puede utilizarse como indicador general. La interpretación de los demás factores se puede hacer normalmente teniendo la precaución de que las contribuciones a la varianza del segundo factor en adelante probablemente son muy pequeñas respecto al factor tamaño, pero no por esto pierden importancia en el análisis.
- **Variables suplementarias.** En algunos casos es necesario incluir variables que han sido observadas en otros contextos pero que no se desea que hagan parte de los cálculos de las componentes. A éstas variables se les llama variables suplementarias o ilustrativas y se pueden considerar yuxtapuestas a la tabla de variables de la tabla de datos original, llamadas también **variablesactivas** debido a que es con estas que se calculan las componentes. Sea $Y_{n \times p}^+$ la matriz que contiene las variables suplementarias entonces

las variables activas yuxtapuestas tiene la siguiente estructura $X:Y^+$. Así, la proyección de las variables suplementarias sobre el α -ésimo factor es:

$$\left[X:Y^+ \right] \quad \text{y la proyección sobre el } \alpha\text{-ésimo vector propio es } Y_{n \times p}^+ u_\alpha,$$

La cercanía de las proyecciones a las variables suplementarias a las activas se interpreta como el grado de asociación entre ellas.

- **Objetos suplementarios.** Análogamente, cuando se dispone de objetos a los cuales se observaron las mismas variables que a los objetos originales, se les denomina objetos suplementarios o ilustrativos y se pueden considerar apilados en la tabla de los objetos originales **activos**. Sea $Y_+^{n^+} \times p$ la matriz que contiene los n^+ objetos ilustrativos. entonces la matriz ampliada con objetos ilustrativos tiene la siguiente estructura:

$$\begin{bmatrix} Y \\ \dots \\ Y_+ \end{bmatrix}, \quad \text{y la proyección de los individuos sobre el } \alpha\text{-ésimo vector propio es } Y_+ v_\alpha$$

La proyección sobre los planos factoriales se interpreta como el grado de similitud entre los objetos suplementarios y los objetos activos.

1.2. Ejemplo cálculos e interpretación del ACP

Ejemplo 1.2.1. Para ilustrar las ideas anteriores sobre la interpretación del ACP, se utiliza un sencillo caso con tres variables. Naturalmente el análisis de una tabla de tres variables generalmente no justifica un ACP puesto que se puede hacer fácilmente con la matriz de correlación y un par de gráficas. Sin embargo, se presenta aquí con el único objetivo de ilustrar de la manera más simple posible la forma de hacer las interpretaciones.

Para este ejemplo se tiene en cuenta que los rankings Scimago, Web y Qs son indicadores de capacidades investigativas, presencia en la web y reputación (académicos y empleadores) respectivamente. Entonces, asumiendo que el promedio de los rankings de las universidades de un país es un indicador de la situación global de las universidades del país a la luz de los tres indicadores considerados, se contruyó la Tabla 1.1, la cual contiene dichos promedios por país ordenados por el Scimago. Bajo estas condiciones, la tabla representa aproximadamente la situación global de los países en el contexto latinoamericano.

Sin embargo, por tratarse de rankings los mejores puestos son para los países cuyas universidades ocupan los primeros puestos (valores pequeños en los rankings: 1, 2, 3, . . .), y debido a que el ACP se lleva a cabo sobre la matriz de correlaciones, la cual asocia valores grandes de las variables con los países que tienen dichos valores, el ACP con los rankings promedio originales produce factores que asocian en sus extremos a países cuyas universidades tienen rankings promedio más altos y por tanto las interpretaciones se dificultan un poco. Por esta razón análisis se construye un **puntaje** que corresponde al valor del ranking promedio invertido $\text{máx}(\text{Rank}) - \text{Rank}$, de manera que los países con mayor puntaje son aquellos cuyas universidades ocupan los primeros puestos. Estos puntajes se muestran en la Tabla 1.2. Al comparar las dos tablas se puede comprobar que los países quedan en el mismo orden, pero a hora los mejores puntajes están para los países que tenían los mejores rankings promedio en la tabla 1.1.

En la Tabla 1.1 por ejemplo, se observa que en promedio, las universidades de Puerto rico (PRI) ocupan la mejor posición tanto en el MedPais.SC.Lac como en el MedPais.WEB, pero no en el MedPais.QS, ranking en el que las dos universidades de Costa Rica (CRI) ocupan la posición promedio 38.5 que es la mejor entre los países analizados. Así mismo Brasil (BRA) ocupa el segundo puesto en el Scimago y en el Web, pero no en el Qs. Esto indica que tanto Puerto Rico como el Brasil se distinguen por su actividad investigativa, pero mientras PRI tiene el segundo mejor puesto en reputación, BRA ocupa el sexto. Esto mismo se puede ver en la Tabla 1.2 pero con los puntajes después de la transformación $\text{máx}(\text{Rank}) - \text{Rank}$.

Tabla 1.1: Medias-país de los Rankings Scimago, Qs y Webranking

	MedPais.SC.Lac	MedPais.QS	MedPais.WEB
PRI	26.0	48.0	26.0
BRA	45.6	77.6	60.1
CUB	77.0	91.0	60.0
MEX	96.3	79.3	101.2
CRI	96.5	38.5	61.0
CHL	113.0	69.7	126.9
VEN	164.9	81.1	170.0
COL	169.1	63.9	143.9
ARG	179.4	68.3	195.5
BOL	207.0	112.0	125.0
PER	211.2	83.4	199.4
ECU	240.0	100.7	121.3
PY	253.0	78.0	204.0
URY	266.8	92.0	313.0
PAN	281.0	110.5	285.5

Tabla 1.2: Puntajes por país construido con la transformación $\max(Rank) - Rank$

	MedPais.SC.Lac	MedPais.QS	MedPais.WEB
PRI	255.0	64.0	287.0
BRA	235.4	34.4	252.9
CUB	204.0	21.0	253.0
MEX	184.7	32.7	211.8
CRI	184.5	73.5	252.0
CHL	167.9	42.3	186.1
VEN	116.1	30.9	143.0
COL	111.9	48.1	169.1
ARG	101.6	43.7	117.5
BOL	74.0	0.0	188.0
PER	69.8	28.6	113.6
ECU	41.0	11.3	191.7
PY	28.0	34.0	109.0
URY	14.2	20.0	0.0
PAN	0.0	1.5	27.5

Los cálculos de las componentes se hacen con el comando *PCA* del paquete *FactoMineR*, el cual además de las componentes produce las correlaciones variable-factor que coinciden con las coordenadas, las contribuciones de las variables a las varianzas de los factores y los cosenos cuadrados, indicadores requeridos para la interpretación y para la visualización de los resultados. El código para los cálculos es el siguiente:

```
> require(FactoMineR)
> rlpaises<-PCA(rankingsPaises)
> # tresRank<-PCA(-rankingsPaises, graph = F)
```

La salida del PCA está en el archivo *rlpaises* y contiene los varios objetos de *R*, cuyo contenido se encuentra en la "description".

```
> print(rlpaises)
```

```
**Results for the Principal Component Analysis (PCA)**
The analysis was performed on 15 individuals, described by 3 variables
*The results are available in the following objects:
```

	name	description
1	"\$eig"	"eigenvalues"
2	"\$var"	"results for the variables"
3	"\$var\$coord"	"coord. for the variables"
4	"\$var\$cor"	"correlations variables - dimensions"
5	"\$var\$cos2"	"cos2 for the variables"
6	"\$var\$contrib"	"contributions of the variables"
7	"\$ind"	"results for the individuals"
8	"\$ind\$coord"	"coord. for the individuals"
9	"\$ind\$cos2"	"cos2 for the individuals"
10	"\$ind\$contrib"	"contributions of the individuals"
11	"\$call"	"summary statistics"
12	"\$call\$centre"	"mean of the variables"

```

13 "$call$ecart.type" "standard error of the variables"
14 "$call$row.w"      "weights for the individuals"
15 "$call$col.w"      "weights for the variables"

```

Para comenzar se mira la calidad de la representación que se encuentra en el objeto "rlpaíses\$eig" el cual contiene los valores propios de R , los cuales son a su vez las varianzas de los factores.

En la tabla (1.3) se puede ver por ejemplo que la suma de los valores propios (columna "eig") es 3 que es el número de variables $p = 3$ como se esperaba puesto que $\text{var}(Y_j) = 1$. La columna "percentage of variance" contiene los porcentajes con los que cada componente contribuye a la varianza total y la columna "cumulative percentage of variance" el acumulado de éstos porcentajes. En este caso se observa que entre los dos primeros factores se acumula el 99% de la varianza, lo cual indica que los dos primeros factores dan una buena aproximación de la matriz de datos. .

```

> require(kableExtra)
> Vp<-round(rlpaíses$eig,3)
> kable(Vp, "latex", booktabs = T,
+       caption = "Valores propios, porcentajes de varianza
+       y de varianza acumulados", label = "vprankis") %>%
+   kable_styling(latex_options = c("striped", "scale_down",
+                                   "hold_position"))

```

Tabla 1.3: Valores propios, porcentajes de varianza y de varianza acumulados

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.325	77.517	77.517
comp 2	0.562	18.723	96.240
comp 3	0.113	3.760	100.000

Ahora para interpretar los factores se utilizan las correlaciones variable-factor, las cuales coinciden con las coordenadas ya que por default PCA utiliza la matriz de correlación. (En caso de que se requiera calcular con la matriz de covarianzas hay que ajustar el parámetro `scale.unit=F`).

La tabla Tabla 1.4 muestra las correlaciones variable-factor, las cuales están en `rlpaíses$var$cor` producto del PCA. Se observa que las tres variables correlacionan altamente con el Factor 1. Además, `MedPais.QS` aporta también un alto porcentaje a la varianza del Factor 2, lo cual indica que `MedPais.QS` se puede utilizar para tipificar los dos factores. Esto se puede apreciar en la parte A) de la gráfica (1.1), donde `MedPais.SC.Lac` y `MedPais.WEB` se encuentran en la zona de valores positivos del primer factor y valores negativos del segundo factor (cuadrante IV), mientras que `MedPais.QS` también está en la zona de valores positivos del Factor 1 pero en la zona de valores positivos del Factor 2 (cuadrante I).

Las altas correlaciones de `MedPais.SC.Lac` y `MedPais.WEB` con el Factor 1 lo tipifican como un indicador de capacidades de investigación y presencia en la web y un buen nivel de reputación en el sentido del `MedPais.QS`. El Factor 2 por su parte, es más que todo indicador de reputación debido a que `MedPais.QS` es el que más varianza aporta a éste.

En la parte B) de la misma gráfica se muestran los países en los dos primeros factores. A la luz de la interpretación de los dos factores, se puede asociar a los países que se encuentran en el cuadrante IV, características de sus universidades relacionadas con buenas capacidades investigativas, buena presencia en la web y buena reputación, y a los países que se encuentran en el cuadrante I universidades con buena reputación aunque por estar en el cuadrante opuesto al de `MedPais.SC.Lac` y `MedPais.WEB` las universidades de dichos países tendrían menos capacidades de investigación y de presencia en la web que aquellos que se encuentran en el cuadrante IV.

```

> kable(round(rlpaíses$var$cor,3), "latex", booktabs = T,
+       caption = "Correlaciones variable-factor", label = "cor_var_fact") %>%

```

```
+ kable_styling(latex_options = c("striped",  
+                               "hold_position"))
```


Tabla 1.4: Correlaciones variable-factor

	Dim.1	Dim.2	Dim.3
MedPais.SC.Lac	0.954	-0.166	-0.251
MedPais.QS	0.772	0.633	0.058
MedPais.WEB	0.906	-0.364	0.215

```

> require(factoextra)
> library(gridExtra)
> biplot1=fviz_pca_var(rlpaises, labelsiz = 3) + ggtitle("A) Variables") + xlim(-1.3, 1.3)
> biplot2=fviz_pca_ind(rlpaises, labelsiz = 3) + ggtitle("B) Países (objetos)") + xlim(-3.5, 3.5)
> grid.arrange(biplot1, biplot2, nrow=1)

```




Gráfica 1.1: A) Vectores que representan las variables sobre los dos primeros factores. B) Países representados en los dos primeros factores

Estas asociaciones entre propiedades de los factores y los países se pueden visualizar más claramente en un gráfico de representación simultánea de objetos y variables llamado biplot mostrado en la gráfica 1.2. Las posiciones de Brasil (BRA), México (MEX) y en parte Cuba (CUB) indican que las universidades de éstos países tienen muy buenas capacidades de investigación pero no gozan de mucha reputación. Mientras que por ejemplo Costa Rica (CRI) se distingue más por la reputación de sus universidades junto con Colombia (COL) país cuyas universidades tienen algún grado de reputación y de capacidades de investigación. Las universidades de Puerto Rico (PRI) se podrían caracterizar por tener las mejores capacidades de investigación y presencia en la web, además de buena reputación.

En los países que se encuentran en el cuadrante II, por encontrarse en el lado opuesto de MedPais.SC.Lac y MedPais.WEB, sus universidades tienden a tener muy bajos niveles de investigación y presencia en la web, pero por estar en la zona de valores positivos del Factor 2 tienden a ser reconocidas o por tener algún grado de reputación.

Finalmente, en Ecuador (ECU) y Bolivia (BOL) por estar en el cuadrante III sus universidades tienen algunas capacidades de investigación y presencia en la web que de alguna manera son similares a las de BRA, pero su reputación no es de las mejores.

```
> fviz_pca_biplot(rlpaises)
```



Gráfica 1.2: Representación simultánea de los rankings y los países

Los indicadores para este análisis son las coordenadas, las contribuciones y los cosenos cuadrados que se muestran en la tabla (1.5), en la cual todos los indicadores se encuentran ordenados por el primer factor.

Por coordenadas, contribuciones y cosenos cuadrados se observa que por el lado de valores positivos del Factor 1, PRI y CRI son los que lo definen, y además los altos cosenos2 indican que estos dos países están muy bien representados en dicho factor. Le siguen en importancia por los tres indicadores BRA, CUB y MEX, resaltando que CUB y MEX contribuyen también al Factor 2, pero los cosenos2 indican que CUB solo están bien representados sobre el primer factor.

EN la zona de valores negativos del Factor 1 se distinguen PAN y URY que tienen coordenadas altas, pero sus contribuciones y cosenos2, pero la contribución de PAN es mayor al Factor 2 y también está mejor representado en éste factor.

Tabla 1.5: Indicadores para interpretación de los objetos (países)

Países	Coordenadas		Contribuciones		Cosenos2	
	Dim.1	Dim.2	Dim.1	Dim.2	Dim.1	Dim.2
PRI	2.766	0.237	21.928	0.666	0.992	0.007
CRI	2.193	1.051	21.812	0.222	0.989	0.002
BRA	1.603	-0.763	16.218	7.180	0.896	0.104
CUB	1.016	-1.245	13.790	13.100	0.888	0.042
MEX	0.856	-0.444	7.364	6.908	0.875	0.094
CHL	0.779	0.169	3.504	5.393	0.790	0.181
COL	0.359	0.674	3.008	22.633	0.778	0.176
ARG	-0.217	0.828	2.961	18.386	0.736	0.198
VEN	-0.240	0.088	2.688	8.147	0.662	0.246
PER	-0.880	0.299	2.220	1.065	0.600	0.080
ECU	-0.968	-0.829	2.099	2.338	0.428	0.313
BOL	-1.024	-1.381	1.741	0.337	0.393	0.590
PY	-1.106	0.674	0.368	5.396	0.343	0.624
URY	-2.379	0.778	0.165	0.091	0.203	0.718
PAN	-2.758	-0.137	0.134	8.139	0.063	0.915

Variables suplementarias o ilustrativas

Son variables que han sido observadas en los mismos objetos del análisis original, pero posiblemente con otros objetivos. Éstas naturalmente no hacen parte de la construcción de las componentes, pero pueden ilustrar, complementar y enriquecer el análisis. También pueden utilizarse para la validación de índices o indicadores contruidos con criterios externos, como en el caso que se presenta en el ejemplo 1.2.2.

Ejemplo 1.2.2. (Variables suplementarias) La mayoría de los rankings de universidades se construyen a partir de unos criterios predefinidos por la entidad que los produce, criterios a los cuales se asignan ponderaciones justificadas conceptualmente, con la intención de que tanto los criterios como los rankings asignados a las universidades sean comparables.

Para validar dichas ponderaciones suelen utilizarse criterios estadísticos basados por ejemplo en el ACP como se ilustra en este ejemplo. Se realiza un ACP a los criterios con los que se construye el ARWU (ejemplo ??) y se proyectan como variables suplementarias los rankings nacional, regional y mundial, así como el puntaje total (Total Score) que da origen al ranking de las universidades. La intención es verificar si los vectores que representan los criterios están en la misma dirección de los factores, lo cual sería un indicador de que las ponderaciones asignadas conceptualmente son consistentes con las que producen las componentes, y de que los criterios están ponderados razonablemente a la luz de los datos.


En la tabla 1.6 se puede observar que las publicaciones en el Nature y Science (N.S) tienen muy alta correlación con el factor 1 (0.92), son las que más contribuyen (21.93) y están mejor representadas sobre éste factor ($\text{Cos}2 = 0.85$). Le siguen las publicaciones altamente citadas (HiCi) y los premios Nobel o medallas Field obtenidos por investigadores de las universidades (Award) (0.84) y por los mismos premios obtenidos por los exalumnos (alumni) (0.81). Por su parte, el número de artículos publicados en revistas indexadas en SCI y SSCI correlaciona más con el factor 2 (0.73) aunque correlaciona también con el factor 1 (0.58).

```
> arwu<-read.csv2("ARWU_100_top.csv")
> rownames(arwu)<-arwu[,1]; arwu[,1]<-NULL
> arwu$National.Rank=-arwu$National.Rank
> arwu$Regional.Rank=-arwu$Regional.Rank
```

```
> arwu$World.Rank = -arwu$World.Rank
> pcARWU<-PCA(arwu[,3:12], quanti.sup = c(1:3,10), graph = F)
```

Tabla 1.6: Correlaciones, contribuciones y cosenos cuadrados

	Coord		Contr		Cos2	
	Factor 1	Factor 2	Factor 1	Factor 2	Factor 1	Factor 2
Alumni	0.81	-0.29	16.75	7.48	0.65	0.09
Award	0.84	-0.40	18.18	14.03	0.70	0.16
HiCi	0.84	0.37	18.40	11.62	0.71	0.13
N.S	0.92	0.21	21.93	3.70	0.85	0.04
PUB	0.58	0.73	8.62	46.37	0.33	0.54
PCP	0.79	-0.44	16.12	16.80	0.62	0.19



Gráfica 1.3: Indicadores del ARWU sobre el plano 1-2

En el plano 1-2 mostrado en la figura 1.3 se muestran estas asociaciones. Se observa que el ranking mundial (World.Rank) casi coincide con el número de artículos publicados en Nature o Science (N.S). También se nota que el puntaje total (Total score) casi coincide con el primer factor. Indicando que las ponderaciones que producen la primera componente son cercanas a las ponderaciones asignadas conceptualmente a los criterios y muestra que están adecuadamente asignadas a los criterios. Por otra parte el hecho de que el puntaje total y el ranking mundial estén muy cerca es natural puesto que el ranking se construye con el puntaje total.

Ejemplo 1.2.3. (Objetos suplementarios o ilustrativos.) La tabla para este análisis consta de las 14 universidades colombianas que quedaron entre los primeros 149 puestos del ranking QS Cuatro de ellas son públicas y las

demás privadas. Para conservar el orden en que se encuentran las universidades, pero disminuir la dispersión que producen los rankings originales, se asignaron posiciones a las universidades de acuerdo con los puestos ocupados en cada ranking y se utilizaron estos nuevos puestos para el análisis.

También, para que los vectores que representan las posiciones asignadas se orienten en la dirección positiva, se utilizaron los negativos de dichas posiciones. En la tabla 1.7 se muestran los negativos de los nuevos puestos, utilizados para el análisis. Se construyen primero las componentes a partir de las universidades **públicas** y luego se proyectan las universidades **privadas** sobre los planos producidos por las públicas.


Tabla 1.7: Negativos de los puestos de las universidades colombianas asignados por las posiciones ocupadas en cada uno de los tres rankings

	SC.Reord	Qs.Reord	Web.Reord	Estatus
LOS ANDES	-3	-1	-3	Pri
NACIONAL	-1	-2	-1	Pub
ANTIOQUIA	-2	-3	-2	Pub
JAVERIANA	-5	-4	-4	Pri
ROSARIO	-7	-5	-7	Pri
DEL VALLE	-4	-6	-5	Pub
LA SABANA	-10	-7	-10	Pri
UIS	-6	-8	-6	Pub
DEL NORTE	-14	-9	-11	Pri
EAFIT	-9	-10	-8	Pri
PT BOLIVARIA	-8	-11	-9	Pri
EXTERNADO	-13	-12	-14	Pri
TADEO	-11	-13	-12	Pri
LA SALLE	-12	-14	-13	Pri

En la Gráfica 1.4 se muestran las universidades privadas proyectadas sobre el plano formado por las dos primeras componentes que produce un PCA realizado con las universidades públicas, las cuales acumulan el 99.2% de la varianza. Se observa que las universidades públicas en color azul, se encuentran todas en el cuadrante IV, al cual apuntan también el Scimago y el Qs, indicando que se encuentran bien posicionadas tanto por su actividad investigativa (Scimago) como por su presencia en la Web. Por otra parte, se observa que Los Andes, la Javeriana y la universidad del Rosario se distinguen principalmente por su reputación entre pares académicos y empleadores (Qs). EL hecho de que las universidades del Norte, La Sabana y el Externado estén en la zona de valores positivos del factor dos dominado por el Qs, lo cual indica que gozan de cierta reputación entre pares y empleadores pero su actividad investigativa es muy pobre, pues se encuentran en el cuadrante II región opuesta al buen desempeño en actividades investigativas (Scimago) y a la presencia en la web (Web). finalmente, las cuatro restantes que se encuentran en el cuadrante IV no gozan de buena reputación entre pares académicos ni empleadores, ni se distinguen por su actividad investigativa o presencia en la Web.

```
> coll_pca = PCA(colombianas1, quali.sup = 4)
```

```
> fviz_pca_biplot(coll_pca, habillage = 4, title = "Unis pub frente a priv", repel = TRUE
```



Gráfica 1.4: Universidades privadas proyectadas como ilustrativas sobre el plano 1-2, construido con las universidades públicas

1.3. Dos aplicaciones de las componentes principales para apoyo de métodos estadísticos

Regresión con componentes principales

La idea es reemplazar la matriz X del modelo de regresión $Y = X\beta + \epsilon$ por la matriz de las primeras $q < p$ de componentes principales W de manera que la regresión toma la forma $Y = Wb + \epsilon$. Como estas componentes acumulan la mayor cantidad posible de varianza, se espera que den cuenta de la variabilidad de los datos, y que sean buenos predictores de Y . El supuesto que hay inherente a esta regresión es que las direcciones en que los datos tienen la máxima varianza son las direcciones que asocian con la respuesta Y . Una discusión del tema se puede consultar en Gareth et al. (2021) sección (6.3.1).

Imputación: estimación de datos perdidos

El tratamiento de datos perdidos es común en las aplicaciones debido a múltiples razones. Si el número de valores perdidos no es muy grande una posibilidad es eliminar los datos perdidos y correr los procedimientos sin ellos. Sin embargo, esta práctica no resulta en un desperdicio cuando son muchos los valores perdidos. Otra práctica común es reemplazar los y_{ij} perdidos por los promedios $\bar{x}_j$, donde los promedios se calculan con los valores de y_{ij} que están completos. Gareth et al. (2021) presentan un algoritmo para estimar los datos faltantes basado en la metodología de componentes principales, la cual aprovecha la estructura de correlación de los datos. La clave del método está en utilizar la misma metodología que para optimizar la suma de cuadrados de las diferencias entre las observaciones y sus aproximaciones, pero aplicada solamente sobre el conjunto $\mathcal{O}$ de pares

1.3. DOS APLICACIONES APLICACIONES DE LAS COMPONENTES PRINCIPALES PARA APOYO DE MÉTODOS ESTADÍSTICOS

de observaciones completas:

$$\text{minimizar respecto a } a_{ir}b_{jr} \quad \left\{ \sum_{i,j \in \mathcal{O}} \left(y_{ij} - \sum_{r=1}^q a_{ir}b_{jr} \right)^2 \right\} \quad (1.27)$$

Entonces se puede estimar una observación perdida y_{ij} con $\hat{y}_{ij} = \sum_{r=1}^q a_{ir}b_{jr}$. El algoritmo completo así como dos interesantes ejemplos se pueden consultar en la sección (12.3) del texto de Gareth et al. (2021). Uno de los ejemplos se ocupa de completar una matriz cuyos elementos contienen los puntajes asignados por los clientes a las películas que han visto, con el fin de predecir y sugerir películas a otros clientes que puntuaron parecido las películas que ambos han visto. Naturalmente, como no todos los clientes han visto todas las películas, la tabla tiene más datos faltantes que observaciones.