

Medidas descriptivas multivariadas

Por:

Jimmy A. Corzo S.

Profesor Titular

Departamento de Estadística

Facultad de Ciencias

Universidad Nacional de Colombia- Sede Bogotá

18 de marzo de 2026

Índice general

1. Medidas descriptivas multivariadas	5
1.1. Notación	5
1.2. Vector de medias o centroide, matriz de covarianzas y matriz de correlación	7
1.3. Combinaciones lineales	10
1.4. Combinación lineal que produce las componentes principales	12
1.5. Teorema de la descomposición espectral (TDE)	12
1.6. Teorema de la descomposición en valores singulares (TDVS)	13
1.7. Laboratorio	16

```
> confianza = read.csv2(paste0(rut_archv, "Confianza.csv"))
```

Capítulo 1

Medidas descriptivas multivariadas

1.1. Notación

Por analogía con los métodos univariados y bivariados, medidas como la media, la varianza, la covarianza y el coeficiente de correlación tienen su versión multivariada que corresponde a arreglos de éstas mismas medidas en vectores como el vector de medias o en matrices como la matriz de covarianzas o la matriz de correlación, entre otros.

En el contexto multivariado se observan p variables $X_1, \dots, X_p$ simultáneamente sobre un mismo objeto i (que puede ser una ciudad, una universidad, una planta, una persona), y por tanto una observación para el objeto i es un vector de p componentes $x'_i = (x_{i1}, \dots, x_{ip})$, donde x_{ij} es la observación de la variable j sobre el objeto i . Para n objetos las observaciones se arreglan en una tabla de datos como la siguiente:

Variables					
Objeto	X_1	$\cdots$	X_j	$\cdots$	X_p
1	x_{11}	$\cdots$	x_{1j}	$\cdots$	x_{1p}
$\vdots$	$\vdots$	$\cdots$	$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\cdots$	x_{ij}	$\cdots$	$\vdots$
$\vdots$	$\vdots$	$\cdots$	$\vdots$	$\vdots$	$\vdots$
n	x_{n1}	$\cdots$	x_{nj}	$\cdots$	x_{np}

La media, la varianza, la covarianza y el coeficiente de correlación se definen de la misma forma que en el caso univariado agregando subíndices que identifican la variable para la que se están calculando como sigue:

$$\begin{aligned}\bar{x}_j &= med(X_j) = \frac{1}{n} \sum_{i=1}^n x_{ij} && \text{media de la variable } X_j \\ s_j^2 &= var(X_j) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 && \text{varianza de la variable } X_j \\ s_{jk} &= cov(X_j, X_k) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k), && s_{jj} = s_j^2 \\ r_{jk} &= corr(X_j, X_k) = \frac{s_{jk}}{s_j s_k}, && s_j = \sqrt{s_j^2}\end{aligned} \tag{1.1}$$

Nótese que para el cálculo de la varianza y la covarianza, se utilizó como denominador n debido a que en datos multivariados se considera suficientemente grande como para que s^2 siga siendo un estimador insesgado de la varianza poblacional¹.

Para propósitos de cálculos las tablas de datos multivariados se consideran también matrices de datos. Por esta razón se utilizará aquí la palabra **tabla** para referirse a los datos con nombres en las filas y columnas, y el término **matriz** cuando se van a utilizar las propiedades algebraicas de la tabla. En este caso se le llama matriz de datos X y se define por:

$$X = \{x_{ij}\} = \begin{bmatrix} x_{11} & \cdots x_{1j} & \cdots & x_{1p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{i1} & \cdots x_{ij} & \cdots & x_{ip} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & \cdots x_{nj} & \cdots & x_{np} \end{bmatrix}$$

Se define **Varianza total** de los datos

En esta matriz la columna j , o el punto-variable j , representa las observaciones de la variable X_j sobre los n objetos y se denota como un vector columna:

$$X_{.j} = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix}, j = 1, \dots, p \quad (1.2)$$

Análogamente, la fila i , o punto objeto i , representa las observaciones de las p variables sobre el objeto i y se denota como un vector columna:

$$x_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} = (x_{i1}, \dots, x_{ip})', i = 1, \dots, n. \quad (1.3)$$

Ejemplo 1.1.1. La Tabla 1.1 es típica de un **pequeño** conjunto de datos multivariados con $p = 5$ variables y $n = 22$ ciudades colombianas (objetos). Las variables son: X_1 : Num.Hab (número de habitantes), X_2 : indicador de analfabetismo, X_3 : Cobertura.pria.secdaria (indicador de cobertura en educación primaria y secundaria), X_4 : Cobertura.ed.sup (indicador de cobertura en educación superior) y X_5 : Rel.al.prof (relación alumno profesor).

La fila 5 de la Tabla 1.1 es la observación de las cinco variables para la ciudad de Cali (objeto 5):

$$x'_5 = (14,59, 0,08, 1,02, 0,22, 22)' = \begin{bmatrix} 14,59 \\ 0,08 \\ 1,02 \\ 0,22 \\ 22 \end{bmatrix}$$

y la variable X_4 Cobertura en educación superior es la columna

$$X_4 = \begin{bmatrix} 0,27 \\ 0,31 \\ \vdots \\ 0,15 \\ 0,17 \end{bmatrix}$$

¹Los comandos var() y cov() de R utilizan $n - 1$ y por tanto para los cálculos debe hacerse la modificación correspondiente.

1.2. VECTOR DE MEDIAS O CENTROIDE, MATRIZ DE COVARIANZAS Y MATRIZ DE CORRELACIÓN

Tabla 1.1: Tabla de datos multivariados de ciudades colombianas con indicadores de educación y la población en número de habitantes

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	284120	0.09	1.09	0.27	22.4
Barranquilla	1163007	0.09	1.08	0.31	22.5
Bogota	7050228	0.10	1.00	0.54	22.6
Bucaramanga	520080	0.08	1.19	0.33	22.2
Cali	2169801	0.08	1.02	0.22	22.0
Cartagena	912674	0.12	1.21	0.15	24.4
Cucuta	600049	0.11	1.15	0.22	22.4
Ibague	509796	0.11	0.98	0.18	23.4
Manizales	383483	0.08	1.14	0.23	22.2
Medellin	2264776	0.13	1.22	0.30	26.3
Monteria	390996	0.16	1.11	0.15	26.1
Neiva	322098	0.11	1.10	0.18	23.3
Pasto	394074	0.11	1.05	0.13	21.8
Pereira	448971	0.10	1.12	0.28	22.6
Popayan	261694	0.09	1.14	0.16	21.5
Riohacha	184847	0.27	1.00	0.15	26.1
San Andres	66675	0.08	0.80	0.11	20.4
Santa Marta	428374	0.12	1.00	0.12	22.9
Sincelejo	245180	0.16	1.23	0.11	24.9
Tunja	161209	0.10	1.04	0.24	22.1
Valledupar	373872	0.16	1.02	0.15	24.5
Villavicencio	400475	0.10	1.19	0.17	25.4

1.2. Vector de medias o centroide, matriz de covarianzas y matriz de correlación

Es el arreglo de las medias de las variables en un vector que se interpreta como el centro de gravedad o **centroide** de la matriz de datos y se define por:

$$med(X) = \bar{x} = \frac{1}{n} X' \mathbf{1}_n = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}, \text{ donde } \mathbf{1}_n = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1_n \end{bmatrix} \quad (1.4)$$

Ejemplo 1.2.1. El vector de medias de los indicadores de ciudades expresado como un vector es:
 $\bar{x}' = (13,09, 0,12, 1,09, 0,21, 23,27)'$. En la tabla 1.2 se muestra el mismo vector con los nombres de las variables correspondientes:

```
> # med<-round(t(colMeans(ciudades[,2:6])),2)
> med<-as.data.frame(round(colMeans(ciudades[,2:6]),2))
> colnames(med)<-c("Media")
```

Tabla 1.2: Vector de medias para variables de educación de la tabla de ciudades

	Media
Num.Hab	888021.77
Analfabetismo	0.12
Cobertura.pria.y.secdaria	1.09
Cobertura.ed.sup	0.21
Rel.al.prof	23.27

Matriz de datos centrados

$$\tilde{X} = X - \mathbf{1}_n \bar{x}' = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \cdots & x_{1p} - \bar{x}_p \\ x_{21} - \bar{x}_1 & x_{22} - \bar{x}_2 & \cdots & x_{2p} - \bar{x}_p \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} - \bar{x}_1 & x_{n2} - \bar{x}_2 & \cdots & x_{np} - \bar{x}_p \end{bmatrix}, \{\tilde{x}_{ij}\} = \{x_{ij} - \bar{x}_j\} \quad (1.5)$$

Observe que

$$\text{med}(\tilde{X}) = \frac{1}{n} \tilde{X}' \mathbf{1}_n = \left(\frac{1}{n} X' \mathbf{1}_n - \frac{1}{n} \bar{x}' \mathbf{1}_n' \mathbf{1}_n \right) = 0 \quad (1.6)$$

El comando para obtener la matriz de datos centrados es:

```
> Xtil<-scale(ciudades[,2:6], scale = F)
```

Matriz de covarianzas

Es una matriz simétrica que contiene en su diagonal las varianzas de las variables s_j^2 , y por fuera de la diagonal las covarianzas s_{jk} entre ellas.

$$S = \frac{1}{n} \tilde{X}' \tilde{X} = \begin{bmatrix} s_1^2 & s_{12} & \cdots & s_{1p} \\ s_{21} & s_2^2 & \cdots & s_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_p^2 \end{bmatrix}, \quad s_j^2 = s_{jj}$$

Nótese que comunmente se utiliza el estimador insesgado para la varianza $s_j = \frac{1}{(n-1)} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$, $j = 1, \dots, p$. Sin embargo, cuando se trata de datos poblacionales como es el caso de los datos de las ciudades colombianas, o cuando n es suficientemente grande, se puede utilizar como denominador n debido a que por ejemplo para $n > 100$, la diferencia entre dividir por n y por $n - 1$ resulta despreciable.

Ejemplo 1.2.2. En la tabla 1.3 se muestra la matriz de covarianzas entre los indicadores de las ciudades.

```
> MC<-var(ciudades[,2:6])
```

Matriz de datos centrados estandarizados

Esta matriz que se obtiene estandarizando la matriz de datos centrados como sigue:

$$\tilde{Y} = \tilde{X} D^{-1/2}, \quad \text{donde} \quad D = \text{diag} \{s_j^2\} \quad \text{y} \quad D^{-1/2} = \text{diag} \left\{ \frac{1}{s_j} \right\}, \quad (1.7)$$

1.2. VECTOR DE MEDIAS O CENTROIDE, MATRIZ DE COVARIANZAS Y MATRIZ DE CORRELACIÓN⁹

Tabla 1.3: Matriz de covarianzas de las variables del archivo de ciudades

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Num.Hab	2.228013e+12	-9797.725	-13331.063	116811.812	-34962.921
Analfabetismo	-9.797725e+03	0.002	0.000	-0.001	0.050
Cobertura.pria.y.secdaria	-1.333106e+04	0.000	0.010	0.001	0.070
Cobertura.ed.sup	1.168118e+05	-0.001	0.001	0.010	-0.025
Rel.al.prof	-3.496292e+04	0.050	0.070	-0.025	2.721

Explícitamente

$$\tilde{Y} = \begin{bmatrix} \frac{x_{11}-\bar{x}_1}{s_1} & \frac{x_{12}-\bar{x}_2}{s_2} & \dots & \frac{x_{1p}-\bar{x}_p}{s_p} \\ \frac{x_{21}-\bar{x}_1}{s_1} & \frac{x_{22}-\bar{x}_2}{s_2} & \dots & \frac{x_{2p}-\bar{x}_p}{s_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{x_{n1}-\bar{x}_1}{s_1} & \frac{x_{n2}-\bar{x}_2}{s_2} & \dots & \frac{x_{np}-\bar{x}_p}{s_p} \end{bmatrix}$$

Utilizando (1.5) se obtiene:

$$\text{med}(\tilde{Y}) = \tilde{Y}' \mathbf{1}_n = D^{-1/2} \tilde{X}' \mathbf{1}_n = D^{-1/2} \cdot 0 = 0$$

La matriz de datos centrados estandarizados se obtiene con el comando

```
> Xtil<-scale(ciudades[,2:6], scale = T)
```

Matriz de correlación

Es una matriz simétrica que contiene unos en la diagonal que son las correlaciones de las variables consigo mismas y por fuera de la diagonal las correlaciones r_{ij} entre pares de variables. Se define por el producto:

$$R = D^{-1/2} S D^{-1/2} \quad (1.8)$$

y también se obtiene a partir de la matriz de datos centrados estandarizados así:

$$R = \frac{1}{n} \tilde{Y}' \tilde{Y} = \begin{bmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \dots & 1 \end{bmatrix}, \quad r_{ij} = \frac{s_{ij}}{s_i s_j} \quad (1.9)$$

Nótese que la matriz de covarianzas de $\tilde{Y}$ es también R puesto que

$$S_{\tilde{Y}} = \frac{1}{n} \tilde{Y}' \tilde{Y} = \frac{1}{n} D^{-1/2} \tilde{X}' \tilde{X} D^{-1/2} = D^{-1/2} S D^{-1/2} = R \quad (1.10)$$

Matriz de datos centrados, estandarizados y normados

$$Y = \frac{1}{\sqrt{n}} \tilde{Y} = \frac{1}{\sqrt{n}} \tilde{X} D^{-1/2} \quad (1.11)$$

la cual también está centrada puesto que

$$\text{med}(Y) = \frac{1}{\sqrt{n}} \text{med}(\tilde{Y}) = 0$$

y por estar autoponderada por $\frac{1}{\sqrt{n}}$ el producto consigo misma es su matriz de covarianzas y también la matriz de correlación:

$$S_Y = Y' Y = \frac{1}{n} \tilde{Y}' \tilde{Y} = R. \quad (1.12)$$

Varianza total

Es un indicador de la variabilidad total de la matriz de datos. Se define por

$$V_T = \sum_{j=1}^p s_j^2 \quad (1.13)$$

En particular, como $S_{\tilde{Y}} = S_Y = R$ entonces:

$$V_T(\tilde{Y}) = V_T(Y) = p \quad (1.14)$$

Ejemplo 1.2.3. En la tabla 1.4 se muestra la matriz correlación entre las variables de la tabla de ciudades.

```
> # MCor<-round(cor(ciudades[,2:6]),2)
> # install.packages("Hmisc") # genera correlaciones y los p-val
> library(Hmisc)
> MCor = rcorr(as.matrix(ciudades[,2:6]), type = "pearson")
```

Allí sobresalen algunas correlaciones altas y significativas: una entre Cobertura.ed.sup y Num.Hab (0.79 con valor $p = 1.2e-05$). Otra entre Rel.al.prof y Analfabetismo (0.71, con valor $p = 0.000206$). Y un poco más baja pero también significativa entre Rel.al.prof y Cobertura.pria.y.secdaria (0.42, con valor $p = 0.049872$)

Tabla 1.4: Matriz de correlación de las variables del archivo de ciudades

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Num.Hab	1.00	-0.15	-0.09	0.79	-0.01
Analfabetismo	-0.15	1.00	-0.01	-0.34	0.71
Cobertura.pria.y.secdaria	-0.09	-0.01	1.00	0.09	0.42
Cobertura.ed.sup	0.79	-0.34	0.09	1.00	-0.15
Rel.al.prof	-0.01	0.71	0.42	-0.15	1.00

1.3. Combinaciones lineales

Una combinación lineal es una suma ponderada de los valores de una variable observada en varios objetos, como lo es la media por ser la suma de los valores de la variable ponderados por $1/n$, o como la varianza que es la suma de los desvíos de los valores de la variable respecto a la media $(x_i - \bar{x})^2$ ponderados por $1/n$.

También es combinación lineal la una suma ponderada de los valores de varias variables observadas en un mismo objeto. Son combinaciones lineales por ejemplo, los rankings universitarios; el índice de pobreza multidimensional es una combinación lineal por ser la suma ponderada de indicadores de temas como vivienda, servicios básicos, estándar de vida, educación y empleo, y protección social; también es combinación lineal el índice de desarrollo humano que es una suma ponderada de indicadores de dimensiones como la esperanza de vida, educación y riqueza. Así mismo son combinaciones lineales la mayoría de los índices o indicadores utilizados en economía y finanzas para describir y comparar cantidades de diferente naturaleza.

Las combinaciones lineales son útiles en muchos contextos estadísticos y especialmente en el caso de datos multivariados, donde por ejemplo, las componentes principales son combinaciones lineales de los valores de las variables cuyas ponderaciones se construyen para que acumulen la mayor cantidad posible de la varianza de las variables.

Combinación lineal de los valores de una variable observada en n objetos

Sea $X_{.j}$ la j -ésima columna de la matriz de datos como se definió en 1.2. Se define la combinación de los n valores de la variable j con constantes de ponderación $a' = (a_1, \dots, a_n)'$ por:

$$X_j^* = a' X_{.j} = \sum_{i=1}^n a_i x_{ij} \quad j = 1, \dots, p. \quad (1.15)$$

Ejemplo 1.3.1. El promedio de la variable j es una combinación lineal con constantes de ponderación $p' = (\frac{1}{n}, \dots, \frac{1}{n})'$:

$$\bar{x}_j = p' X_{.j} = \sum_{i=1}^n \frac{1}{n} x_{ij} \quad (1.16)$$

donde $X_{.j}$ es como en 1.2.

Combinación lineal de valores de p variables observadas sobre un mismo objeto

Para el objeto i cuyas observaciones están en la fila $x_{i.}$ de la matriz de datos, se define la combinación lineal de los valores de las p variables con ponderaciones $b' = (b_1, \dots, b_p)$ por:

$$z_i = b' x_{i.} = \sum_{j=1}^p b_j x_{ij} \quad i = 1, \dots, n \quad (1.17)$$

donde $x_{i.}$ es como en (1.3). Conviene aclarar que este tipo de combinaciones lineales solo tienen sentido si las variables están estandarizadas, o cuando todas vienen medidas en las mismas escalas.

Ejemplo 1.3.2. Los rankings universitarios son clasificaciones de universidades con criterios predefinidos por las entidades que los producen, de acuerdo con un modelo de universidad implícito que define lo que es una universidad de élite. Los criterios generalmente apuntan a ese modelo predefinido y por tanto pueden cambiar considerablemente de un ranking a otro.. Uno de los más exigentes del mundo es el Academic Rank of World Universities (ARWU) que utiliza los siguientes seis criterios de actividad académica e investigativa de las universidades (en paréntesis las ponderaciones de cada criterio):

- Premios Nobel de exalumnos (Score on Alumni: X_1) (10 %)
- Premios Nobel de docentes de la universidad (Score on Award: X_2) (20 %)
- Artículos altamente citados en 21 categorías temáticas (Score on HiCi: X_3) (20 %)
- artículos publicados en las reconocidas revistas Nature y Science (Score on N&S: X_4) (20 %)
- artículos indexados en alguno de los índices de citación como el Science Citation Index-expanded o en el Social Science Citation Index (Score on PUB: X_5) (20 %)
- Productividad per cápita de los docentes de la universidad (Score on PCP: X_6) (10 %)

Los valores de los rankings para las primeras 10 universidades en el año 2013 se muestran en la tabla 1.5:

El puntaje total (Total.Score) del ranking es una combinación lineal de los puntajes obtenidos por una universidad en los criterios con ponderaciones $b' = (0,1,0,2,0,2,0,2,0,2,0,1)$, de manera que por ejemplo para la universidad de Harvard, cuyos puntajes en los criterios que están en la fila uno de la tabla 1.5 son $x_1' = (100, 100, 100, 100, 100, 69, 2)$, el valor de su puntaje total en el ranking es:

Tabla 1.5: Puntajes de las diez primeras universidades del ARWU

	Alumni	Award	HiCi	N.S	PUB	PCP	Total.Score
Harvard	100.0	100.0	100.0	100.0	100.0	69.2	100.0
California, Berkeley	67.6	79.3	69.0	70.9	70.6	54.2	72.4
Stanford	40.2	78.4	87.6	68.4	69.7	50.1	72.1
MIT	70.5	80.3	66.8	70.1	61.4	64.5	71.4
Cambridge	88.5	92.6	53.9	54.3	65.7	53.1	69.6
California I of Tech	50.3	68.8	56.7	64.8	46.9	100.0	64.4
Princeton	56.4	84.8	61.1	43.3	44.3	65.5	60.8
Columbia	70.7	67.4	56.2	47.6	69.9	32.1	60.4
Chicago	65.5	83.9	50.9	39.8	50.5	40.0	57.3
Oxford	56.2	57.6	48.8	49.8	68.5	41.1	56.4

$$b'x_1 = y_1 = 0,1 \times 100 + 0,2 \times 100 + 0,2 \times 100 + 0,2 \times 100 + 0,2 \times 100 + 0,1 \times 69,2 = 0,9692$$

el cual ha sido ajustado a 100 en la tabla como máximo valor de referencia. Esto significa que para obtener los puntajes totales de la tabla hay que ajustar los valores que produce la combinación lineal. Por ejemplo, para la universidad de Cambridge x_5 la combinación lineal produce el puntaje:

$$b'x_5 = y_5 = 0,1 \times 88,5 + 0,2 \times 92,6 + 0,2 \times 53,9 + 0,2 \times 54,3 + 0,2 \times 65,7 + 0,1 \times 53,1 = 67,46$$

y por tanto después de ajustado con una regla de tres simple el puntaje total es $67,46/0,9692 = 69,6$.

1.4. Combinación lineal que produce las componentes principales

Las componentes principales son combinaciones lineales de los valores de las variables para cuya construcción se utilizan unas ponderaciones $v'_1 = (v_{11}, \dots, v_{p1})$ tales que por ejemplo, la primera componente para el objeto i cuyas observaciones para las p variables están la i -ésima fila de Y la matriz de datos centrados estandarizados y_i , tiene la forma:

$$z_{i1} = y'_i v_1 = \sum_{j=1}^p v_{j1} y_{ij}, \quad i = 1, \dots, n \quad (1.18)$$

y por tanto ésta es un promedio ponderado de los valores de las variables observadas en el objeto i . Dicho de otra forma, la primera componente para el objeto i es la proyección de los valores de las variables observadas en éste, sobre el vector de ponderaciones v_1 . En el siguiente capítulo se hace la construcción formal de las componentes y las ponderaciones. Como se verá en el siguiente capítulo, estas componentes tienen, entre otras, dos importantes propiedades:

Van en direcciones que acumulan la mayor cantidad posible de varianza de la tabla de datos X , útil para reducir la dimensionalidad del problema en el sentido de que basta con unas cuantas de ellas para interpretar y descubrir asociaciones e información intrínseca en los datos.

que **Todas las componentes son ortogonales entre sí**, que facilita representaciones gráficas de los datos.

1.5. Teorema de la descomposición espectral (TDE)

Este teorema garantiza que una matriz simétrica $B_{p \times p}$, como la matriz de covarianzas o de correlación (ambas semidefinidas positivas), se puede reconstruir (o factorizar) a partir de sus **valores** y **vectores propios** como

sigue:

$$B = U \Lambda U' \quad (1.19)$$

donde $U_{p \times p}$ es una **matriz ortogonal cuyas columnas son los vectores propios estandarizados de B** y $\Lambda = \text{diag}\{\lambda_\alpha\}$, $\lambda_\alpha \geq 0$ y $\lambda_1 \geq \dots \geq \lambda_p$, son los **valores propios de B** arreglados en forma descendente.

1.6. Teorema de la descomposición en valores singulares (TDVS)

La descomposición en valores singulares es un poco más general que el TDE puesto que no requiere que la matriz a descomponer sea simétrica, lo cual garantiza que también la matriz de datos se puede descomponer. El **TDVS** garantiza que una matriz $C_{n \times p}$, con $n \geq p$ y rango r , equivalentemente con r columnas linealmente independientes (por ejemplo la matriz de datos X o la estandarizada Y definida en (??)) se puede factorizar así (ver por ejemplo Sudipto & Anindya (2014) Mardia et al. (1992)):

$$C = U L V' \quad (1.20)$$

donde

U y V son matrices con columnas ortonormales lo que implica $U'U = V'V = I_r$.

$L_{r \times r} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_r})$, $\sqrt{\lambda_1} \geq \sqrt{\lambda_2} \geq \dots \geq \sqrt{\lambda_r} > 0$.

$\sqrt{\lambda_j}$ son los valores singulares de C ,

$V_{p \times r} = (v_1, \dots, v_r)$ contiene en sus columnas los vectores propios de $C'C$,

$U_{n \times r} = (u_1, \dots, u_r)$ contiene en sus columnas los vectores propios de CC' ,

La equivalencia con los valores propios no nulos de CC' se establece escogiendo

$$L = \text{diag}(\sqrt{\mu_1}, \dots, \sqrt{\mu_r}),$$

donde μ_α es el α -ésimo valor propio no nulo de CC' . No obstante, no es necesario escribir ambas versiones, ya que los valores propios no nulos de $C'C$ y CC' coinciden.

En efecto, si L contiene las raíces cuadradas de los valores propios de $C'C$, entonces

$$C'C u_\alpha = \lambda_\alpha u_\alpha,$$

mientras que si L contiene las raíces cuadradas de los valores propios de CC' , se tiene

$$CC' v_\alpha = \mu_\alpha v_\alpha.$$

La teoría espectral garantiza que

$$\lambda_\alpha = \mu_\alpha, \quad \alpha = 1, \dots, r,$$

y, por tanto, ambas formulaciones del TDVS son equivalentes.

La Descomposición en Valores Singulares (TDVS) constituye un resultado más general que el Teorema de la Descomposición Espectral (TDE), en la medida en que no requiere que la matriz a descomponer sea simétrica. Sin embargo, cuando la TDVS se aplica a una matriz simétrica $B_{p \times p}$, se obtiene como caso particular el TDE (ver, por ejemplo, Mardia et al. (1979), Sudipto & Anindya (2014)).

La TDVS de una matriz real B se escribe como

$$B = U L V',$$

donde U y V son matrices ortonormales tales que $U'U = V'V = I_p$, y $L = \text{diag}(\sigma_1, \dots, \sigma_p)$ contiene los valores singulares de B , ordenados típicamente como $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$.

Si B es simétrica, entonces $B' = B$. Pero la TDVS implica que

$$B' = V L U'.$$

Igualando ambas expresiones, se obtiene

$$U L V' = V L U'.$$

Esto solo puede cumplirse si U y V coinciden (hasta un posible cambio de signo en algunas columnas), de modo que

$$U = V.$$

Sustituyendo en la descomposición TDVS, esta se reduce a

$$B = U L U'.$$

Para una matriz simétrica real, los valores singulares σ_j satisfacen $\sigma_j = |\lambda_j|$, donde λ_j es el j -ésimo valor propio de B . Si, además, B es semidefinida positiva (como sucede en aplicaciones estadísticas al considerar matrices de covarianzas, correlaciones o productos matriciales $X'X$), se tiene $\lambda_j \geq 0$, lo cual implica que $\sigma_j = \lambda_j$, es decir que . En tal caso, la matriz L coincide con la matriz diagonal de valores propios,

$$L = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p). \quad (1.21)$$

Así, la TDVS aplicada a una matriz simétrica produce exactamente el TDE:

$$B = U \Lambda U',$$

donde Λ contiene los valores propios λ_j de B y las columnas de U son los vectores propios asociados. De esta forma, el TDE se obtiene como un caso particular de la TDVS, con valores singulares coincidiendo con los valores propios y vectores singulares coincidiendo con los vectores propios de B .

Ejemplo 1.6.1. *Reconstrucción de la matriz de datos de los puntajes de las universidades en los criterios del ranking ARWU a partir del TDVS. El ejercicio implica los siguientes pasos:*

1. **Lectura de los datos** y construcción de la matriz $C \in \mathbb{R}^{n \times p}$. con los puntajes de las universidades

2. **Cálculo de las matrices**

$$C'C \quad \text{y} \quad CC'.$$

3. **Cálculo de**

- los valores propios de $C'C$,
- la matriz V de vectores propios de $C'C$.

4. **Selección de los valores propios estrictamente positivos** y construcción de la submatriz V_r con los vectores propios asociados.

5. **Cálculo de los valores singulares de C :**

$$\sigma_\alpha = \sqrt{\lambda_\alpha}.$$

6. **Construcción de la matriz diagonal**

$$L = \text{diag}(\sigma_1, \dots, \sigma_r).$$

7. **Cálculo de la matriz U de vectores propios de CC' mediante**

$$U = CV_r L^{-1}, \quad \text{donde } U'U = I_r.$$

8. **Reconstrucción de la matriz C usando el TDVS:**

$$C = ULV_r'.$$

9. Evaluación del error de reconstrucción, calculando la diferencia:

$$C - ULV_r'$$

o equivalentemente:

$$\|C - ULV_r'\|_F \approx 0$$

Matriz reconstruida

	[, 1]	[, 2]	[, 3]	[, 4]	[, 5]	[, 6]
Harvard	100.0	100.0	100.0	100.0	100.0	69.2
California, Berkeley	67.6	79.3	69.0	70.9	70.6	54.2
Stanford	40.2	78.4	87.6	68.4	69.7	50.1
MIT	70.5	80.3	66.8	70.1	61.4	64.5
Cambridge	88.5	92.6	53.9	54.3	65.7	53.1
California I of Tech	50.3	68.8	56.7	64.8	46.9	100.0
Princeton	56.4	84.8	61.1	43.3	44.3	65.5
Columbia	70.7	67.4	56.2	47.6	69.9	32.1
Chicago	65.5	83.9	50.9	39.8	50.5	40.0
Oxford	56.2	57.6	48.8	49.8	68.5	41.1

Calculo del error en la aproximación

	Alumni	Award	HiCi	N.S	PUB	PCP
Harvard	0	0	0	0	0	0
California, Berkeley	0	0	0	0	0	0
Stanford	0	0	0	0	0	0
MIT	0	0	0	0	0	0
Cambridge	0	0	0	0	0	0
California I of Tech	0	0	0	0	0	0
Princeton	0	0	0	0	0	0
Columbia	0	0	0	0	0	0
Chicago	0	0	0	0	0	0
Oxford	0	0	0	0	0	0

Reconstrucción directa con comandos de R

[1] 5.868326e-13

Reconstrucción desde comandos R

	[, 1]	[, 2]	[, 3]	[, 4]	[, 5]	[, 6]
[1,]	100.0	100.0	100.0	100.0	100.0	69.2
[2,]	67.6	79.3	69.0	70.9	70.6	54.2
[3,]	40.2	78.4	87.6	68.4	69.7	50.1
[4,]	70.5	80.3	66.8	70.1	61.4	64.5
[5,]	88.5	92.6	53.9	54.3	65.7	53.1
[6,]	50.3	68.8	56.7	64.8	46.9	100.0
[7,]	56.4	84.8	61.1	43.3	44.3	65.5
[8,]	70.7	67.4	56.2	47.6	69.9	32.1
[9,]	65.5	83.9	50.9	39.8	50.5	40.0
[10,]	56.2	57.6	48.8	49.8	68.5	41.1

Error en la aproximación desde comandos R

[1] 5.868326e-13

1.7. Laboratorio

Utilizar los datos del archivo “original-filtrado-con etiquetas” y los mismos grupos de variables asignados en el ejercicio ?? del Laboratorio ?? y la subtabla de indicadores de Recursos Humanos del mismo archivo de ciudades para conformar una nueva tabla que contenga los dos conjuntos de variables.

1. Calcular el vector de medias de todas las variables del conjunto que le correspondió al grupo.
2. Calcular la matriz de datos centrados
3. Calcular la matriz de covarianzas a partir de la matriz de datos centrados.
4. Calcular la matriz de covarianzas con el comando *cov* de R. ¿Coincide con la obtenida a partir de la matriz de datos centrados? ¿Sí? ¿No? ¿Por qué?
5. Calcular la matriz $\tilde{Y}$ de datos centrados estandarizados1.
6. Calcular la matriz de correlación a partir de la matriz de datos centrados estandarizados.

Calcular la matriz de correlación con el comando *cor* de R. ¿coincide con $\frac{1}{n}\tilde{Y}'\tilde{Y}$? ¿Sí? ¿No? ¿Por qué?

7. Calcular la matriz de covarianzas S e Identificar las dos variables con mayor covarianza y las dos con menor covarianza
8. Calcular la matriz de correlación R e Identificar las dos variables con mayor correlación y las dos con menor correlación. ¿Son las mismas que las que tienen mayor y menor covarianza identificadas en el punto 7?
9. Calcular el producto $\frac{1}{n}Y'Y$ y verificar que es exactamente la matriz R obtenida en el punto 8. ¿Por qué?
10. Comprobar que la matriz de covarianzas se puede obtener con el producto $\frac{1}{n}\tilde{X}'\tilde{X}$.
11. Comprobar que la matriz de correlación se puede obtener con el producto $\frac{1}{n}Y'Y$.
12. Construir una matriz de datos los puntajes en los seis criterios del ranking arwu para las universidades asignadas al grupo y comprobar que con el TDVS se puede reconstruirla.

- **Grupo 1:** universidades en puestos 91 a 100 inclusive.
- **Grupo 2:** universidades en puestos 81 a 90 inclusive.
- **Grupo 3:** universidades en puestos 71 a 80 inclusive.
- **Grupo 4:** universidades en puestos 61 a 70 inclusive.
- **Grupo 5:** universidades en puestos 51 a 60 inclusive.
- **Grupo 6:** universidades en puestos 41 a 50 inclusive.

Bibliografía

Mardia, K., Kent, J. & BibbY, J. (1992), *Multivariate Analysis*, eighth printing edn, Academic Press, San Diego, CA 92101.

Mardia, K. V., Kent, J. T. & Bibby, J. M. (1979), *Multivariate Analysis*, Academic Press, London.

Sudipto, B. & Anindya, R. (2014), Linear algebra and matrix analysis for statistics, in ‘Texts in Statistical Science’, Chapman and Hall/CRC.