

Medidas descriptivas multivariadas

Por:

Jimmy A. Corzo S.

Profesor Titular

Departamento de Estadística

Facultad de Ciencias

Universidad Nacional de Colombia- Sede Bogotá

18 de marzo de 2026

Índice general

1. Medidas descriptivas multivariadas	5
1.1. Notación	5
1.2. Vector de medias o centroide, matriz de covarianzas y matriz de correlación	7
1.3. Combinaciones lineales	10
1.4. Combinación lineal que produce las componentes principales	12
1.5. Datos atípicos en una variable - Rango intercuartílico: $IQR = Q_{0,75} - Q_{0,25}$	12
1.6. El problema de datos atípicos en varias variables	15
1.7. Distancias entre observaciones multivariadas	15
1.7.1. Distancia del valor absoluto	16
1.7.2. Distancia Manhattan	16
1.7.3. Distancia euclidiana	16
1.7.4. Distancia de Mahalanobis	18
1.8. Teorema de la descomposición espectral (TDE)	21
1.9. Teorema de la descomposición en valores singulares (TDVS)	21
1.10. Laboratorio	23

```
> confianza = read.csv2(paste0(rut_archv, "Confianza.csv"))
```

Capítulo 1

Medidas descriptivas multivariadas

1.1. Notación

Por analogía con los métodos univariados y bivariados, medidas como la media, la varianza, la covarianza y el coeficiente de correlación tienen su versión multivariada que corresponde a arreglos de éstas mismas medidas en vectores como el vector de medias o en matrices como la matriz de covarianzas o la matriz de correlación, entre otros.

En el contexto multivariado se observan p variables $X_1, \dots, X_p$ simultáneamente sobre un mismo objeto i (que puede ser una ciudad, una universidad, una planta, una persona), y por tanto una observación para el objeto i es un vector de p componentes $x'_i = (x_{i1}, \dots, x_{ip})$, donde x_{ij} es la observación de la variable j sobre el objeto i . Para n objetos las observaciones se arreglan en una tabla de datos como la siguiente:

	Variables				
Objeto	X_1	$\cdots$	X_j	$\cdots$	X_p
1	x_{11}	$\cdots$	x_{1j}	$\cdots$	x_{1p}
$\vdots$	$\vdots$	$\cdots$	$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\cdots$	x_{ij}	$\cdots$	$\vdots$
$\vdots$	$\vdots$	$\cdots$	$\vdots$	$\vdots$	$\vdots$
n	x_{n1}	$\cdots$	x_{nj}	$\cdots$	x_{np}

La media, la varianza, la covarianza y el coeficiente de correlación se definen de la misma forma que en el caso univariado agregando subíndices que identifican la variable para la que se están calculando como sigue:

$$\begin{aligned}
 \bar{x}_j &= med(X_j) = \frac{1}{n} \sum_{i=1}^n x_{ij} && \text{media de la variable } X_j \\
 s_j^2 &= var(X_j) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 && \text{varianza de la variable } X_j \\
 s_{jk} &= cov(X_j, X_k) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k), && s_{jj} = s_j^2 \\
 r_{jk} &= corr(X_j, X_k) = \frac{s_{jk}}{s_j s_k}, && s_j = \sqrt{s_j^2}
 \end{aligned} \tag{1.1}$$

Nótese que para el cálculo de la varianza y la covarianza, se utilizó como denominador n debido a que en datos multivariados se considera suficientemente grande como para que s^2 siga siendo un estimador insesgado de la varianza poblacional¹.

Para propósitos de cálculos las tablas de datos multivariados se consideran también matrices de datos. Por esta razón se utilizará aquí la palabra **tabla** para referirse a los datos con nombres en las filas y columnas, y el término **matriz** cuando se van a utilizar las propiedades algebraicas de la tabla. En este caso se le llama matriz de datos X y se define por:

$$X = \{x_{ij}\} = \begin{bmatrix} x_{11} & \cdots x_{1j} & \cdots & x_{1p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{i1} & \cdots x_{ij} & \cdots & x_{ip} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & \cdots x_{nj} & \cdots & x_{np} \end{bmatrix}$$

Se define **Varianza total** de los datos

En esta matriz la columna j , o el punto-variable j , representa las observaciones de la variable X_j sobre los n objetos y se denota como un vector columna:

$$X_{.j} = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix}, j = 1, \dots, p \quad (1.2)$$

Análogamente, la fila i , o punto objeto i , representa las observaciones de las p variables sobre el objeto i y se denota como un vector columna;

$$x_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{bmatrix} = (x_{i1}, \dots, x_{ip})', i = 1, \dots, n. \quad (1.3)$$

Ejemplo 1.1.1. La Tabla 1.1 es típica de un **pequeño** conjunto de datos multivariados con $p = 5$ variables y $n = 22$ ciudades colombianas (objetos). Las variables son: X_1 : Num.Hab (número de habitantes), X_2 : indicador de analfabetismo, X_3 : Cobertura.pria.secdaria (indicador de cobertura en educación primaria y secundaria), X_4 : Cobertura.ed.sup (indicador de cobertura en educación superior) y X_5 : Rel.al.prof (relación alumno profesor).

La fila 5 de la Tabla 1.1 es la observación de las cinco variables para la ciudad de Cali (objeto 5):

$$x'_5 = (14,59, 0,08, 1,02, 0,22, 22)' = \begin{bmatrix} 14,59 \\ 0,08 \\ 1,02 \\ 0,22 \\ 22 \end{bmatrix}$$

y la variable X_4 Cobertura en educación superior es la columna

$$X_4 = \begin{bmatrix} 0,27 \\ 0,31 \\ \vdots \\ 0,15 \\ 0,17 \end{bmatrix}$$

¹Los comandos var() y cov() de R utilizan $n - 1$ y por tanto para los cálculos debe hacerse la modificación correspondiente.

1.2. VECTOR DE MEDIAS O CENTROIDE, MATRIZ DE COVARIANZAS Y MATRIZ DE CORRELACIÓN

Tabla 1.1: Tabla de datos multivariados de ciudades colombianas con indicadores de educación y la población en número de habitantes

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	284120	0.09	1.09	0.27	22.4
Barranquilla	1163007	0.09	1.08	0.31	22.5
Bogota	7050228	0.10	1.00	0.54	22.6
Bucaramanga	520080	0.08	1.19	0.33	22.2
Cali	2169801	0.08	1.02	0.22	22.0
Cartagena	912674	0.12	1.21	0.15	24.4
Cucuta	600049	0.11	1.15	0.22	22.4
Ibague	509796	0.11	0.98	0.18	23.4
Manizales	383483	0.08	1.14	0.23	22.2
Medellin	2264776	0.13	1.22	0.30	26.3
Monteria	390996	0.16	1.11	0.15	26.1
Neiva	322098	0.11	1.10	0.18	23.3
Pasto	394074	0.11	1.05	0.13	21.8
Pereira	448971	0.10	1.12	0.28	22.6
Popayan	261694	0.09	1.14	0.16	21.5
Riohacha	184847	0.27	1.00	0.15	26.1
San Andres	66675	0.08	0.80	0.11	20.4
Santa Marta	428374	0.12	1.00	0.12	22.9
Sincelejo	245180	0.16	1.23	0.11	24.9
Tunja	161209	0.10	1.04	0.24	22.1
Valledupar	373872	0.16	1.02	0.15	24.5
Villavicencio	400475	0.10	1.19	0.17	25.4

1.2. Vector de medias o centroide, matriz de covarianzas y matriz de correlación

Es el arreglo de las medias de las variables en un vector que se interpreta como el centro de gravedad o **centroide** de la matriz de datos y se define por:

$$med(X) = \bar{x} = \frac{1}{n} X' \mathbf{1}_n = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}, \text{ donde } \mathbf{1}_n = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1_n \end{bmatrix} \quad (1.4)$$

Ejemplo 1.2.1. El vector de medias de los indicadores de ciudades expresado como un vector es:
 $\bar{x}' = (13,09, 0,12, 1,09, 0,21, 23,27)'$. En la tabla 1.2 se muestra el mismo vector con los nombres de las variables correspondientes:

```
> # med<-round(t(colMeans(ciudades[,2:6])),2)
> med<-as.data.frame(round(colMeans(ciudades[,2:6]),2))
> colnames(med)<-c("Media")
```

Tabla 1.2: Vector de medias para variables de educación de la tabla de ciudades

	Media
Num.Hab	888021.77
Analfabetismo	0.12
Cobertura.pria.y.secdaria	1.09
Cobertura.ed.sup	0.21
Rel.al.prof	23.27

Matriz de datos centrados

$$\tilde{X} = X - \mathbf{1}_n \bar{x}' = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \cdots & x_{1p} - \bar{x}_p \\ x_{21} - \bar{x}_1 & x_{22} - \bar{x}_2 & \cdots & x_{2p} - \bar{x}_p \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} - \bar{x}_1 & x_{n2} - \bar{x}_2 & \cdots & x_{np} - \bar{x}_p \end{bmatrix}, \{\tilde{x}_{ij}\} = \{x_{ij} - \bar{x}_j\} \quad (1.5)$$

Observe que

$$\text{med}(\tilde{X}) = \frac{1}{n} \tilde{X}' \mathbf{1}_n = \left(\frac{1}{n} X' \mathbf{1}_n - \frac{1}{n} \bar{x}' \mathbf{1}_n' \mathbf{1}_n \right) = 0 \quad (1.6)$$

El comando para obtener la matriz de datos centrados es:

```
> Xtil<-scale(ciudades[,2:6], scale = F)
```

Matriz de covarianzas

Es una matriz simétrica que contiene en su diagonal las varianzas de las variables s_j^2 , y por fuera de la diagonal las covarianzas s_{jk} entre ellas.

$$S = \frac{1}{n} \tilde{X}' \tilde{X} = \begin{bmatrix} s_1^2 & s_{12} & \cdots & s_{1p} \\ s_{21} & s_2^2 & \cdots & s_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_p^2 \end{bmatrix}, \quad s_j^2 = s_{jj}$$

Nótese que comunmente se utiliza el estimador insesgado para la varianza $s_j = \frac{1}{(n-1)} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$, $j = 1, \dots, p$. Sin embargo, cuando se trata de datos poblacionales como es el caso de los datos de las ciudades colombianas, o cuando n es suficientemente grande, se puede utilizar como denominador n debido a que por ejemplo para $n > 100$, la diferencia entre dividir por n y por $n - 1$ resulta despreciable.

Ejemplo 1.2.2. En la tabla 1.3 se muestra la matriz de covarianzas entre los indicadores de las ciudades.

```
> MC<-var(ciudades[,2:6])
```

Matriz de datos centrados estandarizados

Esta matriz que se obtiene estandarizando la matriz de datos centrados como sigue:

$$\tilde{Y} = \tilde{X} D^{-1/2}, \quad \text{donde} \quad D = \text{diag} \{s_j^2\} \quad \text{y} \quad D^{-1/2} = \text{diag} \left\{ \frac{1}{s_j} \right\}, \quad (1.7)$$

1.2. VECTOR DE MEDIAS O CENTROIDE, MATRIZ DE COVARIANZAS Y MATRIZ DE CORRELACIÓN⁹

Tabla 1.3: Matriz de covarianzas de las variables del archivo de ciudades

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Num.Hab	2.228013e+12	-9797.725	-13331.063	116811.812	-34962.921
Analfabetismo	-9.797725e+03	0.002	0.000	-0.001	0.050
Cobertura.pria.y.secdaria	-1.333106e+04	0.000	0.010	0.001	0.070
Cobertura.ed.sup	1.168118e+05	-0.001	0.001	0.010	-0.025
Rel.al.prof	-3.496292e+04	0.050	0.070	-0.025	2.721

Explícitamente

$$\tilde{Y} = \begin{bmatrix} \frac{x_{11}-\bar{x}_1}{s_1} & \frac{x_{12}-\bar{x}_2}{s_2} & \dots & \frac{x_{1p}-\bar{x}_p}{s_p} \\ \frac{x_{21}-\bar{x}_1}{s_1} & \frac{x_{22}-\bar{x}_2}{s_2} & \dots & \frac{x_{2p}-\bar{x}_p}{s_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{x_{n1}-\bar{x}_1}{s_1} & \frac{x_{n2}-\bar{x}_2}{s_2} & \dots & \frac{x_{np}-\bar{x}_p}{s_p} \end{bmatrix}$$

Utilizando (1.5) se obtiene:

$$\text{med}(\tilde{Y}) = \tilde{Y}' \mathbf{1}_n = D^{-1/2} \tilde{X}' \mathbf{1}_n = D^{-1/2} \cdot 0 = 0$$

La matriz de datos centrados estandarizados se obtiene con el comando

```
> Xtil<-scale(ciudades[,2:6], scale = T)
```

Matriz de correlación

Es una matriz simétrica que contiene unos en la diagonal que son las correlaciones de las variables consigo mismas y por fuera de la diagonal las correlaciones r_{ij} entre pares de variables. Se define por el producto:

$$R = D^{-1/2} S D^{-1/2} \quad (1.8)$$

y también se obtiene a partir de la matriz de datos centrados estandarizados así:

$$R = \frac{1}{n} \tilde{Y}' \tilde{Y} = \begin{bmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \dots & 1 \end{bmatrix}, \quad r_{ij} = \frac{s_{ij}}{s_i s_j} \quad (1.9)$$

Nótese que la matriz de covarianzas de $\tilde{Y}$ es también R puesto que

$$S_{\tilde{Y}} = \frac{1}{n} \tilde{Y}' \tilde{Y} = \frac{1}{n} D^{-1/2} \tilde{X}' \tilde{X} D^{-1/2} = D^{-1/2} S D^{-1/2} = R \quad (1.10)$$

Matriz de datos centrados, estandarizados y normados

$$Y = \frac{1}{\sqrt{n}} \tilde{Y} = \frac{1}{\sqrt{n}} \tilde{X} D^{-1/2} \quad (1.11)$$

la cual también está centrada puesto que

$$\text{med}(Y) = \frac{1}{\sqrt{n}} \text{med}(\tilde{Y}) = 0$$

y por estar autoponderada por $\frac{1}{\sqrt{n}}$ el producto consigo misma es su matriz de covarianzas y también la matriz de correlación:

$$S_Y = Y' Y = \frac{1}{n} \tilde{Y}' \tilde{Y} = R. \quad (1.12)$$

Varianza total

Es un indicador de la variabilidad total de la matriz de datos. Se define por

$$V_T = \sum_{j=1}^p s_j^2 \quad (1.13)$$

En particular, como $S_{\tilde{Y}} = S_Y = R$ entonces:

$$V_T(\tilde{Y}) = V_T(Y) = p \quad (1.14)$$

Ejemplo 1.2.3. En la tabla 1.4 se muestra la matriz correlación entre las variables de la tabla de ciudades.

```
> # MCor<-round(cor(ciudades[,2:6]),2)
> # install.packages("Hmisc") # genera correlaciones y los p-val
> library(Hmisc)
> MCor = rcorr(as.matrix(ciudades[,2:6]), type = "pearson")
```

Allí sobresalen algunas correlaciones altas y significativas: una entre Cobertura.ed.sup y Num.Hab (0.79 con valor $p = 1.2e-05$). Otra entre Rel.al.prof y Analfabetismo (0.71, con valor $p = 0.000206$). Y un poco más baja pero también significativa entre Rel.al.prof y Cobertura.pria.y.secdaria (0.42, con valor $p = 0.049872$)

Tabla 1.4: Matriz de correlación de las variables del archivo de ciudades

	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Num.Hab	1.00	-0.15	-0.09	0.79	-0.01
Analfabetismo	-0.15	1.00	-0.01	-0.34	0.71
Cobertura.pria.y.secdaria	-0.09	-0.01	1.00	0.09	0.42
Cobertura.ed.sup	0.79	-0.34	0.09	1.00	-0.15
Rel.al.prof	-0.01	0.71	0.42	-0.15	1.00

1.3. Combinaciones lineales

Una combinación lineal es una suma ponderada de los valores de una variable observada en varios objetos, como lo es la media por ser la suma de los valores de la variable ponderados por $1/n$, o como la varianza que es la suma de los desvíos de los valores de la variable respecto a la media $(x_i - \bar{x})^2$ ponderados por $1/n$.

También es combinación lineal la una suma ponderada de los valores de varias variables observadas en un mismo objeto. Son combinaciones lineales por ejemplo, los rankings universitarios; el índice de pobreza multidimensional es una combinación lineal por ser la suma ponderada de indicadores de temas como vivienda, servicios básicos, estándar de vida, educación y empleo, y protección social; también es combinación lineal el índice de desarrollo humano que es una suma ponderada de indicadores de dimensiones como la esperanza de vida, educación y riqueza. Así mismo son combinaciones lineales la mayoría de los índices o indicadores utilizados en economía y finanzas para describir y comparar cantidades de diferente naturaleza.

Las combinaciones lineales son útiles en muchos contextos estadísticos y especialmente en el caso de datos multivariados, donde por ejemplo, las componentes principales son combinaciones lineales de los valores de las variables cuyas ponderaciones se construyen para que acumulen la mayor cantidad posible de la varianza de las variables.

Combinación lineal de los valores de una variable observada en n objetos

Sea $X_{.j}$ la j -ésima columna de la matriz de datos como se definió en 1.2. Se define la combinación de los n valores de la variable j con constantes de ponderación $a' = (a_1, \dots, a_n)'$ por:

$$X_j^* = a' X_{.j} = \sum_{i=1}^n a_i x_{ij} \quad j = 1, \dots, p. \quad (1.15)$$

Ejemplo 1.3.1. El promedio de la variable j es una combinación lineal con constantes de ponderación $p' = (\frac{1}{n}, \dots, \frac{1}{n})'$:

$$\bar{x}_j = p' X_{.j} = \sum_{i=1}^n \frac{1}{n} x_{ij} \quad (1.16)$$

donde $X_{.j}$ es como en 1.2.

Combinación lineal de valores de p variables observadas sobre un mismo objeto

Para el objeto i cuyas observaciones están en la fila $x_{i.}$ de la matriz de datos, se define la combinación lineal de los valores de las p variables con ponderaciones $b' = (b_1, \dots, b_p)$ por:

$$z_i = b' x_{i.} = \sum_{j=1}^p b_j x_{ij} \quad i = 1, \dots, n \quad (1.17)$$

donde $x_{i.}$ es como en (1.3). Conviene aclarar que este tipo de combinaciones lineales solo tienen sentido si las variables están estandarizadas, o cuando todas vienen medidas en las mismas escalas.

Ejemplo 1.3.2. Los rankings universitarios son clasificaciones de universidades con criterios predefinidos por las entidades que los producen, de acuerdo con un modelo de universidad implícito que define lo que es una universidad de élite. Los criterios generalmente apuntan a ese modelo predefinido y por tanto pueden cambiar considerablemente de un ranking a otro.. Uno de los más exigentes del mundo es el Academic Rank of World Universities (ARWU) que utiliza los siguientes seis criterios de actividad académica e investigativa de las universidades (en paréntesis las ponderaciones de cada criterio):

- Premios Nobel de exalumnos (Score on Alumni: X_1) (10 %)
- Premios Nobel de docentes de la universidad (Score on Award: X_2) (20 %)
- Artículos altamente citados en 21 categorías temáticas (Score on HiCi: X_3) (20 %)
- artículos publicados en las reconocidas revistas Nature y Science (Score on N&S: X_4) (20 %)
- artículos indexados en alguno de los índices de citación como el Science Citation Index-expanded o en el Social Science Citation Index (Score on PUB: X_5) (20 %)
- Productividad per cápita de los docentes de la universidad (Score on PCP: X_6) (10 %)

Los valores de los rankings para las primeras 10 universidades en el año 2013 se muestran en la tabla 1.5:

El puntaje total (Total.Score) del ranking es una combinación lineal de los puntajes obtenidos por una universidad en los criterios con ponderaciones $b' = (0,1,0,2,0,2,0,2,0,2,0,1)$, de manera que por ejemplo para la universidad de Harvard, cuyos puntajes en los criterios que están en la fila uno de la tabla 1.5 son $x_1' = (100, 100, 100, 100, 100, 69, 2)$, el valor de su puntaje total en el ranking es:

Tabla 1.5: Puntajes de las diez primeras universidades del ARWU

	Alumni	Award	HiCi	N.S	PUB	PCP	Total.Score
Harvard	100.0	100.0	100.0	100.0	100.0	69.2	100.0
California, Berkeley	67.6	79.3	69.0	70.9	70.6	54.2	72.4
Stanford	40.2	78.4	87.6	68.4	69.7	50.1	72.1
MIT	70.5	80.3	66.8	70.1	61.4	64.5	71.4
Cambridge	88.5	92.6	53.9	54.3	65.7	53.1	69.6
California I of Tech	50.3	68.8	56.7	64.8	46.9	100.0	64.4
Princeton	56.4	84.8	61.1	43.3	44.3	65.5	60.8
Columbia	70.7	67.4	56.2	47.6	69.9	32.1	60.4
Chicago	65.5	83.9	50.9	39.8	50.5	40.0	57.3
Oxford	56.2	57.6	48.8	49.8	68.5	41.1	56.4

$$b'x_1 = y_1 = 0,1 \times 100 + 0,2 \times 100 + 0,2 \times 100 + 0,2 \times 100 + 0,2 \times 100 + 0,1 \times 69,2 = 0,9692$$

el cual ha sido ajustado a 100 en la tabla como máximo valor de referencia. Esto significa que para obtener los puntajes totales de la tabla hay que ajustar los valores que produce la combinación lineal. Por ejemplo, para la universidad de Cambridge x_5 la combinación lineal produce el puntaje:

$$b'x_5 = y_5 = 0,1 \times 88,5 + 0,2 \times 92,6 + 0,2 \times 53,9 + 0,2 \times 54,3 + 0,2 \times 65,7 + 0,1 \times 53,1 = 67,46$$

y por tanto después de ajustado con una regla de tres simple el puntaje total es $67,46/0,9692 = 69,6$.

1.4. Combinación lineal que produce las componentes principales

Las componentes principales son combinaciones lineales de los valores de las variables para cuya construcción se utilizan unas ponderaciones $v'_1 = (v_{11}, \dots, v_{p1})$ tales que por ejemplo, la primera componente para el objeto i cuyas observaciones para las p variables están la i ésima fila de Y la matriz de datos centrados estandarizados y_i , tiene la forma:

$$z_{i1} = y'_i v_1 = \sum_{j=1}^p v_{j1} y_{ij}, \quad i = 1, \dots, n \quad (1.18)$$

y por tanto ésta es un promedio ponderado de los valores de las variables observadas en el objeto i . Dicho de otra forma, la primera componente para el objeto i es la proyección de los valores de las variables observadas en éste, sobre el vector de ponderaciones v_1 . En el siguiente capítulo se hace la construcción formal de las componentes y las ponderaciones. Como se verá en el siguiente capítulo, estas componentes tienen, entre otras, dos importantes propiedades:

Van en direcciones que acumulan la mayor cantidad posible de varianza de la tabla de datos X , útil para reducir la dimensionalidad del problema en el sentido de que basta con unas cuantas de ellas para interpretar y descubrir asociaciones e información intrínseca en los datos.

que **Todas las componentes son ortogonales entre sí**, que facilita representaciones gráficas de los datos.

1.5. Datos atípicos en una variable - Rango intercuartílico:

$$IQR = Q_{0,75} - Q_{0,25}$$

El rango intercuartílico es un indicador del grado de dispersión de los datos: $IQR = Q_{0,75} - Q_{0,25}$. A partir de éste se construye un rango $(Q_{0,25} - 1,5 * IQR, Q_{0,25} + 1,5 * IQR)$ por fuera del cual una observación se

1.5. DATOS ATÍPICOS EN UNA VARIABLE - RANGO INTERCUARTÍLICO: $IQR = Q_{0,75} - Q_{0,25}$ 13

puede declarar atípica. La construcción de este rango se basa en una propiedad de la distribución $N(\mu, \sigma^2)$, en la cual aproximadamente el 68 % de las observaciones se encuentran en el rango $\mu \pm \sigma$; el 95 % están en el rango $\mu \pm 2\sigma$ y el 99 % en el rango $\mu \pm 3\sigma$.

Como el rango intercuartílico es una medida robusta a observaciones atípicas, puede reflejar bien aquellas observaciones que podrían ser atípicas, en datos provenientes de una distribución arbitraria.


Ejemplo 1.5.1. Para este ejemplo se utiliza la tabla 1.1 que contiene datos del número de habitantes y cuatro indicadores de educación en 22 ciudades colombianas.

Utilizando el criterio del rango intercuartílico en la Tabla 1.6 se identifican con asterisco * las ciudades atípicas en alguna variables. Se nota por ejemplo, que Barranquilla, Bogotá, Cali y Medellín son atípicas por el número de habitantes y que Bogotá también es atípica en Cobertura en educación superior. También se ve que Riohacha es atípica en Analfabetismo y San Andres lo es en Cobertura en educación primaria y secundaria.

Tabla 1.6: Ciudades atípicas por cada variable


	Ciudad	Num.Hab	Analfabetismo	Cobertura.pria.y.secdaria	Cobertura.ed.sup	Rel.al.prof
Armenia	Armenia	284120	0.088	1.095	0.266	22.4
Barranquilla	Barranquilla	*	0.0922	1.083	0.306	22.5
Bogota	Bogota	*	0.0973	0.999	*	22.6
Bucaramanga	Bucaramanga	520080	0.076	1.192	0.326	22.2
Cali	Cali	*	0.0831	1.019	0.223	22.0
Cartagena	Cartagena	912674	0.1213	1.207	0.147	24.4
Cucuta	Cucuta	600049	0.1133	1.147	0.217	22.4
Ibague	Ibague	509796	0.1073	0.983	0.181	23.4
Manizales	Manizales	383483	0.0769	1.143	0.23	22.2
Medellin	Medellin	*	0.1256	1.219	0.3	26.3
Monteria	Monteria	390996	0.1587	1.109	0.151	26.1
Neiva	Neiva	322098	0.1131	1.1	0.179	23.3
Pasto	Pasto	394074	0.1115	1.052	0.128	21.8
Pereira	Pereira	448971	0.1007	1.124	0.283	22.6
Popayan	Popayan	261694	0.0915	1.135	0.163	21.5
Riohacha	Riohacha	184847	*	1	0.152	26.1
San Andres	San Andres	66675	0.0772	*	0.107	20.4
Santa Marta	Santa Marta	428374	0.1244	1.005	0.116	22.9
Sincelejo	Sincelejo	245180	0.1612	1.228	0.107	24.9
Tunja	Tunja	161209	0.1023	1.036	0.245	22.1
Valledupar	Valledupar	373872	0.1587	1.017	0.147	24.5
Villavicencio	Villavicencio	400475	0.1017	1.193	0.174	25.4

Las ciudades atípicas según Cobertura.pria.y.secdaria y Analfabetismo se muestran en la Gráfica 1.1



Gráfica 1.1: Cobertura.pria.y.secdaria vs. Analfabetismo. Se distinguen como atípicas según el Rango intercuartílico las ciudades de San Andrés y Riohacha.

En la gráfica 1.2 se reslatan las ciudades atípicas en dos variables separadamente según el rango intercuartílico mostrado en la Tabla 1.6.



Gráfica 1.2: Num.Hab vs. Cobertura.ed.sup. Según el Rango intercuartílico, se distingue Bogotá como atípica en las dos variables y Cali, Medellín y Barranquilla como atípicas solamente en Num.Hab

1.6. El problema de datos atípicos en varias variables

El criterio basado en el rango intercuartílico (IQR), aunque útil en el análisis univariado, tiene varias limitaciones que lo hacen poco útil en datos multivariados, debido a que identifica observaciones atípicas en cada variable separadamente, pero ignora la estructura de dependencia entre ellas.

En particular, no permite identificar observaciones atípicas debido a combinaciones poco usuales de variables, aun cuando estas no sean extremas individualmente, ni tiene en cuenta diferencias en las varianzas o la presencia de correlaciones.

Por otra parte, el IQR no es invariante ante transformaciones lineales y carece de una base probabilística multivariada que permita establecer umbrales de decisión estadísticamente significativos. En contraste, la distancia de Mahalanobis incorpora explícitamente la matriz de covarianzas, lo que le permite ajustar la medición de distancia a la escala y correlación de las variables, generando regiones elipsoidales de igual distancia y proporcionando un criterio más adecuado para identificar observaciones atípicas en presencia de estructuras multivariadas complejas.

1.7. Distancias entre observaciones multivariadas

Intuitivamente la distancia entre dos puntos A y B en una superficie plana es la longitud del espacio que hay entre ellos. Entonces si se desea ir de A hacia B la distancia se puede medir en metros y esto da idea de lo lejos

(o cerca) que están.

Esta idea de distancia tiene las siguientes propiedades: Sean A , B y C dos puntos en el espacio R^2

- * Si los dos puntos están en el mismo sitio es decir son un mismo punto, naturalmente la distancia entre ellos es cero: $d(A, A) = 0$
- * de lo contrario la distancia entre A y B es mayor que cero: $d(A, B) \geq 0$
- * Además la distancia de A a B es la misma que de B a A : $d(A, B) = d(B, A)$
- * Adicionalmente si hay un tercer punto C , ir de A a B directamente tiene que ser más cerca que ir de A a B pasando primero por C , es decir, la distancia entre A y B tiene que ser menor o igual que la distancia entre A y C más la distancia entre C y B :

$$d(A, B) \leq d(A, C) + d(C, B)$$

1.7.1. Distancia del valor absoluto

Ejemplo de estas métricas es el valor absoluto o distancia entre dos números a y b . La distancia se mide por la diferencia entre ellos: $a - b$ o $b - a$, pero para evitar la ambigüedad que produce el signo de la diferencia, se utiliza como distancia el valor absoluto $|a - b|$ que siempre es positiva y cumple las propiedades mencionadas de una distancia.

1.7.2. Distancia Manhattan

También la llaman distancia en manzanas de una ciudad (city-block distance) o métrica del taxista. En general para cualesquiera dos filas $x'_i = (x_{i1}, \dots, x_{ip})'$ y $x'_{i'} = (x_{i'1}, \dots, x_{i'p})'$ de la matriz de datos X la distancia Manhattan es la suma de las diferencias entre las coordenadas de cada variable:

$$d_{M_{ht}}(x_i, x_{i'}) = \sum_{j=1}^p |x_{ij} - x_{i'j}| \quad (1.19)$$

1.7.3. Distancia euclidiana

Similarmente, para cualesquiera dos filas $x'_i = (x_{i1}, \dots, x_{ip})'$ y $x'_{i'} = (x_{i'1}, \dots, x_{i'p})'$ de la matriz de datos X la distancia euclidiana es la suma de las diferencias entre las coordenadas de cada variable:

$$d_e(x_i, x_{i'}) = \sqrt{(x_i - x_{i'})'(x_i - x_{i'})} = \sqrt{\sum_{j=1}^p (x_{ij} - x_{i'j})^2} \quad (1.20)$$

En datos multivariados las distancias suelen medirse con respecto al centroide. La distancia euclidiana en este caso tiene la siguiente expresión:

$$d_e(x_i, \bar{x}) = \sqrt{(x_i - \bar{x})'(x_i - \bar{x})} = \sqrt{\sum_{j=1}^p (x_{ij} - \bar{x}_j)^2} \quad (1.21)$$

Ejemplo 1.7.1. En particular por ejemplo, cuando solo se observan dos variables en n objetos la matriz de

datos es tiene la forma

$$X_{n \times 2} = \begin{bmatrix} x_{11} & x_{12} \\ \vdots & \vdots \\ x_{i1} & x_{i2} \\ \vdots & \vdots \\ x_{i'1} & x_{i'2} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{bmatrix}, \quad (1.22)$$

y la distancia euclidiana entre los objetos (filas) $x_i = (x_{i1}, x_{i2})'$ y $x_{i'} = (x_{i'1}, x_{i'2})'$ es:

$$d_e(x_i, x_{i'}) = \sqrt{(x_{i1} - x_{i'1})^2 + (x_{i2} - x_{i'2})^2} \quad (1.23)$$

Esta distancia solo es útil cuando las variables están medidas en las mismas unidades para que las diferencias tengan sentido. Otra limitación es que no incluye información acerca del grado de asociación entre las variables.

Ejemplo 1.7.2. Para ilustrar el problema de identificar datos atípicos se utiliza aquí el caso bidimensional, en el cual puede ocurrir que el conjunto de datos tenga valores atípicos en más de una variable. El Rango intercuartílico no puede identificar si esto ocurre. En la tabla 1.7 de distancias euclidianas entre las ciudades respecto a las variables Relación alumno profesor (Rel.al.prof) y Analfabetismo, se observa que según ésta distancia, San Andrés es la ciudad que está más lejos de cinco ciudades: Medellín, Riohacha, Montería, Villavicencio y Sincelejo. Estas distancias se muestran en la gráfica ???. En la Gráfica 1.3 que muestra las distancias euclidianas con respecto al promedio, se notan más las distancias entre estas ciudades


Claramente Riohacha es atípico en cuanto a su tasa de analfabetismo, y podría serlo también por su Relación alumno profesor junto con Montería, Medellín, Villavicencio y sincelejo, Valledupar y Cartagena, puesto que sus tasas de relación alumno profesor están por encima del rango de la mayoría de las ciudades el cual oscila entre 21.5 (Popayán) y 23.6 (Medellín).

San Andrés podría ser atípico por su baja relación profesor alumno, pero no por su tasa de analfabetismo que es muy parecida a la de ciudades como Bucaramanga, Manizales o Cali.

Sin embargo estas apreciaciones no tienen en cuenta que entre estas dos variables hay una correlación de 0.76, el cual indica que a mayor relación profesor alumno mayores tasas de analfabetismo, asociación que naturalmente debe afectar la percepción sobre los datos atípicos.

Tabla 1.7: Distancias euclidianas de las ciudades al centroide respecto a las variables Rel.al.prof, Analfabetismo

Ciudad	Dist_eu	Ciudad_cont	Dist_eu_cont
Riohacha	4.00	Pasto	0.90
Monteria	1.98	Armenia	0.84
San Andres	1.96	Tunja	0.78
Medellin	1.85	Barranquilla	0.73
Sincelejo	1.44	Cartagena	0.69
Villavicencio	1.33	Bogota	0.60
Valledupar	1.24	Pereira	0.54
Popayan	1.22	Cucuta	0.53
Bucaramanga	1.14	Santa Marta	0.30
Manizales	1.12	Ibague	0.22
Cali	1.09	Neiva	0.07



Gráfica 1.3: Distancias euclidianas de Relación alumno profesor vs. Analfabetismo con respecto al promedio en ciudades colombianas.

Un problema más se ilustra en la gráfica 1.4 donde se observa que Bogotá es una ciudad atípica por su número de habitantes, pero no lo es por su tasa de analfabetismo, mientras que Riohacha es atípica por su alta tasa de analfabetismo pero no por su número de habitantes.

1.7.4. Distancia de Mahalanobis

La distancia de Mahalanobis entre dos objetos o filas de la matriz de datos X $x_i' = (x_{i1}, \dots, x_{ip})'$ y $x_{i'}' = (x_{i'1}, \dots, x_{i'p})'$, utiliza además de las distancias euclidianas, la estructura de correlación entre las variables involucradas al incluir la matriz de covarianzas entre ellas S^{-1} :


$$d_M(x_i, x_{i'}) = \sqrt{(x_i - x_{i'})' S^{-1} (x_i - x_{i'})} \quad (1.24)$$

la cual es siempre positiva porque la matriz de covarianzas es por definición semidefinida ppositiva, con lo cual la forma cuadrática $(x_i - x_{i'})' S^{-1} (x_i - x_{i'}) \geq 0$ y por tanto la raíz cuadrada es positiva.

Para la identificación de datos atípicos esta disitancia se calcula con respecto al centroide reemplazando $x_{i'}$ en 1.24 por el vector de medias $\bar{x} = (\bar{x}_1, \dots, \bar{x}_p)$:

$$d_M(x_i, \bar{x}) = \sqrt{(x_i - \bar{x})' S^{-1} (x_i - \bar{x})} \quad (1.25)$$

Una limitante de la distancia de Mahalanobis es que los resultados solo tienen poder inferencial cuando la distribución de los datos sea la normal multivariada. Por tanto, para utilizar la distancia de Mahalanobis con significancia estadística, es necesario hacer preliminarmente alguna prueba de normalidad multivariada como la prueba



Gráfica 1.4: Número de habitantes vs. Analfabetismo en 10 ciudades colombianas.

de Mardia, de Henze-Zirkler, de de Royston que es una extensión multivariada de la prueba de Shapiro-Wilk. Respecto al desempeño de estas pruebas se puede consultar por ejemplo Porras (2016). Por esta razón aquí se utiliza **únicamente como indicador descriptivo de posibles datos atípicos**.

Para ilustrar cómo la distancia de Mahalanobis funciona teniendo en cuenta la estructura de correlación entre las variables, se utiliza el caso particular de dos variables para $X_{n \times 2}$ como en (1.22). Se utiliza el hecho de que $s_{12} = r_{12}s_1s_2$ (ver (1.9)) para calcular la inversa de la matriz de covarianzas:

$$S^{-1} = \frac{1}{(1 - r_{12}^2)} \begin{bmatrix} s_1^{-2} & -r_{12}s_1^{-1}s_2^{-1} \\ -r_{12}s_1^{-1}s_2^{-1} & s_2^{-2} \end{bmatrix} \quad (1.26)$$

Entonces, reemplazando S^{-1} en (1.24) la distancia entre los objetos (filas) $x_i = (x_{i1}, x_{i2})'$ y $x_{i'} = (x_{i'1}, x_{i'2})'$ antes de tomar la raíz cuadrada, es:

$$d_M^2(i, i') = \frac{1}{(1 - r_{12}^2)} \left[\frac{(x_{i1} - x_{i'1})^2}{s_1^2} + \frac{(x_{i2} - x_{i'2})^2}{s_2^2} - 2r_{12} \frac{(x_{i1} - x_{i'1})(x_{i2} - x_{i'2})}{s_1s_2} \right] \quad (1.27)$$

donde $\frac{(x_{i1} - x_{i'1})^2}{s_1^2}$ y $\frac{(x_{i2} - x_{i'2})^2}{s_2^2}$ son las distancias euclidianas estandarizadas entre los dos puntos y r_{12} es el coeficiente de correlación entre X_1 y X_2 .

Nótese en la ecuación 1.27 que el término negativo crece cuando $r_{12} \rightarrow 1$, con lo cual $d_M^2(i, i')$ decrece, indicando que las dos variables por su alta correlación se encuentran más cerca. Recíprocamente, cuando $r_{12} \rightarrow$


-1 , $d_M^2(i, i')$ crece, reflejando que, como las variables están correlacionadas negativamente, se encuentran más distantes. Y finalmente, cuando $r_{12} \rightarrow 0$ las variables son incorrelacionadas y la distancia es simplemente la suma de las distancias euclidianas entre ellas.

En particular, cuando solo hay dos observaciones y dos variables la matriz de datos se reduce a

$$\begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix},$$

y por tanto como $n = 2$ las varianzas son solamente a las sumas de cuadrados $s_j^2 = \sum_{i=1}^2 (x_{ij} - \bar{x}_j)^2$, $j = 1, 2$. Sin embargo este caso puede carecer de interés por tratarse de tan pocas observaciones.

Ejemplo 1.7.3. *Identificación de datos atípicos con las distancias euclidianas y las distancias de Mahalanobis. En la Tabla 1.7 se muestran los valores de las distancias euclidianas al centroide se visualizan en la gráfica 1.5. Sobresale el hecho de que Riohacha es la más lejana del centroide respecto a estas dos variables, mientras que Neiva está casi en el mismo punto que el centroide.*



Gráfica 1.5: Ciudades, centroide, distancias euclidianas y segmentos de distancia

En la tabla 1.8 se muestran las distancias de Mahalanobis respecto al centroide entre las ciudades. Se observa un considerable cambio en el orden en que aparecen por sus distancias de Mahalanobis respecto a las distancias euclidianas de la tabla 1.7.

Debido a que la distancia de Mahalanobis solo tiene propiedades inferenciales cuando las variables tienen distribución Normal Multivariada, suele utilizarse la siguiente regla práctica como criterio eurístico. Declarar una observación atípica cuando:

$$d_m^2 > \chi_{p,0.975}^2 \quad (1.28)$$

En este ejemplo $d_m^2(\text{Riohacha}) = 14,5466$ y $\chi_{2,0.975}^2 = 7,38$. Por tanto Riohacha es la única ciudad que puede declararse empíricamente como atípica a la luz de la distancia de Mahalanobis.

Tabla 1.8: Distancias de Mahalanobis de las ciudades al centroide respecto a las variables Rel.al.prof, Analfabetismo

Ciudad_1	Dist_Mah	Ciudad_2	Dist_Mah_cont
Riohacha	3.81	Cartagena	0.86
Medellin	2.40	Cali	0.83
Villavicencio	2.20	Tunja	0.76
San Andres	1.80	Cucuta	0.69
Monteria	1.74	Armenia	0.66
Pasto	1.17	Barranquilla	0.56
Popayan	1.11	Santa Marta	0.55
Sincelejo	1.10	Bogota	0.46
Valledupar	0.99	Pereira	0.42
Bucaramanga	0.93	Ibague	0.38
Manizales	0.91	Neiva	0.12

Para terminar se introducen dos teoremas por medio de los cuales se definen las componentes principales como direcciones de máxima varianza de los datos.

1.8. Teorema de la descomposición espectral (TDE)

Este teorema garantiza que una matriz simétrica $B_{p \times p}$, como la matriz de covarianzas o de correlación (ambas semidefinidas positivas), se puede reconstruir (o factorizar) a partir de sus **valores y vectores propios** como sigue:

$$B = U\Lambda U' \quad (1.29)$$

donde $U_{p \times p}$ es una **matriz ortogonal cuyas columnas son los vectores propios estandarizados de B** y $\Lambda = \text{diag}\{\lambda_\alpha\}$, $\lambda_\alpha \geq 0$ y $\lambda_1 \geq \dots \geq \lambda_p$, son los **valores propios de B** arreglados en forma descendente.

1.9. Teorema de la descomposición en valores singulares (TDVS)

La descomposición en valores singulares es un poco más general que el TDE puesto que no requiere que la matriz a descomponer sea simétrica, lo cual garantiza que también la matriz de datos se puede descomponer. El **TDVS** garantiza que una matriz $C_{n \times p}$, con $n \geq p$ y rango r , equivalentemente con r columnas linealmente independientes (por ejemplo la matriz de datos X o la estandarizada Y definida en (??)) se puede factorizar así (ver por ejemplo Sudipto & Anindya (2014) Mardia et al. (1992)):

$$C = ULV' \quad (1.30)$$

donde

U y V son matrices con columnas ortonormales lo que implica $U'U = V'V = I_r$.

$L_{r \times r} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_r})$, $\sqrt{\lambda_1} \geq \sqrt{\lambda_2} \geq \dots \geq \sqrt{\lambda_r} > 0$.

$\sqrt{\lambda_j}$ son los valores singulares de C ,

$V_{n \times r} = (v_1, \dots, v_r)$ contiene en sus columnas los vectores propios de $C'C$,

$U_{p \times r} = (u_1, \dots, u_r)$ contiene en sus columnas los vectores propios de CC' ,

La equivalencia con los valores propios no nulos de CC' se establece escogiendo

$$L = \text{diag}(\sqrt{\mu_1}, \dots, \sqrt{\mu_r}),$$

donde μ_α es el α -ésimo valor propio no nulo de CC' . No obstante, no es necesario escribir ambas versiones, ya que los valores propios no nulos de $C'C$ y CC' coinciden.

En efecto, si L contiene las raíces cuadradas de los valores propios de $C'C$, entonces

$$C'C u_\alpha = \lambda_\alpha u_\alpha,$$

mientras que si L contiene las raíces cuadradas de los valores propios de CC' , se tiene

$$CC' v_\alpha = \mu_\alpha v_\alpha.$$

La teoría espectral garantiza que

$$\lambda_\alpha = \mu_\alpha, \quad \alpha = 1, \dots, r,$$

y, por tanto, ambas formulaciones del TDVS son equivalentes.

La Descomposición en Valores Singulares (TDVS) constituye un resultado más general que el Teorema de la Descomposición Espectral (TDE), en la medida en que no requiere que la matriz a descomponer sea simétrica. Sin embargo, cuando la TDVS se aplica a una matriz simétrica $B_{p \times p}$, se obtiene como caso particular el TDE (ver, por ejemplo, Mardia et al. (1979), Sudipto & Anindya (2014)).

La TDVS de una matriz real B se escribe como

$$B = U L V',$$

donde U y V son matrices ortonormales tales que $U'U = V'V = I_p$, y $L = \text{diag}(\sigma_1, \dots, \sigma_p)$ contiene los valores singulares de B , ordenados típicamente como $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$.

Si B es simétrica, entonces $B' = B$. Pero la TDVS implica que

$$B' = V L U'.$$

Igualando ambas expresiones, se obtiene

$$U L V' = V L U'.$$

Esto solo puede cumplirse si U y V coinciden (hasta un posible cambio de signo en algunas columnas), de modo que

$$U = V.$$

Sustituyendo en la descomposición TDVS, esta se reduce a

$$B = U L U'.$$

Para una matriz simétrica real, los valores singulares σ_j satisfacen $\sigma_j = |\lambda_j|$, donde λ_j es el j -ésimo valor propio de B . Si, además, B es semidefinida positiva (como sucede en aplicaciones estadísticas al considerar matrices de covarianzas, correlaciones o productos matriciales $X'X$), se tiene $\lambda_j \geq 0$, lo cual implica que $\sigma_j = \lambda_j$, es decir que. En tal caso, la matriz L coincide con la matriz diagonal de valores propios,

$$L = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p). \quad (1.31)$$

Así, la TDVS aplicada a una matriz simétrica produce exactamente el TDE:

$$B = U \Lambda U',$$

donde Λ contiene los valores propios λ_j de B y las columnas de U son los vectores propios asociados. De esta forma, el TDE se obtiene como un caso particular de la TDVS, con valores singulares coincidiendo con los valores propios y vectores singulares coincidiendo con los vectores propios de B .

1.10. Laboratorio

Utilizar los datos del archivo “original-filtrado-con etiquetas” y los mismos grupos de variables asignados en el ejercicio 9 del Laboratorio ?? y la subtabla de indicadores de Recursos Humanos del mismo archivo de ciudades para conformar una nueva tabla que contenga los dos conjuntos de variables.

1. Calcular el vector de medias de todas las variables del conjunto que le correspondió al grupo.
2. Calcular la matriz de datos centrados
3. Calcular la matriz de covarianzas a partir de la matriz de datos centrados.

Calcular la matriz de covarianzas con el comando *cov* de R. ¿Coincide con la obtenida a partir de la matriz de datos centrados? ¿Sí? ¿No? ¿Por qué?

4. Calcular la matriz Y de datos centrados y estandarizados1.
5. Calcular la matriz de correlación a partir de la matriz Y de datos centrados y estandarizados.

Calcular la matriz de correlación con el comando *cor* de R.

6. Calcular la matriz de covarianzas S e Identificar las dos variables con mayor covarianza y las dos con menor covarianza
7. Calcular la matriz de correlación R e Identificar las dos variables con mayor correlación y las dos con menor correlación. ¿Son las mismas que las que tienen mayor y menor covarianza identificadas en el punto 6?
8. Calcular el producto $\frac{1}{n} Y'Y$ y verificar que es exactamente la matriz R obtenida en el punto 7. ¿Por qué?

9. Para este ejercicio, utilizar el archivo “ciudades original-filtrado-con etiquetas” con las siguientes variables para cada grupo.

Grupo_1: Ciencia y Tecnología C&T

Grupo_2: Infraestructura INFRA

Grupo_3: Finanzas FIN

Grupo_4: Gestión productividad GOB

Grupo_5: Crecimiento FOR

Grupo_6: Internacionalización INT

Grupo_7: Recursos humanos RH

- a) Utilizar el rango intercuartílico para identificar observaciones atípicas en alguna de las variables del archivo del grupo.
- b) Cambiar la definición original del rango intercuartílico ($Q_{0,25} - 1,5 * IQR, Q_{0,25} + 1,5 * IQR$) por esta más estricta: ($Q_{0,25} - IQR, Q_{0,25} + IQR$). Identificar nuevamente las observaciones atípicas en alguna de las variables ¿son las mismas que con la definición original del rango intercuartílico?.
- c) Cambiar la definición original del rango intercuartílico ($Q_{0,25} - 1,5 * IQR, Q_{0,25} + 1,5 * IQR$) por esta más laxa: ($Q_{0,25} - 2 * IQR, Q_{0,25} + 2 * IQR$).
 - 1) ¿son las mismas que resultaron con la definición original del rango intercuartílico?
 - 2) ¿Son las mismas que salieron con la definición más estricta?
- d) Tanto en 9a como en 9b dar alguna justificación de los cambios, si los hay, a la luz del criterio intuitivo sobre la distribución Normal que se utilizó en la definición del rango intercuartílico.

10. Con los mismos grupos de variables que le correspondieron al grupo en el punto 9 elaborar gráficos de dispersión del tipo ?? y 1.4 e identificar visualmente posibles datos atípicos en alguna o en las dos variables de cada gráfico.
 - a) Calcular las distancias de euclidiana e identificar ciudades atípicas en algunas de las variables
 - b) Calcular las distancias de Mahalanobis e identificar ciudades atípicas en algunas de las variables
 - c) Identificar la ciudades que salieron atípicas con el rango intercuartílico, la distancia euclidiana y la distancia de Mahalanobis.
 - d) Identificar la ciudades que salieron atípicas con la distancia euclidiana y la distancia de Mahalanobis.
11. Calcular la distancia euclidiana entre ciudades respecto a las variables Analfabetismo y Rel.al.prof e identificar las dos ciudades más cercanas y las dos ciudades más lejanas.
12. Calcular la distancia de Mahalanobis entre ciudades respecto a las variables Analfabetismo y Rel.al.prof e identificar las dos ciudades más cercanas y las dos ciudades más lejanas. ¿Son las mismas ciudades que cercanas o lejanas que las obtenidas con las distancias euclidianas del punto 11?
13. Comprobar que la matriz de covarianzas se puede obtener con el producto $\frac{1}{n} \tilde{X}' \tilde{X}$.
14. Comprobar que la matriz de correlación se puede obtener con el producto $\frac{1}{n} Y' Y$.

Bibliografía

Mardia, K., Kent, J. & Bibby, J. (1992), *Multivariate Analysis*, eighth printing edn, Academic Press, San Diego, CA 92101.

Mardia, K. V., Kent, J. T. & Bibby, J. M. (1979), *Multivariate Analysis*, Academic Press, London.

Porras, J. C. (2016), Comparación de pruebas de normalidad multivariada, *in* 'Anales científicos', Vol. 77, Universidad Nacional Agraria La Molina, pp. 141–146.

Sudipto, B. & Anindya, R. (2014), Linear algebra and matrix analysis for statistics, *in* 'Texts in Statistical Science', Chapman and Hall/CRC.