

INTRODUCCIÓN AL
APRENDIZAJE ESTADÍSTICO NO SUPERVISADO:
**PANORAMA DE LA ESTADISTICA DESCRIPTIVA
MULTIVARIADA**

Por:

Jimmy A. Corzo S. J. Giovany Bababtiva M.

Profesor Titular

Departamento de Estadística

Facultad de Ciencias

Universidad Nacional de Colombia- Sede Bogotá

16 de marzo de 2026

Índice general

1. Prefacio	5
2. Introducción	7
3. Panorama del análisis multivariado	13
3.1. Tipos de variables	13
3.2. El papel de las componentes principales	13
3.3. Correspondencias simples y análisis de tablas de contingencia	19
3.4. Correspondencias múltiples: Tablas de tablas de contingencia.	25
3.5. Métodos de agrupamiento (Clustering)	30
3.6. Laboratorio	42

Capítulo 1

Prefacio

A mediados de la década de 1970, cuando cursábamos la carrera de Estadística en la Universidad Nacional, los cursos de Análisis Multivariado estaban dominados por un enfoque esencialmente teórico, centrado en la demostración de los principales teoremas y en la resolución de ejercicios formales, tomados de textos clásicos como los de Morrison y Mardia. Las aplicaciones prácticas eran necesariamente limitadas y se realizaban sobre conjuntos de datos muy pequeños, debido tanto a la complejidad computacional de los métodos como a las restricciones tecnológicas de la época, en marcado contraste con las posibilidades actuales de análisis multivariado apoyadas en herramientas computacionales avanzadas.

El contacto con las aplicaciones de los métodos multivariados se dio a finales del 1999, cuando, junto con el profesor Antanas Mockus, obtuvimos financiación de Colciencias para un proyecto de investigación sobre convivencia ciudadana en colegios públicos de Bogotá. El proyecto consistía en elaborar una encuesta, aplicarla a estudiantes de los grados 10.º y 11.º de una muestra de colegios de la ciudad, realizar el análisis correspondiente y publicar un libro con los resultados. El libro se tituló Factores de convivencia y su relación con normas y acuerdos, y fue publicado por la editorial de la Universidad Nacional Mockus et al. (2003). El proyecto produjo también dos artículos: Mockus & Corzo (2003) y Mockus & Corzo (2005). [La metodología utilizada para el análisis de la encuesta fue el Análisis de Correspondencias Múltiples, que permitió construir indicadores de convivencia, algunos de los cuales se utilizaron para desarrollar e implementar uno de los objetivos del plan de desarrollo de la alcaldía en el período 2001 – 2003 del profesor Mockus.](#)

El texto también fue motivado por la experiencia acumulada en desarrollo de los cursos de Estadística Descriptiva Multivariada, Análisis Multivariado Aplicado y Aprendizaje Estadístico que he dictado para la Carrera, la Especialización y la maestría en Estadística intermitentemente desde 2012 en el Departamento de Estadística de la Facultad de Ciencias de la Universidad Nacional de Colombia-Sede Bogotá. Adicionalmente, el texto es motivado por la experiencia acumulada en proyectos de extensión realizados a través de convenios interadministrativos con entidades públicas, o logrados en concursos de méritos en los cuales la Universidad Nacional fue seleccionada para la realización y ejecución de los contratos. En estos proyectos los métodos de Aprendizaje Estadístico no supervisado fueron una valiosa herramienta para la exploración y descripción tanto de conjuntos de datos recolectados en los mismos proyectos, como de bases de datos de dominio público, o de combinaciones de ambas fuentes. Cabe anotar que el uso los métodos de Aprendizaje Estadístico no supervisado en estos proyectos ha contribuido al desarrollo de una Cultura Estadística, al punto de que recientemente, algunos de los productos de éstos métodos son solicitados como parte de los entregables en los convenios o contratos. Lo anterior fue motivación para incluir también algunos métodos avanzados no tradicionales en los cursos de la carrera o de la Especialización.

Capítulo 2

Introducción

El contexto en el que surgen y se consolidan los métodos supervisados y no supervisados de aprendizaje estadístico está fuertemente ligado al desarrollo tecnológico ocurrido a partir de la década de los años ochenta del siglo pasado, en particular al crecimiento en la capacidad de cómputo de los computadores personales y, posteriormente, a la aparición de sistemas capaces de almacenar y procesar grandes volúmenes de datos. Dichos datos comenzaron a estar disponibles de manera masiva en instituciones públicas y privadas, plataformas de internet, redes sociales, sistemas de posicionamiento global (GPS), sensores, bases de datos administrativas y científicas, entre otros.

Estos avances tecnológicos dieron origen a nuevas formas de análisis de datos, como el Aprendizaje Automático (*Machine Learning*), el Aprendizaje Estadístico (*Statistical Learning*) y la Ciencia de Datos, que responden a la necesidad de extraer información, patrones y conocimiento a partir de datos cada vez más complejos y de gran dimensión. En este nuevo escenario, muchas técnicas estadísticas desarrolladas con anterioridad, como la regresión lineal múltiple y los métodos de análisis multivariado, adquirieron una relevancia práctica sin precedentes, al hacerse computacionalmente viables para conjuntos de datos de gran tamaño.

Antes de estos avances, la aplicación de tales métodos se encontraba limitada en la práctica debido a la imposibilidad de realizar la gran cantidad de cálculos que requieren. La evolución del hardware y del software estadístico permitió no solo su uso rutinario, sino también su expansión hacia nuevas áreas del conocimiento. En la actualidad, los métodos de aprendizaje estadístico se utilizan de manera extensiva en campos como las ciencias sociales y políticas, la economía, la ingeniería, y las ciencias básicas, incluyendo la geología, la biología, la genética y los estudios del genoma humano, entre muchos otros.

Un problema de **Aprendizaje Estadístico Supervisado** consiste en predecir, con cierta precisión, una variable respuesta Y a partir de un conjunto de variables explicativas o predictores $X_1, \dots, X_p$, mediante un modelo de la forma $Y = f(X_1, \dots, X_p)$. La calidad del modelo se evalúa comparando las predicciones con los valores observados de la respuesta, a través de un criterio externo de error. El término *supervisado* hace referencia a que, al disponer de una respuesta observada Y , es posible entrenar el modelo usando una parte de los datos y evaluar su desempeño utilizando otra parte independiente, comparando las predicciones $\hat{y}_i$ con las observaciones reales y_i . Este enfoque permite tanto evaluar la capacidad predictiva del modelo como realizar inferencias sobre la relación entre Y y las variables explicativas. Métodos estadísticos clásicos como la regresión lineal, la regresión logística, los modelos lineales generalizados, los modelos aditivos generalizados y los métodos de clasificación pertenecen a esta categoría.


En contraste, el **Aprendizaje Estadístico No Supervisado** se refiere a situaciones en las que solo se dispone de un conjunto de variables explicativas $X_1, \dots, X_p$, sin una variable respuesta asociada que permita supervisar o evaluar el ajuste del modelo mediante un criterio externo de error, como ocurre en el aprendizaje supervisado. En consecuencia, un problema de Aprendizaje Estadístico No Supervisado, no queda bien definido en términos de predicción supervisada, ya que no existe una respuesta observable que se desee predecir. En este contexto, el interés del análisis no supervisado no se centra en la predicción de una variable respuesta, sino en la exploración de la estructura interna de los datos. En particular, se busca identificar asociaciones simultáneas entre las varia-

bles, detectar similitudes o agrupamientos entre los individuos u objetos observados, construir representaciones gráficas informativas, descubrir patrones o estructuras latentes inmersas en los datos, o reducir la dimensionalidad del problema, entre otros objetivos.

El carácter de *aprendizaje* en los métodos de Aprendizaje Estadístico No Supervisado consiste en que, en ausencia de un criterio externo de error basado en una variable respuesta, estos métodos utilizan algoritmos que optimizan criterios internos para descubrir estructuras latentes en los datos. Dichos criterios pueden estar asociados a la geometría del espacio de las observaciones, a medidas de similitud o distancia, a funciones de densidad o a errores de reconstrucción, y permiten identificar patrones, asociaciones, agrupamientos o representaciones de baja dimensión que facilitan la tipificación y descripción de los datos.

En síntesis, mientras el aprendizaje supervisado se orienta a la predicción y evaluación del desempeño mediante una respuesta observable, el aprendizaje no supervisado se orienta al descubrimiento y descripción de la estructura latente de los datos, sin referencia a una verdad externa observada.

El mapa conceptual mostrado en la gráfica 2.1 clasifica los métodos no supervisados según el tipo de estructura latente que modelan, el criterio de optimización que usan, la representación final que producen, el marco matemático en que se fundamentan y los supuestos geométricos o probabilísticos que hacen sobre los datos.



Gráfica 2.1: Dentro de las cajas se muestran varios de los métodos que incluye cada categoría.

Métodos de reducción de las dimensiones

Los métodos de reducción de las dimensiones pueden ser lineales que son los basados en el Teorema de las descomposición en valores singulares (SVD por sus siglas en inglés), y no lineales que utilizan que no utilizan la SVD. A continuación una breve descripción

Metodos basados directamente en SVD

- **PCA (Principal Components Analysis)**. Metodo lineal para variables numericas que busca direcciones de maxima varianza. **Basado directamente en la SVD** de la matriz centrada.
- **CA (Correspondence Analysis)**. Tecnica para tablas de contingencia basada en perfiles centrados y ponderados. **Utiliza una SVD ponderada** para obtener coordenadas principales.
- **MCA (Multiple Correspondence Analysis)**. Extension del CA a multiples variables categoricas mediante la matriz indicatoria o de Burt. **Fundamentado en una SVD en el espacio chi-cuadrado**.
- **MFA (Multiple Factor Analysis)**. Metodo para grupos de variables que normaliza cada bloque y luego aplica **una SVD global** para extraer factores comunes.
- **STATIS (incluye DiSTATIS)**. Metodo para tablas estructuradas en tres vias; construye una compromise matrix y aplica **SVD o descomposicion espectral** para obtener configuraciones y compromisos.
- **MDS clasico (Classical Multidimensional Scaling o CMDS)**. Recupera coordenadas en un espacio euclidiano mediante la **descomposicion espectral de la matriz de distancias doblemente centrada**, algebraicamente equivalente a una SVD.

Metodos no lineales o no basados en SVD

- **t-SNE (t-distributed Stochastic Neighbor Embedding)**. Metodo no lineal que minimiza la divergencia de Kullback–Leibler entre distribuciones de vecinos. **No utiliza SVD** salvo como opcion para inicializacion.
- **UMAP (Uniform Manifold Approximation and Projection)**. Metodo de aprendizaje de variedades basado en grafos fuzzy y optimizacion de atraccion-repulsion. **No utiliza SVD** excepto cuando se inicializa con PCA.
- **Isomap**. Metodo de aprendizaje de manifolds basado en distancias geodesicas. Realiza MDS al final, pero **no es un metodo basado en SVD**, aunque emplea descomposicion espectral en la etapa final.
- **NMF (Nonnegative Matrix Factorization)**. Factorizacion iterativa de matrices no negativas mediante algoritmos multiplicativos o ALS. **No utiliza SVD**, aunque puede inicializarse con ella.

Descripciones más detalladas de los métodos mencionados en el mapa acerca de aprendizaje estadístico supervisado y no supervisado se encuentran por ejemplo en Hastie et al. (2009), James et al. (2021); reducción de dimensión (PCA, MDS, Isomap, t-SNE, UMAP) Jolliffe & Cadima (2016), Tenenbaum et al. (2000), van der Maaten & Hinton (2008), McInnes et al. (2018); agrupamientos (Clustering) (k-means, jerárquico, DBSCAN, GMM, espectral) Kaufman & Rousseeuw (2005), MacQueen (1967), Ester et al. (1996), Ng et al. (2002); métodos basados en densidad (KDE, modelos de mezcla, procesos de Dirichlet, LOF) Silverman (1986), McLachlan & Peel (2000), Breunig et al. (2000); redes neuronales no supervisadas (SOM, autoencoders, RBMs, VAE) Kohonen (2001), Hinton et al. (2006), Kingma & Welling (2014); detección de anomalías (Isolation Forest, One-Class SVM) Liu et al. (2008), Schölkopf et al. (2001).

Métodos de agrupamiento (Clustering)

- **K-means**. Algoritmo particional que asigna cada observacion al centroide mas cercano, minimizando la suma de distancias cuadraticas dentro de cada grupo. Requiere fijar el numero de clusters y es sensible a valores atipicos.
- **K-medoids (PAM)**. Variante robusta de k-means que utiliza medoids (observaciones reales) en lugar de centroides, adecuada para diferentes metricas de distancia y menos sensible a valores atipicos.

- **Clustering jerárquico (aglomerativo o divisivo).** Construye un dendrograma que agrupa observaciones de manera secuencial. No requiere especificar el número de clusters a priori y permite distintos criterios de enlace (single, complete, average, Ward).
- **DBSCAN.** Método basado en densidad que identifica regiones densas separadas por zonas de baja densidad. Detecta ruido y produce clusters de formas arbitrarias sin necesidad de fijar el número de grupos.
- **HDBSCAN.** Extensión jerárquica de DBSCAN que permite densidades variables. Produce clusters más estables y una mejor detección de ruido en datos con heterogeneidad de densidad.
- **GMM (Gaussian Mixture Models).** Modelo probabilístico que representa los datos como una mezcla de distribuciones normales. Ofrece pertenencias suaves (probabilidades) mediante el algoritmo EM y permite clusters elípticos.
- **Clustering espectral.** Método que utiliza los autovectores del Laplaciano de un grafo de similitudes para representar los datos en un espacio reducido, donde luego se aplica un algoritmo particional como k-means. Permite detectar clusters no lineales.

En este texto se presentan todos los métodos basados en SVD están en la primera línea de la caja de Reducción de las dimensiones (PCA, CA, MCA, MFA, STATIS, MDS) y los dos más conocidos de la caja de Clustering (k-means, Clustering jerárquico), todos métodos bien conocidos entre estadísticos. Dichos métodos se utilizan para describir, analizar o entender conjuntos de datos, arreglados generalmente en tablas o matrices, en cuyas filas están los n objetos observados (ciudades, países, universidades, individuos, comunidades, animales, entidades, etc.) y en sus columnas están los valores observados de las variables $(X_1, \dots, X_p)$ medidos en dichos objetos. Este tipo de datos arreglados en tablas estas tablas se denominan datos estructurados¹.

Otros métodos no supervisados menos comunes entre los estadísticos, que se pueden presentar en un curso más avanzado, se pueden consultar por ejemplo en Miller et al. (2018), Pelaez (2012), Tello & Informáticos (2007), Sánchez et al. (2008), Stack (2021).

Un excelente complemento a este texto es el recientemente publicado texto del Profesor Campo E. Pardo *Pardo (2020)*. También son buenos complementos de Lebart et al. (2006), Tusell (2012), Everitt & Hothorn (2011) Kassambara (2017), Husson et al. (2017), y el capítulo 12 del texto Gareth et al. (2021)) para el aprendizaje no supervisado

Organización del texto

Los capítulos del texto están divididos en dos partes: en la primera, muestra los métodos de manera intuitiva a través de ejemplos con datos reales, y en la segunda se presentan las justificaciones algebraicas a la mayoría de ellos. Esta estructura permite mostrar en dos niveles de dificultad los temas: uno para estudiantes recién graduados o de últimos semestres de la carrera de Estadística, estudiantes de la especialización provenientes de otras áreas estudiantes de la maestría de profundización en Estadística; y otro para estudiantes de maestría y primeros semestres del doctorado y a investigadores avanzados de otras áreas. Adicionalmente, todos los capítulos incluyen un laboratorio y a través de todo el texto se va mostrando el código R para reproducir completamente los cálculos y gráficos mostrados.

El Capítulo 1 es una especie de motivación al uso de los métodos multivariados a través de visualizaciones básicas de conjuntos de datos con pocas variables, en diferentes contextos, con un rápido acercamiento a la utilidad de la distancia de Mahalanobis para la identificación de datos atípicos (outliers).

En el Capítulo 2 se introducen las versiones multivariadas de la media, mediana, varianza, covarianza y correlación, la distancia euclidiana y la de Mahalanobis, y se presentan expresiones algebraicas para estas medidas,

¹En el contexto del Big Data estas tablas se llaman datos estructurados para distinguirlos de las imágenes, videos, audios, texto, etc., que se denominan datos no estructurados, para los cuales también existen varios métodos de Aprendizaje Estadístico supervisado y no supervisado

así como una expresión, en términos de sumas ponderadas (combinaciones lineales), que genera las componentes principales. Se introduce la expresión general para la distancia de Mahalanobis y al final se introducen los Teoremas de la descomposición espectral y de la descomposición en valores singulares, teoremas que soportan los métodos PCA, CA, MCA, MFA, STATIS, y MDS presentados en este texto En el Capítulo 3

la segunda parte incluye métodos que utilizan las componentes principales como insumo para métodos más generales como la Regresión por componentes principales y el Escalamiento multidimensional, o como los el métodos de análisis de tablas múltiples como el Análisis Factorial Múltiple, Análisis Conjunto de Tablas ACT también llamado STATIS.

Uno de los objetivos de los métodos no supervisados es facilitar las interpretaciones de conjuntos o matrices de datos con varias variables utilizando representaciones gráficas fáciles de entender. Estas se presentan en el capítulo 3, con la intención de familiarizar al lector con métodos gráficos de tipo cartesiano para representaciones gráficas de hasta cuatro variables en una sola gráfica. El capítulo termina con gráficos boxplot y nubes de palabras muy utilizadas últimamente en los medios para resaltar la importancia de documentos escritos.

En el capítulo ?? se introducen las extensiones multivariadas naturales de la media a vector de medias o centroide, de la varianza a matriz de covarianzas y del coeficiente de correlación a matriz de correlación. Después se presenta el concepto de combinación lineal o suma ponderada que será útil para la construcción de las componentes, y el concepto de distancia entre datos multivariados usado en varios contextos como la identificación de datos atípicos y en escalamiento multidimensional entre otros. En la última sección se presentan formalmente los mismos conceptos y algunos teoremas que justifican y sustentan la construcción de las Componentes Principales, que son la base de la mayoría de los métodos multivariados presentados en el texto.

El ACP se utiliza para variables de naturaleza continua. Las componentes principales son combinaciones lineales de las variables que representan las direcciones en las que tienen la varianza los datos. Su construcción se hace de manera que la primera componente principal es la dirección en que más varianza tienen los datos, la segunda componente es la segunda dirección en que los datos acumulan la segunda proporción más grande de varianza y así sucesivamente. Debido a que todos los métodos presentados tienen como soporte las componentes principales, el capítulo ?? está dedicado a su construcción e interpretación

Cuando las tablas contienen datos de variables de tipo cualitativo (categórico o nominal) el ACP no se puede aplicar directamente sobre los datos originales debido a las dificultades que implica justificar los códigos asignados a las modalidades, especialmente en el caso nominal. En el siguiente ejemplo reportado por Gareth et al. (2021), los síntomas de un paciente pueden dar lugar a tres posibles diagnósticos 1=Ataque cardíaco, 2=Epilepsia o 3=Efectos de sobredosis. En este caso no se puede justificar por qué el 1 representa el ataque cardíaco y no la epilepsia, o por qué el 3 representa los efectos de la sobredosis, y más aún, por qué hay una unidad de diferencia entre ataque cardíaco y epilepsia, y dos unidades de diferencia entre ataque cardíaco y efectos de una sobredosis, etc. Los métodos para tratar este tipo de datos se conocen como métodos de correspondencias Simples cuando se trata de dos variables y Correspondencias Múltiples cuando son más de dos variables. Estos se presentan en los capítulos ?? y ?? respectivamente.

Los métodos de aglomeración o de agrupamiento se utilizan para construir patrones o grupos de objetos similares, y se introducen en el Capítulo ?. Se incluyen por tanto métodos como el k -means, clasificación jerárquica, clasificación mixta, y algunos métodos que utilizan las componentes principales para optimizar los algoritmos para las aglomeraciones de los objetos observados.

Elementos básicos de álgebra lineal requeridos para mejor comprensión

- **Espacios vectoriales:** vectores, subespacios, bases y dimensión.

- **Producto interno:** norma, ángulos y ortogonalidad.
- **Proyección ortogonal** y mínimos cuadrados.
- **Matrices:** operaciones matriciales, rango, traza e inversa (cuando existe).
- **Matrices simétricas** y definidas positivas.
- **Valores y vectores propios.**
- **Teorema de la descomposición espectral (TDE).**
- **Teorema de la descomposición en valores singulares (TDVS).**

=====

Conjuntos de datos utilizados en los ejemplos y ejercicios

- **ciudades** Tabla de datos de 22 ciudades colombianas con 6 variables referentes a la educación y número de habitantes.
- `etiq_ciudades`
- **ciudadesC** Tabla de datos de 22 ciudades colombianas con 84 variables clasificadas en grupos que abarcan temas como Recursos Humanos, Ciencia y Tecnología, Infraestructura, Finanzas públicas entre otros.
- **Etiquetas ciudades** Contiene las etiquetas del archivo ciudadesC
- **ARWU_100_top** Tabla de datos de puntajes y posiciones de las 100 mejores universidades del mundo según el ranking Academic Rank of World Universities (ARWU)
- `arwu`
- **r14_Sci_Qs_Webometrics** Tabla de datos de puntajes y posiciones de 149 universidades latinoamericanas según estos tres rankings
- **confianza** Tabla con lresultados sobre confianza en instituciones
- **ConfianzaJUsticia.** Tabla resultados de confianza en la justicia
- **RankLatino** Rankins latinoamericanos
- **CCLatin** Ciudades latinoamericanas
- **rankings** Tabla con otros Rankings

Capítulo 3

Panorama del análisis multivariado

3.1. Tipos de variables

Los tipos de variables que suelen utilizarse en la visualización de datos suelen clasificarse por el tipo de información que contienen. Aquí una breve descripción de algunos de los tipos de variables utilizados con frecuencia en el análisis no supervisado.

Variables cualitativas que pueden ser de dos tipos: **nominales** cuando solo son códigos que distinguen entre objetos como los nombres de ciudades, países, etc., o de tipo **categorías** cuando sus valores ordenan o clasifican los objetos en categorías que representan diferentes grados de una cualidad o jerarquía, como los estratos socioeconómicos, los niveles educativos, o las posiciones de las universidades en los rankings universitarios. En ambos casos estos códigos se llamarán modalidades u opciones de respuesta.

Variables cuantitativas que se pueden dividir en dos clases: **continuas** cuya escala es numérica y por tanto sus valores representan diferentes grados distinguibles y comparables de distancias en el sentido euclidiano, a las cuales caben todo tipo de operaciones aritméticas y algebraicas. La interpretación de estas variables es directa y fácil. Ejemplos de estas, son las longitudes, las alturas, los ingresos, las edades, etc.; y **discretas** cuyas propiedades en términos de su escala son las mismas que las de las variables continuas, pero toman valores discretos como el número de habitantes, el número de éxitos en n repeticiones de un experimento binario, el número de aviones que llegan a un aeropuerto, el número de usuarios de un servicio de salud, etc. Este hecho hace que las interpretaciones de las variables discretas no sea tan fácil como en las continuas, porque cuando se operan aritmética o algebraicamente se pueden producir números fraccionarios que no corresponden directamente a lo que representa la variable. Por ejemplo un promedio del número de aviones que llegan a un aeropuerto en un minuto puede resultar en 4.6 aviones lo cual no es interpretable directamente.

La elección del método de análisis multivariado depende directamente del **tipo de variables** disponibles. En análisis no supervisado, los métodos más utilizados son:

PCA (Análisis de Componentes Principales): variables **cuantitativas** (continuas o discretas tratadas como numéricas).

MCA (Análisis de Correspondencias Múltiples) Variables **cualitativas** (nominales u ordinales codificadas en modalidades).

MFA (Análisis Factorial Múltiple) Conjuntos de variables **mixtas** o **estructuradas en grupos** (cuantitativas y/o cualitativas).

3.2. El papel de las componentes principales

Una de las formas más sencillas y utilizadas para representar datos correspondientes a variables cuantitativas, ya sean discretas o continuas, es mediante gráficos de dispersión. Estos gráficos representan los objetos observados en un plano cartesiano, utilizando como coordenadas las observaciones asociadas a un par de variables. A

partir de ellos es posible identificar patrones de asociación, tendencias, agrupamientos, así como la presencia de valores atípicos.

Adicionalmente, los gráficos de dispersión pueden enriquecerse incorporando información de otras variables mediante el uso de tamaños, colores, símbolos o etiquetas, lo que permite representar simultáneamente hasta cuatro o cinco variables en un mismo gráfico. Sin embargo, esta estrategia presenta una limitación fundamental: la representación geométrica sigue estando restringida a un plano definido por variables originales, y su capacidad de síntesis se deteriora rápidamente a medida que el número de variables aumenta.

Cuando el conjunto de datos involucra muchas variables cuantitativas, resulta difícil —o incluso imposible— obtener representaciones bidimensionales que capturen adecuadamente la estructura global de los datos utilizando únicamente pares de variables originales. En este contexto, surge la necesidad de construir nuevos ejes de representación, definidos como combinaciones lineales de las variables originales, que permitan proyectar los datos en planos de menor dimensión sin perder información relevante.

Las componentes principales responden precisamente a esta necesidad: definen direcciones ortogonales en el espacio de las variables que maximizan la variabilidad de los datos proyectados. De este modo, los planos generados por las primeras componentes principales proporcionan representaciones bidimensionales más informativas y sintéticas que los gráficos de dispersión basados en variables originales, especialmente cuando se analizan conjuntos de datos con muchas variables.

Ejemplo 3.2.1. *Los **rankings universitarios** son clasificaciones de universidades con criterios predefinidos por las entidades que los producen, de acuerdo con un modelo de universidad implícito que define lo que es una universidad de élite. Los criterios generalmente apuntan al modelo de universidad predefinido por la entidad que los produce y por tanto pueden cambiar considerablemente de un ranking a otro. Criterios comunes en algunos rankings son por ejemplo, el número de publicaciones de los docentes, el impacto que éstas tienen en el mundo académico, el nivel impacto de las revistas donde publican los docentes-investigadores, las actividades en investigación o de innovación de las universidades, el número de docentes con doctorado, la reputación de las universidades entre pares académicos y empleadores, la presencia internacional, los premios obtenidos por docentes activos o por exalumnos de las universidades, etc.*

Desde el punto de vista estadístico, los rankings se construyen calculando combinaciones lineales (sumas ponderadas) de los puntajes obtenidos por las universidades en los criterios del ranking, sumas que producen un puntaje total con el cual se asigna el puesto 1 a la universidad que obtiene el mayor puntaje en el ranking, el puesto 2 a la universidad que obtenga el segundo mayor puntaje, y así sucesivamente.

*Uno de los rankings universitarios más reconocidos y selectivos es el **Academic Ranking of World Universities** (ARWU). Su metodología se basa en seis indicadores objetivos asociados principalmente al desempeño académico y de investigación: (i) el número de egresados (alumni) que han obtenido premios Nobel o medallas Fields, (ii) el número de docentes (staff) con premios Nobel o medallas Fields, (iii) el número de investigadores altamente citados (Highly Cited Researchers), (iv) el número de publicaciones en las revistas Nature y Science, (v) el número de artículos indexados en los índices SCIE/SSCI (Web of Science), y (vi) el **desempeño per cápita** (PCP) del personal académico Liu & Cheng (2005).*

*El ARWU publica el ranking mundial de universidades; a partir de este listado es posible obtener rankings **nacionales** y **regionales** mediante la correspondiente agregación o filtrado por país y región. En este ejemplo se consideran las universidades ubicadas en los **100 primeros puestos del ranking mundial ARWU** para el año 2013, junto con sus posiciones nacional y regional derivadas.*

En la tabla 3.1 se muestra el número de universidades por país. Se observa que Estados Unidos (US) tiene 54 de las primeras 100 universidades, seguido por el Reino Unido (UK) que solo tiene 11, Alemania y Japón con apenas 5, etc. Los siguientes países en la tabla son Canadá (CA), Australia (AS), Francia (FR), Suecia (SE), Suiza (SW), Dinamarca (DE), Países bajos (NL), Bélgica (BE), Finlandia (FI), Israel (IR), Noruega (NW) y Rusia (RU).

EL código R para reproducir la tabla 3.1 es:

```
> arwu<-read.csv2("arwu.csv")
> require(kableExtra)
> library(magrittr)
```

Tabla 3.1: Distribución de las 100 mejores universidades por países según el ARWU 2013

US	UK	GE	JP	CA	AS	FR	SE	SW	DE	NL	BE	FI	IR	NW	RU
54	11	5	5	4	3	3	3	3	2	2	1	1	1	1	1

```

> arwunispais = t(sort(table(arwu$Country), decreasing = T))
> kable(arwunispais, "latex", booktabs = T, digits = 1,
+       caption = "Distribución de las 100 mejores universidades
+       por países según el ARWU 2013", label = " TablARWUpais") %>%
+   kable_styling(latex_options = c("striped", "scale_down",
+                                   "hold_position"))

```

En la tabla 3.2 se muestran las primeras 20 universidades clasificadas como las mejores del mundo en 2013 según el ARWU. La tabla muestra el nombre de la universidad (**Institution**), la región del mundo donde se encuentra (**Region**), el país (**Country**), el puesto en la región (**Regional.Rank**), el puesto en el mundo (**World.Rank**) y el puesto en el país (**National.Rank**). En la columna del país sobresale el hecho de que apenas dos universidades de UK y una de JP están entre las mejores 20 del mundo, mientras que las demás son de US.

Tabla 3.2: 20 mejores universidades del mundo según el ARWU 2013

Institution	Region	Country	Regional.Rank	World.Rank	National.Rank
Harvard University	Americas	US	1	1	1
University of California, Berkeley	Americas	US	2	2	2
Stanford University	Americas	US	3	3	3
Massachusetts Institute of Technology (MIT)	Americas	US	4	4	4
University of Cambridge	Europe	UK	1	5	1
California Institute of Technology	Americas	US	5	6	5
Princeton University	Americas	US	6	7	6
Columbia University	Americas	US	7	8	7
University of Chicago	Americas	US	8	9	8
University of Oxford	Europe	UK	2	10	2
Yale University	Americas	US	9	11	9
Cornell University	Americas	US	10	12	10
University of California, Los Angeles	Americas	US	11	13	11
University of California, San Diego	Americas	US	12	14	12
University of Pennsylvania	Americas	US	13	15	13
University of Washington	Americas	US	14	16	14
University of Wisconsin - Madison	Americas	US	15	17	15
The Johns Hopkins University	Americas	US	16	18	16
University of California, San Francisco	Americas	US	16	18	17
The University of Tokyo	Asia/Pacific	JP	1	20	1

Una visión comparativa de los tres rankings en términos del país de donde provienen las universidades se puede apreciar en la gráfica de dispersión 3.1a. En ella se muestran los puestos (rankings) de las 100 universidades en el contexto regional frente a sus puestos en el contexto mundial etiquetadas por los países de origen. Para la interpretación conviene aclarar que **las mejores universidades ocupan los primeros puestos**, y por tanto se encuentran cerca del origen.

Esta situación se ilustra en la gráfica 3.1a para los rankings regional y mundial, en la cual se distinguen tres estelas o grupos de universidades, que muestran las diferencias naturales entre los puestos en la región respecto a los puestos en el mundo. Lo primero que se nota es que todas las universidades se encuentran por encima de

la diagonal, lo cual indica que todas ocupan mejores posiciones en su región que en el contexto mundial como es de esperar, puesto que regionalmente las universidades son clasificadas solo con respecto a universidades de su región.


El grupo de arriba donde todas las universidades tienen ranking mundial por encima de 60, está formado por tres universidades austrianas (AS), tres universidades japonesas (JP), y una universidad de Israel (IR) las cuales ocupan en la región posiciones debajo del puesto 16.

El segundo grupo (la estela debajo del grupo anterior), incluye universidades que tienen puestos por encima de 20 en el ranking mundial y por debajo de 30 en el ranking regional. Tiene un primer subgrupo con dos universidades japonesas (JP), dos del Reino Unido (UK) y una suiza (SW), las cuales tienen rankings regionales por debajo de 10 y rankings mundiales entre 20 y 30. El otro subgrupo contiene universidades con rankings mundiales por encima de 40 y regionales por debajo de 40.


El tercer grupo cerca de la diagonal, está formado mayoritariamente por universidades de Estados Unidos (US). Se observa que entre las primeras 20 los rankings regional y mundial casi coinciden. Pero en la medida que el ranking regional aumenta, el ranking mundial aumenta más que el regional.

En la Gráfica 3.1b se encuentran las mismas 100 universidades que en la Gráfica 3.1a, proyectadas sobre las primeras dos componentes principales generadas por los dos rankings. Se observa cómo las dos componentes reflejan claramente las tres estelas de universidades. Se observa que la estela de países que estaban cerca de la diagonal en la Gráfica 3.1a, ahora se ve casi horizontal por encima del cero de la Dim 2, la cual corresponde a la dirección de varianza máxima de los dos rankings. EL código R que genera la gráfica 3.1a a) es es siguiente:

```
> # arwu<-read.csv2("arwu.csv")
> plot(arwu$Regional.Rank, arwu$World.Rank, type = "n",
+       xlab = "Regional.Rank", ylab = "World.Rank",
+       xlim = c(0,100), main = "Ranking regional vs. Ranking mundial")
> text(arwu$Regional.Rank, arwu$World.Rank, arwu$Country,
+       cex = 0.7, pos = 3)
> abline(a = 0, b = 1, col = "red", lty = 2)
```



(a) Posición regional vs. posición mundial de las primeras 100 universidades según el ranking ARWU, etiquetadas por su país de origen.



(b) Posición regional vs. posición mundial de las primeras 100 universidades según el ranking ARWU, sobre las dos primeras componentes principales.

Gráfica 3.1: Comparación de la visualización de los datos originales con su proyección sobre las dos primeras componentes principales

Ejemplo 3.2.2. Sobre inconsistencias en algunos rankings universitarios Análisis de las posiciones asignadas a universidades latinoamericanas por tres conocidos rankings universitarios: **a) Scimago** definido como indicador de evaluación de la **actividad investigativa** de universidades e instituciones de investigación. Incluye nueve indicadores de investigación entre los que se cuentan indicadores de impacto, productividad, colaboración internacional, publicaciones de alta calidad, liderazgo científico, excelencia y talento científico entre otros; tres de innovación y tres de factor social (Más detalles se pueden consultar en Ranking (2024)). **b) Webranking** o ranking de **presencia en la web** que utiliza el número de enlaces entrantes al dominio de las universidades, el

número de páginas web, el número de archivos publicados en formatos pdf, doc, excel, etc., colgados en el dominio de las universidades, y un indicador de excelencia tomado del Scimago (Detalles en webometrics (2024)).

c) Qs que utiliza dos indicadores de reputación de las universidades: uno entre pares académicos y otro entre empleadores que se miden a partir de dos encuestas; el número de estudiantes por profesor; el número de profesores con doctorado; el número de citas por artículo; el promedio de artículos por docente, y el impacto en la web tomado del Webranking. Los dos indicadores de reputación tienen una ponderación del 25 % cada uno, mientras que los demás solo tienen el 10 % cada uno. Por lo anterior este ranking se considera más que todo un ranking de **reputación** de las universidades (Detalles para la metodología en el 2014 en Rankings (2014)).

Para este ejemplo se escogieron universidades latinoamericanas que ocuparon los primeros 149 puestos en el ranking QS para el año 2014. En la Tabla 3.3 se muestran las primeras 20 universidades ordenadas según el QS con sus posiciones en los otros dos rankings y el país a que pertenecen ¹:


Se observa por ejemplo que la Universidad Austral de Argentina (AUSTRAL - ARG) se encuentra en el puesto 20 según el QS.Ranking, lo que significa que tiene buena reputación entre académicos y empleadores, pero se encuentra en el puesto 250 según el SC.Lac.Ranking, lo que indica que a pesar de la reputación que tiene, sus indicadores de actividad académica investigativa que son los del Scimago, no son los mejores. Estas mismas inconsistencias (paradojas) se observan también para la Universidad de Santiago de Chile (SANTIAGO DE (USACH) - CHL) que está en el puesto 16 según el QS.Ranking pero en el puesto 60 según el SC.Lac.Ranking, y para el Tecnológico de Monterrey de México (TECNOLOGICO DE MONTERREY (ITESM) - MEX) que ocupa el puesto 7 del QS.Ranking, pero en cuanto a su actividad investigativa ocupa el puesto 56 según el SC.Lac.Ranking.

Tabla 3.3: Primeras 20 universidades según el ranking Qs


	UniPais	Pais	SC.Lac.Ranking	QS.Ranking	WEB.Ranking.LA
10	POTFIC CATOLICA DE - CHL	CHL	13	1	24
1	DE SAO PAULO (USP) - BRA	BRA	1	2	1
3	Es DE CAMPIS (UNICAMP) - BRA	BRA	4	3	8
5	DO RD Janeiro FED - BRA	BRA	5	4	5
21	LOS ANDES - COL	COL	47	5	38
9	U de - CHL	CHL	10	6	6
61	TECNOLOGICO DE MONTERREY (ITESM) - MEX	MEX	56	7	28
2	NAL AUTONO DE (UM) - MEX	MEX	2	8	2
6	EEs PAULISTA JULIO MESQU - BRA	BRA	3	9	11
7	Fe DO RG D SUL - BRA	BRA	6	10	3
8	Fe MG - BRA	BRA	8	10	9
20	CONCEPCION - CHL	CHL	28	12	32
37	POTFIC CATOLICA DO R de Janeiro -PUC - BRA	BRA	40	13	30
26	NAL DE - COL	COL	18	14	10
11	Fe DE SAO PAULO (UNIFESP) - BRA	BRA	9	15	54
42	SANTIAGO DE (USACH) - CHL	CHL	60	16	34
15	DE BRASILIA - BRA	BRA	19	17	13
16	Fe DE SAO CARLOS - BRA	BRA	21	18	43
4	BUENOS AIRES - ARG	ARG	7	19	7
116	AUSTRAL - ARG	ARG	250	20	262

Estas inconsistencias se hacen evidentes en los graficos de dispersión de la Gráfica 3.2 a), b) y c), en la cual Se distinguen por encima de la digonal (azul) y por debajo (rojo) las universidades cuyos rangos difieren en los correspondientes rankings.

¹Una descripción detallada se puede consultar en las páginas web de los rankings directamente, o en Corzo (2017)



Gráfica 3.2: Comparación entre rankings (Scimago, QS y WEB). Entre más lejos de la diagonal mas diferentes son los rankings correspondientes



Gráfica 3.3: Los dos vectores que representan los ranking SC.Lac.Ranking y WEB.Ranking.LA reflejan su grado de asociación visualizado en la gráfica 3.2 b). El vector QS.Ranking muestra el grado de independencia de éste con los otros dos rankings, ya identificada en los gráficos 3.2 a) y 3.2 c).

En la gráfica 3.3 se ven los vectores que representan los rankings SC.Lac.Ranking y WEB.Ranking en el cuadrante IV tipificando países cuyas universidades que se encuentran en los últimos puestos en estos dos rankings, y por tanto indican que en las universidades de dichos países no se distinguen por sus niveles de investigación o de presencia en la web. En el cuadrante II opuesto al cuadrante I, se ven muchas universidades brasileñas

ocupando los primeros puestos en estos dos rankings, lo cual indica que dichas universidades se distinguen por ser las que tienen los mayores niveles de investigación y presencia en la web. En el cuadrante II se encuentra el vector que representa al QS.Ranking indicando que las universidades de los países que se encuentran en este cuadrante se distinguen más que todo por su prestigio entre académicos y empleadores.

A manera de conclusión, el análisis muestra claramente las diferencias entre los aspectos que miden estos dos rankings y explica en parte la razón de las inconsistencias en las posiciones de las universidades en cada ranking: mientras que el SC.Lac.Ranking se orienta principalmente a resaltar la actividad académica-investigativa, el QS.Ranking le da en ese año el 50 % de peso a la reputación de las universidades entre académicos y empleadores y el resto para algunos aspectos de importancia en el quehacer universitario. También sobresale el hecho de que 10 de las 20 primeras según el QS son universidades brasileñas, y que sus posiciones en ambos rankings son muy cercanas, lo cual indica que su actividad investigativa es consistente con su nivel de reputación entre académicos y empleadores.

El código para reproducir la parte a) de la gráfica 3.2 es el siguiente:

```
> ##===== (a) Scimago vs QS =====
> x <- RankLatino$SC.Lac.Ranking
> y <- RankLatino$QS.Ranking
> plot(x, y, type="n",
+      xlim=c(0,270), ylim=c(0,270),
+      xlab="Ranking Scimago", ylab="Ranking QS")
> abline(a=0,b=1,col="red",lty=2)
> highlight_indices <- which(y < x)
> for(i in seq_along(x)) {
+   if(!(i %in% highlight_indices)) {
+     text(x[i], y[i], RankLatino$Pais[i], cex=0.8, pos=2)
+   }
+ }
> delta <- 8
> y_lab <- pmax(0, y[highlight_indices] - delta)
> text(x[highlight_indices], y_lab,
+      labels = RankLatino$Pais[highlight_indices],
+      col="red", font=3, cex=0.8, pos=3)
> mtext("a) Muchas universidades por encima de 150 en Sc \n posicionadas por debajo de 150",
```

Las partes b) y c) se obtienen reemplazando x y y por los correspondientes rankings.

3.3. Correspondencias simples y análisis de tablas de contingencia

Una **tabla de contingencia** es un arreglo de las frecuencias de ocurrencia simultánea de las opciones de respuesta de dos variables cualitativas, X con I modalidades en las filas y Y con J modalidades en las columnas. Formalmente se escribe como

$$G = \{n_{ij}\} = \begin{pmatrix} n_{11} & n_{12} & \cdots & n_{1J} \\ n_{21} & n_{22} & \cdots & n_{2J} \\ \vdots & \vdots & \ddots & \vdots \\ n_{I1} & n_{I2} & \cdots & n_{IJ} \end{pmatrix},$$

donde n_{ij} representa el número de individuos que simultáneamente presentan la modalidad i de X y la modalidad j de Y . El tamaño muestral total es

$$n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}.$$

El análisis de este tipo de tablas permite estudiar la **asociación entre variables cualitativas**, pues no solo describe las frecuencias marginales sino la estructura conjunta de respuestas.

Se definen ahora los totales marginales por fila y columna:

$$n_{i\cdot} = \sum_{j=1}^J n_{ij}, \quad n_{\cdot j} = \sum_{i=1}^I n_{ij}.$$

Cada fila de la tabla puede interpretarse como un **perfil fila**, es decir, una distribución condicional de Y dada la modalidad i de X :

$$f_{ij} = \frac{n_{ij}}{n_{i\cdot}}, \quad j = 1, \dots, J,$$

mientras que cada columna define un **perfil columna**, correspondiente a la distribución condicional de X dada la modalidad j de Y :

$$c_{ij} = \frac{n_{ij}}{n_{\cdot j}}, \quad i = 1, \dots, I.$$

De este modo, la tabla de contingencia se transforma en una nube de puntos fila en $\mathbb{R}^J$ y una nube de puntos columna en $\mathbb{R}^I$, cuyas coordenadas son probabilidades empíricas.

En el contexto de teoría de probabilidad, si dos variables aleatorias X y Y son independientes, entonces:

$$P(X = i, Y = j) = P(X = i)P(Y = j), \quad i = 1, \dots, I, j = 1, \dots, J$$

Empíricamente, esta relación de independencia entre X y Y se traduce en que aproximadamente.

$$\frac{n_{ij}}{n} \approx \frac{n_{i\cdot}}{n} \frac{n_{\cdot j}}{n},$$

entonces las desviaciones respecto a esta estructura de independencia contienen toda la información sobre la asociación entre modalidades.

Para cuantificar la proximidad entre perfiles se introduce naturalmente la **distancia** χ^2 . Entre dos perfiles fila i y i' se define como

$$d_{\chi^2}^2(i, i') = \sum_{j=1}^J \frac{1}{n_{\cdot j}/n} \left(\frac{n_{ij}}{n_{i\cdot}} - \frac{n_{i'j}}{n_{i'\cdot}} \right)^2.$$

Análogamente, puede definirse una distancia χ^2 entre perfiles columna.

Esta métrica pondera las diferencias entre perfiles según la importancia de cada modalidad, medida por su frecuencia marginal, y constituye el fundamento geométrico del **Análisis de Correspondencias Simples**, que busca representar estas nubes de perfiles en espacios de baja dimensión conservando, en lo posible, dichas distancias.

Ejemplo 3.3.1. *La Encuesta Mundial de Valores se realiza periódicamente desde 1981. Investiga opiniones de la gente acerca de temas como la democracia, la tolerancia hacia las minorías, el papel de la religión en la sociedad, la globalización, el medio ambiente y la diversidad entre otros temas (Inglehart et al. (2000), Bridge (2001)).*

Una de las muchas preguntas de esta encuesta pregunta por la confianza en la justicia en 38 países, entre los cuales se encuentran algunos países latinoamericanos. La pregunta es la siguiente:

¿Cree usted que la justicia en este país se aplica de manera justa para todos, independientemente de su origen social o económico?			
Muchísimo	Mucho	No mucho	Nada

Las frecuencias de respuesta a esa pregunta se muestran en la Tabla de contingencia 3.4. En las filas de esta tabla se muestran siete países latinoamericanos que participaron en la encuesta (variable-fila) y en las columnas las cuatro modalidades de respuesta a la pregunta variable-columna. Para el análisis se eliminaron las respuestas no sabe y no responde puesto que son muy pocas y no aportan al análisis.

A primera vista la tabla 3.4 muestra que Brasil, México, Colombia y Ecuador en su orden, son los países donde hay la mayoría de respuestas de “muchísima” confianza en la justicia, mientras que en Argentina Perú y Chile es donde hay menos respuestas de “muchísima” confianza en la justicia. Sin embargo, en la Tabla 3.5 que contiene los perfiles fila, es decir la proporción de respuestas “muchísima” con respecto al total de los que contestaron en cada país, se nota que sigue siendo en Brasil donde hay mas respuestas a la modalidad “muchísima”, pero ahora se invierte el orden de Ecuador y México, países donde la proporción de respuestas está cerca de la mitad de las de Brasil.


En cuanto a las respuestas “Mucho” la Tabla 3.4 muestra que en Brasil, Ecuador, México y Chile la gente confía mucho en la justicia, pero en la Tabla 3.5 de los perfiles fila, se observa que en realidad es en Brasil, Ecuador, Chile y Argentina donde están las mayores proporciones de respuesta a “mucho” confianza en la justicia.

Tabla 3.4: Confianza en la justicia en países seleccionados

	muchis.	mucho	no_mucho	nada	Total_F
Brasil	208	678	404	408	1698
Mexico	105	280	552	778	1715
Colombia	96	105	885	434	1520
Ecuador	90	394	460	237	1181
Chile	43	258	443	235	979
Peru	25	110	389	861	1385
Argentina	17	176	427	365	985
Total_C	584	2001	3560	3318	

Tabla 3.5: Perfiles fila, por países para los grados de confianza en la justicia ordenados por la opción muchísimo

	muchis.	mucho	no_mucho	nada	Suma
Brasil	0.122	0.399	0.238	0.240	1
Ecuador	0.076	0.334	0.390	0.201	1
Colombia	0.063	0.069	0.582	0.286	1
Mexico	0.061	0.163	0.322	0.454	1
Chile	0.044	0.264	0.453	0.240	1
Peru	0.018	0.079	0.281	0.622	1
Argentina	0.017	0.179	0.434	0.371	1




Gráfica 3.4: Gráfico de barras por país para confianza en la justicia

Por otra parte, en cuanto a los niveles de confianza en la justicia en la Tabla 3.4 de frecuencias de respuesta, se observa que con excepción de Brasil, la mayor cantidad de respuestas en los demás países se encuentra en las columnas “no mucho” y “nada” dando la impresión de que en el resto de países predomina la poca o ninguna confianza en la justicia. Sin embargo, la Tabla 3.6 de perfiles columna (frecuencias condicionales respecto al total de encuestados por cada modalidad de respuesta), muestra que el panorama no es tan desafortunado, puesto que por ejemplo en la modalidades “mucho” y “muchísimo” dominan en Brasil y México, aunque Brasil duplica las proporciones de respuestas en estas dos modalidades. También en Colombia y Ecuador hay proporciones importantes de respuestas en la modalidad “muchísimo”. La modalidad “mucho” tiene proporciones importantes en Brasil, Ecuador, México y Chile.

Tabla 3.6: Perfiles por modalidades de confianza en la justicia respecto a los países encuestados, ordenados por la opción muchísimo

	muchis.	mucho	no_mucho	nada
Brasil	0.356	0.339	0.113	0.123
Mexico	0.180	0.140	0.155	0.234
Colombia	0.164	0.052	0.249	0.131
Ecuador	0.154	0.197	0.129	0.071
Chile	0.074	0.129	0.124	0.071
Peru	0.043	0.055	0.109	0.259
Argentina	0.029	0.088	0.120	0.110
Suma	1.000	1.000	1.000	1.000



Gráfica 3.5: Comparación de países por proporción de respuestas a la percepción de la justicia

El código para reproducir la gráfica 3.5 es el siguiente:


```
> library(ggplot2)
> library(tidyr)
> library(dplyr)
> # Tabla completa (sin fila Suma)
> tabla <- data.frame(
+   Pais = c("Brasil", "Mexico", "Colombia", "Ecuador", "Chile", "Peru", "Argentina"),
```

```

+ muchis    = c(0.356, 0.180, 0.164, 0.154, 0.074, 0.043, 0.029),
+ mucho     = c(0.339, 0.140, 0.052, 0.197, 0.129, 0.055, 0.088),
+ no_mucho  = c(0.113, 0.155, 0.249, 0.129, 0.124, 0.109, 0.120),
+ nada      = c(0.123, 0.234, 0.131, 0.071, 0.071, 0.259, 0.110)
+ )
> # Formato largo + control de orden (modalidades y países)
> datos_long <- tabla |>
+   pivot_longer(
+     cols = -Pais,
+     names_to = "Modalidad",
+     values_to = "Perfil"
+   ) |>
+   mutate(
+     Modalidad = factor(
+       Modalidad,
+       levels = c("muchis", "mucho", "no_mucho", "nada"),
+       labels = c("Muchísimo", "Mucho", "No mucho", "Nada")
+     ),
+     Pais = factor(
+       Pais,
+       levels = c("Brasil", "Mexico", "Colombia", "Ecuador",
+                  "Chile", "Peru", "Argentina")
+     )
+   )
> # Faceteado
> ggplot(datos_long, aes(x = Modalidad, y = Perfil)) +
+   geom_col(fill = "lightblue", width = 0.8) +
+   geom_text(
+     aes(label = sprintf("%.3f", Perfil)),
+     vjust = -0.35,
+     size = 2.8
+   ) +
+   facet_wrap(~ Pais, ncol = 3) +
+   scale_y_continuous(
+     limits = c(0, max(datos_long$Perfil) * 1.15),
+     expand = expansion(mult = c(0, 0))
+   ) +
+   labs(
+     title = "Frecuencias condicionales por modalidad y país",
+     x = "Modalidad de respuesta",
+     y = "Perfil condicional"
+   ) +
+   theme_minimal() +
+   theme(
+     panel.grid.minor = element_blank(),
+     strip.text = element_text(face = "bold"),
+     axis.text.x = element_text(
+       angle = 30,          # ← ángulo razonable
+       hjust = 1,
+       size = 9
+     )
+   )

```


+)
>



Gráfica 3.6: Plano de correspondencias simples que muestra tendencias de los países en cuanto a percepciones sobre confianza en la justicia

3.4. Correspondencias múltiples: Tablas de tablas de contingencia.

Ejemplo 3.4.1. La *Encuesta de Cultura Ciudadana (ECC)* fue realizada por la Corporación Visionarios en varias capitales y grandes ciudades de países latinoamericanos, con cierta periodicidad. Constituye un instrumento de observación y análisis de diversos aspectos relacionados con la cultura ciudadana y el comportamiento social.

Entre los temas abordados se incluyen, por ejemplo, preguntas sobre los sentimientos de los encuestados frente a conceptos como normas o reglas (Ley, Moral y Cultura), la facilidad con que pueden actuar conforme a la ley, las capacidades para celebrar y cumplir acuerdos y las reacciones ante su incumplimiento, así como dimensiones asociadas al pluralismo (aceptación de las diferencias e inclusión), la seguridad, la confianza interpersonal, la confianza en las instituciones y la victimización, entre otros aspectos.

Para este ejemplo se analiza la pregunta presentada en la Tabla 3.7, referida a las **justificaciones para la desobediencia de la ley**. La pregunta sugiere varios interrogantes de interés analítico, entre los que destacan:

- ¿Existe alguna tendencia a la desobediencia de la ley diferenciada por ciudades?
- En caso afirmativo, ¿cuáles son las justificaciones más recurrentes?
- ¿Existe alguna asociación entre las distintas justificaciones, o al menos entre las más recurrentes?

Como la pregunta se compone de **11 ítems** con respuesta dicotómica (**Sí/No**), para responder a los interrogantes teniendo en cuenta los 11 ítems simultáneamente, hacen falta varias tablas de contingencia **tablas de contingencia**.


Tabla 3.7: Pregunta 20. Justificaciones a la desobediencia de la ley

20. Dígame si en su opinión se justifica o no desobedecer la ley:					
	Sí	No		Sí	No
a. Cuando es la única manera de alcanzar sus objetivos	1	2	g. Cuando es bastante seguro que uno no será castigado	1	2
b. Cuando es la única manera de ayudarlo a la familia	1	2	h. Cuando alguien lo ha hecho y le ha ido bien	1	2
c. Cuando es la única manera de luchar públicamente contra una ley o un régimen injusto	1	2	i. Cuando es lo acostumbrado	1	2
d. Cuando es muy provechoso económicamente	1	2	j. Para pagar un favor	1	2
e. Cuando la creencia religiosa lo permite	1	2	k. Para defender propiedades o bienes	1	2
f. Cuando se hace para responder a una ofensa al honor	1	2			

A manera de ejemplo y únicamente con el objetivo de justificar la necesidad del Análisis de Correspondencias Múltiples (ACM), en la gráfica 3.7 se muestran las tablas de contingencia por ciudad y por pregunta. Las barras azules corresponden al número de respuestas "No" a la pregunta indicada es un poco más baja. La similitud gráfica de las respuestas a las preguntas P20a, y de la P20d a la P20j muestran respuestas alternantes entre ciudades, que tiene un patrón sinuoso, aunque este patrón **no es estadísticamente significativo** y **tampoco indica que exista un orden geográfico, temporal o socioeconómico subyacente**.

La pregunta P20b, cuando es la única manera de ayudarlo a la familia, genera una mayor polaridad puesto que, con excepción de B Horizonte, en las demás ciudades la cantidad de respuestas "Sí" es muy cercana a la de "No". La pregunta P20c, Cuando es la única manera de luchar públicamente contra una ley o un régimen injusto, exceptuando a B Horizonte y Bogotá, en las otras ciudades hay mayor predisposición a justificar la desobediencia civil. Llama mucho la atención que la pregunta P20k, Para defender propiedades o bienes, con excepción de Quito, en todas las otras ciudades domina el "Sí"

El análisis de la pregunta vía tablas de contingencia puede ser un poco largo debido a que habría que hacer todas las 55 combinaciones de pares de ítems y sus combinaciones con las ciudades. Por esta razón resulta necesario un método que permita responder a los interrogantes planteados arriba. El método adecuado para esto es el Análisis de Correspondencias Múltiples.



Gráfica 3.7: Frecuencias de respuesta por países. Se observa una tendencia general a no justificar la desobediencia de la ley: Barras azules mayores que las rojas. Sin embargo, las preguntas P20b, P20c y P20k, muestran mayor cercanía entre Sí y No

El código para reproducir la gráfica 3.7 es:

```
> cclat = CCLatin
> # Selección de la pregunta 20
> cclat_p20 <- cclat[, c("city", paste0("P20_", letters[1:11]))]
> # 1) Largo: city + P20_a ... P20_k
> datos_long <- cclat_p20 %>%
+   select(city, paste0("P20_", letters[1:11])) %>%
+   pivot_longer(
```

```


+   cols = starts_with("P20_"),
+   names_to = "Item",
+   values_to = "Valor"
+ )
> # 2) Recodificar Sí/No desde el texto (p20x_...=1_si / =2_no)
> datos_freq <- datos_long %>%
+   mutate(
+     Respuesta = case_when(
+       grepl("=1_", Valor) ~ "Sí",
+       grepl("=2_", Valor) ~ "No",
+       TRUE ~ NA_character_
+     ),
+     Respuesta = factor(Respuesta, levels = c("Sí", "No")),
+     # Etiqueta bonita del ítem (P20a, P20b, ...)
+     Item = factor(Item,
+                   levels = paste0("P20_", letters[1:11]),
+                   labels = paste0("P20", letters[1:11]))
+   ) %>%
+   filter(!is.na(Respuesta), !is.na(city)) %>%
+   count(city, Item, Respuesta, name = "Frecuencia")
> # 3) Gráfico facetado (un panel por ítem)
> ggplot(datos_freq, aes(x = city, y = Frecuencia, fill = Respuesta)) +
+   geom_col(position = position_dodge(width = 0.8), width = 0.7) +
+   facet_wrap(~ Item) +
+   labs(
+     title = "P20 (a-k). Frecuencias de respuesta Sí/No por ciudad",
+     x = "Ciudad",
+     y = "Frecuencia",
+     fill = "Respuesta"
+   ) +
+   theme_minimal() +
+   theme(axis.text.x = element_text(angle = 45, hjust = 1))

```

Para cerrar el ejemplo y mostrar las ventajas del ACM, En la gráfica 3.8 se muestran los resultados de un ACM para la pregunta P20 con todos sus ítems y las ciudades sobre las primeras dos componentes del análisis.

El gráfico muestra un cúmulo de respuestas "No" alrededor del origen que indica las altas frecuencias de respuesta negativa a la desobediencia de la ley en todas las ciudades, representadas por las barras azules en la gráfica 3.7.

También se ve en la esquina superior derecha del cuadrante I un cúmulo de respuestas "Sí" a los ítems P20h, P20j y P20i que tienen frecuencias bajas reflejadas en los diagramas con barras rojas. Éstas corresponden a justificaciones a la desobediencia de la ley por razones Por seguir el ejemplo de que alguien lo ha hecho y le ha ido bien, para pagar un favor y por seguir la costumbre. En el mismo cuadrante pero en la región inferior derecha se ve otro cúmulo de respuestas "Sí" de bajas frecuencias de respuesta a los ítems P20g, P20e y P20d que corresponden a la justificación cuando hay impunidad (bastante seguro no ser castigado), por creencia religiosa y por provecho económico.



Gráfica 3.8: Tendencias a justificar la desobediencia de la ley por ciudades



Los métodos de agrupamiento (clustering) son algoritmos de aprendizaje no supervisado que buscan identificar conjuntos de objetos homogéneos a partir de un conjunto de observaciones de múltiples variables (observaciones multivariadas), realizadas sobre ellos, de manera que cada objeto está representado por su correspondiente conjunto de características

El objetivo es construir particiones o estructuras jerárquicas tales que:


y la variabilidad entre grupos sea grande (separación).

Ejemplo 3.5.1. *El Sistema Universitario Estatal (SUE) es una red de universidades públicas colombianas, orientada hacia la colaboración académica, la investigación y la gestión conjunta de recursos entre estas. Datos de éstas universidades se recolectan en una tabla que contiene 32 indicadores de educación superior para 32 universidades estatales entre 2003 y 2012. Para este ejemplo se utilizan seis de dichos indicadores: Docentes de tiempo completo o equivalente (DCTC2012), gastos en personal administrativo (GPA2012), matrícula de pregrado (MPRE2012), matrícula de posgrado (MPOS2012), graduados de pregrado (GrPre2012) y graduados de posgrado (GrPos2012). En la tabla 3.8 los valores de estos indicadores para las 32 universidades públicas. El objetivo es construir grupos de universidades que tengan características comunes respecto a estos indicadores.*


La importancia y necesidad de un proceso iterativo y automatizado para construir agrupaciones de universidades, se hacen evidentes al intentar identificar patrones de agrupamiento mediante comparaciones manuales de múltiples representaciones gráficas, en las cuales solo es posible explorar pares de variables a la vez. Aunque este análisis visual permite develar ciertas tendencias iniciales, se vuelve rápidamente insuficiente en contextos multivariados de mayor dimensión por la cantidad de gráficas y comparaciones que habría que hacer. Esto evidencia la necesidad de desarrollar y utilizar algoritmos de agrupamiento capaces de integrar simultáneamente la información de todas las variables observadas. El proceso comparativo se muestra en las gráficas 3.10 a 3.16. En el nombre de cada gráfica se analizan y describen los aspectos sobresalientes de las universidades respecto a los indicadores comparados.

Tabla 3.8: Indicadores del SUE para 32 universidades públicas en el año 2012


	DCTC2012	GPA2012	MPRE2012	MPOS2012	GrPre2012	GrPos2012
NACIONAL	2161	347233353	42120	9299	4903	3181
PEDAGOGICA	440	7986738	9321	1614	1186	362
UPTC	828	20641880	24644	2360	3190	1225
CAUCA	550	28539431	12859	700	1372	303
TEC DE PEREIRA	442	15343348	15423	1319	1532	299
CALDAS	418	12877924	12261	971	1953	266
CORDOBA	336	17354987	12081	377	809	0
SURCOLOMBIANA	284	10982676	9867	435	1113	265
AMAZONIA	198	6113236	6851	332	724	177
MILITAR	375	10673047	12850	2678	978	1218
TEC DEL CHOCO	240	21314583	10668	43	1536	49
LLANOS	201	13159385	5218	267	653	136
POPU DEL CESAR	184	5206608	13127	0	1653	159
MAY DE CNAMARCA	203	7597155	5028	235	870	237
PACIFICO	65	3613371	2115	0	128	0
ANTIOQUIA	1848	71634254	36788	2760	3437	815
ATLANTICO	371	11693780	19907	255	1559	151
VALLE	935	61192000	26245	3238	3209	800
UIS	632	49145313	19897	1869	2726	607
CARTAGENA	435	44876932	18804	861	1236	320
NARINO	296	9449989	11099	549	1208	270
TOLIMA	321	23307867	37080	1183	4499	577
QUINDIO	437	13088429	15740	140	2051	45
UFPS_CUCUTA	288	7109593	20528	555	2273	200
UFPS_OCANA	56	3881551	4588	57	307	43
PAMPLONA	525	9552468	23887	317	5320	315
MAGDALENA	307	4944457	20082	613	2910	345
CUNDINAMARCA	309	11632868	10432	107	1064	171
SUCRE	116	3997130	4838	66	678	0
GUAJIRA	224	9381315	7962	277	696	0
DISTRITAL	758	16043464	27293	1696	2974	683
UNAD	743	14683191	64558	1678	2106	124




Gráfica 3.10: Docentes de tiempo completo o equiv. vs. GPA2012, MPRE2012 y MPOS2012. En las tres gráficas se observa que para el indicador DTCE las universidades Nacional y de Antioquia tienen valores cercanos en este indicador con respecto a los tres indicadores comparados, por lo que podrían formar un grupo.




Gráfica 3.11: Docentes de tiempo completo o equiv. vs. GrPre2012 y GrPos2012. También aquí se distinguen las universidades de Antioquia y Nacional por sus valores en el indicador DTCE




Gráfica 3.12: GPA vs. MPRE2012 y MPOS2012. Se ve que la universidad Nacional es un dato atípico en cuanto a GPA. Además las universidades de ANTioquia, Valle y UIS están cerca en los cuatro gráficos sugiriendo un grupo de estas tres con respecto a GPA.




Gráfica 3.13: GPA vs. GrPre2012 y GrPos2012. También aquí sobresale la universidad Nacional por sus altos GPA



Gráfica 3.14: MPRE2012 vs. MPOS2012, GrPre2012, GrPos2012. Aquí sobresale la UNAD como dato atípico por su matrícula de pregrado y distingue a la Nacional por su matrícula de posgrado y por sus graduados de posgrado



Gráfica 3.15: MPOS2012 vs. GrPre2012, GrPos2012. Se distingue la Nacional por su matrícula y sus graduados de posgrado



Gráfica 3.16: MPOS2012 vs. GrPos2012. distingue a la Nacional tanto por sus graduados de pregrado como por los de posgrado. Y muestra parecido con las universidades del Tolima y de Pamplona por sus graduados de pregrado.

El código para generar cualquiera de las gráficas del tipo 3.10 a 3.16 es:

```
> library(purrr)
> # df = SUEsolo2012
> # Variables numéricas
> vars <- names(df)[-1] # quita "Universidades"
> # Todas las combinaciones pares
> pares <- combn(vars, 2, simplify = FALSE)
> # Función para cada gráfico
```

```


> plot_pair <- function(v1, v2){
+
+   ymax <- max(df[[v2]], na.rm = TRUE)
+
+   ggplot(df, aes_string(x = v1, y = v2, label = "Universidades")) +
+     geom_point(size = 1.1, color = "steelblue") +
+     geom_text_repel(size = 2.3) +
+     ylim(0, ymax * 1.3) +
+     labs(
+       title = paste(v1, "vs", v2),
+       x = v1,
+       y = v2
+     ) +
+     theme_minimal()
+ }
> # Crear los 15 gráficos
> graficos <- map(pares, ~ plot_pair(.x[1], .x[2]))
> # Mostrar uno por uno
> # graficos
> #
> library(patchwork)
> wrap_plots(graficos, ncol = 3)
> pa_dtc_1 <- wrap_plots(graficos[1:3], ncol = 1)
> pa_dtc_2 <- wrap_plots(graficos[4:5], ncol = 1)
> pa_gpa_1 <- wrap_plots(graficos[6:7], ncol = 1)
> pa_gpa_2 <- wrap_plots(graficos[8:9], ncol = 1)
> pa_3 <- wrap_plots(graficos[10:12], ncol = 1)
> pa_4 <- wrap_plots(graficos[13:14], ncol = 1)
> pa_5 <- wrap_plots(graficos[15], ncol = 1)
> pa_gpa_1

```

En las comparaciones hechas en los gráficos de dispersión se observaron similitudes entre las universidades dependiendo de los indicadores comparados. Estas similitudes se pueden sintetizar por medio de un método de agrupamiento que incluya todos los indicadores y agrupa las universidades por sus parecidos en todos los indicadores simultáneamente. En la gráfica 3.17: se muestran dos agrupamientos de las universidades. En ambas agrupaciones queda la Universidad Nacional aparte de las demás. Otro grupos estable en las dos clasificaciones es el formado por las Universidades de Antioquia, Valle y Cartagena. La de cuatros grupos divide el más grande en dos.



En la Gráfica 3.18 se encuentran proyectados los tres grupos sobre las primeras dos componentes principales:



Gráfica 3.18: Agrupamiento de universidades del SUE en tres grupos

3.6. Laboratorio

Recomendaciones generales:

- Desarrollar el laboratorio en R Markdown y ocultar el código
- El documento debe tener el siguiente nombre: Grupo_## Lab_##
- Entregar únicamente documento pdf
- Entregar un solo documento por grupo

Ejercicios

1. Con los datos del archivo `arwu_top_100_2025.csv` reproducir gráficas del tipo 3.2 a), b) y c), para comparar el puntaje total (`total_score`) con cada uno de los criterios que le correspondieron al grupo y entre los dos criterios. Esto implica mínimo tres gráficas.

Grupo_1: Premios Nobel o medallas Field obtenidos por sus docentes o egresados (alumni y award)

Grupo_2: Premios Nobel o medallas Field obtenidos por sus docentes y artículos altamente citados (award y hici)

Grupo_3: Número de investigadores altamente citados y publicaciones en Nature o Science (hici y n.s)

Grupo_4: Publicaciones en Nature o Science y número de publicaciones (n.s y pub)

Grupo_5: Número de publicaciones y productividad (pub y pcp)

Grupo_6: Productividad y rango en el mundo (pcp y worldrank)

Grupo_7: Compara worldrank vs desempeño per cápita de su personal académico (pcp y award)

- a) Identificar tendencias o patrones tanto entre el `total_score` y los criterios que le correspondieron al grupo
- b) Identificar tendencias o patrones entre los criterios mismos.

2. Utilizar los datos del archivo `ConfianzaJusticia.csv` para elaborar tablas de contingencia del tipo 3.4 perfiles fila 3.5 y de perfiles columna tipo 3.6, y gráficos de dispersión del tipo 3.4

Grupo_1: Países del grupo Lat con E_Occ

Grupo_2: Países del grupo Lat E_Ori

Grupo_3: Países del grupo Lat Iberico

Grupo_4: Países del grupo Lat Oceania

Grupo_5: Países del grupo Lat Us_Ca

Grupo_6: Países del grupo Iberico E_Ori

Grupo_7: Países de los grupos E_Occ E_Ori

- a) Identificar potrones o tendencias en la tabla de contingencia
- b) Identificar potrones o tendencias en la tabla de perfiles fila y compararlos con los patrones encontrados en la tabla de contingencia y decir cuáles son las principales diferencias encontradas
- c) Identificar potrones o tendencias en la tabla de perfiles columna y compararlos con los patrones encontrados en la tabla de contingencia y decir cuáles son las principales diferencias encontradas

3. Utilizar el archivo Muestra_CC.csv para reproducir gráficas del tipo 3.7

Grupo_1: p23

Grupo_2: p24

Grupo_3: p33

Grupo_4: p34

Grupo_5: p35

Grupo_6: p38

Grupo_7: p45

- a) Identificar patrones de respuesta entre las distribuciones de los items por ciudad como en la gráfica 3.7.
 - b) Para cada ciudad, señalar cuáles son las opciones de respuesta que tienen mayores frecuencias y cuáles tienen las menores
4. Filtrar del archivo r14_Sci_Qs_Webometrics.csv los países asignados a cada grupo para elaborar gráficas del tipo 3.10 y las seis subsiguientes. El objetivo es comparar el puntaje en QS.Reputacion.academica en las ordenadas con los puntajes en los indicadores del Scimago "SC.Productividad", "SC.Colaboracion.Interciol", "SC.Impacto.normalizado", "SC.Publicaciones.de.alta.calidad", "SC.Indice.de.excelencia", "SC.Liderazgo.cientifico".
- Grupo_1: ARG COL
- Grupo_2: BRA COL
- Grupo_3: CHL COL
- Grupo_4: COL, ECU, VEN, PER
- Grupo_5: MEX, BRA
- Grupo_6: BOL, CRI, CUB, ECU, PAN, PER, PRI, PY, URY VEN
- Grupo_7: MEX, CRI, CUB, PAN, PRI
- a) Hacer un análisis de las gráficas para identificar si sobresale alguno de los países comparados
 - b) ¿Alguno de los indicadores del Scimago que muestre alta correlación con QS.Reputacion.academica?
 - c) Identificar las universidades más parecidas de los dos países de acuerdo con los dos criterios
 - d) ¿En alguna de las comparaciones se pueden identificar visualmente grupos de universidades? ¿Por qué sí?, ¿Por qué no?

Bibliografía

- Breunig, M. M., Kriegel, H.-P., Ng, R. T. & Sander, J. (2000), 'Lof: Identifying density-based local outliers', *Proceedings of the ACM SIGMOD Conference* pp. 93–104.
- Bridge, A.-M. (2001), 'Wikipedia, the free encyclopedia', *San Francisco (CA): Wikimedia Foundation* .
- Corzo, J. A. (2017), 'Análisis factorial múltiple para clasificación de universidades latinoamericanas', *Comunicaciones en Estadística* **10**(1), 57–82.
- Ester, M., Kriegel, H.-P., Sander, J. & Xu, X. (1996), 'A density-based algorithm for discovering clusters in large spatial databases with noise', *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining* pp. 226–231.
- Everitt, B. & Hothorn, T. (2011), *An introduction to applied multivariate analysis with R*, Springer Science & Business Media.
- Gareth, J., Daniela, W., Trevor, H. & Robert, T. (2021), *An introduction to statistical learning: with applications in R, Second Edition*, Spinger.
- Hastie, T., Tibshirani, R. & Friedman, J. (2009), *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd edn, Springer, New York.
- Hinton, G. E., Osindero, S. & Teh, Y. W. (2006), 'A fast learning algorithm for deep belief nets', *Neural Computation* **18**(7), 1527–1554.
- Husson, F., Lê, S. & Pagès, J. (2017), *Exploratory multivariate analysis by example using R*, Chapman and Hall/CRC.
- Inglehart, R., Basanez, M., Diez-Medrano, J., Halman, L. & Luijkx, R. (2000), 'World values surveys and european values surveys, 1981-1984, 1990-1993, and 1995-1997', *Ann Arbor-Michigan, Institute for Social Research, ICPSR version* .
- James, G., Witten, D., Hastie, T. & Tibshirani, R. (2021), *An Introduction to Statistical Learning*, 2nd edn, Springer, New York.
- Jolliffe, I. T. & Cadima, J. (2016), 'Principal component analysis: A review and recent developments', *Philosophical Transactions of the Royal Society A* **374**(2065).
- Kassambara, A. (2017), *Practical guide to cluster analysis in R: unsupervised machine learning*, Vol. 1, STHDA.
- Kaufman, L. & Rousseeuw, P. J. (2005), *Finding Groups in Data: An Introduction to Cluster Analysis*, Wiley, New York.
- Kingma, D. P. & Welling, M. (2014), 'Auto-encoding variational bayes', *International Conference on Learning Representations* .

- Kohonen, T. (2001), *Self-Organizing Maps*, 3rd edn, Springer, Berlin.
- Lebart, L., Piron, M. & Morineau, A. (2006), *Statistique exploratoire multidimensionnelle: visualisation et inférences en fouilles de données*.
- Liu, F. T., Ting, K. M. & Zhou, Z.-H. (2008), 'Isolation forest', *IEEE International Conference on Data Mining* pp. 413–422.
- Liu, N. C. & Cheng, Y. (2005), 'The academic ranking of world universities', *Higher education in Europe* **30**(2), 127–136.
- MacQueen, J. (1967), 'Some methods for classification and analysis of multivariate observations', *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics* **1**, 281–297.
- McInnes, L., Healy, J. & Melville, J. (2018), 'Umap: Uniform manifold approximation and projection for dimension reduction', *arXiv preprint arXiv:1802.03426*.
- McLachlan, G. & Peel, D. (2000), *Finite Mixture Models*, Wiley, New York.
- Miller, C., Nagy, Z. & Schlueter, A. (2018), 'A review of unsupervised statistical learning and visual analytics techniques applied to performance analysis of non-residential buildings', *Renewable and Sustainable Energy Reviews* **81**, 1365–1377.
- Mockus, A. & Corzo, J. (2003), 'Dos caras de la convivencia. cumplir acuerdos y normas y no usar ni sufrir violencia', *Análisis político* (48), 3–25.
- Mockus, A. & Corzo, J. (2005), 'Ley o moral: ¿cuál prima?', *Análisis político* **18**(54), 3–17.
- Mockus, A., Corzo, J. et al. (2003), 'Cumplir para convivir: factores de convivencia y su relación con normas y acuerdos.'
- Ng, A. Y., Jordan, M. I. & Weiss, Y. (2002), 'On spectral clustering: Analysis and an algorithm', *Advances in Neural Information Processing Systems* **14**.
- Pardo, C. (2020), *Estadística Descriptiva Multivariada*, Facultad de Ciencias, Universidad Nacional de Colombia.
- Pelaez, N, L. E. M. (2012), Aprendizaje no supervisado y el algoritmo wake-sleep en redes neuronales, PhD thesis, UNIVERSIDAD TECNOLÓGICA DE LA MIXTECA.
- Ranking, S. I. (2024), 'Ranking methodology', <https://www.scimagoir.com/methodology.php>. Consultado el: 19-10-2024.
- Rankings, Q. W. U. (2014), 'Qs methodology 2014', <https://www.council.su.ac.th/files/document/Ranking> Consultado el: 19-10-2024.
- Sánchez, L. G., Osorio, G. A. & Suárez, J. F. (2008), 'Introducción a kernel acp y otros métodos espectrales aplicados al aprendizaje no supervisado', *Revista Colombiana de Estadística* **31**(1), 19–40.
- Schölkopf, B., Platt, J. C., Shawe-Taylor, J., Smola, A. & Williamson, R. C. (2001), 'Estimating the support of a high-dimensional distribution', *Neural Computation* **13**(7), 1443–1471.
- Silverman, B. W. (1986), *Density Estimation for Statistics and Data Analysis*, Chapman and Hall, London.
- Stack, P. (2021), 'Métodos de aprendizaje supervisado y no supervisado para la estimación de microestructura cerebral en datos de dwmr', *Centro de Investigación En Matemáticas, AC* <https://cimat.repositorioinstitucional.mx/jspui/bitstream/1008/1129/1/TE> **20835**.

- Tello, J. C. & Informáticos, S. (2007), 'Reconocimiento de patrones y el aprendizaje no supervisado', *Universidad de Alcalá, Madrid*.
- Tenenbaum, J. B., de Silva, V. & Langford, J. C. (2000), 'A global geometric framework for nonlinear dimensionality reduction', *Science* **290**(5500), 2319–2323.
- Tusell, F. (2012), *Análisis multivariante*, 1a edn, Autor en internet, Curso de análisis multivariante.
- van der Maaten, L. & Hinton, G. (2008), 'Visualizing data using t-sne', *Journal of Machine Learning Research* **9**, 2579–2605.
- webometrics (2024), 'Methodology', <https://www.webometrics.info/en/Methodology>. Consultado el: 19-10-2024.